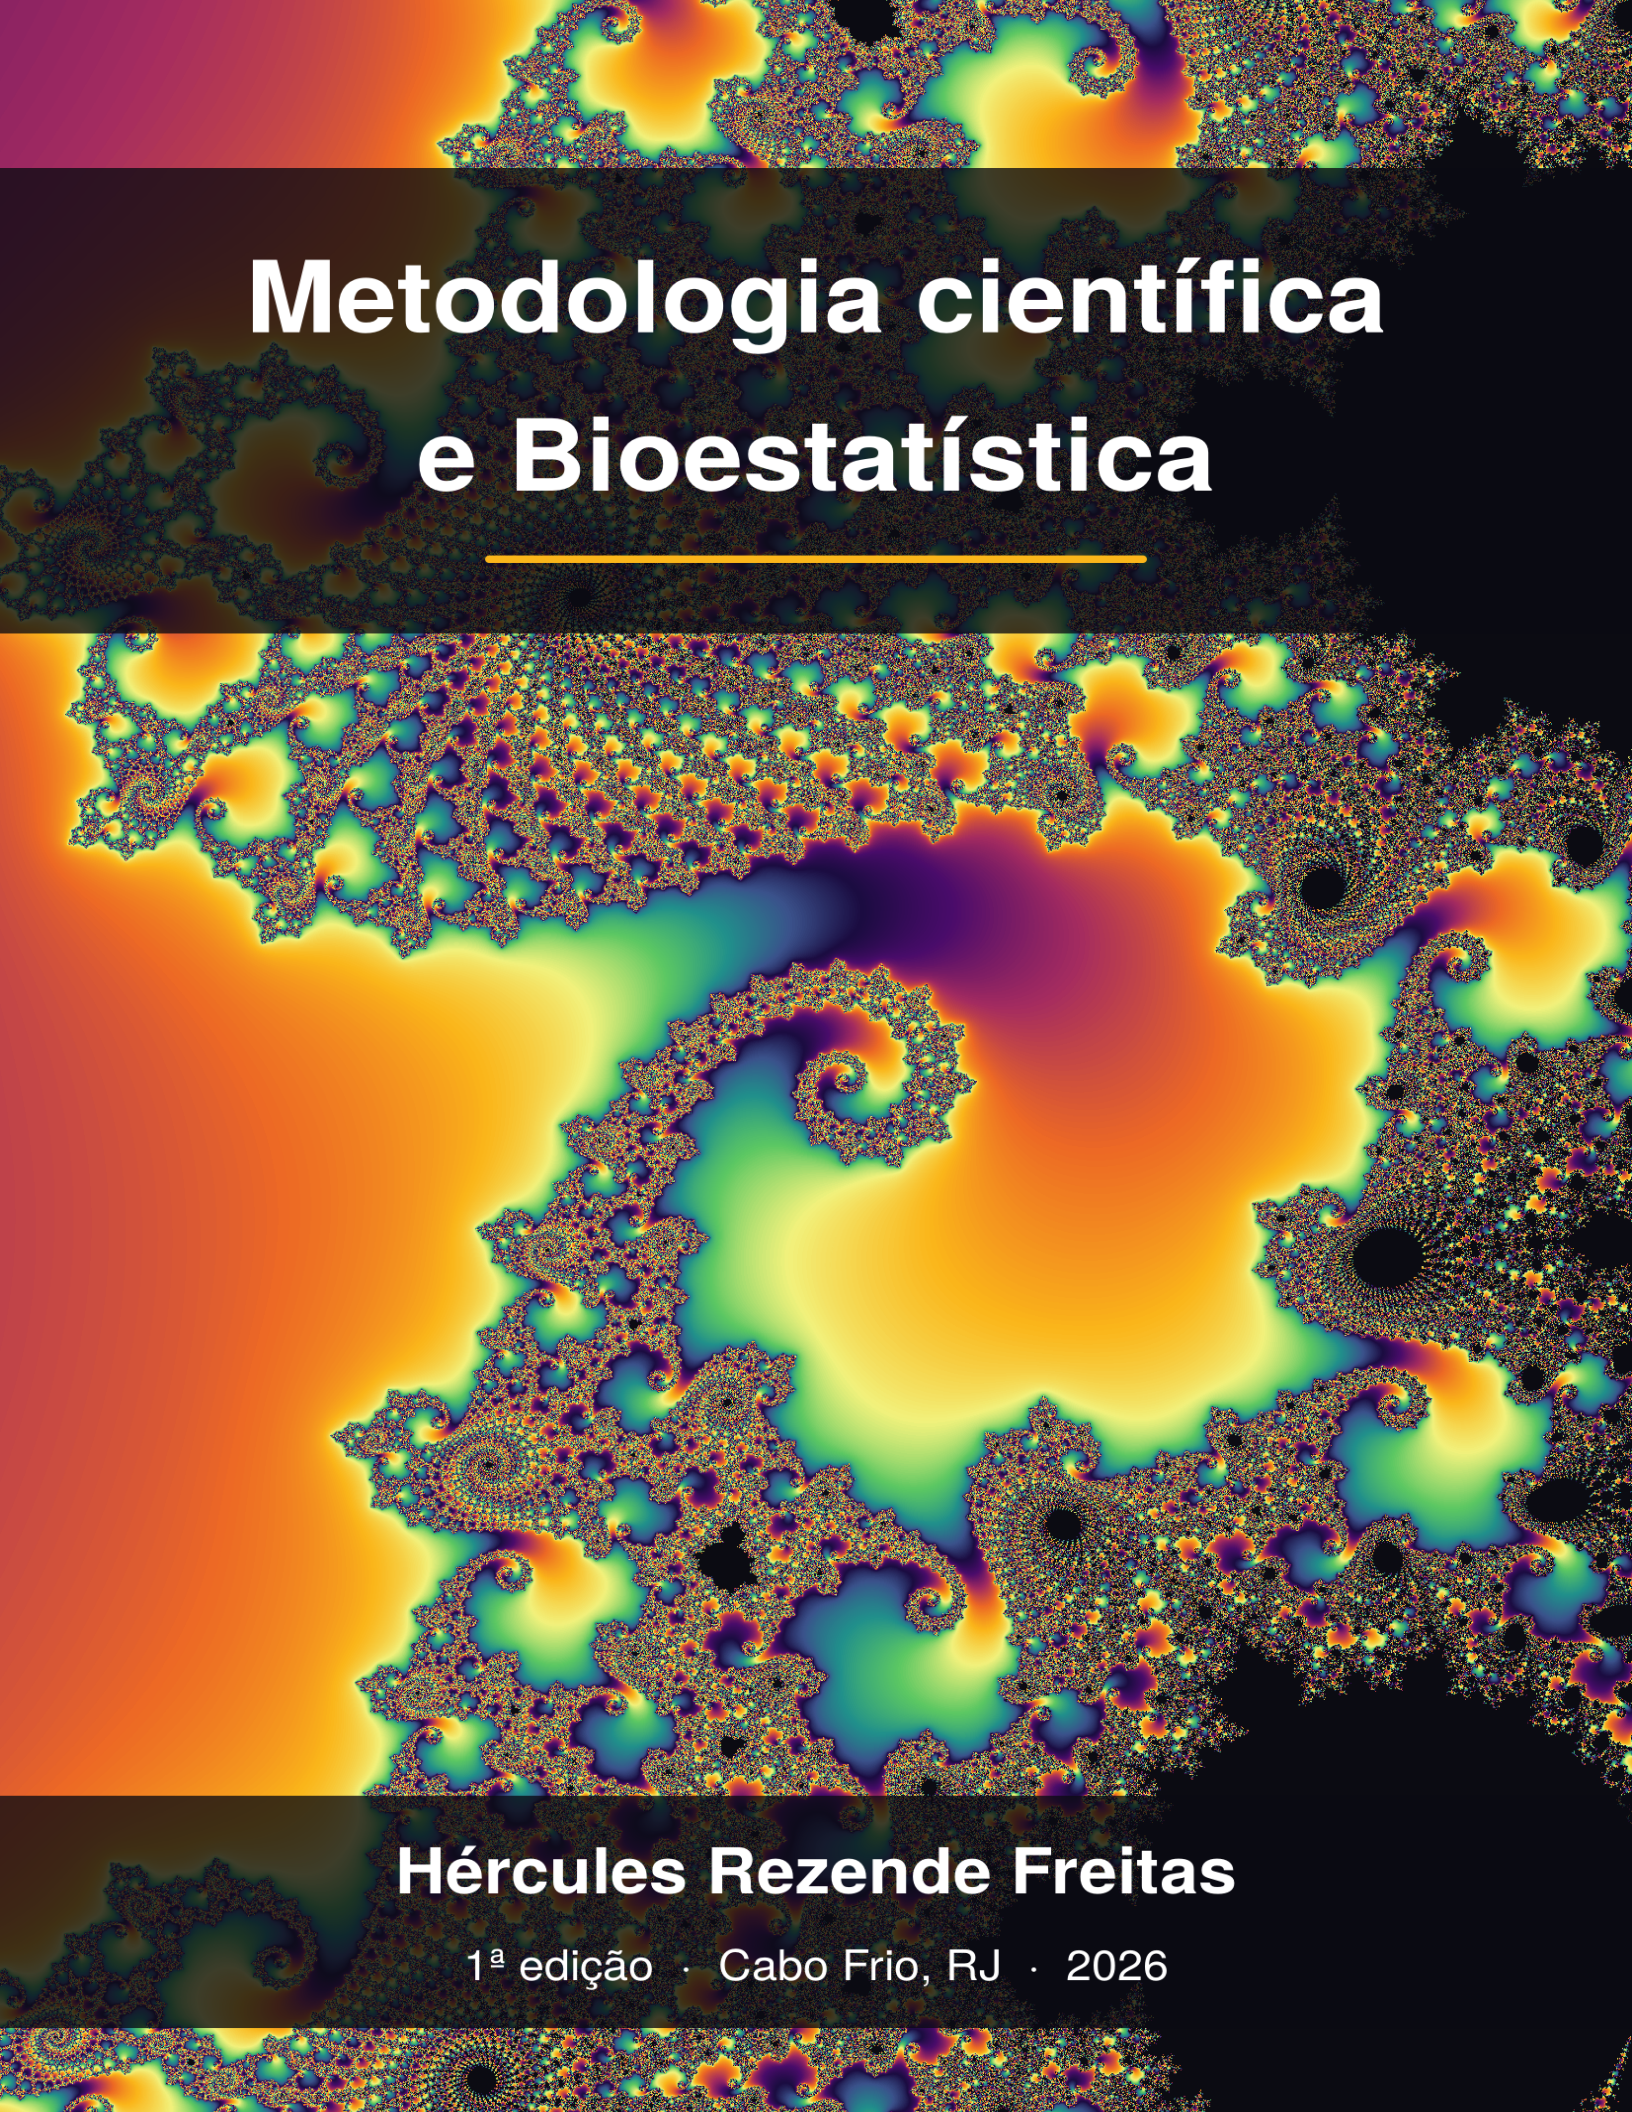


Metodologia científica e Bioestatística

Hércules Rezende Freitas

1ª edição · Cabo Frio, RJ · 2026

Hércules Rezende Freitas

Metodologia científica e Bioestatística

1ª edição

Cabo Frio, RJ
2026

Autor: Hércules Rezende Freitas, Universidade do Estado do Rio de Janeiro (UERJ), Faculdade de Ciências Médicas, Departamento de Ciências Médicas Integradas, Laboratório de Informática em Saúde (LabInfoS), Cabo Frio, RJ, Brasil. ORCID: 0000-0003-1584-9157. Contato: hercules.freitas@uerj.br.

Edição: 1ª edição, Cabo Frio, RJ, 2026. Publicação eletrônica de acesso aberto, sem editora (edição do autor).

Texto, revisão, programação, diagramação e capa: Hércules Rezende Freitas.

Capa: imagem gerada em R a partir do conjunto de Mandelbrot, com coloração cíclica (código em `capa/capa.R`, no repositório do projeto).

Versão *online*: https://drhrf.github.io/MCBS/. **Arquivos-fonte**: https://github.com/drhrf/MCBS.

Licença: © 2026 Hércules Rezende Freitas. Esta obra está licenciada sob a licença Creative Commons Atribuição 4.0 Internacional (CC BY 4.0). É permitido copiar, redistribuir, adaptar e usar o material para qualquer finalidade, inclusive comercial, desde que seja dado o crédito apropriado ao autor, com indicação da fonte, de um link para a licença e das alterações realizadas. Texto da licença: https://creativecommons.org/licenses/by/4.0/.

Declaração sobre o uso de inteligência artificial: na preparação desta edição, o autor utilizou uma ferramenta de inteligência artificial generativa (Claude, da Anthropic) como apoio à edição de texto, à escrita e à revisão dos códigos em R e Python. Todo o conteúdo foi revisado pelo autor, que é o responsável pelo texto, pelos exemplos, pelos códigos e pelas referências. Os exemplos numéricos e os códigos em R são executados a cada compilação do livro, e os resultados citados no texto são gerados a partir deles. Por ser uma obra de acesso aberto, em permanente aprimoramento, este livro convida leitores, revisores e editores a apontar erros e a propor melhorias, conforme descrito na seção *Como contribuir*.

Ficha catalográfica

[a ser inserida após elaboração por bibliotecário]

ISBN: [a ser atribuído]

Conteúdos

1 Sobre o projeto **7**

2 Introdução à metodologia científica **11**

2.1 Conceitos básicos de ciência 11

2.2 O método científico 14

2.3 Paradigmas científicos 17

2.4 Ética na pesquisa científica 19

2.5 Resumo do capítulo 19

2.6 Exercícios 20

2.7 Respostas dos exercícios 20

3 Formulação de problemas e hipóteses **23**

3.1 Identificação de problemas de pesquisa 23

3.2 Revisão da literatura 25

3.3 Definição de objetivos 28

3.4 Formulação de hipóteses 29

3.5 Resumo do capítulo 31

3.6 Exercícios 31

3.7 Respostas dos exercícios 32

4 Desenhos de pesquisa **35**

4.1 Da pergunta ao desenho 35

4.2 Medidas de frequência e de associação 37

4.3 Validade: erro aleatório, viés e confusão 39

4.4 Estudos observacionais 42
4.5 Ensaios clínicos 47
4.6 Estudos experimentais 51
4.7 Resumo do capítulo 53
4.8 Exercícios 54
4.9 Respostas dos exercícios 55

5 Bioestatística descritiva 57

5.1 Tipos de variáveis e escalas de medida 58
5.2 Medidas de tendência central 60
5.3 Medidas de dispersão 65
5.4 Distribuições de frequência 72
5.5 Representações gráficas 75
5.6 Como relatar estatísticas descritivas 81
5.7 Resumo do capítulo 83
5.8 Exercícios 84
5.9 Respostas dos exercícios 84

6 Bioestatística inferencial 87

6.1 População, amostra e variabilidade amostral 87
6.2 Conceitos de probabilidade 88
6.3 Distribuições de probabilidade 92
6.4 Estimação e intervalos de confiança 100
6.5 Testes de hipóteses 104
6.6 Resumo do capítulo 115
6.7 Exercícios 116
6.8 Respostas dos exercícios 117

7 Análise de dados 119

7.1 Correlação e regressão 120
7.2 Análise de variância (ANOVA) 133
7.3 Análise multivariada 140

7.4 Resumo do capítulo 147
7.5 Exercícios 148
7.6 Respostas dos exercícios 149

8 Uso de *softwares* estatísticos 153
8.1 *Softwares* "no-code" e "low-code" 153
8.2 R para análise estatística 155
8.3 Python para análise estatística 196
8.4 Visualização de dados e figuras científicas 220

9 Comunicação científica 227
9.1 Redação de artigos científicos 227
9.2 Estrutura de relatórios de pesquisa 232
9.3 Apresentações orais e pôsteres 233
9.4 Publicação e revisão por pares 234
9.5 Resumo do capítulo 237
9.6 Exercícios 237
9.7 Respostas dos exercícios 238

10 Ética e boas práticas em pesquisa 241
10.1 Consentimento informado e conformidade ética 241
10.2 Plágio e integridade acadêmica 246
10.3 Regulamentações e normas em pesquisa 248
10.4 Responsabilidade social do cientista 249
10.5 Resumo do capítulo 251
10.6 Exercícios 251
10.7 Respostas dos exercícios 252

11 Aplicações práticas e estudos de caso 255
11.1 Epidemiologia e saúde pública 255
11.2 Genética e biologia molecular 260
11.3 Ecologia e conservação 263
11.4 Farmacologia e ensaios clínicos 266

11.5 Resumo do capítulo 270
11.6 Exercícios 271
11.7 Respostas dos exercícios 272

12 Tópicos avançados em bioestatística **275**
12.1 Modelos lineares generalizados 275
12.2 Modelos mistos 278
12.3 Análise de sobrevivência 280
12.4 Inferência bayesiana 284
12.5 Bioinformática e *big data* 286
12.6 Metanálise 288
12.7 Resumo do capítulo 292
12.8 Exercícios 292
12.9 Respostas dos exercícios 293

13 Recursos adicionais **295**
13.1 Bibliografia recomendada 295
13.2 Glossário de termos 296
13.3 Tabelas estatísticas 299
13.4 Links e ferramentas *online* 300

Capítulo 1

Sobre o projeto

O autor

É Professor Adjunto de Metodologia Científica na Faculdade de Ciências Médicas da Universidade do Estado do Rio de Janeiro (FCM/UERJ), onde também atua como Coordenador de Pesquisa, no campus de Cabo Frio. Coordena o Laboratório de Informática em Saúde (LabInfoS) e o Núcleo Bertrand Russell para Excelência Científica (NEC/UERJ), além de integrar o corpo docente do Programa de Pós-Graduação em Ciências Médicas (PGCM/UERJ). Exerce, ainda, a função de bioestatístico no Instituto Nacional de Traumatologia e Ortopedia Jamil Haddad (INTO).

Sua formação acadêmica abrange diferentes áreas do conhecimento. É licenciado em Ciências e em Matemática, bacharel em Biologia e em Nutrição, mestre e doutor em Biofísica pela Universidade Federal do Rio de Janeiro (UFRJ), com grau acadêmico também pela Universidade de Coimbra. Realizou estágio pós-doutoral em Neuropatologia no MIND Institute, da University of California, Davis, sob a supervisão do Dr. Lee-Way Jin e da Dra. Izumi Maezawa. Atuou, ainda, como pesquisador visitante no Multidisciplinary Institute of Ageing, da Universidade de Coimbra.

Ao longo de sua trajetória, foi contemplado com bolsas e auxílios de pesquisa concedidos por instituições nacionais e internacionais, incluindo a Coordenação de Aperfeiçoamento de Pessoal de Nível Superior (CAPES-BR), o Conselho Nacional de Desenvolvimento Científico e Tecnológico (CNPq-BR), o National Institutes of Health (NIH-EUA), a Tess Research Foundation (TRF-USA) e o Coimbra Group (CG-EU).

Sua produção científica inclui a coautoria de livros de referência, como *Nutritional Neuroscience* e *Omega Fatty Acids in Brain and Neurological Health*, publicados pela Academic Press, e *Neurociência da mente e do comportamento*, publicado pela Guanabara Koogan. Atua como revisor de periódicos científicos internacionais, entre eles *British Journal of Pharmacology*, *Frontiers in Neuroscience*, *Neurochemical Research*, *BMJ Open* e *Food Research International*.

Também integra o corpo editorial das revistas *Frontiers in Nutrition* e *Frontiers in Neuroscience* e atua como consultor ad hoc na avaliação de projetos submetidos ao Natural Sciences and Engineering Research Council of Canada (NSERC).

Metodologia científica e Bioestatística

O projeto "Metodologia científica e Bioestatística" é de acesso aberto e está aberto a colaborações. Esta primeira edição foi escrita por um único autor; o objetivo é que o texto seja continuamente atualizado e que todas as pessoas que vierem a contribuir sejam reconhecidas pelo seu trabalho.

Proposta e público

Este livro reúne, em um único texto, os fundamentos da metodologia científica e da bioestatística aplicados às ciências da saúde e da vida. Foi pensado para estudantes de graduação e de pós-graduação em medicina, enfermagem, nutrição, biologia, farmácia e áreas afins, e para pesquisadores e profissionais que precisam planejar estudos, analisar dados ou ler criticamente a literatura científica. O texto procura ser rigoroso sem pressupor formação matemática avançada: as fórmulas são apresentadas e justificadas, os cálculos são feitos passo a passo em exemplos pequenos e, em seguida, reproduzidos em R com conjuntos de dados maiores.

Organização

Os capítulos seguem a ordem em que as decisões aparecem em uma pesquisa:

- **Introdução à metodologia científica** e **Formulação de problemas e hipóteses** tratam da natureza do conhecimento científico, da construção da pergunta de pesquisa, da revisão da literatura, dos objetivos e das hipóteses;
- **Desenhos de pesquisa** apresenta as medidas de frequência e de associação, as ameaças à validade (erro aleatório, viés e confusão) e os principais desenhos observacionais, experimentais e de ensaios clínicos;
- **Bioestatística descritiva**, **Bioestatística inferencial** e **Análise de dados** formam o núcleo estatístico do livro: descrição de dados, probabilidade, distribuições, intervalos de confiança, testes de hipóteses, correlação, regressão, análise de variância e métodos multivariados;
- **Uso de softwares estatísticos** introduz o R, o Python, os programas com interface gráfica e os princípios de construção de figuras científicas;
- **Comunicação científica** e **Ética e boas práticas em pesquisa** tratam da redação, da publicação, da integridade e da regulamentação da pesquisa no Brasil;
- **Aplicações práticas e estudos de caso** e **Tópicos avançados em bioestatística** aplicam e estendem os métodos a problemas de epidemiologia, genética, ecologia e farmacologia, e introduzem modelos lineares generalizados, modelos mistos, análise de sobrevivência, inferência bayesiana, dados de alta dimensão e metanálise;

- **Recursos adicionais** reúne bibliografia comentada, glossário, tabelas estatísticas e endereços úteis.

Como ler este livro

Os capítulos podem ser lidos de forma independente, mas os de bioestatística pressupõem os anteriores: a inferência usa os conceitos da estatística descritiva, e a análise de dados usa os da inferência. Cada capítulo termina com um resumo, exercícios e respostas comentadas. Recomenda-se tentar resolver os exercícios antes de consultar as respostas e reproduzir no próprio computador os códigos apresentados.

Algumas convenções são usadas ao longo do texto:

- no texto, os números usam vírgula como separador decimal; nas saídas do R e do Python, ponto;
- letras gregas (μ, σ, π) indicam parâmetros populacionais, e letras latinas ($\bar{x}$, s, $\hat{p}$), estatísticas calculadas nas amostras;
- os conjuntos de dados usados nos exemplos são fictícios ou simulados, construídos para ilustrar os métodos, e isso é indicado em cada caso. Nenhum deles corresponde a pessoas reais.

Reprodutibilidade

O livro é escrito em R Markdown e compilado com o pacote **bookdown**. Os números citados no texto que dependem de análises são, sempre que possível, gerados diretamente pelo código no momento da compilação, e todas as simulações usam sementes fixas (`set.seed()`), de modo que qualquer leitor obtém exatamente os mesmos resultados. Esta versão foi compilada em 20/10/2026, com R version 4.5.3 (2026-03-11). Os arquivos-fonte estão disponíveis no repositório do projeto: https://github.com/drhrf/MCBS.

Como contribuir

Contribuições são bem-vindas: novos conteúdos, revisão de seções, correção de erros, sugestões de exemplos ou exercícios. Elas podem ser enviadas por e-mail ao autor (hercules.freitas@uerj.br) ou propostas diretamente no repositório do projeto, por meio de *issues* ou *pull requests*. Todas as pessoas que contribuírem com conteúdo serão reconhecidas como coautoras das seções correspondentes, e as contribuições de revisão serão registradas nos agradecimentos.

Como citar

Freitas HR. *Metodologia científica e Bioestatística* [livro eletrônico]. 1. ed. Cabo Frio, RJ: edição do autor; 2026. Disponível em: https://drhrf.github.io/MCBS/.

Ao citar um capítulo específico, indique também o título e o número do capítulo.

Capítulo 2

Introdução à metodologia científica

Hércules Rezende Freitas, Ph.D.[1]

[1]Universidade do Estado do Rio de Janeiro (UERJ), Faculdade de Ciências Médicas, Departamento de Ciências Médicas Integradas, Laboratório de Informática em Saúde (LabInfoS), Cabo Frio/RJ, Brasil.

Este livro trata de como produzir conhecimento confiável em ciências da saúde e da vida. Os capítulos de bioestatística ensinam a descrever dados, quantificar incerteza e modelar relações entre variáveis; os capítulos de metodologia ensinam a formular perguntas, escolher desenhos de estudo, conduzir a pesquisa com integridade e comunicar os resultados. Antes de qualquer técnica, porém, é preciso responder a uma pergunta anterior: o que distingue o conhecimento científico de outras formas de conhecer, e por que ele merece a confiança que lhe atribuímos?

Este capítulo apresenta os conceitos básicos de ciência, as formas de raciocínio que compõem o chamado método científico, as principais ideias sobre como a ciência muda ao longo do tempo e os fundamentos éticos que delimitam o que se pode fazer em nome dela.

2.1 Conceitos básicos de ciência

2.1.1 Formas de conhecimento

Há muitas maneiras de saber algo sobre o mundo. O **conhecimento do senso comum** vem da experiência cotidiana e da tradição: sabemos que o fogo queima e que o frio "causa" resfriado. É útil e frequentemente correto, mas não é sistemático, raramente é posto à prova e mistura observações com crenças não examinadas (o resfriado é causado por vírus, e a associação com o frio é bem mais indireta do que o senso comum supõe). O **conhecimento religioso** se apoia na revelação e na fé, e suas afirmações centrais não se submetem à verificação

empírica. O **conhecimento filosófico** usa a razão para examinar questões que nem sempre podem ser decididas pela observação, como o que é uma boa vida ou o que conta como evidência.

O **conhecimento científico** se distingue por um conjunto de características:

- é **empírico**: suas afirmações sobre o mundo devem, em algum momento, ser confrontadas com observações;
- é **sistemático**: organiza-se em teorias coerentes, e não em afirmações soltas;
- é **metódico**: segue procedimentos explícitos, que outros podem examinar e repetir;
- é **público**: seus métodos e resultados são expostos à crítica de outros pesquisadores;
- é **falível** e **provisório**: qualquer afirmação científica pode ser revista diante de novas evidências.

Essa última característica é frequentemente mal compreendida. Que o conhecimento científico seja provisório não significa que seja frágil ou arbitrário: significa que ele contém os mecanismos para corrigir os próprios erros. A teoria de que a úlcera péptica era causada por estresse e excesso de ácido foi substituída, na década de 1980, pela demonstração de que a maioria das úlceras está associada à infecção por *Helicobacter pylori* (Marshall and Warren 1984), o que mudou o tratamento de milhões de pessoas. Essa revisão é um exemplo do funcionamento normal da ciência, e não de seu fracasso.

2.1.2 O vocabulário da ciência

Alguns termos são usados com sentidos técnicos que diferem do uso cotidiano.

- **Fato** (ou dado): uma observação registrada, como "a pressão arterial deste paciente foi de 150 mmHg nesta medida". Mesmo os fatos dependem de instrumentos e de conceitos: medir a pressão pressupõe uma teoria sobre o funcionamento do esfigmomanômetro.
- **Conceito**: uma abstração que agrupa fenômenos, como "hipertensão", "ansiedade" ou "qualidade de vida".
- **Variável**: uma característica que pode assumir valores diferentes entre unidades ou ao longo do tempo. Um conceito precisa ser **operacionalizado** para virar variável: "hipertensão" pode ser operacionalizada como "pressão sistólica $\geq$ 140 mmHg ou diastólica $\geq$ 90 mmHg em duas medidas, ou uso de anti-hipertensivo". A operacionalização é uma escolha, e diferentes escolhas podem produzir resultados diferentes. Os tipos de variáveis são tratados no capítulo *Bioestatística descritiva*.

- **Hipótese**: uma proposição testável sobre a relação entre variáveis, formulada antes da coleta de dados (capítulo *Formulação de problemas e hipóteses*).
- **Lei**: uma regularidade bem estabelecida, frequentemente expressa em forma matemática, como a lei de Fick para a difusão. Leis descrevem como os fenômenos se comportam.
- **Teoria**: um sistema articulado de conceitos, leis e mecanismos que **explica** um conjunto amplo de fenômenos e permite derivar novas hipóteses. A teoria da evolução por seleção natural e a teoria microbiana das doenças são exemplos. No uso cotidiano, "é só uma teoria" sugere um palpite; na ciência, uma teoria é o nível mais alto de conhecimento organizado, e não um estágio anterior à "prova".
- **Modelo**: uma representação simplificada de um sistema, usada para compreendê-lo ou prever seu comportamento. Os modelos estatísticos dos capítulos seguintes (a regressão linear, por exemplo) são modelos nesse sentido: todos são simplificações, e a pergunta relevante não é se são verdadeiros, mas se são úteis para o propósito.

2.1.3 Pesquisa básica, aplicada e translacional

A **pesquisa básica** busca compreender fenômenos sem um objetivo prático imediato: como uma proteína se dobra, como os neurônios codificam a memória. A **pesquisa aplicada** busca resolver problemas práticos: qual o melhor tratamento para a hipertensão resistente, como reduzir infecções hospitalares. A distinção é útil, mas não rígida: grande parte das aplicações médicas mais importantes nasceu de pesquisas básicas sem finalidade prática evidente (a reação em cadeia da polimerase depende de uma enzima descoberta em bactérias de fontes termais). A **pesquisa translacional** trata explicitamente da passagem entre os dois mundos, da bancada ao leito e do leito à população.

2.1.4 Ciência e pseudociência

Como distinguir ciência de pseudociência, isto é, de afirmações que se apresentam como científicas sem sê-lo? Esse é o **problema da demarcação**. Não há critério único e definitivo, mas alguns sinais de alerta são confiáveis:

- afirmações formuladas de modo que nenhuma observação possível poderia contradizê-las;
- recurso sistemático a explicações *ad hoc* para acomodar resultados desfavoráveis;
- ausência de publicação em veículos com revisão por pares, ou recusa em expor métodos e dados;
- apelo à autoridade, à tradição ou ao número de adeptos, em vez de evidência;

- ausência de progresso: as mesmas afirmações se repetem por décadas sem refinamento.

2.2 O método científico

Fala-se em "o método científico" como se houvesse um procedimento único, aplicado da mesma forma por físicos, epidemiologistas e ecólogos. Na prática, cada área desenvolveu métodos próprios. O que elas compartilham é um conjunto de formas de raciocínio e de atitudes diante da evidência.

2.2.1 Indução

A **indução** parte de observações particulares para chegar a generalizações: observamos que muitos pacientes tratados com um medicamento melhoraram e concluímos que o medicamento é eficaz. Francis Bacon, no século XVII, propôs a indução como base da ciência, em oposição ao raciocínio puramente dedutivo herdado da escolástica.

A indução tem um problema lógico, formulado por David Hume no século XVIII: nenhum número de observações particulares garante a verdade de uma generalização. Ter observado mil cisnes brancos não prova que todos os cisnes sejam brancos, como os europeus descobriram ao chegar à Austrália. Toda generalização indutiva vai além dos dados, e por isso é sempre **provável**, nunca certa. A estatística inferencial pode ser vista como a disciplina que quantifica essa incerteza.

2.2.2 Dedução

A **dedução** parte de premissas gerais para chegar a conclusões particulares: se todos os mamíferos têm coração e o morcego é um mamífero, o morcego tem coração. Se as premissas forem verdadeiras e o raciocínio válido, a conclusão é **necessariamente** verdadeira. A dedução não acrescenta informação nova às premissas, mas torna explícitas suas consequências, e é isso que permite testar teorias: deduzimos o que deveríamos observar se a teoria estiver correta e comparamos com o que observamos.

2.2.3 O método hipotético-dedutivo

O **método hipotético-dedutivo** combina as duas formas de raciocínio e descreve bem a lógica da pesquisa empírica:

1. diante de um problema, formula-se uma **hipótese** que poderia explicá-lo;

2. **deduzem-se** consequências observáveis da hipótese (se a hipótese for verdadeira, então deveríamos observar tal coisa);
3. realizam-se observações ou experimentos para verificar se as consequências ocorrem;
4. se as consequências **não** ocorrem, a hipótese é refutada (ou, pelo menos, posta em dúvida); se ocorrem, a hipótese é **corroborada**, mas não provada.

O caso clássico, analisado pelo filósofo Carl Hempel (1966), é o de Ignaz Semmelweis, médico do Hospital Geral de Viena na década de 1840. Na Primeira Clínica de obstetrícia, atendida por médicos e estudantes, a mortalidade materna por febre puerperal era muito maior que na Segunda Clínica, atendida por parteiras. Semmelweis examinou e descartou várias hipóteses: "influências epidêmicas" não explicavam a diferença entre clínicas vizinhas na mesma cidade; a superlotação era maior na Segunda Clínica; mudanças na posição do parto não alteraram a mortalidade. Quando um colega morreu de uma doença semelhante após se ferir durante uma autópsia, Semmelweis formulou a hipótese de que "matéria cadavérica" levada pelas mãos dos médicos, que vinham da sala de autópsias, causava a doença. A consequência dedutível era clara: se os médicos lavassem as mãos com uma solução de cal clorada antes de examinar as parturientes, a mortalidade deveria cair. Ela caiu drasticamente.

O exemplo também ilustra as limitações do método. A hipótese de Semmelweis estava parcialmente errada (não era "matéria cadavérica", mas bactérias, que só seriam identificadas décadas depois), e mesmo assim permitiu uma intervenção eficaz. E foi rejeitada por muitos contemporâneos, em parte porque contrariava as teorias aceitas na época, um tema que retomaremos ao falar de paradigmas.

2.2.4 Falseabilidade

O filósofo Karl Popper (1959) argumentou que a assimetria entre confirmação e refutação é o coração da ciência. Nenhum número de observações favoráveis prova uma teoria universal, mas uma única observação contrária, bem estabelecida, pode refutá-la. Para Popper, o que torna uma teoria científica é ser **falseável**: ela precisa proibir certos resultados, de modo que, se esses resultados forem observados, a teoria será considerada falsa. Teorias que acomodam qualquer resultado possível não dizem nada sobre o mundo.

A falseabilidade influenciou profundamente a prática científica e está na lógica dos testes de hipóteses (capítulo *Bioestatística inferencial*), em que se tenta rejeitar uma hipótese nula. Mas ela tem limites. Na prática, um resultado contrário raramente refuta uma teoria de forma isolada, porque toda previsão depende de hipóteses auxiliares (que os instrumentos funcionaram, que a amostra é representativa, que não houve erro de medida); diante de um resultado inesperado, é legítimo perguntar qual dessas hipóteses falhou. Há também outro limite: as previsões em ciências da saúde são probabilísticas: a teoria não prevê

que todo fumante terá câncer, mas que fumantes terão mais câncer, e um único fumante longevo não refuta nada.

2.2.5 Abdução e a geração de hipóteses

De onde vêm as hipóteses? O método hipotético-dedutivo descreve como testá-las, mas não como inventá-las. O filósofo Charles S. Peirce chamou de **abdução** o raciocínio que, diante de uma observação surpreendente, propõe a explicação que, se verdadeira, tornaria a observação esperada. É a forma de raciocínio do diagnóstico clínico: diante de febre, tosse e uma imagem radiológica característica, o médico infere a hipótese de pneumonia, que depois será testada. A geração de hipóteses envolve conhecimento prévio, imaginação e, frequentemente, acaso; não há algoritmo para ela.

2.2.6 Reprodutibilidade e autocorreção

A ciência se corrige porque seus resultados são públicos e podem ser repetidos por outros. Convém distinguir três termos, usados de maneira inconsistente na literatura:

- **reprodutibilidade computacional**: obter os mesmos resultados a partir dos mesmos dados e do mesmo código;
- **replicação**: obter resultados consistentes em um novo estudo, com novos dados, sobre a mesma pergunta;
- **robustez**: obter conclusões semelhantes com análises alternativas razoáveis dos mesmos dados.

Nas últimas duas décadas, tornou-se claro que esse mecanismo de autocorreção funciona pior do que se supunha. Ioannidis (2005) argumentou, com um modelo simples, que a maioria dos achados publicados em áreas com estudos pequenos, efeitos modestos, muitas hipóteses testadas e flexibilidade analítica tende a ser falsa. Um esforço coletivo para replicar 100 estudos publicados em periódicos de psicologia obteve resultados estatisticamente significativos em apenas cerca de 36% das replicações, contra 97% dos estudos originais, com efeitos, em média, com metade da magnitude (Open Science Collaboration 2015). Problemas semelhantes foram documentados na pesquisa pré-clínica e em outras áreas.

As causas identificadas incluem estudos com poder estatístico baixo, análises escolhidas depois de ver os dados, publicação seletiva de resultados "positivos" e incentivos que premiam a quantidade e a novidade em detrimento da confiabilidade. As respostas incluem o registro prévio de estudos e análises, o compartilhamento de dados e código, estudos de replicação e a valorização de resultados nulos. Esses temas atravessam todo o livro, em particular os capítulos *Bioestatística inferencial*, *Comunicação científica* e *Ética e boas práticas em pesquisa*.

2.3 Paradigmas científicos

2.3.1 Kuhn e as revoluções científicas

O físico e historiador Thomas Kuhn (1962) propôs uma descrição da mudança científica muito diferente da imagem de acúmulo gradual de conhecimento. Para Kuhn, a maior parte do tempo a ciência funciona como **ciência normal**, organizada em torno de um **paradigma**: um conjunto de teorias, métodos, problemas considerados legítimos e exemplos de soluções bem-sucedidas, compartilhado por uma comunidade. Na ciência normal, os pesquisadores não questionam o paradigma; resolvem "quebra-cabeças" dentro dele.

Com o tempo, acumulam-se **anomalias**, observações que o paradigma não consegue explicar. Quando as anomalias se tornam numerosas ou importantes demais, instala-se uma **crise**, que pode levar a uma **revolução científica**: a substituição do paradigma por outro, incompatível com o anterior. A passagem da astronomia ptolomaica para a copernicana, da química do flogisto para a de Lavoisier e da física newtoniana para a relativística são os exemplos clássicos. Para Kuhn, paradigmas sucessivos são, em certo grau, **incomensuráveis**: os mesmos termos mudam de significado, os problemas considerados relevantes mudam, e a escolha entre paradigmas não se decide apenas pela lógica e pelos dados, mas envolve também julgamento e persuasão.

Na medicina, a teoria microbiana das doenças, que substituiu a teoria dos miasmas na segunda metade do século XIX, tem muitas características de uma revolução kuhniana, e a resistência às ideias de Semmelweis pode ser lida como a de uma comunidade que trabalhava em um paradigma em que suas observações não faziam sentido.

2.3.2 Outras perspectivas

A obra de Kuhn provocou intenso debate. Imre Lakatos propôs que a ciência é composta por **programas de pesquisa**, com um núcleo de hipóteses protegido por um "cinturão" de hipóteses auxiliares que são ajustadas diante de anomalias; um programa é **progressivo** quando esses ajustes levam a previsões novas e confirmadas, e **degenerativo** quando apenas acomodam os fatos depois que eles ocorrem. Paul Feyerabend argumentou que nenhuma regra metodológica foi seguida em todos os episódios importantes da história da ciência. Essas posições não precisam ser adotadas integralmente para serem úteis: elas lembram que a ciência é uma atividade humana e coletiva, sujeita a influências sociais, e que suas regras de método são orientações, não algoritmos.

2.3.3 Paradigmas de pesquisa em saúde

Em um sentido mais amplo, o termo "paradigma" é usado também para designar as orientações filosóficas que fundamentam abordagens de pesquisa diferentes:

- a **abordagem quantitativa**, associada a uma tradição positivista ou pós-positivista, busca medir variáveis, estimar parâmetros e testar hipóteses, com ênfase em generalização e controle de vieses. É a abordagem da maior parte deste livro;
- a **abordagem qualitativa**, associada a tradições interpretativas, busca compreender significados, experiências e contextos a partir da perspectiva dos participantes, com dados como entrevistas, observação e documentos. Pergunta, por exemplo, como pacientes com uma doença crônica vivenciam o tratamento, ou por que profissionais de saúde não aderem a um protocolo;
- os **métodos mistos** combinam as duas abordagens de forma planejada, por exemplo usando entrevistas para interpretar os resultados de um inquérito.

Nenhuma é superior em abstrato. A escolha depende da pergunta: estimar a prevalência de uma doença exige métodos quantitativos; compreender as barreiras ao acesso ao tratamento pode exigir métodos qualitativos. Os critérios de rigor também diferem: na pesquisa quantitativa, falamos em validade e precisão; na qualitativa, em credibilidade, transferibilidade e reflexividade. Este livro concentra-se nos métodos quantitativos, mas o leitor deve saber que eles não esgotam a pesquisa em saúde.

2.3.4 Medicina baseada em evidências

Um exemplo de mudança de paradigma na prática clínica é a **medicina baseada em evidências** (MBE), proposta no início da década de 1990 como uma "nova abordagem para o ensino da prática da medicina" (Evidence-Based Medicine Working Group 1992). Em vez de basear decisões principalmente na intuição, na experiência não sistematizada e na fisiopatologia, a MBE propõe integrar a melhor evidência disponível de pesquisas clínicas com a experiência do clínico e os valores e preferências do paciente (Sackett et al. 1996). A MBE foi criticada por supostamente reduzir a medicina a protocolos, crítica que seus proponentes rejeitam: a evidência informa a decisão, mas não a substitui. Para o leitor deste livro, a MBE tem uma consequência direta: avaliar criticamente um estudo exige conhecer os desenhos, os vieses e os métodos estatísticos tratados nos capítulos seguintes.

2.4 Ética na pesquisa científica

A ciência não é eticamente neutra. A escolha do que pesquisar, os riscos impostos aos participantes, a honestidade no registro e na comunicação dos resultados e o uso que se faz do conhecimento produzido envolvem decisões morais. A história da pesquisa com seres humanos inclui episódios graves, como os experimentos realizados por médicos nazistas em prisioneiros de campos de concentração, julgados em Nuremberg em 1946 e 1947, e o estudo de Tuskegee, nos Estados Unidos, em que centenas de homens negros com sífilis foram acompanhados sem tratamento de 1932 a 1972, mesmo depois de a penicilina se tornar o tratamento padrão.

Desses episódios nasceram os princípios que hoje regem a pesquisa: o **consentimento livre e esclarecido** dos participantes, a avaliação de **riscos e benefícios**, a proteção dos **vulneráveis** e a **revisão independente** dos projetos por comitês de ética. No Relatório Belmont, de 1979, esses princípios foram sintetizados em três: **respeito às pessoas**, **beneficência** e **justiça**. No Brasil, a pesquisa com seres humanos é regulada pela Lei nº 14.874/2024 e pelas resoluções do Conselho Nacional de Saúde, e a pesquisa com animais, pela Lei nº 11.794/2008.

A ética também se aplica à conduta do pesquisador em relação ao próprio conhecimento: não fabricar nem falsificar dados, não plagiar, relatar os métodos de forma completa, publicar resultados independentemente de sua direção, declarar conflitos de interesse. Esses temas, e a regulamentação brasileira, são tratados em detalhe no capítulo *Ética e boas práticas em pesquisa*.

2.5 Resumo do capítulo

- O conhecimento científico é empírico, sistemático, metódico, público e falível. Sua provisoriedade é o que permite a autocorreção.
- Teoria, na ciência, é um sistema explicativo amplo e bem fundamentado, e não um palpite. Conceitos precisam ser operacionalizados para virar variáveis mensuráveis.
- A indução generaliza a partir de observações e nunca é certa; a dedução deriva consequências de premissas. O método hipotético-dedutivo formula hipóteses, deduz consequências observáveis e as confronta com dados.
- Para Popper, uma teoria científica precisa ser falseável. Na prática, as previsões dependem de hipóteses auxiliares e são frequentemente probabilísticas.
- A geração de hipóteses (abdução) envolve conhecimento, imaginação e acaso; não há algoritmo para ela.
- Reprodutibilidade, replicação e robustez são conceitos distintos. Baixo poder, flexibilidade analítica e publicação seletiva contribuem para que muitos achados publicados não se repliquem.

- Kuhn descreveu a ciência como alternância entre períodos de ciência normal, organizados por paradigmas, e revoluções. Abordagens quantitativas, qualitativas e mistas respondem a perguntas diferentes.
- A medicina baseada em evidências integra a melhor evidência de pesquisa, a experiência clínica e os valores do paciente.
- A pesquisa científica está sujeita a princípios éticos (respeito às pessoas, beneficência, justiça) e a normas de integridade.

2.6 Exercícios

1. Classifique cada afirmação como fato, hipótese, lei ou teoria, e justifique: (a) "a glicemia de jejum do paciente foi de 126 mg/dL"; (b) "a suplementação de vitamina D reduz a incidência de fraturas em idosos institucionalizados"; (c) "a velocidade de uma reação catalisada por enzima segue a equação de Michaelis–Menten em determinadas condições"; (d) "as espécies se modificam ao longo das gerações por seleção natural de variações hereditárias".

2. Proponha duas operacionalizações diferentes para o conceito de "obesidade" e discuta como a escolha poderia alterar os resultados de um estudo sobre obesidade e doença cardiovascular.

3. A afirmação "este suplemento fortalece a energia vital do organismo" é falseável? Reescreva-a de modo que possa ser testada empiricamente.

4. Um estudo encontrou associação entre o uso de um medicamento e a redução da mortalidade. Um segundo estudo, maior e mais bem conduzido, não encontrou associação. Explique por que esse resultado não significa que "a ciência não sabe de nada", e cite pelo menos duas razões pelas quais os estudos podem ter discordado.

5. Descreva o episódio de Semmelweis com as etapas do método hipotético-dedutivo. Que hipóteses auxiliares estavam envolvidas no teste da hipótese da "matéria cadavérica"?

6. Dê um exemplo de pergunta de pesquisa em saúde que exija uma abordagem qualitativa e outro que exija uma abordagem quantitativa.

2.7 Respostas dos exercícios

1. (a) Fato: uma observação registrada. (b) Hipótese: uma proposição testável sobre a relação entre variáveis (que, de fato, foi testada em ensaios clínicos). (c) Lei: descreve uma regularidade quantitativa,

sem, por si só, explicar o mecanismo. (d) Teoria: um sistema explicativo amplo, que dá conta de um conjunto enorme de fenômenos e permite derivar hipóteses.

2. Por exemplo: IMC $\geq$ 30 kg/m², ou circunferência da cintura acima de pontos de corte específicos por sexo. O IMC não distingue gordura de massa magra nem considera a distribuição da gordura; a circunferência da cintura capta a adiposidade abdominal, mais associada ao risco cardiovascular. Um estudo pode encontrar associações de magnitudes diferentes conforme a operacionalização, e pessoas classificadas como obesas por um critério podem não sê-lo pelo outro.

3. Não é falseável na forma apresentada: "energia vital" não é definida de maneira mensurável, e nenhuma observação poderia contradizer a afirmação. Uma versão testável seria: "adultos sedentários que tomam o suplemento por 8 semanas relatam menor escore de fadiga, medido pela escala X, do que adultos que tomam placebo".

4. A ciência se corrige exatamente por meio de novos estudos; a discordância é parte do processo, e a evidência acumulada é que orienta a conclusão. Razões possíveis para a discordância: erro aleatório (o primeiro estudo pode ter sido um falso positivo, sobretudo se era pequeno); confusão no primeiro estudo (por exemplo, se observacional, os usuários do medicamento podem ser mais saudáveis por outros motivos); diferenças nas populações, doses ou tempos de acompanhamento; publicação seletiva.

5. Problema: mortalidade por febre puerperal maior na Primeira Clínica. Hipótese: "matéria cadavérica" transmitida pelas mãos dos médicos. Consequência deduzida: a lavagem das mãos com solução clorada deveria reduzir a mortalidade. Teste: introdução da lavagem. Resultado: queda acentuada da mortalidade, que corrobora a hipótese. Hipóteses auxiliares: que a solução clorada de fato eliminava a "matéria cadavérica"; que a lavagem foi efetivamente realizada; que nenhum outro fator mudou ao mesmo tempo na clínica; que o registro dos óbitos era confiável.

6. Qualitativa: "como mulheres com diagnóstico recente de câncer de mama vivenciam a decisão entre mastectomia e cirurgia conservadora?". Quantitativa: "qual a sobrevida em cinco anos de mulheres com câncer de mama em estágio inicial tratadas com cirurgia conservadora e radioterapia, comparada à da mastectomia?".

Capítulo 3

Formulação de problemas e hipóteses

Hércules Rezende Freitas, Ph.D.[1]

[1]Universidade do Estado do Rio de Janeiro (UERJ), Faculdade de Ciências Médicas, Departamento de Ciências Médicas Integradas, Laboratório de Informática em Saúde (LabInfoS), Cabo Frio/RJ, Brasil.

Uma pesquisa começa muito antes da coleta de dados. Começa quando alguém percebe que algo não é conhecido, ou é conhecido de forma insuficiente, e decide investigar. A qualidade dessa etapa inicial condiciona tudo o que vem depois: uma pergunta vaga produz um desenho vago, uma análise sem foco e conclusões que não respondem a nada. Por outro lado, uma pergunta clara já sugere o desenho adequado, as variáveis a medir, o tamanho amostral necessário e a análise estatística.

Este capítulo percorre o caminho que vai de um tema de interesse a um problema de pesquisa, deste a uma revisão da literatura que mostra o que já se sabe, e daí aos objetivos e hipóteses que orientarão o estudo.

3.1 Identificação de problemas de pesquisa

3.1.1 Do tema ao problema e à pergunta

É útil distinguir três níveis de especificidade.

- O **tema** é uma área ampla de interesse: “doença de Alzheimer”, “obesidade infantil”, “infecções hospitalares”.
- O **problema de pesquisa** é uma lacuna ou contradição específica dentro do tema, que justifica a investigação: “não se sabe se os inibidores da colinesterase, usados para tratar sintomas da doença de Alzheimer, alteram a mortalidade dos pacientes no contexto do sistema público brasileiro”.

- A **pergunta de pesquisa** é a formulação precisa, respondível, do que o estudo fará: "em pacientes com doença de Alzheimer que iniciam tratamento pelo SUS, o uso de donepezila, comparado ao de rivastigmina, está associado a diferença na mortalidade em três anos?".

O erro mais comum de pesquisadores iniciantes é tentar responder a um tema, em vez de a uma pergunta. "Estudar a obesidade infantil" não é um projeto; "estimar a prevalência de obesidade em escolares de 6 a 10 anos da rede municipal de um município e sua associação com o tempo diário de tela" é.

3.1.2 Fontes de problemas

Problemas de pesquisa surgem de várias fontes:

- **a prática profissional**: observações clínicas inesperadas, dúvidas sobre a melhor conduta, variações de resultados entre serviços;
- **a literatura**: estudos com resultados contraditórios, limitações apontadas pelos próprios autores, recomendações de "pesquisas futuras", revisões sistemáticas que concluem haver evidência insuficiente;
- **novas tecnologias e dados**: um novo método de medida, uma base de dados recém-disponibilizada, uma técnica analítica que permite responder a perguntas antes inacessíveis;
- **demandas sociais e de saúde pública**: epidemias, mudanças demográficas, prioridades de agências de fomento e do sistema de saúde;
- **teorias**: consequências de uma teoria que ainda não foram testadas.

3.1.3 Critérios para uma boa pergunta: FINER

Hulley e colaboradores (2013) propuseram o acrônimo **FINER** para avaliar uma pergunta de pesquisa. Uma boa pergunta deve ser:

- **F**actível: há participantes suficientes, recursos técnicos, tempo, financiamento e competência para respondê-la? Um estudo sobre uma doença rara em um único hospital pode não ter pacientes suficientes; um estudo de coorte que exige 20 anos de acompanhamento pode não ser viável em um mestrado;
- **I**nteressante: a resposta interessa ao pesquisador e à comunidade científica? O interesse sustenta o esforço ao longo de anos;
- **N**ova: a resposta acrescenta algo ao que se sabe? Pode confirmar, refutar ou estender achados anteriores; replicar um estudo importante em uma população diferente também é uma contribuição nova;
- **É**tica: o estudo pode ser realizado sem expor os participantes a riscos inaceitáveis? (capítulo *Ética e boas práticas em pesquisa*);
- **R**elevante: a resposta tem potencial de influenciar o conhecimento científico, a prática clínica ou as políticas de saúde?

3.1.4 Estruturando a pergunta

Para perguntas sobre efeitos de intervenções ou exposições, o formato **PICO** (População, Intervenção, Comparador, *Outcome*/desfecho), apresentado no capítulo *Desenhos de pesquisa*, ajuda a garantir que nenhum componente essencial fique implícito. Variações incluem **PECO** (Exposição, em estudos observacionais), **PICOT** (acrescentando o Tempo de acompanhamento) e **PIRD** (População, teste Índice, teste de Referência, Diagnóstico) para estudos de acurácia diagnóstica. Para perguntas descritivas e qualitativas, outros formatos são usados, como **PCC** (População, Conceito, Contexto), comum em revisões de escopo.

Um exemplo de refinamento progressivo:

1. "O exercício faz bem para idosos?" (tema, não pergunta);
2. "O exercício melhora a cognição de idosos?" (ainda vago: qual exercício? qual cognição? comparado a quê?);
3. "Em idosos com comprometimento cognitivo leve (P), um programa de treinamento aeróbico de intensidade moderada, três vezes por semana durante seis meses (I), comparado a um programa de alongamento com a mesma frequência (C), melhora a memória episódica, medida pelo teste X (O), ao final da intervenção (T)?".

A última versão já indica o desenho (ensaio randomizado), a população a recrutar, o desfecho principal e permite calcular o tamanho amostral.

3.2 Revisão da literatura

A revisão da literatura tem duas funções. **Antes** de definir a pergunta, ela mostra o que já se sabe e onde estão as lacunas, evitando que se repita desnecessariamente o que já está estabelecido. **Durante** o projeto, ela fundamenta a justificativa, orienta a escolha de métodos e instrumentos (como outros estudos mediram o mesmo desfecho?) e fornece dados para o cálculo do tamanho amostral (qual a variabilidade esperada? qual o tamanho de efeito plausível?).

3.2.1 Tipos de revisão

- **Revisão narrativa**: síntese não sistemática, em geral escrita por especialistas, útil para apresentar um tema amplo. Não segue um protocolo explícito de busca e seleção, e por isso está sujeita à seleção dos estudos que confirmam a visão do autor.
- **Revisão integrativa**: combina estudos de diferentes desenhos (inclusive qualitativos e teóricos) com método explícito de busca; comum na enfermagem.

- **Revisão de escopo** (*scoping review*): mapeia a extensão e a natureza da literatura sobre um tema amplo, identifica conceitos e lacunas, sem necessariamente avaliar a qualidade dos estudos ou sintetizar resultados.
- **Revisão sistemática**: responde a uma pergunta específica seguindo um protocolo pré-definido de busca, seleção, extração de dados e avaliação do risco de viés, de modo transparente e reprodutível. Deve ter seu protocolo registrado previamente (por exemplo, na base PROSPERO) e ser relatada segundo a diretriz PRISMA 2020 (Page et al. 2021).
- **Metanálise**: combinação estatística dos resultados de estudos incluídos em uma revisão sistemática, quando são suficientemente homogêneos (capítulo *Tópicos avançados em bioestatística*).

Para fundamentar um projeto de pesquisa, não é necessário realizar uma revisão sistemática completa, mas é muito recomendável adotar seus princípios: busca em várias bases, estratégia explícita e registro do que foi encontrado. Se já existir uma revisão sistemática recente sobre a pergunta, ela é o melhor ponto de partida.

3.2.2 Onde buscar

As principais bases bibliográficas em ciências da saúde são:

- **MEDLINE**, acessada gratuitamente pelo **PubMed**, mantido pela Biblioteca Nacional de Medicina dos Estados Unidos;
- **LILACS** (Literatura Latino-Americana e do Caribe em Ciências da Saúde), acessada pela **Biblioteca Virtual em Saúde** (BVS), indispensável para localizar a produção latino-americana, frequentemente ausente das bases internacionais;
- **SciELO**, biblioteca de periódicos de acesso aberto da América Latina, da Península Ibérica e da África do Sul;
- **Embase**, com maior cobertura de periódicos europeus e de farmacologia;
- **Web of Science** e **Scopus**, bases multidisciplinares com informações de citação;
- **Cochrane Library**, que reúne revisões sistemáticas Cochrane e um registro de ensaios controlados;
- registros de ensaios clínicos (**ClinicalTrials.gov**, **ReBEC**, plataforma ICTRP da Organização Mundial da Saúde), que permitem identificar estudos em andamento e estudos concluídos e não publicados.

Pesquisadores vinculados a instituições brasileiras têm acesso a muitas dessas bases pelo **Portal de Periódicos da CAPES**.

3.2.3 Como buscar

Uma busca eficiente combina três elementos.

1. **Vocabulário controlado.** As bases indexam os artigos com descritores padronizados: os **MeSH** (*Medical Subject Headings*), no MEDLINE, e os **DeCS** (Descritores em Ciências da Saúde), trilíngues, na BVS. Buscar pelo descritor recupera artigos que usam sinônimos diferentes para o mesmo conceito ("infarto do miocárdio", "ataque cardíaco").
2. **Termos livres.** Como artigos recentes podem ainda não estar indexados, e nem todo conceito tem descritor, combinam-se os descritores com palavras do título e do resumo, incluindo sinônimos, grafias alternativas e truncamentos (`hypertens*` recupera *hypertension*, *hypertensive*).
3. **Operadores booleanos.** `OR` une sinônimos de um mesmo conceito (amplia a busca); `AND` combina conceitos diferentes (restringe a busca); `NOT` exclui termos (deve ser usado com cautela, pois pode excluir artigos relevantes). Parênteses definem a ordem das operações.

Um exemplo de estratégia no PubMed para a pergunta sobre exercício aeróbico e cognição em idosos com comprometimento cognitivo leve:

```
("Cognitive Dysfunction"[MeSH] OR "mild cognitive impairment"[tiab] OR
 ↪  MCI[tiab])
AND
("Exercise"[MeSH] OR "aerobic exercise"[tiab] OR "aerobic training"[tiab]
 ↪  OR "physical activity"[tiab])
AND
("Randomized Controlled Trial"[pt] OR randomi*[tiab])
```

O campo `[tiab]` restringe a busca ao título e ao resumo, e `[pt]` ao tipo de publicação. A estratégia deve ser registrada exatamente como foi executada, com a data da busca, para que possa ser reproduzida e atualizada.

3.2.4 Organizar e avaliar

Os resultados devem ser exportados para um **gerenciador de referências** (como Zotero, de código aberto, ou Mendeley e EndNote), que remove duplicatas, armazena os textos completos e formata as citações automaticamente. O Zotero se integra ao R Markdown e ao Quarto, que geram as citações deste livro a partir de um arquivo BibTeX.

Ler não é o mesmo que aceitar. Cada estudo relevante deve ser **avaliado criticamente**: qual o desenho? A amostra é representativa? Há risco de viés de seleção, de informação ou de confusão? O tamanho do efeito é clinicamente relevante e estimado com precisão? Os resultados foram relatados de forma completa? Ferramentas estruturadas ajudam nessa avaliação, como o RoB 2 para ensaios randomizados e o ROBINS-I para estudos não randomizados de intervenções. Os capítulos *Desenhos de pesquisa* e *Bioestatística inferencial* fornecem a base para essa leitura crítica.

A revisão escrita, no projeto ou no artigo, não deve ser uma lista de resumos ("Silva et al. encontraram… Souza et al. encontraram…"), mas uma síntese organizada por ideias, que mostre o que está estabelecido, o que é controverso e onde está a lacuna que o estudo pretende preencher. É essa lacuna que justifica o projeto.

3.3 Definição de objetivos

Os objetivos dizem **o que o estudo fará** para responder à pergunta. São tradicionalmente divididos em:

- **objetivo geral**: uma única frase que expressa o propósito central do estudo, diretamente ligado à pergunta de pesquisa;
- **objetivos específicos**: as etapas concretas necessárias para alcançar o objetivo geral, cada uma correspondendo a uma análise ou resultado do estudo.

Objetivos bem formulados começam com um **verbo no infinitivo** que indique uma ação verificável. Verbos como "estimar", "comparar", "avaliar a associação entre", "descrever", "identificar" e "desenvolver" indicam claramente o que será feito. Verbos como "conhecer", "compreender", "estudar" ou "analisar" isoladamente são vagos e devem vir acompanhados de complementos que os tornem precisos. Objetivos também não devem ser confundidos com a **justificativa** ("contribuir para a melhoria da saúde dos idosos" é um propósito desejável, mas não algo que o estudo fará e cujo cumprimento possa ser verificado).

Um exemplo:

- **Objetivo geral**: avaliar o efeito de um programa de treinamento aeróbico sobre a memória episódica de idosos com comprometimento cognitivo leve.
- **Objetivos específicos**:
    1. comparar a variação no escore de memória episódica entre os grupos de treinamento aeróbico e de alongamento ao final de seis meses (desfecho principal);
    2. comparar a variação na função executiva e na velocidade de processamento entre os grupos (desfechos secundários);
    3. descrever a adesão ao programa e a frequência de eventos adversos;
    4. avaliar se o efeito do treinamento sobre a memória difere segundo a presença do alelo APOE $\varepsilon 4$ (análise de subgrupo pré-especificada).

Note a correspondência com o desenho: o objetivo específico 1 define o **desfecho principal**, para o qual o estudo terá seu tamanho amostral calculado. Deve-se definir **um** desfecho principal, ou muito poucos, antes da coleta de dados. Os

desfechos secundários são exploratórios ou de apoio, e os resultados para eles devem ser interpretados com mais cautela, pois múltiplas comparações aumentam a chance de resultados positivos por acaso (capítulo *Bioestatística inferencial*).

3.4 Formulação de hipóteses

3.4.1 Hipótese de pesquisa e hipótese estatística

A **hipótese de pesquisa** (ou científica) é uma proposição sobre a relação entre variáveis, derivada da teoria ou da literatura, que o estudo testará. Por exemplo: "o treinamento aeróbico melhora a memória episódica de idosos com comprometimento cognitivo leve, por aumentar o fluxo sanguíneo hipocampal".

Nem todo estudo precisa de hipóteses. Estudos **descritivos** (estimar uma prevalência, descrever o perfil de usuários de um serviço) têm objetivos, mas não hipóteses a testar. Estudos **exploratórios**, que buscam gerar hipóteses a partir de dados, também não precisam, desde que sejam apresentados como tais. Estudos **confirmatórios**, que pretendem testar uma relação específica, precisam de hipóteses formuladas antes da coleta e da análise dos dados.

A hipótese de pesquisa é traduzida em **hipóteses estatísticas** sobre parâmetros populacionais, que podem ser testadas com os métodos do capítulo *Bioestatística inferencial*:

- **hipótese nula** (H_0): $\mu_{\text{aeróbico}} - \mu_{\text{alongamento}} = 0$, isto é, não há diferença na variação média do escore de memória entre os grupos;
- **hipótese alternativa** (H_1): $\mu_{\text{aeróbico}} - \mu_{\text{alongamento}} \neq 0$.

A tradução nem sempre é imediata, e é nela que muitos estudos se perdem. A hipótese de pesquisa fala em "melhorar a memória"; a hipótese estatística precisa especificar **qual** medida de memória, **em que momento**, **comparada a quê** e **com que parâmetro** (diferença de médias, razão de riscos). Ela também deixa claro que o teste estatístico avalia a associação entre o grupo e o desfecho, não o mecanismo proposto ("por aumentar o fluxo sanguíneo hipocampal"), que exigiria medidas e análises adicionais.

3.4.2 Características de uma boa hipótese

Uma hipótese útil deve ser:

1. **testável e falseável**: deve ser possível imaginar resultados que a contradigam (capítulo *Introdução à metodologia científica*);

2. **específica**: deve identificar as variáveis, a população e a direção esperada da relação;
3. **fundamentada**: deve derivar de teoria, de estudos anteriores ou de observações sistemáticas, e não de um palpite sem justificativa;
4. **formulada a priori**: antes da coleta e, sobretudo, antes da análise dos dados;
5. **coerente com o desenho**: uma hipótese causal exige um desenho capaz de sustentar inferências causais.

3.4.3 Estimação ou teste?

Formular o estudo apenas em termos de "rejeitar ou não a hipótese nula" empobrece a pergunta. Em muitas situações, o que interessa não é **se** há uma diferença, mas **quanto** ela vale e com que precisão é estimada. Por isso, é cada vez mais comum, e recomendável, formular os objetivos em termos de **estimação**: "estimar a diferença média no escore de memória entre os grupos, com intervalo de confiança de 95%". O tamanho amostral, nesse caso, pode ser calculado para obter uma precisão desejada (uma largura máxima do intervalo), e não apenas um poder desejado. Quando um teste é necessário, deve-se especificar também a **diferença mínima clinicamente relevante**, que é a base do cálculo do tamanho amostral.

3.4.4 HARKing e registro prévio

HARKing (*Hypothesizing After the Results are Known*, formular hipóteses depois de conhecer os resultados) é a prática de apresentar como hipótese prévia o que, na verdade, foi sugerido pelos dados (Kerr 1998). Se um pesquisador analisa vinte associações, encontra uma estatisticamente significativa e escreve o artigo como se essa tivesse sido a hipótese desde o início, o valor p relatado perde o sentido: a probabilidade de encontrar ao menos um resultado significativo em vinte testes, mesmo sem nenhum efeito real, é alta.

Explorar os dados não é errado; apresentar exploração como confirmação é. A proteção mais eficaz é o **registro prévio** (*preregistration*): a publicação, antes da coleta ou da análise dos dados, das hipóteses, do desfecho principal e do plano de análise, em uma plataforma pública com data registrada (Nosek et al. 2018). Para ensaios clínicos, o registro prévio é exigido pela legislação e pelos principais periódicos (capítulo *Desenhos de pesquisa*). Para outros estudos, há plataformas como o OSF (*Open Science Framework*). O registro não impede análises não planejadas; ele permite que o leitor distinga o que foi planejado do que foi descoberto ao longo do caminho.

3.5 Resumo do capítulo

- Distinga tema, problema e pergunta de pesquisa. Projetos respondem a perguntas, não a temas.
- Avalie a pergunta pelos critérios FINER (factível, interessante, nova, ética, relevante) e estruture-a com PICO ou formatos equivalentes.
- A revisão da literatura mostra o que se sabe e onde está a lacuna. Busque em várias bases (incluindo LILACS e SciELO), combine vocabulário controlado (MeSH, DeCS) e termos livres com operadores booleanos, registre a estratégia e avalie criticamente os estudos.
- Objetivos começam com verbos que indicam ações verificáveis. Defina um desfecho principal antes da coleta.
- Hipóteses de pesquisa devem ser testáveis, específicas, fundamentadas e formuladas a priori; sua tradução em hipóteses estatísticas exige especificar medida, momento, comparação e parâmetro.
- Prefira formular objetivos em termos de estimação, com a diferença clinicamente relevante explícita.
- Não apresente hipóteses sugeridas pelos dados como hipóteses prévias (HARKing). O registro prévio permite distinguir confirmação de exploração.

3.6 Exercícios

1. Transforme o tema “diabetes gestacional” em um problema de pesquisa e em uma pergunta estruturada no formato PICO ou PECO.

2. Avalie a seguinte pergunta pelos critérios FINER: “a vacina X reduz a mortalidade por todas as causas em adultos jovens saudáveis?”, considerando que a mortalidade nessa população é de cerca de 1 por 1.000 por ano.

3. Construa uma estratégia de busca para o PubMed para a pergunta: “em adultos com lombalgia crônica, a acupuntura reduz a dor, comparada à acupuntura simulada?”.

4. Reescreva os objetivos a seguir de forma verificável: (a) “conhecer a saúde mental dos estudantes de medicina”; (b) “contribuir para a redução das infecções hospitalares”.

5. Para a hipótese de pesquisa “o consumo de ultraprocessados está associado a maior risco de depressão em adultos”, escreva as hipóteses estatísticas correspondentes, especificando o parâmetro.

6. Um pesquisador coletou dados de 40 variáveis em 300 pacientes e encontrou associação estatisticamente significativa entre o grupo sanguíneo e o

tempo de internação por COVID-19. No artigo, apresentou essa associação como a hipótese principal do estudo. Qual o problema e como ele deveria ter relatado o achado?

3.7 Respostas dos exercícios

1. Um problema possível: "não está claro se o rastreamento universal do diabetes gestacional com o teste oral de tolerância à glicose, comparado ao rastreamento baseado em fatores de risco, reduz desfechos perinatais adversos no contexto da atenção primária brasileira". Pergunta (PICO): em gestantes atendidas na atenção primária (P), o rastreamento universal com TOTG de 75 g entre 24 e 28 semanas (I), comparado ao rastreamento baseado em fatores de risco (C), reduz a incidência de macrossomia fetal (O)?

2. Factibilidade é o principal problema: com mortalidade de 1 por 1.000 por ano, detectar uma redução relativa de, digamos, 20% exigiria centenas de milhares de participantes acompanhados por anos. A pergunta pode ser interessante e relevante, e ser ética se a vacina tiver perfil de segurança conhecido, mas provavelmente não é factível como ensaio clínico; desfechos mais frequentes (infecção específica, hospitalização) seriam alternativas.

3. Uma possibilidade:

```
("Low Back Pain"[MeSH] OR "low back pain"[tiab] OR "lumbago"[tiab]
 ↪ OR "lumbar pain"[tiab])
AND ("Chronic Pain"[MeSH] OR chronic[tiab])
AND ("Acupuncture Therapy"[MeSH] OR acupunctur*[tiab])
AND (sham[tiab] OR placebo[tiab] OR "Placebos"[MeSH])
```

   A estratégia deveria ser complementada com buscas em outras bases (Embase, LILACS, Cochrane Library) e registrada com a data.

4. (a) "Estimar a prevalência de sintomas depressivos e ansiosos, medidos pelas escalas PHQ-9 e GAD-7, em estudantes de medicina de uma universidade pública, e comparar as prevalências entre os ciclos básico, clínico e internato." (b) "Avaliar se a implementação de um protocolo de higiene das mãos com auditoria e retorno mensal está associada à redução da taxa de infecção de corrente sanguínea associada a cateter, por 1.000 cateteres-dia, em unidades de terapia intensiva." O texto original de (b) expressa um propósito, adequado à justificativa, não um objetivo.

5. Por exemplo, em uma coorte, com o consumo dicotomizado (alto versus baixo) e o desfecho incidência de depressão em cinco anos: H_0: RR $= 1$; H_1: RR $\neq 1$, em que RR é o risco relativo de depressão entre adultos com

alto e baixo consumo. Com o consumo como variável contínua (percentual da energia proveniente de ultraprocessados) e um modelo de regressão, $H_0 \colon \beta = 0$, em que β é o logaritmo da razão de riscos por aumento de 10 pontos percentuais no consumo. Em ambos os casos, o protocolo deveria especificar o ajuste para confundidores.

6. É HARKing: com 40 variáveis testadas, a probabilidade de ao menos uma associação significativa por acaso é alta, e apresentá-la como hipótese principal torna o valor p enganoso. O achado deveria ser relatado como exploratório, informando quantas associações foram examinadas, de preferência com ajuste para comparações múltiplas, e com a recomendação de que seja testado em um estudo independente, com hipótese registrada previamente.

Capítulo 4

Desenhos de pesquisa

Hércules Rezende Freitas, Ph.D.[1]

[1]Universidade do Estado do Rio de Janeiro (UERJ), Faculdade de Ciências Médicas, Departamento de Ciências Médicas Integradas, Laboratório de Informática em Saúde (LabInfoS), Cabo Frio/RJ, Brasil.

O desenho de um estudo é o plano que define quem será estudado, o que será medido, quando e como. Ele determina, mais do que qualquer análise estatística, o que o estudo é capaz de responder. Nenhum método de análise, por mais sofisticado, recupera a informação que o desenho não coletou, nem corrige os vieses que o desenho introduziu. Por isso, os capítulos de bioestatística deste livro supõem, repetidamente, que os dados vieram de um estudo bem desenhado, e é deste capítulo que essa suposição depende.

O capítulo começa pelas ferramentas comuns a todos os desenhos: as medidas de frequência e de associação, e as três ameaças à validade de um estudo (erro aleatório, viés e confusão). Em seguida, apresenta os principais desenhos observacionais (transversal, coorte e caso-controle), os ensaios clínicos randomizados e, por fim, os princípios do desenho de experimentos de laboratório.

4.1 Da pergunta ao desenho

4.1.1 A pergunta de pesquisa

Todo desenho começa por uma pergunta bem formulada. Em pesquisa clínica, um formato útil é o acrônimo **PICO** (ou PECO, em estudos observacionais):

- **P**opulação: quem são os participantes (por exemplo, adultos com hipertensão estágio 1 atendidos na atenção primária);
- **I**ntervenção ou **E**xposição: o que se quer avaliar (um anti-hipertensivo, o consumo de sódio);

- **C**omparador: em relação a quê (placebo, outro tratamento, ausência de exposição);
- **O** (*outcome*), desfecho: o que será medido e quando (pressão arterial em 12 semanas, acidente vascular cerebral em cinco anos).

A pergunta também define o **tipo** de resposta buscada. Perguntas **descritivas** querem saber como algo é ou quanto há (qual a prevalência de hipertensão em adultos de Cabo Frio?). Perguntas **analíticas** ou **causais** querem saber se uma exposição altera um desfecho (o consumo de sódio aumenta a pressão arterial?). Perguntas **preditivas** querem estimar o risco de um indivíduo (qual a chance de este paciente ter um AVC em cinco anos?). Os desenhos e as análises adequados a cada tipo são diferentes, e muitos problemas na literatura surgem de estudos que não deixam claro qual pergunta estão respondendo. A formulação de problemas e hipóteses é tratada em detalhe no capítulo *Formulação de problemas e hipóteses*.

4.1.2 Uma classificação dos desenhos

A primeira distinção é entre estudos **observacionais** e **experimentais**. Nos observacionais, o pesquisador observa as exposições como elas ocorrem, sem interferir: as pessoas fumam ou não por razões próprias. Nos experimentais, o pesquisador **atribui** a exposição: decide quem recebe o tratamento. Quando a atribuição é feita por sorteio, o estudo é **randomizado**. A Figura 4.1 organiza os desenhos tratados neste capítulo.

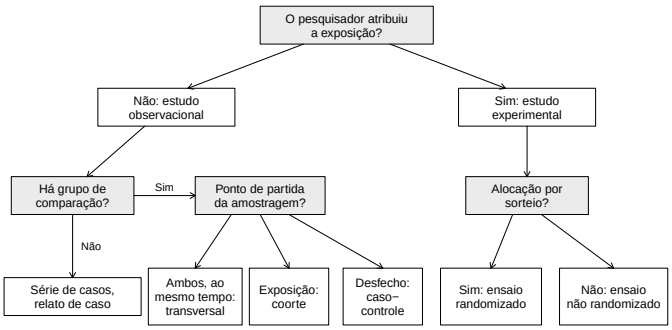


Figura 4.1: Classificação dos principais desenhos de estudo segundo a atribuição da exposição e a existência de grupo de comparação.

É comum apresentar os desenhos em uma "pirâmide de evidências", com relatos de caso na base e revisões sistemáticas de ensaios randomizados no topo. A pirâmide é uma simplificação útil, mas enganosa se tomada ao pé da letra.

O desenho mais adequado depende da pergunta: para estimar a prevalência de uma doença, um estudo transversal com amostra representativa é o desenho correto, e um ensaio clínico não faria sentido; para estudar efeitos adversos raros e tardios, coortes grandes ou estudos caso-controle são frequentemente a única opção viável. E um ensaio randomizado mal conduzido pode fornecer evidência mais fraca que uma coorte bem conduzida. A qualidade da execução importa tanto quanto o rótulo do desenho.

4.2 Medidas de frequência e de associação

4.2.1 Prevalência e incidência

As duas medidas fundamentais de frequência de doença respondem a perguntas diferentes.

A **prevalência** é a proporção de pessoas que **têm** a condição em um momento:

$$\text{Prevalência} = \frac{\text{número de pessoas com a condição em um momento}}{\text{número de pessoas na população nesse momento}}.$$

É uma medida de **carga**: informa quanto da população está afetado e é útil para o planejamento de serviços. Mas mistura duas coisas: quantos casos surgem e quanto tempo eles duram. Uma doença crônica e pouco letal acumula casos e tem prevalência alta, mesmo que surjam poucos casos novos por ano. Aproximadamente, em uma população estável, prevalência $\approx$ incidência $\times$ duração média.

A **incidência** mede o surgimento de **casos novos** em pessoas que estavam livres da condição. Há duas formas principais:

- **incidência cumulativa** (ou **risco**): proporção de pessoas inicialmente sem a doença que a desenvolvem em um período definido. Exige que todos sejam acompanhados durante todo o período e precisa sempre vir acompanhada desse período ("risco de 4% em cinco anos"; um risco sem período não tem significado);
- **taxa de incidência** (ou densidade de incidência): número de casos novos dividido pela soma dos tempos em que cada pessoa esteve em risco (a **pessoa-tempo**). Se 10 casos ocorrem em 2.000 pessoas-ano de acompanhamento, a taxa é de 5 por 1.000 pessoas-ano. A taxa acomoda acompanhamentos de durações diferentes, comuns em coortes reais.

4.2.2 Medidas de associação em tabelas 2 $\times$ 2

Para comparar a frequência do desfecho entre expostos e não expostos, os dados são organizados em uma tabela 2 $\times$ 2 com a notação da Tabela 4.1.

Tabela 4.1: Notação da tabela 2 × 2.

	Com o desfecho	Sem o desfecho	Total
Expostos	a	b	$a+b$
Não expostos	c	d	$c+d$

O risco nos expostos é $R_1 = a/(a+b)$ e nos não expostos, $R_0 = c/(c+d)$. A partir deles:

- **Risco relativo** (RR), ou razão de riscos: $\text{RR} = R_1/R_0$. Indica quantas vezes o risco é maior nos expostos. $\text{RR} = 1$ indica ausência de associação; $\text{RR} > 1$, associação positiva; $\text{RR} < 1$, associação negativa (exposição "protetora").
- **Diferença de riscos** (DR), ou risco atribuível: $\text{DR} = R_1 - R_0$. Indica o excesso **absoluto** de risco associado à exposição. Seu inverso, $1/|\text{DR}|$, é o **número necessário para tratar** (NNT), quando a exposição é um tratamento benéfico, ou o **número necessário para causar dano** (NNH), quando a exposição é prejudicial.
- **Razão de chances** (RC, ou *odds ratio*, OR): a **chance** (*odds*) de um evento é a razão entre a probabilidade de ele ocorrer e a de não ocorrer, $p/(1-p)$. A razão de chances compara as chances do desfecho nos dois grupos: $\text{OR} = \frac{a/b}{c/d} = \frac{ad}{bc}$.

Exemplo. Em uma coorte de 5.000 adultos acompanhados por cinco anos, 2.000 eram fumantes, dos quais 80 desenvolveram a doença; dos 3.000 não fumantes, 30 a desenvolveram (dados fictícios).

```
a <- 80; b <- 2000 - 80; c_ <- 30; d <- 3000 - 30
r1 <- a / (a + b); r0 <- c_ / (c_ + d)
c(risco_expostos = r1, risco_nao_expostos = r0,
  RR = r1 / r0, DR = r1 - r0, NNH = 1 / (r1 - r0), OR = (a * d) / (b *
  ↪ c_))
```

```
##     risco_expostos risco_nao_expostos                RR
##            0.04000            0.01000           4.00000
##                 DR                NNH                OR
##            0.03000           33.33333           4.12500
```

O risco em cinco anos foi de 4% nos fumantes e de 1% nos não fumantes: RR = 4, DR = 3 pontos percentuais e NNH ≈ 33 (para cada 33 fumantes acompanhados por cinco anos, ocorre um caso a mais do que ocorreria se não fumassem, supondo que a associação seja causal). A razão de chances foi de 4,1, próxima do RR porque o desfecho é raro.

Medidas relativas e absolutas se complementam. Um RR de 4 parece impressionante, mas seu impacto depende do risco basal: quadruplicar um risco de 1 em 100.000 produz poucos casos; quadruplicar um risco de 10% produz muitos. Para decisões clínicas e de saúde pública, a diferença de riscos (ou o NNT/NNH) é frequentemente mais informativa, e as diretrizes de relato recomendam apresentar as duas.

A razão de chances não é o risco relativo. Quando o desfecho é raro (risco abaixo de cerca de 10% em ambos os grupos), a OR aproxima o RR. Quando o desfecho é comum, a OR se afasta de 1 mais do que o RR e não deve ser interpretada como "quantas vezes o risco é maior". A OR é a medida natural dos estudos caso-controle e da regressão logística, o que explica sua presença frequente na literatura. Os intervalos de confiança dessas medidas são apresentados no capítulo *Aplicações práticas e estudos de caso*.

4.3 Validade: erro aleatório, viés e confusão

Uma estimativa obtida em um estudo pode se afastar do valor verdadeiro por três motivos, e o desenho existe para minimizá-los.

4.3.1 Erro aleatório

O **erro aleatório** é a variação que ocorre por acaso, porque estudamos uma amostra e não a população inteira. Ele afeta a **precisão** da estimativa, não sua direção: estudos repetidos erram para mais e para menos, e na média acertam. É reduzido aumentando o tamanho da amostra ou a precisão das medidas, e é quantificado pelos intervalos de confiança e testes de hipóteses do capítulo *Bioestatística inferencial*.

4.3.2 Viés

O **viés** (ou erro sistemático) é um desvio que empurra a estimativa sempre na mesma direção. Ao contrário do erro aleatório, **não diminui com o aumento da amostra**: um estudo enviesado com 100.000 participantes produz uma estimativa errada com grande precisão. Os vieses são classificados em dois grandes grupos.

Viés de seleção ocorre quando a forma como os participantes entram no estudo (ou permanecem nele) está relacionada tanto à exposição quanto ao desfecho. Exemplos:

- em um estudo caso-controle hospitalar, os controles são escolhidos entre pacientes internados por outras doenças; se essas doenças forem associadas

à exposição estudada (o tabagismo, por exemplo, causa muitas doenças que levam à internação), a frequência de exposição nos controles não representa a da população de origem dos casos;
- em uma coorte, as **perdas de seguimento** são mais frequentes entre os expostos que adoecem (pacientes que pioram deixam de comparecer);
- o **efeito do trabalhador sadio**: trabalhadores de uma indústria têm, em geral, mortalidade menor que a da população geral, porque pessoas doentes têm menos chance de estar empregadas, o que pode mascarar efeitos nocivos de exposições ocupacionais.

Viés de informação (ou de aferição, ou de classificação) ocorre quando a exposição ou o desfecho são medidos com erro. A classificação errada pode ser:

- **não diferencial**, quando o erro de medida da exposição é igual em quem tem e quem não tem o desfecho (ou o erro de medida do desfecho é igual entre expostos e não expostos). Para exposições binárias, ela em geral **atenua** a associação, puxando-a em direção à nulidade;
- **diferencial**, quando o erro difere entre os grupos. Pode distorcer a associação em qualquer direção. O exemplo clássico é o **viés de memória** em estudos caso-controle: mães de crianças com malformações tendem a recordar com mais detalhe as exposições durante a gestação do que mães de crianças saudáveis.

O exemplo a seguir mostra o efeito da classificação errada não diferencial. Suponha que a OR verdadeira seja 3 (50% dos casos e 25% dos controles são expostos) e que a exposição seja medida com sensibilidade de 80% e especificidade de 90%, iguais em casos e controles:

```
exposicao_observada <- function(p, sens = 0.80, espec = 0.90) p * sens +
 ↪  (1 - p) * (1 - espec)
odds <- function(p) p / (1 - p)
p_casos <- exposicao_observada(0.50); p_controles <-
 ↪  exposicao_observada(0.25)
c(OR_verdadeira = odds(0.50) / odds(0.25), OR_observada = odds(p_casos) /
 ↪  odds(p_controles))
```

```
## OR_verdadeira  OR_observada
##      3.000000      2.157025
```

A OR observada cai de 3,0 para 2,2. Um questionário impreciso, aplicado igualmente a todos, faz a associação parecer mais fraca do que é. Esse resultado não autoriza, porém, concluir que uma associação observada em um estudo com classificação errada seja "certamente subestimada": a regra vale em média, não necessariamente em um estudo específico, e não vale para exposições com mais de duas categorias ou quando os erros são correlacionados.

Tabela 4.2: Consumo de café e infarto, estratificado por tabagismo (dados fictícios). O risco relativo bruto (2,33) desaparece dentro de cada estrato.

Estrato	Café	Infartos	Total	Risco (%)	RR
Fumantes	Sim	40	400	10,0	1,0
Fumantes	Não	10	100	10,0	
Não fumantes	Sim	2	100	2,0	1,0
Não fumantes	Não	8	400	2,0	
Todos (bruto)	Sim	42	500	8,4	2,33
Todos (bruto)	Não	18	500	3,6	

Sackett (1979) catalogou dezenas de vieses específicos. Mais útil que memorizar nomes é perguntar, diante de qualquer estudo: como os participantes foram selecionados, e isso pode estar relacionado à exposição e ao desfecho? Como a exposição e o desfecho foram medidos, e o erro de medida pode diferir entre os grupos?

4.3.3 Confusão

A **confusão** ocorre quando a associação entre exposição e desfecho é distorcida por um terceiro fator que está associado à exposição e é causa (ou marcador de uma causa) do desfecho, sem estar no caminho causal entre eles. O exemplo da Tabela 4.2 mostra um caso extremo: o consumo de café parece aumentar o risco de infarto, mas, dentro de cada categoria de tabagismo, não há associação alguma.

O RR bruto é $(42/500)/(18/500) = 2{,}33$, mas, entre os fumantes, o risco é de 10% com ou sem café, e entre os não fumantes, de 2% com ou sem café. A associação bruta é inteiramente produzida pelo tabagismo: fumantes bebem mais café (400 de 500 fumantes bebem café, contra 100 de 500 não fumantes) e têm mais infartos. O tabagismo é um **fator de confusão**.

Diagramas causais. A forma mais clara de raciocinar sobre confusão é com **diagramas causais acíclicos dirigidos** (DAGs, do inglês *directed acyclic graphs*) (Greenland et al. 1999), em que setas representam relações causais supostas. A Figura 4.2 mostra os três papéis que uma terceira variável Z pode ter na relação entre uma exposição E e um desfecho D.

Os diagramas tornam explícitas três lições. Primeira: a confusão é um conceito **causal**, não estatístico; nenhum teste nos dados decide se uma variável é um confundidor, e a decisão depende do conhecimento sobre o problema. Segunda: ajustar para todas as variáveis disponíveis não é uma estratégia segura, porque ajustar para um mediador remove parte do efeito de interesse e ajustar para um colisor cria associações espúrias. Terceira: só se pode ajustar para o que foi

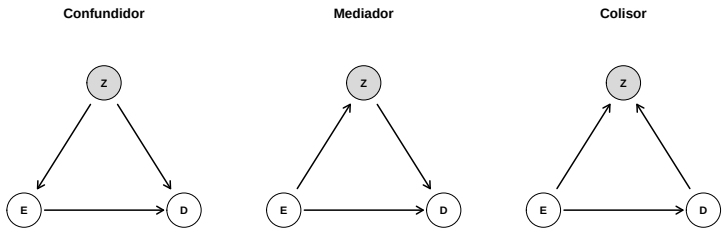


Figura 4.2: Três papéis de uma terceira variável Z na relação entre exposição (E) e desfecho (D). Confundidor: causa comum de E e D; deve ser ajustado. Mediador: está no caminho causal de E para D; ajustar remove parte do efeito que se quer estimar. Colisor: efeito comum de E e D; ajustar (ou selecionar a amostra com base nele) cria uma associação espúria.

medido; a **confusão residual** por fatores não medidos é a principal limitação dos estudos observacionais.

A confusão pode ser controlada no **desenho** (restrição, pareamento, randomização) ou na **análise** (estratificação, regressão múltipla, como no capítulo *Análise de dados*, escores de propensão). Apenas a randomização controla também os confundidores não medidos.

4.3.4 Da associação à causalidade

Uma associação que sobreviveu ao exame do acaso, do viés e da confusão ainda não é, automaticamente, causal. Em 1965, Austin Bradford Hill (1965) propôs nove aspectos a considerar ao julgar se uma associação observada é causal: força da associação, consistência entre estudos, especificidade, temporalidade (a causa deve preceder o efeito), gradiente biológico (relação dose-resposta), plausibilidade, coerência com o conhecimento existente, evidência experimental e analogia. O próprio Hill advertiu que nenhum deles, exceto a temporalidade, é necessário ou suficiente; eles não são uma lista de verificação, mas um roteiro para o julgamento.

4.4 Estudos observacionais

4.4.1 Estudos transversais

No estudo **transversal** (ou de prevalência, ou seccional), exposição e desfecho são medidos **ao mesmo tempo**, em um único momento, em uma amostra da

população. É como uma fotografia da população. Inquéritos de saúde nacionais, como a Pesquisa Nacional de Saúde e o Vigitel, são exemplos.

Usos. O desenho transversal é o adequado para estimar a **prevalência** de doenças, fatores de risco, comportamentos e uso de serviços, e para gerar hipóteses. Quando a amostra é probabilística, permite generalizar para a população.

Medida de associação. Calcula-se a **razão de prevalências** (RP), análoga ao RR, ou a razão de chances de prevalência. Quando o desfecho é frequente, a RP é preferível, pela razão discutida na seção anterior.

Limitações. A principal é a **ambiguidade temporal**: como exposição e desfecho são medidos juntos, não se sabe qual veio antes. Em um estudo transversal que encontra associação entre depressão e sedentarismo, não é possível distinguir se o sedentarismo aumenta o risco de depressão ou se a depressão leva ao sedentarismo (**causalidade reversa**). Outro problema decorre de o estudo medir casos prevalentes: ele sobrerrepresenta os casos de longa duração: se a exposição prolongar a sobrevida dos doentes, ela parecerá associada à doença mesmo sem aumentar sua ocorrência (**viés de prevalência**, ou de Neyman). Estudos transversais não são adequados para doenças de curta duração ou muito raras.

Amostragem. Como o objetivo frequentemente é estimar prevalências populacionais, a forma de amostragem é decisiva. Amostras de conveniência (os pacientes de um ambulatório, os voluntários de uma campanha) podem fornecer estimativas muito diferentes das da população. Inquéritos populacionais usam amostragens complexas (por conglomerados, estratificadas, com probabilidades desiguais de seleção), que exigem métodos de análise que incorporem o desenho amostral (pesos e estrutura de conglomerados); analisar esses dados como se fossem uma amostra aleatória simples produz erros padrão incorretos.

4.4.2 Estudos de coorte

No estudo de **coorte**, um grupo de pessoas livres do desfecho é classificado segundo a exposição e **acompanhado ao longo do tempo** para observar a ocorrência de casos novos. O termo vem das unidades do exército romano, que marchavam juntas. O estudo de Framingham, iniciado em 1948 nos Estados Unidos, é o exemplo clássico: identificou a hipertensão, o colesterol e o tabagismo como fatores de risco para doença cardiovascular.

Prospectivas e retrospectivas. Na coorte **prospectiva** (ou concorrente), os participantes são recrutados no presente e acompanhados para o futuro. Na coorte **retrospectiva** (ou histórica), exposição e desfecho já ocorreram e são reconstituídos a partir de registros existentes (prontuários, bases administrativas, registros ocupacionais). O que define as duas como coortes é a **lógica**, idêntica em ambas: parte-se da exposição e observa-se o desfecho que ocorre depois. A diferença está apenas no momento em que o pesquisador inicia o estudo

em relação aos eventos. Coortes retrospectivas a partir de grandes bases de dados (como o DATASUS e outros sistemas de informação em saúde) tornaram-se muito frequentes, e trazem os problemas próprios de dados coletados para outros fins: variáveis ausentes, erros de codificação, mudanças de definição ao longo do tempo.

Vantagens.

- A **temporalidade** é clara: a exposição é medida antes do desfecho.
- Permite calcular diretamente **incidências**, riscos relativos e diferenças de riscos.
- Permite estudar **múltiplos desfechos** de uma mesma exposição.
- É o desenho adequado para exposições **raras**, porque o pesquisador pode selecionar deliberadamente um grupo exposto (trabalhadores de uma indústria específica, por exemplo).
- Na coorte prospectiva, a exposição é medida antes do desfecho, o que evita o viés de memória.

Limitações.

- Coortes prospectivas são **caras e demoradas**, especialmente para desfechos que levam anos para ocorrer.
- São ineficientes para **desfechos raros**: para observar dezenas de casos de uma doença com incidência de 1 por 10.000 por ano, seria preciso acompanhar centenas de milhares de pessoas.
- As **perdas de seguimento** podem introduzir viés de seleção, se forem relacionadas à exposição e ao desfecho.
- Por serem observacionais, estão sujeitas à **confusão**.

Dois cuidados de desenho em coortes. Em estudos de efeitos de medicamentos com bases de dados, dois erros de desenho são tão frequentes quanto graves. O primeiro é o **viés do tempo imortal**: quando os pacientes são classificados como "tratados" com base em um uso que ocorreu depois do início do acompanhamento, o período entre o início e o primeiro uso é contado como tempo dos tratados, que obrigatoriamente sobreviveram até receber o tratamento. Isso produz um benefício aparente do tratamento que não existe. O segundo é a inclusão de **usuários prevalentes** (pacientes que já usavam o medicamento havia anos, e que são, portanto, os que o toleraram e sobreviveram), em vez de **novos usuários**. A abordagem de **emulação de um ensaio-alvo** (*target trial emulation*) (Hernán and Robins 2016) evita esses erros ao especificar explicitamente o ensaio randomizado que se gostaria de realizar (critérios de elegibilidade, estratégias de tratamento, início do acompanhamento, desfechos) e desenhar o estudo observacional para imitá-lo, alinhando no tempo zero a elegibilidade, a atribuição do tratamento e o início do acompanhamento.

4.4.3 Estudos de caso-controle

No estudo **caso-controle**, o ponto de partida é o **desfecho**. Selecionam-se pessoas com a doença (**casos**) e pessoas sem a doença (**controles**), e compara-se a frequência de exposição passada nos dois grupos. O estudo clássico de Doll e Hill (1950), que comparou o hábito de fumar entre pacientes com câncer de pulmão e pacientes com outras doenças em hospitais de Londres, é um dos marcos do desenho.

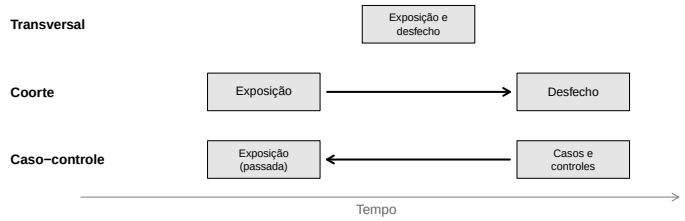


Figura 4.3: Direção da investigação nos três desenhos observacionais. No transversal, exposição e desfecho são medidos no mesmo momento; na coorte, parte-se da exposição e acompanha-se até o desfecho; no caso-controle, parte-se do desfecho e investiga-se a exposição passada.

Por que a razão de chances. Em um estudo caso-controle, o pesquisador decide quantos casos e quantos controles incluir (por exemplo, dois controles para cada caso). Por isso, a proporção de doentes na amostra é artificial, e os riscos não podem ser calculados: um "risco" de 33% refletiria apenas a escolha de dois controles por caso. A razão de chances, porém, tem uma propriedade notável: a OR da exposição entre casos e controles é igual à OR do desfecho entre expostos e não expostos. Assim, o estudo caso-controle estima a OR da população. Quando a doença é rara, essa OR aproxima o RR. Quando os controles são amostrados entre as pessoas em risco no momento em que cada caso ocorre (**amostragem por densidade de incidência**), a OR estima diretamente a razão de taxas de incidência, sem necessidade da suposição de doença rara.

Exemplo. Em 200 casos de uma doença, 120 relataram a exposição; em 400 controles, 120 relataram a exposição. Então $\text{OR} = (120 \times 280)/(80 \times 120) = 3{,}5$: a chance de exposição entre os casos foi 3,5 vezes a dos controles.

Vantagens.

- É **eficiente para doenças raras** e para doenças com longo período de latência, porque parte de casos já ocorridos.
- É relativamente **rápido e barato**.

- Permite estudar **múltiplas exposições** para um mesmo desfecho.

Limitações.

- A **seleção dos controles** é o ponto mais delicado. Os controles devem representar a distribuição da exposição na **população de origem dos casos**, isto é, devem ser pessoas que, se tivessem desenvolvido a doença, teriam sido incluídas como casos. Controles hospitalares, convenientes, podem ter exposições diferentes da população por causa das doenças que os levaram ao hospital.
- A informação sobre a exposição, colhida depois do desfecho, está sujeita ao **viés de memória** e ao viés do entrevistador (quando quem coleta os dados sabe quem é caso).
- Não permite calcular incidências (exceto em situações especiais, como os estudos aninhados em coortes) e é ineficiente para exposições raras.

Pareamento. É comum selecionar controles **pareados** aos casos por fatores como idade e sexo, para garantir que os grupos sejam comparáveis nesses fatores. O pareamento em estudos caso-controle tem uma consequência frequentemente esquecida: ele introduz, por si só, um viés de seleção em direção à nulidade, que só é removido se a análise levar o pareamento em conta (por exemplo, com regressão logística condicional). Também não é possível estudar o efeito das variáveis usadas no pareamento, e parear por um fator que não é confundidor (o **sobrepareamento**) reduz a eficiência do estudo.

Caso-controle aninhado. Quando casos e controles são selecionados dentro de uma coorte já existente, o desenho combina vantagens dos dois: a exposição foi registrada antes do desfecho (sem viés de memória) e os custos de medidas caras (como análises de amostras biológicas armazenadas) se restringem a uma fração da coorte.

4.4.4 Outros desenhos observacionais

- **Relatos e séries de casos** descrevem um ou mais pacientes com uma condição. Não têm grupo de comparação e, portanto, não permitem avaliar associações, mas são fundamentais para identificar doenças novas e efeitos adversos inesperados (a epidemia de aids e a embriopatia da talidomida foram reconhecidas por séries de casos).
- **Estudos ecológicos** usam grupos (municípios, países, períodos), e não indivíduos, como unidade de análise. São úteis para avaliar efeitos de políticas e exposições de nível populacional, mas a associação observada entre grupos não pode ser transferida para indivíduos (a **falácia ecológica**, discutida no capítulo *Análise de dados*).

Para o relato de estudos observacionais, a diretriz **STROBE** (von Elm et al. 2007) especifica os itens que um artigo deve conter.

4.5 Ensaios clínicos

4.5.1 Ensaios randomizados controlados

No **ensaio clínico randomizado** (ECR), os participantes elegíveis são **alocados por sorteio** para receber a intervenção em estudo ou um comparador (placebo, tratamento padrão, nenhuma intervenção), e os grupos são acompanhados para comparar os desfechos. É o desenho de referência para avaliar a eficácia de intervenções.

4.5.1.1 Por que randomizar

A randomização resolve o problema central dos estudos observacionais. Quando o médico ou o paciente escolhe o tratamento, a escolha depende de características (gravidade, prognóstico, preferências, acesso) que também afetam o desfecho: é a **confusão por indicação**. Quando a alocação é feita por sorteio, ela não pode depender de nenhuma característica do paciente, medida ou não. Em consequência:

1. os grupos tendem a ser **comparáveis em todos os fatores prognósticos**, inclusive os desconhecidos e os não medidos. Essa é a propriedade que nenhum ajuste estatístico em um estudo observacional consegue reproduzir;
2. as diferenças que restam entre os grupos no início do estudo são **aleatórias**, e é exatamente esse tipo de erro que os testes de hipóteses e os intervalos de confiança quantificam. A randomização fornece a base lógica da inferência estatística no ensaio.

A randomização garante comparabilidade **em média**, não em cada ensaio. Em ensaios pequenos, desequilíbrios por acaso em fatores importantes são esperados. A simulação a seguir mostra a diferença, entre os dois braços, na proporção de pacientes com um fator prognóstico presente em 40% da população, em 1.000 ensaios simulados de cada tamanho:

```
set.seed(1)
desequilibrio <- function(n_por_braco) {
  replicate(1000, {
    fator <- rbinom(2 * n_por_braco, 1, 0.4)
    braco <- sample(rep(c("A", "B"), n_por_braco))
    abs(mean(fator[braco == "A"]) - mean(fator[braco == "B"]))
  })
}
p90 <- sapply(c(n_10 = 10, n_50 = 50, n_500 = 500),
              function(n) quantile(desequilibrio(n), 0.9))
round(p90, 3)
```

```
##  n_10.90%  n_50.90% n_500.90%
##     0.400     0.160     0.052
```

Com 10 pacientes por braço, em 10% dos ensaios a diferença na proporção do fator chega a 40 pontos percentuais ou mais; com 50 por braço, a 16 pontos; com 500 por braço, apenas 10% dos ensaios têm diferença acima de 5 pontos. Por isso, testar estatisticamente a diferença entre os grupos nas características iniciais ("Tabela 1" com valores p) não faz sentido em um ensaio randomizado: se a randomização foi bem feita, qualquer diferença é, por definição, aleatória. O que importa é se a diferença é grande o suficiente para afetar o desfecho, e isso se avalia pela magnitude, não pelo valor p. Fatores prognósticos importantes devem ser considerados no desenho (estratificação) e na análise (ajuste pré-especificado).

4.5.1.2 Como randomizar

- **Randomização simples**: cada participante é alocado por um sorteio independente, como o lançamento de uma moeda. Em ensaios pequenos, pode produzir grupos de tamanhos bem diferentes.
- **Randomização em blocos**: os participantes são alocados em blocos (por exemplo, de 4), dentro dos quais há o mesmo número de cada tratamento (AABB, ABAB, BAAB…). Garante grupos de tamanhos semelhantes ao longo de todo o recrutamento. Blocos de tamanho fixo e conhecido permitem prever as últimas alocações de cada bloco; por isso, usam-se blocos de tamanhos variáveis e não revelados.
- **Randomização estratificada**: realiza-se uma randomização em blocos separada dentro de cada estrato de um fator prognóstico importante (por exemplo, centro participante, ou gravidade), garantindo equilíbrio nesse fator.
- **Minimização**: alocação dinâmica que, a cada novo participante, favorece o braço que minimiza o desequilíbrio em vários fatores ao mesmo tempo.

```r
set.seed(2026)
# Randomização em blocos de tamanho 4 ou 6, sorteados, para 20
 ↪  participantes
lista <- character(0)
while (length(lista) < 20) {
  tamanho <- sample(c(4, 6), 1)
  lista <- c(lista, sample(rep(c("A", "B"), tamanho / 2)))
}
lista <- lista[1:20]
lista
```

```
##  [1] "A" "B" "B" "A" "A" "A" "B" "B" "B" "A" "A" "A" "B" "B" "B" "B"
## [17] "A" "B" "A" "A"
```

```r
table(lista)
```

```
## lista
##  A  B
## 10 10
```

Como o último bloco foi cortado para completar 20 participantes, os grupos podem diferir em algumas pessoas (até três, com blocos de seis); em ensaios reais, a lista é gerada com folga e não é truncada antes de o recrutamento terminar.

4.5.1.3 Ocultação da alocação

Gerar uma sequência aleatória não basta. Se quem recruta os pacientes puder conhecer a próxima alocação (por exemplo, porque a lista está afixada na parede ou porque os envelopes são transparentes), ele pode, consciente ou inconscientemente, decidir quem entra no estudo de acordo com o tratamento que receberá, destruindo a randomização. A **ocultação da alocação** (*allocation concealment*) garante que a próxima alocação só seja revelada depois que o participante foi irreversivelmente incluído. Usam-se sistemas centralizados (por telefone ou internet) ou envelopes opacos, selados e numerados sequencialmente. Schulz e colaboradores (Schulz et al. 1995) mostraram que, em comparação com ensaios com ocultação adequada, os ensaios com ocultação pouco clara ou inadequada relatavam efeitos de tratamento exagerados em cerca de 30% e 41%, respectivamente, em termos de razão de chances. A ocultação da alocação, que protege o processo de randomização **antes** da inclusão, não deve ser confundida com o cegamento, que protege o estudo **depois** dela.

4.5.1.4 Análise por intenção de tratar

Em quase todos os ensaios, alguns participantes não recebem o tratamento alocado, abandonam o tratamento ou passam para o outro braço. A análise por **intenção de tratar** (ITT) compara os participantes **conforme o grupo para o qual foram randomizados**, independentemente do que receberam. Ela preserva os benefícios da randomização e estima o efeito de **oferecer** o tratamento na prática. A análise **por protocolo**, que inclui apenas quem seguiu o protocolo, parece mais "pura", mas compara grupos que deixaram de ser comparáveis: os pacientes que abandonam um tratamento costumam ser diferentes (mais graves, com mais efeitos adversos) dos que o mantêm. A análise ITT é a análise principal da maioria dos ensaios de superioridade; a análise por protocolo pode ser apresentada como complementar.

4.5.1.5 Outros desenhos de ensaio

- **Ensaio cruzado** (*crossover*): cada participante recebe os dois tratamentos, em ordem sorteada, separados por um período de eliminação (*washout*). Cada um é seu próprio controle, o que reduz o tamanho amostral necessário. Só é adequado para condições crônicas e estáveis e tratamentos de efeito reversível.
- **Ensaio fatorial**: avalia duas intervenções ao mesmo tempo, alocando os participantes a nenhuma, uma, outra ou ambas (veja a ANOVA fatorial no capítulo *Análise de dados*).
- **Ensaio por conglomerados** (*cluster*): randomizam-se grupos (escolas, unidades de saúde, comunidades), e não indivíduos. Necessário quando a intervenção é aplicada no nível do grupo ou quando há risco de contaminação entre participantes. Como os indivíduos de um mesmo conglomerado são correlacionados, o tamanho amostral e a análise precisam levar em conta essa correlação.
- **Ensaios de não inferioridade**: buscam mostrar que um novo tratamento (mais barato, mais seguro, mais cômodo) não é pior que o padrão por mais do que uma margem predefinida. Exigem cuidados específicos de desenho e análise.

Para o relato de ensaios randomizados, a diretriz de referência é o **CONSORT**, cuja versão mais recente foi publicada em 2025 (Hopewell et al. 2025). O protocolo de todo ensaio clínico deve ser **registrado publicamente antes do início do recrutamento** (no Brasil, no Registro Brasileiro de Ensaios Clínicos, ReBEC, ou em registros internacionais como o ClinicalTrials.gov), com o desfecho principal e o plano de análise. O registro prévio protege contra a troca de desfechos e a publicação seletiva de resultados favoráveis.

4.5.2 Estudos duplo-cegos

O **cegamento** (ou mascaramento) consiste em impedir que pessoas envolvidas no ensaio saibam qual tratamento cada participante recebe. Ele protege contra vieses que surgem **depois** da alocação:

- participantes que sabem estar recebendo o tratamento ativo podem relatar mais melhora (especialmente em desfechos subjetivos, como dor) e aderir de forma diferente;
- profissionais que sabem a alocação podem tratar os pacientes de forma diferente (cointervenções) ou avaliar os desfechos de forma diferente;
- quem analisa os dados pode fazer escolhas analíticas que favoreçam o resultado esperado.

Os termos “simples-cego”, “duplo-cego” e “triplo-cego” são ambíguos: um levantamento mostrou que médicos e livros-texto atribuem a eles significados muito

diferentes (Devereaux et al. 2001). “Duplo-cego” geralmente significa que participantes e investigadores estão cegos, mas “investigadores” pode significar quem trata, quem avalia os desfechos, ou ambos. Por isso, a recomendação atual é **descrever explicitamente quem estava cego** (participantes, profissionais que aplicaram a intervenção, avaliadores dos desfechos, analistas de dados) e como o cegamento foi obtido, em vez de usar esses rótulos.

O cegamento de participantes em ensaios de medicamentos é obtido com **placebos** idênticos em aparência, sabor e posologia. Em ensaios de cirurgia, fisioterapia ou intervenções comportamentais, cegar participantes e profissionais é frequentemente impossível, mas quase sempre é possível cegar o **avaliador do desfecho**, o que já reduz muito o risco de viés. Desfechos objetivos e “duros” (como mortalidade por todas as causas) são menos sensíveis à falta de cegamento do que desfechos subjetivos.

4.6 Estudos experimentais

Os princípios que fazem do ensaio randomizado um bom desenho (controle, randomização, cegamento, tamanho amostral planejado) valem igualmente para os experimentos de laboratório, com células, tecidos ou animais. No entanto, eles são aplicados com frequência muito menor na pesquisa pré-clínica, o que contribui para que muitos achados de laboratório não se reproduzam. As diretrizes **ARRIVE 2.0** (Percie du Sert et al. 2020) para o relato de pesquisas com animais incluem, entre os itens essenciais, exatamente esses elementos de desenho.

4.6.1 Desenho experimental

4.6.1.1 A unidade experimental

O conceito mais importante, e mais frequentemente mal aplicado, no desenho de experimentos de laboratório é o de **unidade experimental**: a menor unidade que pode receber, de forma independente, uma condição experimental. É ela que define o tamanho amostral (n).

- Se um fármaco é administrado a camundongos individualmente, a unidade experimental é o animal, e não cada neurônio medido em seu cérebro.
- Se um tratamento é adicionado ao meio de cultura de uma placa, a unidade é a placa (ou o poço, se cada poço recebeu o tratamento independentemente), e não cada célula contada.
- Se uma dieta é oferecida a uma gaiola com cinco animais, a unidade experimental é a gaiola, porque os animais da mesma gaiola não receberam a dieta de forma independente e compartilham o ambiente.

Medir 50 neurônios de cada um de três animais por grupo e analisar os dados como se houvesse $n = 150$ por grupo é **pseudorreplicação**: as medidas de um mesmo animal são correlacionadas, a variabilidade entre animais (que é a relevante para generalizar) é ignorada, os erros padrão são subestimados e a taxa de falsos positivos dispara. Lazic (2010) encontrou esse problema em uma fração substancial dos artigos de neurociência analisados. As soluções são analisar a média de cada unidade experimental ou usar modelos que considerem a estrutura hierárquica dos dados (modelos mistos). Medidas repetidas da mesma unidade (réplicas técnicas) melhoram a precisão da medida de cada unidade, mas **não** aumentam o n.

4.6.1.2 Desenhos clássicos

- **Inteiramente casualizado**: as unidades experimentais são distribuídas aleatoriamente entre os tratamentos, sem restrições. É o mais simples e adequado quando as unidades são homogêneas.
- **Em blocos casualizados**: as unidades são primeiro agrupadas em **blocos** de unidades semelhantes (animais da mesma ninhada, amostras processadas no mesmo dia, placas do mesmo lote) e, dentro de cada bloco, os tratamentos são sorteados. A variação entre blocos é removida da comparação entre tratamentos, aumentando a precisão. O bloco deve ser incluído na análise (por exemplo, como fator em uma ANOVA).
- **Fatorial**: dois ou mais fatores são estudados simultaneamente em todas as combinações, o que permite avaliar interações com eficiência (capítulo *Análise de dados*).
- **Medidas repetidas**: a mesma unidade é medida várias vezes ao longo do tempo ou sob várias condições, o que exige análises que considerem a correlação entre medidas.

4.6.2 Controle e aleatorização

4.6.2.1 Grupos controle

Um efeito só pode ser atribuído a um tratamento por comparação com um **controle** adequado, tratado de forma idêntica exceto pelo fator em estudo.

- **Controle negativo** ou **veículo**: recebe tudo o que o grupo tratado recebe (o solvente, o volume, a via de administração, o manuseio), exceto o agente ativo. Comparar animais tratados com animais que não receberam nenhuma injeção confunde o efeito do fármaco com o do estresse da injeção e do veículo.
- **Controle simulado** (*sham*): em procedimentos cirúrgicos, o grupo controle passa pela anestesia e pela cirurgia, sem a etapa experimental (por exemplo, a ligadura de um vaso).

- **Controle positivo**: recebe um tratamento de efeito conhecido, para demonstrar que o sistema experimental é capaz de detectar um efeito. Um resultado negativo sem controle positivo não distingue "o tratamento não funciona" de "o ensaio não funcionou".

Os controles devem ser **concorrentes**: estudados ao mesmo tempo e nas mesmas condições que os grupos tratados. Controles "históricos", de experimentos anteriores, incorporam todas as diferenças de lote, de reagentes, de operador e de condições que ocorreram entre os experimentos.

4.6.2.2 Aleatorização no laboratório

Os mesmos vieses que a randomização evita nos ensaios clínicos ocorrem no laboratório. Se o pesquisador escolhe quais animais recebem o tratamento, pode, sem perceber, escolher os mais ativos ou os mais fáceis de manusear. Se todos os animais tratados são operados de manhã e os controles à tarde, ou se as amostras tratadas são processadas no primeiro lote e as controle no segundo, o efeito do tratamento fica **confundido** com o horário ou o lote. Por isso:

1. a **alocação** das unidades aos tratamentos deve ser feita por sorteio, com o computador (como no código da seção de ensaios randomizados), e não por critérios como "os primeiros animais retirados da gaiola";
2. a **ordem** dos procedimentos e das medidas também deve ser aleatorizada ou balanceada entre os grupos, para que fatores como horário, posição na placa ou na estante, e lote não coincidam com o tratamento;
3. quem realiza as medidas e avalia os resultados (por exemplo, quem conta células ou pontua comportamentos) deve estar **cego** ao grupo, usando códigos que só são revelados depois da análise;
4. o **tamanho amostral** deve ser calculado antes do experimento, com base no menor efeito considerado relevante e na variabilidade esperada (capítulo *Bioestatística inferencial*), e os critérios de exclusão de unidades devem ser definidos antes de os dados serem vistos.

Esses princípios custam pouco e aumentam muito a credibilidade de um experimento. Um experimento pequeno, randomizado e cego informa mais do que um experimento grande sem esses cuidados, porque o erro aleatório pode ser quantificado, enquanto o viés, não.

4.7 Resumo do capítulo

- O desenho determina o que um estudo pode responder. Comece por uma pergunta bem formulada (PICO/PECO) e identifique se ela é descritiva, causal ou preditiva.

- Prevalência mede carga; incidência mede ocorrência de casos novos e exige um período ou o uso de pessoa-tempo.
- Risco relativo e diferença de riscos se complementam; a razão de chances aproxima o risco relativo apenas quando o desfecho é raro.
- Erro aleatório afeta a precisão e diminui com o tamanho amostral; viés (de seleção ou de informação) afeta a validade e não diminui com o tamanho amostral. Classificação errada não diferencial de uma exposição binária tende a atenuar associações.
- Confusão é um conceito causal. Diagramas causais distinguem confundidores (que devem ser ajustados) de mediadores e colisores (que não devem). Só a randomização controla confundidores não medidos.
- Estudos transversais estimam prevalências, mas não estabelecem a ordem temporal. Coortes estabelecem a temporalidade e estimam incidências, mas são caras para desfechos raros. Estudos caso-controle são eficientes para doenças raras e estimam a razão de chances, mas dependem criticamente da escolha dos controles.
- Em coortes com bases de dados, evite o viés do tempo imortal e a inclusão de usuários prevalentes; a emulação de um ensaio-alvo organiza o desenho.
- No ensaio randomizado, a randomização equilibra em média todos os fatores prognósticos; a ocultação da alocação protege a randomização; o cegamento protege contra vieses posteriores à alocação; a análise por intenção de tratar preserva a comparabilidade dos grupos. Descreva quem estava cego, em vez de usar “duplo-cego”.
- No laboratório, identifique a unidade experimental (que define o n), evite pseudorreplicação, use controles concorrentes e adequados, e aleatorize a alocação e a ordem dos procedimentos.

4.8 Exercícios

1. Para cada pergunta, indique o desenho mais adequado e justifique: (a) qual a prevalência de diabetes em adultos de um município? (b) o uso de um medicamento na gestação está associado a uma malformação congênita rara? (c) um novo analgésico reduz a dor pós-operatória mais que o padrão? (d) a exposição ocupacional a um solvente aumenta a incidência de vários tipos de câncer?

2. Em uma coorte, 1.000 pessoas expostas tiveram 150 eventos e 1.000 não expostas tiveram 50 eventos em três anos. Calcule o risco em cada grupo, o RR, a diferença de riscos, o NNH e a OR. Por que a OR difere tanto do RR neste caso?

3. Um estudo transversal encontrou que pessoas com doença renal crônica consomem menos proteína do que pessoas sem a doença, e concluiu que o baixo consumo de proteína causa doença renal. Identifique o problema.

4. Em um estudo caso-controle sobre uso de celular e tumores cerebrais, os casos (pacientes com tumor) foram entrevistados no hospital, e os controles, por telefone. Que vieses podem estar presentes?

5. Explique a diferença entre ocultação da alocação e cegamento. É possível ter ocultação da alocação em um ensaio de cirurgia versus fisioterapia, no qual o cegamento dos pacientes é impossível?

6. Em um ensaio, 15% dos pacientes do grupo tratamento abandonaram o medicamento por efeitos adversos. Os autores apresentaram apenas a análise dos pacientes que completaram o tratamento. Qual o problema?

7. Um pesquisador trata 4 camundongos com um fármaco e 4 com veículo, sacrifica os animais e conta a densidade de espinhas dendríticas em 30 neurônios de cada animal. Ele compara os 120 neurônios de cada grupo com um teste t. Qual o n correto e como os dados deveriam ser analisados?

8. Usando a abordagem de diagramas causais, discuta se é correto ajustar para o peso ao nascer ao estudar o efeito do tabagismo materno sobre a mortalidade infantil. (Dica: o tabagismo reduz o peso ao nascer, e o baixo peso ao nascer também pode ser causado por outros fatores, como malformações, que aumentam a mortalidade.)

4.9 Respostas dos exercícios

1. (a) Estudo transversal com amostra probabilística da população: o objetivo é uma prevalência. (b) Caso-controle: o desfecho é raro, e uma coorte precisaria acompanhar um número enorme de gestantes; uma alternativa moderna é a coorte retrospectiva em grandes bases de dados vinculadas. (c) Ensaio clínico randomizado, idealmente com cegamento de pacientes e avaliadores. (d) Coorte (provavelmente retrospectiva, com registros ocupacionais): a exposição é relativamente rara, o que favorece selecionar um grupo exposto, e há múltiplos desfechos de interesse.

2. Riscos: 15% e 5%. RR = 0,15/0,05 = 3,0. DR = 10 pontos percentuais; NNH = 1/0,10 = 10. OR = $(150 \times 950)/(850 \times 50) = 142.500/42.500 \approx 3{,}35$. Como o desfecho é frequente (15% nos expostos), a OR se afasta de 1 mais do que o RR e não deve ser interpretada como "risco 3,35 vezes maior".

3. Ambiguidade temporal e causalidade reversa: pacientes com doença renal crônica recebem orientação para reduzir o consumo de proteína como parte do tratamento. A doença causou a mudança na dieta, e não o contrário. O desenho transversal não permite estabelecer qual veio antes.

4. Viés de informação diferencial: casos e controles foram entrevistados de formas diferentes, e a forma de entrevista pode afetar o relato da exposição. Viés de memória: pacientes com tumor, buscando uma explicação para a doença, podem recordar ou relatar o uso de celular de forma diferente (e frequentemente maior) que os controles. Possível viés de seleção nos controles: pessoas que respondem a entrevistas telefônicas podem diferir da população de origem dos casos, inclusive quanto ao uso de telefone.

5. A ocultação da alocação impede que alguém conheça a próxima alocação **antes** de o participante ser incluído, protegendo a randomização. O cegamento impede que se conheça o tratamento recebido **depois** da alocação, protegendo contra vieses de desempenho e de avaliação. A ocultação da alocação é sempre possível, em qualquer ensaio, inclusive no de cirurgia versus fisioterapia (por exemplo, com randomização central por internet). Nesse ensaio, os pacientes não podem estar cegos, mas os avaliadores dos desfechos podem.

6. A análise por protocolo exclui justamente os pacientes que tiveram efeitos adversos e abandonaram o tratamento, que provavelmente diferem dos que completaram (talvez mais graves ou mais frágeis). Os grupos analisados deixam de ser comparáveis e a vantagem da randomização se perde. A análise principal deveria ser por intenção de tratar, incluindo todos os randomizados no grupo para o qual foram alocados, com estratégia adequada para os dados faltantes.

7. A unidade experimental é o animal: $n = 4$ por grupo, não 120. Os 30 neurônios de cada animal são medidas repetidas (correlacionadas) da mesma unidade. Analisar 120 contra 120 é pseudorreplicação e subestima drasticamente o erro padrão. As alternativas são calcular a média de cada animal e comparar 4 médias contra 4 (teste t com 6 graus de liberdade), ou usar um modelo misto com o animal como efeito aleatório. O pesquisador também deveria informar se a alocação dos animais foi aleatória e se a contagem foi cega.

8. O peso ao nascer é um **mediador** (o tabagismo reduz o peso, e o baixo peso aumenta a mortalidade) e também um **colisor** (é efeito comum do tabagismo e de outros fatores, como malformações, que também afetam a mortalidade). Ajustar para ele, por exemplo comparando apenas bebês de baixo peso, remove a parte do efeito do tabagismo que passa pelo peso e, ao condicionar em um colisor, cria uma associação espúria entre tabagismo e as outras causas de baixo peso. O resultado pode ser o "paradoxo do baixo peso ao nascer": entre bebês de baixo peso, os filhos de fumantes parecem ter mortalidade **menor**, porque seu baixo peso se deve ao tabagismo, enquanto o dos filhos de não fumantes se deve com mais frequência a causas mais graves. Para estimar o efeito total do tabagismo, não se deve ajustar para o peso ao nascer.

Capítulo 5

Bioestatística descritiva

Hércules Rezende Freitas, Ph.D.[1]

[1]Universidade do Estado do Rio de Janeiro (UERJ), Faculdade de Ciências Médicas, Departamento de Ciências Médicas Integradas, Laboratório de Informática em Saúde (LabInfoS), Cabo Frio/RJ, Brasil.

Toda análise de dados começa pela descrição. Antes de estimar parâmetros, testar hipóteses ou ajustar modelos, o pesquisador precisa saber o que tem nas mãos: quantas observações existem, quais valores aparecem com mais frequência, quão dispersos eles estão, se há valores aberrantes, dados faltantes ou erros de digitação. A **estatística descritiva** reúne os métodos numéricos e gráficos que resumem um conjunto de dados sem pretender, por si só, generalizar para além dele. A generalização da amostra para a população é tarefa da estatística inferencial, tratada no capítulo seguinte.

Resumir significa perder informação. Uma média condensa centenas de valores em um único número, e essa compressão só é útil se o número escolhido representar bem o que se quer comunicar. Por isso, a pergunta central deste capítulo não é apenas "como calcular", mas "qual medida é adequada para estes dados e para esta pergunta".

Ao longo do capítulo usaremos dois tipos de exemplo. Os exemplos pequenos, com poucos valores, servem para acompanhar os cálculos à mão. O conjunto `pacientes`, com 120 registros, serve para os exemplos em R e para os gráficos. **Esse conjunto é simulado**: os valores foram gerados por computador com distribuições plausíveis para pacientes adultos internados e não correspondem a pessoas reais. O código que o gera está no início do arquivo-fonte deste capítulo, e qualquer leitor pode reproduzi-lo exatamente, pois usamos uma semente fixa (`set.seed(2024)`).

```
head(pacientes)
```

```
##       sexo idade  tabagismo  imc comorbidades pas tempo
```

```
## 1 Masculino    80 Ex-fumante 28.5            1 130     3
## 2  Feminino    71       Nunca 32.4           1 173     4
## 3 Masculino    67 Ex-fumante 33.6            2 154     6
## 4 Masculino    63 Ex-fumante 32.6            5 148     3
## 5  Feminino    81 Ex-fumante 23.4            1 154     4
## 6 Masculino    59       Atual 36.0           0 154    13
```

```
str(pacientes)
```

```
## 'data.frame':    120 obs. of  7 variables:
## $ sexo : Factor w/ 2 levels "Feminino","Masculino": 2 1 2 2 1 2 1 1
##    2 1 ...
## $ idade : num 80 71 67 63 81 59 37 70 67 36 ...
## $ tabagismo : Factor w/ 3 levels "Nunca","Ex-fumante",..: 2 1 2 2 2
##    3 1 2 1 2 ...
## $ imc : num 28.5 32.4 33.6 32.6 23.4 36 25 28.7 22.5 28.2 ...
## $ comorbidades: int 1 1 2 5 1 0 1 2 2 2 ...
## $ pas : num 130 173 154 148 154 154 155 133 150 159 ...
## $ tempo : num 3 4 6 3 4 13 8 3 4 5 ...
```

As variáveis são: sexo; idade (anos); tabagismo (nunca, ex-fumante, atual); índice de massa corporal (IMC, kg/m²); número de comorbidades; pressão arterial sistólica (`pas`, mmHg) e tempo de internação (`tempo`, dias).

> **Notação.** Uma amostra de tamanho n é escrita como $x_1, x_2, \ldots, x_n$. Quando os mesmos valores aparecem ordenados do menor para o maior, usamos parênteses no índice: $x_{(1)} \le x_{(2)} \le \cdots \le x_{(n)}$. Assim, $x_{(1)}$ é o mínimo e $x_{(n)}$ é o máximo. Letras gregas (μ, σ) indicam parâmetros da população; letras latinas ($\bar{x}$, s) indicam estatísticas calculadas na amostra. No texto usamos vírgula como separador decimal; o R, como a maioria dos programas, usa ponto.

5.1 Tipos de variáveis e escalas de medida

A escolha de qualquer medida descritiva depende do tipo de variável. Calcular a média do grupo sanguíneo não faz sentido, assim como não faz sentido dizer que a moda é a melhor síntese da glicemia de jejum de 500 pacientes. A classificação mais usada vem de Stevens (1946), que propôs quatro escalas de medida.

Variáveis qualitativas (categóricas) registram a pertença a uma categoria.

- **Nominais**: as categorias não têm ordem natural. Exemplos: sexo, grupo sanguíneo, tipo de tratamento, município de residência. Só faz sentido contar quantas observações há em cada categoria.

Tabela 5.1: Escalas de medida e medidas descritivas admissíveis.

Escala	Operações com sentido	Tendência central	Dispersão	Exemplo
Nominal	igual / diferente	moda	proporções por categoria	grupo sanguíneo
Ordinal	+ ordenação (maior / menor)	+ mediana	+ quantis, amplitude interquartil	estadiamento tumoral
Intervalar	+ diferenças	+ média	+ desvio padrão, variância	temperatura (°C)
De razão	+ razões	+ média geométrica	+ coeficiente de variação	creatinina sérica

- **Ordinais**: as categorias têm ordem, mas a distância entre elas não é definida. Exemplos: estadiamento de um tumor (I, II, III, IV), escolaridade, escala de Likert ("discordo totalmente" a "concordo totalmente"), classe funcional da NYHA. Sabemos que o estádio III é mais avançado que o II, mas não que a "distância" entre II e III seja igual à que separa I e II.

Variáveis quantitativas (numéricas) registram uma quantidade.

- **Intervalares**: as diferenças entre valores têm significado, mas o zero é arbitrário. O exemplo clássico é a temperatura em graus Celsius. A diferença entre 10 °C e 20 °C é igual à diferença entre 30 °C e 40 °C, mas 20 °C não é "o dobro" de 10 °C, porque 0 °C não representa ausência de calor.
- **De razão**: além das diferenças, as razões têm significado, porque o zero é absoluto. Exemplos: massa corporal, concentração sérica de creatinina, tempo de internação, temperatura em kelvin. Um paciente com 80 kg tem o dobro da massa de outro com 40 kg.

Uma segunda classificação, transversal à anterior, distingue variáveis quantitativas **discretas** (assumem valores contáveis, em geral inteiros: número de filhos, número de comorbidades, número de crises convulsivas por mês) de **contínuas** (podem assumir qualquer valor em um intervalo, limitadas apenas pela precisão do instrumento: estatura, pressão arterial, concentração de um analito).

A Tabela 5.1 resume quais operações e medidas são admissíveis em cada escala. Cada escala herda as operações das escalas acima dela.

Duas observações práticas evitam erros frequentes.

1. **O código numérico não muda a escala.** Se o sexo for registrado como 1 (feminino) e 2 (masculino), a variável continua nominal. O R calculará sem reclamar a média de um vetor de 1s e 2s, mas o resultado (por exemplo, 1,45) não tem interpretação como "sexo médio". Em R, variáveis categóricas devem ser armazenadas como `factor`, o que impede esse tipo de engano em muitas funções.
2. **Escalas ordinais pedem cautela com médias.** É comum relatar a média de escores de dor (0 a 10) ou de itens de Likert. Isso pressupõe que as distâncias entre categorias sejam iguais, o que nem sempre se justifica. Na dúvida, relate mediana e quartis, e deixe explícito quando optar pela média.

Por fim, uma variável contínua pode ser **categorizada** (por exemplo, IMC em "baixo peso", "eutrofia", "sobrepeso" e "obesidade"). Isso facilita a comunicação, mas descarta informação: um paciente com IMC de 29,9 kg/m² e outro com 25,0 kg/m² passam a ser tratados como iguais. Para descrever e analisar, prefira manter a variável contínua e reserve as categorias para a apresentação, quando houver pontos de corte clinicamente estabelecidos.

5.2 Medidas de tendência central

Medidas de tendência central (ou de posição) indicam um valor "típico" em torno do qual os dados se distribuem. As três principais são a média, a mediana e a moda. Para acompanhar os cálculos, usaremos o tempo de internação, em dias, de sete pacientes:

$$3,\ 4,\ 4,\ 5,\ 6,\ 8,\ 19$$

```r
tempo7 <- c(3, 4, 4, 5, 6, 8, 19)
```

5.2.1 Média

A **média aritmética** é a soma dos valores dividida pelo número de observações:

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i = \frac{x_1 + x_2 + \cdots + x_n}{n} \tag{5.1}$$

No exemplo, $\bar{x} = (3+4+4+5+6+8+19)/7 = 49/7 = 7$ dias.

```r
sum(tempo7) / length(tempo7)
```

```
## [1] 7
```

```
mean(tempo7)
```

```
## [1] 7
```

A média tem uma interpretação física útil: é o **ponto de equilíbrio** dos dados. Se cada observação fosse um peso igual colocado sobre uma régua, a régua ficaria equilibrada exatamente sobre $\bar{x}$. Algebricamente, isso significa que a soma dos desvios em relação à média é sempre zero:

$$\sum_{i=1}^{n}(x_i - \bar{x}) = \sum_{i=1}^{n} x_i - n\bar{x} = n\bar{x} - n\bar{x} = 0.$$

No exemplo, os desvios são $-4, -3, -3, -2, -1, 1, 12$, cuja soma é zero. Observe que um único desvio positivo (12) compensa seis desvios negativos. É por isso que a média é "puxada" por valores extremos.

Uma segunda propriedade explica por que a média é tão central na estatística. Entre todos os números c que poderíamos escolher para representar os dados, a média é o que **minimiza a soma dos quadrados dos desvios** $\sum(x_i - c)^2$. Para ver isso, some e subtraia $\bar{x}$ dentro do parêntese:

$$\sum_{i=1}^{n}(x_i - c)^2 = \sum_{i=1}^{n}\left[(x_i - \bar{x}) + (\bar{x} - c)\right]^2 = \sum_{i=1}^{n}(x_i - \bar{x})^2 + n(\bar{x} - c)^2.$$

O termo cruzado desaparece porque $\sum(x_i - \bar{x}) = 0$. O primeiro termo não depende de c, e o segundo é sempre maior ou igual a zero, valendo zero apenas quando $c = \bar{x}$. Essa propriedade reaparecerá na definição da variância e no método dos mínimos quadrados da regressão linear.

Sensibilidade a valores extremos. Sem o paciente que ficou 19 dias internado, a média dos seis restantes seria $30/6 = 5$ dias. Uma única observação deslocou a média em 2 dias, ou 40%. Diz-se que a média tem **ponto de ruptura** (*breakdown point*) igual a zero: basta uma observação suficientemente extrema, em qualquer tamanho de amostra, para levar a média a qualquer valor. Isso não torna a média uma medida ruim. Em distribuições aproximadamente simétricas ela é a estimativa mais eficiente do centro, e há situações em que os valores extremos importam (o custo total de um serviço de saúde depende justamente dos pacientes mais caros). O que importa é saber o que ela representa.

Transformações lineares. Se cada valor for transformado como $y_i = a + b\,x_i$, a média se transforma da mesma maneira: $\bar{y} = a + b\,\bar{x}$. Isso é útil na conversão de unidades. A glicemia em mg/dL dividida por 18,016 fornece aproximadamente o

valor em mmol/L; portanto, a média em mmol/L é a média em mg/dL dividida pelo mesmo fator, sem necessidade de recalcular a partir dos dados.

Média ponderada. Quando as observações têm importâncias diferentes, usa-se a média ponderada, com pesos $w_i \geq 0$:

$$\bar{x}_w = \frac{\sum_{i=1}^{n} w_i x_i}{\sum_{i=1}^{n} w_i}.$$

O caso mais comum é a combinação de médias de grupos de tamanhos diferentes. Suponha que, em um hospital, 30 pacientes da enfermaria A tenham idade média de 70 anos e 10 pacientes da enfermaria B tenham idade média de 90 anos. A idade média dos 40 pacientes **não** é $(70 + 90)/2 = 80$ anos, mas

$$\bar{x}_w = \frac{30 \times 70 + 10 \times 90}{30 + 10} = \frac{3000}{40} = 75 \text{ anos.}$$

```
weighted.mean(x = c(70, 90), w = c(30, 10))
```

```
## [1] 75
```

Média aparada. Uma solução intermediária entre a média e a mediana é a média aparada (*trimmed mean*): descarta-se uma fração dos valores em cada extremo e calcula-se a média dos restantes. Em R, `mean(x, trim = 0.1)` remove 10% das observações de cada lado.

Média geométrica. Para variáveis de razão estritamente positivas e com assimetria à direita (títulos de anticorpos, concentrações de biomarcadores, cargas virais), é comum usar a média geométrica, $\left(\prod x_i\right)^{1/n}$, que equivale a calcular a média dos logaritmos e depois aplicar a exponencial: `exp(mean(log(x)))`.

5.2.2 Mediana

A **mediana** é o valor que divide a amostra ordenada em duas metades: pelo menos 50% das observações são menores ou iguais a ela, e pelo menos 50% são maiores ou iguais. Com os dados ordenados, $x_{(1)} \leq \cdots \leq x_{(n)}$:

$$\text{Md} = \begin{cases} x_{\left(\frac{n+1}{2}\right)}, & \text{se } n \text{ for ímpar,} \\ \dfrac{x_{\left(\frac{n}{2}\right)} + x_{\left(\frac{n}{2}+1\right)}}{2}, & \text{se } n \text{ for par.} \end{cases}$$

No exemplo, $n = 7$ é ímpar, e a mediana é a observação de posição $(7+1)/2 = 4$, ou seja, Md = 5 dias. Sem o paciente de 19 dias, teríamos $n = 6$, e a mediana seria a média das posições 3 e 4: $(4 + 5)/2 = 4{,}5$ dias. Compare: a retirada do valor extremo alterou a média em 2 dias, mas a mediana em apenas meio dia.

```r
median(tempo7)
```

```
## [1] 5
```

```r
median(tempo7[tempo7 != 19])
```

```
## [1] 4.5
```

A mediana é **robusta**: seu ponto de ruptura é de 50%, isto é, quase metade das observações precisaria ser alterada para levá-la a um valor arbitrário. Assim como a média minimiza a soma dos quadrados dos desvios, a mediana minimiza a soma dos **desvios absolutos**, $\sum |x_i - c|$.

A mediana é a medida de escolha para variáveis ordinais e para variáveis quantitativas com forte assimetria, como tempo de internação, renda, custos hospitalares, concentrações de marcadores inflamatórios e tempo até um evento.

5.2.3 Moda

A **moda** é o valor (ou a categoria) que ocorre com maior frequência. No exemplo, a moda é 4 dias, o único valor que aparece duas vezes. É a única medida de tendência central aplicável a variáveis nominais: em uma amostra de pacientes, a moda do grupo sanguíneo pode ser "O+".

Uma distribuição pode ter mais de uma moda (bimodal, multimodal) ou nenhuma (quando todos os valores são distintos). A presença de duas modas em uma variável contínua costuma indicar a mistura de duas populações diferentes, como a distribuição de estatura em uma amostra que reúne homens e mulheres. Em variáveis contínuas medidas com boa precisão, raramente há valores repetidos, e por isso fala-se em **classe modal**: o intervalo de uma distribuição de frequências (ou o pico de um histograma) com maior concentração de observações.

O R não tem uma função nativa para a moda estatística (a função `mode()` do R informa o tipo de armazenamento de um objeto, o que é outra coisa). Uma implementação simples, que devolve todas as modas em caso de empate, é:

```r
moda <- function(x) {
  freq <- table(x)
  names(freq)[freq == max(freq)]
}
moda(tempo7)
```

```
## [1] "4"
```

```
moda(pacientes$tabagismo)
```

```
## [1] "Nunca"
```

5.2.4 Comparando média, mediana e moda

Em uma distribuição perfeitamente simétrica e unimodal, as três medidas coincidem. Quando há assimetria, elas se separam. No conjunto `pacientes`, o tempo de internação tem cauda longa à direita (alguns pacientes ficam muito mais tempo que os demais): a média é de 5,7 dias e a mediana, de 5,0 dias. A Figura 5.1 mostra as duas medidas sobre o histograma.

```
hist(pacientes$tempo, breaks = seq(0.5, max(pacientes$tempo) + 0.5, by =
↪  1),
     col = "grey85", border = "white",
     main = "", xlab = "Tempo de internação (dias)", ylab = "Número de
      ↪  pacientes")
abline(v = mean(pacientes$tempo), lwd = 2)
abline(v = median(pacientes$tempo), lwd = 2, lty = 2)
legend("topright", legend = c("Média", "Mediana"), lty = c(1, 2), lwd =
↪  2, bty = "n")
```

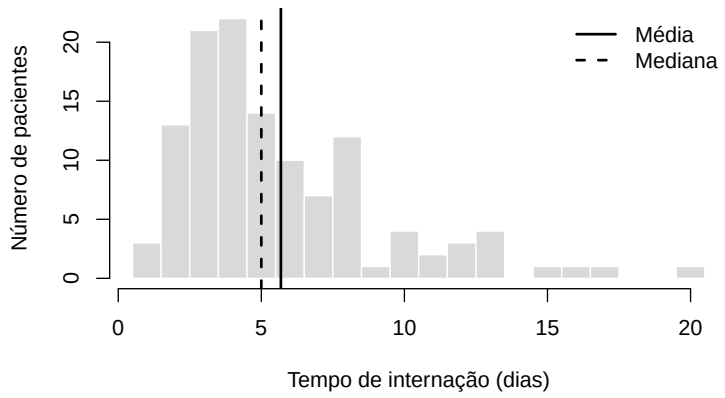


Figura 5.1: Histograma do tempo de internação (dados simulados). A linha contínua indica a média e a linha tracejada, a mediana. A cauda à direita desloca a média para cima.

Muitos livros ensinam a regra "assimetria à direita implica média > mediana > moda". A regra vale para muitas distribuições contínuas usadas na prática, mas **não é um teorema**: há contraexemplos, sobretudo em variáveis discretas e em distribuições multimodais, nos quais a média fica do lado oposto ao que a regra prevê (von Hippel 2005). A comparação entre média e mediana é um indício útil de assimetria, não um teste dela; a forma da distribuição se avalia melhor no gráfico dos dados.

A escolha da medida deve seguir a pergunta. Se o objetivo é estimar o custo total de internações de um serviço, a média é a medida relevante, mesmo com assimetria, porque o total é igual a $n \times \bar{x}$. Se o objetivo é descrever a experiência de um paciente típico, a mediana é mais informativa.

5.3 Medidas de dispersão

Duas amostras podem ter a mesma média e ser completamente diferentes. Os conjuntos $\{49, 50, 51\}$ e $\{0, 50, 100\}$ têm média 50, mas o segundo é muito mais heterogêneo. Medidas de dispersão (ou de variabilidade) quantificam o quanto os valores se afastam uns dos outros ou do centro. Sem elas, uma medida de tendência central é quase impossível de interpretar.

5.3.1 Amplitude

A **amplitude total** é a diferença entre o maior e o menor valor:

$$A = x_{(n)} - x_{(1)}.$$

No exemplo do tempo de internação, $A = 19 - 3 = 16$ dias. Em R, `range()` devolve o mínimo e o máximo, e `diff(range(x))` calcula a amplitude.

```
range(tempo7)
```

```
## [1]  3 19
```

```
diff(range(tempo7))
```

```
## [1] 16
```

A amplitude é fácil de calcular e de comunicar, mas tem duas limitações sérias. Primeiro, depende apenas de duas observações, justamente as mais extremas, e é tão sensível a valores atípicos quanto possível. Segundo, tende a crescer com

o tamanho da amostra: quanto mais pacientes observamos, maior a chance de encontrar alguém muito alto ou muito baixo. Por isso, amplitudes de estudos com tamanhos amostrais diferentes não são comparáveis. Relatar mínimo e máximo continua útil, por exemplo para mostrar a faixa de idade incluída em um estudo, mas não como medida principal de dispersão.

5.3.1.1 Quantis e amplitude interquartil

Uma alternativa robusta usa **quantis**. O quantil de ordem p (com $0 < p < 1$) é um valor abaixo do qual está uma proporção p dos dados. Os **quartis** dividem os dados ordenados em quatro partes: o primeiro quartil (Q_1) corresponde a $p = 0{,}25$; o segundo (Q_2) é a mediana; o terceiro (Q_3) corresponde a $p = 0{,}75$. Os **percentis** usam p em centésimos (o percentil 90 é o quantil 0,90), linguagem comum nas curvas de crescimento infantil.

A **amplitude interquartil** (AIQ, ou IQR, do inglês *interquartile range*) é a distância entre o terceiro e o primeiro quartil:

$$\text{AIQ} = Q_3 - Q_1.$$

Ela cobre os 50% centrais dos dados e, como a mediana, não é afetada pelos 25% de valores em cada extremo.

Há um detalhe técnico que costuma surpreender: não existe uma única definição de quantil amostral. Quando a posição desejada cai entre duas observações, é preciso decidir como interpolar, e os programas estatísticos fazem escolhas diferentes. Hyndman e Fan (1996) catalogaram nove definições, todas disponíveis no argumento `type` da função `quantile()` do R. O padrão do R (tipo 7, o mesmo da função `QUARTIL.INC` do Excel) calcula a posição

$$h = (n-1)p + 1$$

e interpola linearmente entre $x_{(\lfloor h \rfloor)}$ e $x_{(\lfloor h \rfloor + 1)}$, onde $\lfloor h \rfloor$ é a parte inteira de h. No exemplo com $n = 7$:

- para Q_1: $h = 6 \times 0{,}25 + 1 = 2{,}5$, a meio caminho entre $x_{(2)} = 4$ e $x_{(3)} = 4$, logo $Q_1 = 4$;
- para Q_3: $h = 6 \times 0{,}75 + 1 = 5{,}5$, a meio caminho entre $x_{(5)} = 6$ e $x_{(6)} = 8$, logo $Q_3 = 7$.

Assim, AIQ $= 7 - 4 = 3$ dias. O SPSS e o Minitab usam por padrão outra definição (tipo 6), com posição $h = (n+1)p$, que neste exemplo produz $Q_3 = 8$:

```r
quantile(tempo7)            # tipo 7, padrão do R
```

```
##   0%  25%  50%  75% 100%
##    3    4    5    7   19
```

```r
quantile(tempo7, type = 6)  # definição usada pelo SPSS
```

```
##   0%  25%  50%  75% 100%
##    3    4    5    8   19
```

```r
IQR(tempo7)
```

```
## [1] 3
```

Em amostras grandes as diferenças entre definições são desprezíveis, mas em amostras pequenas elas explicam por que dois programas fornecem quartis diferentes para os mesmos dados. Nenhum dos dois está errado. Em trabalhos com amostras pequenas, vale informar o programa usado.

5.3.1.2 Medidas robustas baseadas em desvios absolutos

O **desvio absoluto mediano** (MAD, do inglês *median absolute deviation*) é a mediana das distâncias absolutas entre cada valor e a mediana: $\text{MAD} = \text{Md}(|x_i - \text{Md}(x)|)$. No exemplo, as distâncias à mediana 5 são $2, 1, 1, 0, 1, 3, 14$, cuja mediana é 1. A função `mad()` do R multiplica esse valor por 1,4826 por padrão. Essa constante faz o MAD estimar o desvio padrão quando os dados vêm de uma distribuição normal, o que permite comparar as duas medidas. Use `mad(x, constant = 1)` para obter o valor bruto.

```r
mad(tempo7, constant = 1)
```

```
## [1] 1
```

```r
mad(tempo7)
```

```
## [1] 1.4826
```

Tabela 5.2: Cálculo da variância do tempo de internação de sete pacientes.

i	x_i	$x_i - \bar{x}$	$(x_i - \bar{x})^2$
1	3	-4	16
2	4	-3	9
3	4	-3	9
4	5	-2	4
5	6	-1	1
6	8	1	1
7	19	12	144
Soma	49	0	184

5.3.2 Variância

A ideia natural para medir dispersão é olhar os desvios em relação à média, $x_i - \bar{x}$. Somá-los não funciona, porque a soma é sempre zero. Elevá-los ao quadrado resolve o problema dos sinais e dá peso maior a desvios grandes. A **variância amostral** é

$$s^2 = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \bar{x})^2. \tag{5.2}$$

A Tabela 5.2 mostra o cálculo passo a passo para o exemplo, com $\bar{x} = 7$.

Então $s^2 = 184/(7-1) = 184/6 \approx 30{,}67$ dias². Note que o valor 19, sozinho, contribui com 144 dos 184 da soma de quadrados: elevar ao quadrado amplifica os desvios grandes, e por isso a variância é ainda mais sensível a valores extremos do que a média.

```
sum((tempo7 - mean(tempo7))^2) / (length(tempo7) - 1)
```

```
## [1] 30.66667
```

```
var(tempo7)
```

```
## [1] 30.66667
```

A unidade da variância é o quadrado da unidade original (dias², mmHg², (kg/m²)²), o que dificulta a interpretação direta. Essa é a motivação para o desvio padrão, discutido a seguir.

5.3.2.1 Por que dividir por $n-1$?

Se conhecêssemos a média populacional μ, a variância populacional seria estimada naturalmente por $\frac{1}{n}\sum(x_i-\mu)^2$. Na prática, μ é desconhecida e a substituímos por $\bar{x}$. Ocorre que $\bar{x}$ é, por construção, o valor que minimiza a soma dos quadrados dos desvios (veja a seção sobre a média). Portanto, $\sum(x_i-\bar{x})^2$ é sempre menor ou igual a $\sum(x_i-\mu)^2$: usar a média amostral faz os dados parecerem menos dispersos do que realmente são.

A identidade que vimos na seção da média, com $c=\mu$, quantifica esse viés:

$$\sum_{i=1}^{n}(x_i-\bar{x})^2=\sum_{i=1}^{n}(x_i-\mu)^2-n(\bar{x}-\mu)^2.$$

Tomando o valor esperado (a média ao longo de infinitas amostras repetidas) de cada lado, e usando os fatos de que $E[(x_i-\mu)^2]=\sigma^2$ e $E[(\bar{x}-\mu)^2]=\sigma^2/n$ (a variância da média amostral, que será estudada no próximo capítulo), obtemos

$$E\left[\sum_{i=1}^{n}(x_i-\bar{x})^2\right]=n\sigma^2-n\cdot\frac{\sigma^2}{n}=(n-1)\sigma^2.$$

Logo, dividir a soma de quadrados por $n-1$, e não por n, produz um estimador cuja média ao longo de amostras repetidas é exatamente σ^2, isto é, um estimador **não viesado**. Essa correção é conhecida como correção de Bessel. O número $n-1$ é chamado de **graus de liberdade**: como os desvios em relação a $\bar{x}$ precisam somar zero, conhecidos $n-1$ deles o último está determinado.

Quando o conjunto de dados é a população inteira (por exemplo, todos os leitos de um hospital em um dado dia), a variância é calculada com divisor n e representada por σ^2. Em pesquisa clínica e epidemiológica, quase sempre trabalhamos com amostras, e as funções `var()` e `sd()` do R usam $n-1$.

A simulação a seguir permite verificar a correção empiricamente. Sorteamos 10.000 amostras de tamanho 5 de uma distribuição normal com $\sigma^2=100$ e comparamos a média dos dois estimadores.

```
set.seed(1)
amostras <- replicate(10000, rnorm(5, mean = 50, sd = 10))
var_n1 <- apply(amostras, 2, var)                          # divisor n - 1
var_n  <- apply(amostras, 2, function(x) mean((x - mean(x))^2))  #
 ↪  divisor n
c(divisor_n_menos_1 = mean(var_n1), divisor_n = mean(var_n))
```

```
## divisor_n_menos_1         divisor_n
##         101.32708          81.06166
```

O estimador com divisor n subestima a variância em média por um fator $(n-1)/n = 4/5$, ou seja, fica perto de 80, e não de 100.

> **Nota de cálculo.** Alguns livros apresentam a fórmula "computacional" $s^2 = \left(\sum x_i^2 - n\bar{x}^2\right)/(n-1)$, algebricamente equivalente à Equação (5.2). Ela é cômoda para cálculo manual, mas pode perder precisão no computador quando os valores são grandes e pouco dispersos, porque subtrai dois números muito próximos. Os programas estatísticos usam algoritmos mais estáveis; ao programar suas próprias funções, prefira a forma com desvios.

5.3.3 Desvio padrão

O **desvio padrão** é a raiz quadrada positiva da variância:

$$s = \sqrt{s^2} = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2}.$$

No exemplo, $s = \sqrt{30{,}67} \approx 5{,}54$ dias. A vantagem sobre a variância é que o desvio padrão está na mesma unidade dos dados. Informalmente, ele indica a distância típica entre as observações e a média.

```
sd(tempo7)
```

```
## [1] 5.537749
```

Sob uma transformação linear $y_i = a + b\,x_i$, o desvio padrão se transforma como $s_y = |b|\,s_x$: somar uma constante não altera a dispersão, e multiplicar por uma constante multiplica a dispersão pelo seu valor absoluto.

5.3.3.1 Interpretando o desvio padrão

Quanto dos dados fica a até k desvios padrão da média? A resposta depende da forma da distribuição, e há duas regras que o leitor precisa distinguir.

1. **Desigualdade de Chebyshev (qualquer distribuição).** Para qualquer conjunto de dados e qualquer $k > 1$, a proporção de observações a menos de k desvios padrão da média é de pelo menos $1 - 1/k^2$. Com $k = 2$, pelo menos 75% dos dados estão no intervalo $\bar{x} \pm 2s$; com $k = 3$, pelo menos 88,9%. É uma garantia fraca, mas universal.

2. **Regra empírica (distribuição normal).** Se os dados forem aproximadamente normais, cerca de 68% estão em $\bar{x} \pm s$, 95% em $\bar{x} \pm 1{,}96s$ e 99,7% em $\bar{x} \pm 3s$. Essa regra só vale para distribuições próximas da normal, discutida em detalhe no capítulo de inferência.

```
pas <- pacientes$pas
dentro_2dp <- mean(abs(pas - mean(pas)) < 2 * sd(pas))
dentro_2dp
```

```
## [1] 0.9583333
```

No conjunto simulado, a pressão arterial sistólica tem média de 146,0 mmHg e desvio padrão de 13,8 mmHg; 95,8% dos pacientes estão a menos de dois desvios padrão da média, valor próximo ao esperado para uma distribuição aproximadamente normal.

5.3.3.2 Média ± desvio padrão em dados assimétricos

É muito comum ver em artigos a notação "média ± DP" aplicada a qualquer variável. Para variáveis assimétricas, isso pode ser enganoso. Considere uma variável que não pode ser negativa, como a proteína C-reativa (PCR). Se um artigo relata PCR de 8,2 ± 11,5 mg/L, o intervalo $\bar{x} - 2s$ seria negativo, o que é impossível. Esse é um sinal clássico de assimetria à direita: se a média for menor do que duas vezes o desvio padrão em uma variável estritamente positiva, a distribuição provavelmente é assimétrica (Altman and Bland 1996). Nesses casos, relate mediana e quartis (ou mediana e AIQ).

5.3.3.3 Desvio padrão não é erro padrão

Um erro persistente na literatura biomédica é confundir o desvio padrão (DP) com o **erro padrão da média** (EPM), EP $= s/\sqrt{n}$ (Altman and Bland 2005). As duas medidas respondem a perguntas diferentes:

- o **DP** descreve a variabilidade **entre os indivíduos** da amostra e não diminui sistematicamente com o aumento de n;
- o **EP** descreve a incerteza na **estimativa da média** e diminui à medida que n cresce.

Para descrever a amostra, use o DP. O EP pertence à inferência e é mais bem comunicado na forma de um intervalo de confiança, tema do próximo capítulo. Como o EP é sempre menor que o DP (para $n > 1$), relatar "média ± EP" em uma tabela descritiva dá a falsa impressão de que os dados são pouco variáveis.

5.3.3.4 Coeficiente de variação

Para comparar a dispersão de variáveis em escalas ou unidades diferentes, usa-se o **coeficiente de variação** (CV), o desvio padrão expresso como proporção da média:

$$\text{CV} = \frac{s}{\bar{x}} \times 100\%.$$

Um desvio padrão de 10 kg na massa corporal de adultos (média de 70 kg) corresponde a um CV de 14,3%; um desvio padrão de 0,5 kg no peso ao nascer (média de 3,2 kg) corresponde a um CV de 15,6%. Em termos relativos, a variabilidade é semelhante. O CV também é usado em laboratório para expressar a precisão de um ensaio (CV intra e interensaio). Ele só tem sentido para variáveis de razão: com temperaturas em °C, por exemplo, o CV mudaria ao trocar a escala para Fahrenheit, porque o zero é arbitrário.

```
cv <- function(x) 100 * sd(x) / mean(x)
cv(pacientes$imc)
```

```
## [1] 16.65143
```

5.4 Distribuições de frequência

Uma **distribuição de frequências** mostra como as observações se repartem entre os valores ou classes possíveis. É o primeiro passo para conhecer a forma dos dados e a base de vários gráficos. Para cada valor ou classe j, definimos:

- **frequência absoluta** (f_j): número de observações na classe;
- **frequência relativa** (f_j/n): proporção de observações na classe, frequentemente expressa em porcentagem;
- **frequência acumulada** (F_j): soma das frequências até a classe j, inclusive. Só faz sentido quando há ordem entre as classes (variáveis ordinais ou quantitativas).

Variáveis qualitativas. Para variáveis nominais e ordinais, as classes são as próprias categorias.

```
f  <- table(pacientes$tabagismo)
fr <- prop.table(f)
data.frame(
  Tabagismo = names(f),
  Absoluta = as.vector(f),
```

```
  `Relativa (%)` = round(100 * as.vector(fr), 1),
  `Acumulada (%)` = round(100 * cumsum(as.vector(fr)), 1),
  check.names = FALSE
)
```

```
##    Tabagismo Absoluta Relativa (%) Acumulada (%)
## 1      Nunca       53         44.2          44.2
## 2 Ex-fumante       41         34.2          78.3
## 3      Atual       26         21.7         100.0
```

Como os níveis do fator tabagismo seguem a ordem natural da variável (nunca, ex-fumante, atual), a frequência acumulada pode ser lida, por exemplo, como a proporção de pacientes "no máximo ex-fumantes". Para uma variável nominal, como o grupo sanguíneo, a coluna acumulada não teria interpretação e deveria ser omitida.

Variáveis quantitativas discretas com poucos valores distintos podem ser tabuladas da mesma forma, valor a valor; por exemplo, o comando `table(pacientes$comorbidades)` conta quantos pacientes têm cada número de comorbidades.

Variáveis quantitativas contínuas precisam ser agrupadas em **classes** (intervalos). Três decisões afetam o resultado: o número de classes, a amplitude de cada uma e a convenção nos limites. A notação $[a, b)$ indica que o limite inferior a pertence à classe e o superior b não; assim, um valor igual a b entra na classe seguinte. Classes devem ser mutuamente exclusivas e cobrir todos os valores. No R, a função `cut()` faz o agrupamento, e o argumento `right = FALSE` adota a convenção $[a, b)$.

```
classes_imc <- cut(pacientes$imc,
                   breaks = c(0, 18.5, 25, 30, 35, Inf),
                   labels = c("< 18,5", "18,5 a < 25", "25 a < 30", "30 a
                    ↪  < 35", "≥ 35"),
                   right = FALSE)
f_imc <- table(classes_imc)
cbind(Absoluta = f_imc,
      `Relativa (%)` = round(100 * prop.table(f_imc), 1),
      `Acumulada (%)` = round(100 * cumsum(prop.table(f_imc)), 1))
```

```
##              Absoluta Relativa (%) Acumulada (%)
## < 18,5              3          2.5           2.5
## 18,5 a < 25        31         25.8          28.3
## 25 a < 30          45         37.5          65.8
## 30 a < 35          35         29.2          95.0
## ≥ 35                6          5.0         100.0
```

Aqui os limites foram escolhidos por critério clínico (as faixas de IMC da Organização Mundial da Saúde). Quando não há pontos de corte consagrados, usam-se regras automáticas para definir o número k de classes de mesma largura. A mais antiga é a **regra de Sturges** (Sturges 1926), $k = \lceil \log_2 n \rceil + 1$, adotada por padrão pela função `hist()` do R. Ela foi derivada supondo dados aproximadamente normais e tende a produzir poucas classes em amostras grandes ou assimétricas. A **regra de Freedman–Diaconis** (Freedman and Diaconis 1981) define a largura das classes como $2 \times \text{AIQ} \times n^{-1/3}$; por usar a AIQ, é menos afetada por valores extremos. Nenhuma regra é ótima para todos os casos: a escolha deve ser feita olhando para os dados, e vale experimentar mais de uma.

5.4.1 Forma da distribuição: assimetria e curtose

Além do centro e da dispersão, a forma de uma distribuição pode ser resumida numericamente.

A **assimetria** (*skewness*) indica se uma das caudas é mais longa que a outra. Um coeficiente comum é o terceiro momento padronizado:

$$g_1 = \frac{\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^3}{\left[\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2\right]^{3/2}}.$$

Como os desvios estão elevados ao cubo, desvios positivos grandes produzem $g_1 > 0$ (assimetria à direita, ou positiva) e desvios negativos grandes produzem $g_1 < 0$ (assimetria à esquerda, ou negativa). Em uma distribuição simétrica, $g_1 \approx 0$.

A **curtose** descreve o peso das caudas da distribuição, isto é, a propensão a produzir valores extremos. É medida pelo quarto momento padronizado; subtraindo 3 (o valor da distribuição normal), obtém-se o **excesso de curtose**, positivo em distribuições de caudas mais pesadas que a normal e negativo em distribuições de caudas mais leves. Ao contrário do que se lê com frequência, a curtose diz respeito sobretudo às caudas, e não ao "achatamento" do pico.

O R básico não tem funções para esses coeficientes (pacotes como `moments` e `e1071` as oferecem), mas elas são fáceis de escrever:

```
assimetria <- function(x) {
  d <- x - mean(x)
  mean(d^3) / mean(d^2)^(3/2)
}
excesso_curtose <- function(x) {
  d <- x - mean(x)
  mean(d^4) / mean(d^2)^2 - 3
}
sapply(pacientes[, c("pas", "imc", "tempo")],
       function(v) c(assimetria = assimetria(v), excesso_curtose =
        ↪  excesso_curtose(v)))
```

```
##                       pas         imc    tempo
## assimetria      0.4281397  0.05948108 1.440942
## excesso_curtose 0.3106469 -0.05234317 2.152642
```

O tempo de internação apresenta assimetria positiva bem maior que a da pressão arterial e do IMC, o que confirma a impressão visual da Figura 5.1. Existem várias versões desses coeficientes (com correções para amostras pequenas), e os programas nem sempre usam a mesma; por isso, valores próximos de zero não devem ser interpretados com excesso de precisão. Esses coeficientes também são instáveis em amostras pequenas e muito sensíveis a valores extremos. Eles complementam, mas não substituem, o exame gráfico.

5.5 Representações gráficas

Um bom gráfico revela o que as medidas resumo escondem: assimetrias, múltiplas modas, valores atípicos, erros de digitação, agrupamentos. O exemplo mais famoso é o **quarteto de Anscombe** (Anscombe 1973): quatro conjuntos de dados, cada um com 11 pares (x, y), que têm praticamente as mesmas médias, variâncias e correlação entre x e y, mas padrões completamente diferentes. Os dados acompanham o R (objeto `anscombe`).

```
resumo_anscombe <- sapply(1:4, function(i) {
  x <- anscombe[[paste0("x", i)]]
  y <- anscombe[[paste0("y", i)]]
  c(media_x = mean(x), media_y = mean(y), var_x = var(x), var_y = var(y),
  ↪  r = cor(x, y))
})
colnames(resumo_anscombe) <- paste("Conjunto", 1:4)
round(resumo_anscombe, 2)
```

```
##         Conjunto 1 Conjunto 2 Conjunto 3 Conjunto 4
## media_x       9.00       9.00       9.00       9.00
## media_y       7.50       7.50       7.50       7.50
## var_x        11.00      11.00      11.00      11.00
## var_y         4.13       4.13       4.12       4.12
## r             0.82       0.82       0.82       0.82
```

```
op <- par(mfrow = c(2, 2), mar = c(4, 4, 2, 1))
for (i in 1:4) {
  x <- anscombe[[paste0("x", i)]]
  y <- anscombe[[paste0("y", i)]]
  plot(x, y, pch = 19, col = "grey30", xlim = c(3, 20), ylim = c(3, 13),
```

```
      main = paste("Conjunto", i), xlab = "x", ylab = "y")
  abline(lm(y ~ x), lty = 2)
}
```

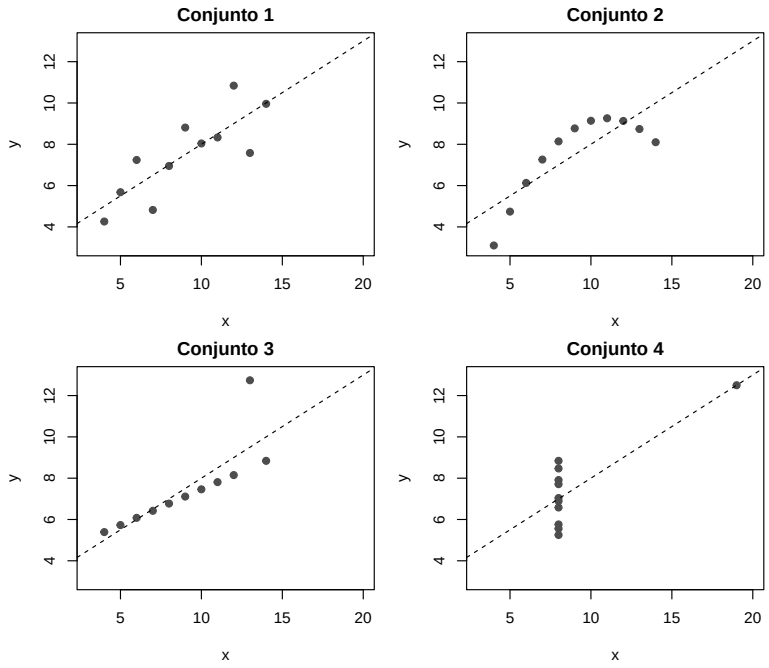


Figura 5.2: Quarteto de Anscombe. Os quatro conjuntos têm médias, variâncias e correlação praticamente iguais, mas padrões muito diferentes.

```
par(op) # restaura os parâmetros gráficos anteriores (layout e margens)
```

Somente o conjunto 1 corresponde ao que as estatísticas resumo sugerem: uma relação linear com dispersão em torno da reta. O conjunto 2 mostra uma relação curva; o conjunto 3, uma relação linear quase perfeita perturbada por um único ponto; o conjunto 4, nenhuma relação, exceto pela influência de um ponto isolado. Por isso, os dados devem ser visualizados antes de serem resumidos.

Alguns princípios gerais orientam a construção de gráficos científicos:

1. **Mostre os dados**, e não apenas resumos. Gráficos de barras com média e barra de erro (às vezes chamados de *dynamite plots*) escondem a distribuição: amostras com distribuições muito diferentes podem gerar barras idênticas. Para variáveis contínuas, especialmente com amostras pequenas, prefira gráficos que mostrem cada observação ou a forma da distribuição (Weissgerber et al. 2015).

2. **Use gráficos de barras para contagens e proporções** de variáveis categóricas, com o eixo vertical começando em zero, já que o comprimento da barra codifica a quantidade.
3. **Rotule os eixos com a variável e a unidade**, e explique na legenda o que cada elemento representa (por exemplo, se a barra de erro é DP, EP ou intervalo de confiança).
4. **Evite efeitos que distorcem a percepção**: perspectiva tridimensional, eixos interrompidos sem aviso, gráficos de pizza com muitas categorias.

5.5.1 Histogramas

O **histograma** é a representação gráfica de uma distribuição de frequências de uma variável quantitativa contínua. O eixo horizontal é dividido em classes contíguas, e sobre cada classe ergue-se um retângulo. Diferentemente do gráfico de barras, não há espaços entre os retângulos, porque as classes cobrem um intervalo contínuo.

Rigorosamente, no histograma é a **área** do retângulo, e não sua altura, que representa a frequência. Quando todas as classes têm a mesma largura, área e altura são proporcionais e a distinção não importa. Com classes de larguras diferentes, o eixo vertical deve mostrar a **densidade** (frequência relativa dividida pela largura da classe), de modo que a área total do histograma seja igual a 1. Em R, `hist(x, freq = FALSE)` produz o histograma em escala de densidade, que permite sobrepor curvas de densidade teóricas.

A aparência de um histograma depende muito do número de classes. A Figura 5.3 mostra o mesmo tempo de internação com três escolhas diferentes.

```
op <- par(mfrow = c(1, 3), mar = c(4, 4, 2, 1))
hist(pacientes$tempo, breaks = 3, col = "grey85", border = "white",
     main = "Poucas classes", xlab = "Dias", ylab = "Frequência")
hist(pacientes$tempo, breaks = "Sturges", col = "grey85", border =
 ↪  "white",
     main = "Regra de Sturges", xlab = "Dias", ylab = "Frequência")
hist(pacientes$tempo, breaks = 40, col = "grey85", border = "white",
     main = "Muitas classes", xlab = "Dias", ylab = "Frequência")
```

```
par(op) # restaura os parâmetros gráficos anteriores (layout e margens)
```

Com poucas classes, a assimetria quase desaparece; com classes demais, o histograma fica fragmentado e sugere irregularidades que são apenas flutuação aleatória. No painel da direita aparecem ainda espaços vazios entre as barras: como o tempo de internação foi registrado em dias inteiros, classes mais estreitas que um dia ficam necessariamente vazias. Em variáveis discretas, as classes

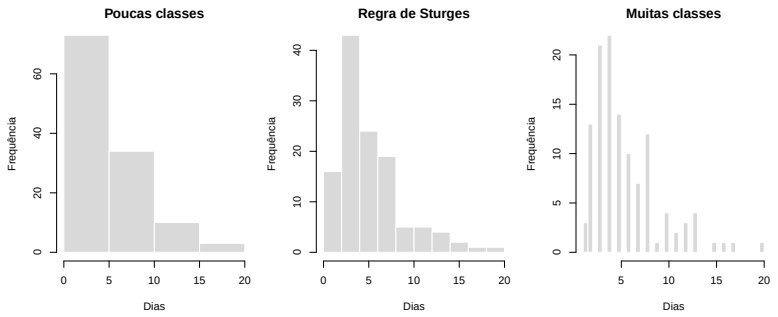


Figura 5.3: O mesmo conjunto de dados (tempo de internação, simulado) representado com diferentes números de classes. Poucas classes ocultam a forma da distribuição; classes demais produzem ruído.

devem ter largura de pelo menos uma unidade, de preferência centradas nos valores possíveis. O argumento `breaks` aceita um número aproximado de classes, um vetor com os limites ou o nome de uma regra (`"Sturges"`, `"FD"`, `"Scott"`). Note que, quando se informa um número, o R o trata como sugestão e escolhe limites "redondos" próximos.

Ao ler um histograma, observe: (i) onde está o centro; (ii) a dispersão; (iii) a forma (simétrica, assimétrica, unimodal, bimodal); (iv) a presença de valores isolados, separados do restante.

5.5.2 Boxplots

O **diagrama de caixa** (*boxplot*), proposto por Tukey (1977), resume uma distribuição em cinco números e destaca valores potencialmente atípicos. Sua construção, na versão mais usada, é a seguinte:

1. a **caixa** vai de Q_1 a Q_3; seu comprimento é a AIQ, e ela contém os 50% centrais dos dados;
2. uma **linha** dentro da caixa marca a mediana;
3. calculam-se as **cercas** (*fences*) inferior e superior: $Q_1 - 1{,}5 \times \text{AIQ}$ e $Q_3 + 1{,}5 \times \text{AIQ}$; as cercas não são desenhadas;
4. as **hastes** (*whiskers*) se estendem da caixa até a observação mais extrema que ainda esteja dentro das cercas;
5. observações além das cercas são desenhadas **individualmente**, como pontos, e sinalizadas como potencialmente atípicas.

No exemplo dos sete pacientes, $Q_1 = 4$, $Q_3 = 7$ e AIQ $= 3$. As cercas ficam em $4 - 4{,}5 = -0{,}5$ e $7 + 4{,}5 = 11{,}5$. A haste superior vai até 8 (o maior valor abaixo de 11,5), e o paciente com 19 dias aparece como ponto isolado.

```
q <- quantile(tempo7, c(0.25, 0.75))
cercas <- c(inferior = q[[1]] - 1.5 * IQR(tempo7), superior = q[[2]] +
 ↪  1.5 * IQR(tempo7))
cercas
```

```
## inferior superior
##     -0.5     11.5
```

```
tempo7[tempo7 < cercas["inferior"] | tempo7 > cercas["superior"]]
```

```
## [1] 19
```

A interpretação exige dois cuidados. Primeiro, o critério de 1,5 × AIQ é uma convenção para chamar atenção, e não uma regra para excluir dados. Em uma distribuição normal, cerca de 0,7% das observações caem além das cercas; em amostras grandes ou distribuições assimétricas, haverá muitos pontos "atípicos" perfeitamente legítimos. Um valor sinalizado deve ser verificado (erro de digitação? unidade trocada? paciente com condição diferente?), e só deve ser removido ou corrigido com justificativa documentada. Segundo, o boxplot esconde a forma da distribuição dentro da caixa: uma distribuição bimodal pode gerar uma caixa idêntica à de uma distribuição unimodal. Também não mostra o tamanho da amostra. Por isso, sobrepor os pontos individuais ao boxplot é uma boa prática, sobretudo com amostras pequenas ou moderadas. McGill, Tukey e Larsen (1978) descreveram variações úteis, como caixas com largura proporcional a $\sqrt{n}$ e entalhes (*notches*) em torno da mediana.

Os boxplots são especialmente úteis para comparar uma variável entre grupos, como na Figura 5.4.

```
boxplot(pas ~ tabagismo, data = pacientes, col = "grey90", outline =
 ↪  FALSE,
        xlab = "Tabagismo", ylab = "Pressão arterial sistólica (mmHg)")
stripchart(pas ~ tabagismo, data = pacientes, vertical = TRUE, method =
 ↪  "jitter",
           jitter = 0.15, pch = 19, col = adjustcolor("grey20", alpha.f =
            ↪  0.5), add = TRUE)
```

O argumento `outline = FALSE` evita que os pontos atípicos sejam desenhados duas vezes, uma pelo `boxplot()` e outra pelo `stripchart()`, que já mostra todas as observações.

5.5.3 Gráficos de dispersão

O **gráfico de dispersão** (*scatter plot*) representa a relação entre duas variáveis quantitativas: cada observação é um ponto, com coordenadas (x_i, y_i). Por con-

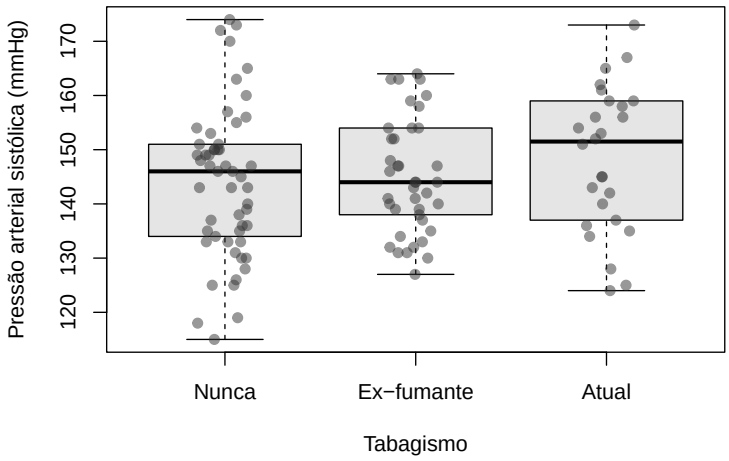


Figura 5.4: Pressão arterial sistólica por categoria de tabagismo (dados simulados). As caixas resumem cada grupo e os pontos mostram as observações individuais.

venção, quando uma variável é considerada explicativa (ou preditora) e a outra resposta, a primeira vai no eixo horizontal e a segunda no vertical.

```
plot(pas ~ imc, data = pacientes, pch = 19, col = adjustcolor("grey20",
 ↪  alpha.f = 0.6),
     xlab = "Índice de massa corporal (kg/m²)", ylab = "Pressão arterial
      ↪  sistólica (mmHg)")
lines(lowess(pacientes$imc, pacientes$pas), lty = 2, lwd = 2)
```

Ao examinar um gráfico de dispersão, procure responder:

1. **Direção**: os valores de y tendem a aumentar (associação positiva) ou a diminuir (associação negativa) à medida que x aumenta?
2. **Forma**: a relação é aproximadamente linear, curva, ou não há padrão?
3. **Intensidade**: os pontos estão concentrados em torno da tendência ou muito dispersos?
4. **Pontos atípicos**: há observações distantes do padrão geral, que possam influenciar desproporcionalmente as análises (como nos conjuntos 3 e 4 de Anscombe)?
5. **Heterogeneidade**: a dispersão de y é semelhante ao longo de todo o eixo x, ou aumenta (formato de funil)?

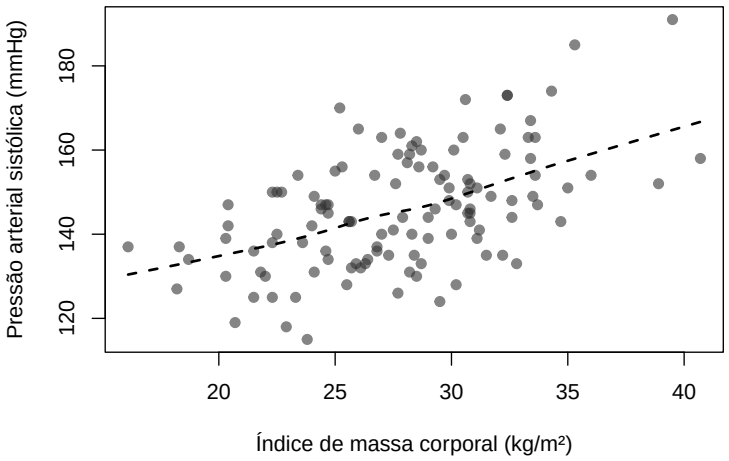


Figura 5.5: Relação entre índice de massa corporal e pressão arterial sistólica (dados simulados). A linha tracejada é uma curva de suavização local, que acompanha a tendência sem impor uma forma linear.

Na Figura 5.5, há uma associação positiva, aproximadamente linear e de intensidade moderada entre IMC e pressão arterial sistólica. A quantificação dessa associação (coeficientes de correlação de Pearson e de Spearman) e sua modelagem (regressão linear) são temas do capítulo *Análise de dados*. Lembre-se também de que associação não implica causalidade: o gráfico de dispersão descreve como as variáveis variam em conjunto, não por que variam.

Quando há muitos pontos sobrepostos, use transparência (como nos exemplos acima, com `adjustcolor()`), pequenos deslocamentos aleatórios (*jitter*) para variáveis discretas, ou gráficos de densidade bidimensional. Para incluir uma terceira variável categórica, varie o símbolo ou a cor dos pontos, sempre com legenda.

5.6 Como relatar estatísticas descritivas

Em artigos originais, as estatísticas descritivas costumam aparecer na primeira tabela, que caracteriza a amostra (a chamada "Tabela 1"). As diretrizes SAMPL (*Statistical Analyses and Methods in the Published Literature*) (Lang and Altman 2015) sistematizam boas práticas de relato. Entre as recomendações aplicáveis à estatística descritiva:

1. **Variáveis aproximadamente normais**: média e desvio padrão, preferencialmente na forma "média (DP)", e não "média ± DP", notação que pode ser confundida com um intervalo.
2. **Variáveis assimétricas ou ordinais**: mediana e amplitude interquartil, ou mediana e quartis, informando qual das duas formas foi usada, por exemplo, "7 (4 a 11) dias" ou "7 [AIQ 7] dias".
3. **Variáveis categóricas**: frequência absoluta e porcentagem, por exemplo, "42 (35,0%)", com o denominador claro sempre que houver dados faltantes.
4. **Não use o erro padrão** para descrever a variabilidade da amostra.
5. **Precisão compatível com os dados**: a média de uma variável medida em números inteiros raramente precisa de mais de uma casa decimal. Porcentagens com uma casa decimal bastam na maioria dos casos; com amostras pequenas (por exemplo, $n < 100$), números inteiros são suficientes.
6. **Informe o número de observações** de cada variável quando houver dados faltantes.

O código a seguir gera um resumo descritivo do conjunto `pacientes` seguindo essas convenções. Pacotes como `gtsummary` e `tableone` automatizam a construção de tabelas desse tipo, mas é instrutivo ver a lógica explicitamente.

```
media_dp <- function(x) sprintf("%s (%s)", num(mean(x)), num(sd(x)))
mediana_q <- function(x) {
  q <- quantile(x, c(0.25, 0.5, 0.75))
  sprintf("%s (%s a %s)", num(q[2], 0), num(q[1], 0), num(q[3], 0))
}
n_pct <- function(x, nivel) sprintf("%d (%s%%)", sum(x == nivel), num(100
 ↪  * mean(x == nivel)))

tabela1 <- data.frame(
  Variavel = c("Idade (anos), média (DP)",
                     "Sexo feminino, n (%)",
                     "IMC (kg/m²), média (DP)",
                     "PAS (mmHg), média (DP)",
                     "Tabagismo atual, n (%)",
                     "Comorbidades, mediana (Q1 a Q3)",
                     "Tempo de internação (dias), mediana (Q1 a Q3)"),
  Valor = c(media_dp(pacientes$idade),
            n_pct(pacientes$sexo, "Feminino"),
            media_dp(pacientes$imc),
            media_dp(pacientes$pas),
            n_pct(pacientes$tabagismo, "Atual"),
            mediana_q(pacientes$comorbidades),
            mediana_q(pacientes$tempo))
)
names(tabela1) <- c("Característica", "Valor")
knitr::kable(tabela1, caption = paste0("Características da amostra
 ↪  simulada (n = ", n, ")."))
```

Tabela 5.3: Características da amostra simulada (n = 120).

Característica	Valor
Idade (anos), média (DP)	61,6 (12,4)
Sexo feminino, n (%)	66 (55,0%)
IMC (kg/m²), média (DP)	27,8 (4,6)
PAS (mmHg), média (DP)	146,0 (13,8)
Tabagismo atual, n (%)	26 (21,7%)
Comorbidades, mediana (Q1 a Q3)	1 (1 a 2)
Tempo de internação (dias), mediana (Q1 a Q3)	5 (3 a 7)

5.7 Resumo do capítulo

- A escala de medida (nominal, ordinal, intervalar, de razão) determina quais medidas descritivas fazem sentido. Códigos numéricos não transformam uma variável categórica em quantitativa.
- A média é o ponto de equilíbrio dos dados e minimiza a soma dos quadrados dos desvios, mas é sensível a valores extremos. A mediana minimiza a soma dos desvios absolutos e é robusta. A moda é a única medida de tendência central aplicável a variáveis nominais.
- A comparação entre média e mediana sugere assimetria, mas a regra "média > mediana implica assimetria à direita" tem exceções.
- A variância amostral divide a soma dos quadrados dos desvios por $n-1$ para ser um estimador não viesado da variância populacional. O desvio padrão está na unidade original dos dados.
- A regra 68–95–99,7% vale apenas para distribuições aproximadamente normais; a desigualdade de Chebyshev vale para qualquer distribuição.
- Desvio padrão descreve a variabilidade entre indivíduos; erro padrão descreve a incerteza de uma estimativa. Não os confunda.
- Quantis amostrais têm várias definições, que podem diferir em amostras pequenas.
- Histogramas, boxplots e gráficos de dispersão devem preceder qualquer resumo numérico. O número de classes de um histograma altera sua aparência; pontos além das cercas do boxplot devem ser investigados, não excluídos automaticamente.
- Relate média (DP) para variáveis aproximadamente simétricas, mediana (AIQ ou quartis) para variáveis assimétricas ou ordinais, e n (%) para variáveis categóricas.

5.8 Exercícios

1. Classifique cada variável quanto à escala de medida (nominal, ordinal, intervalar ou de razão) e, quando quantitativa, como discreta ou contínua: (a) escala visual analógica de dor de 0 a 10, registrada em números inteiros; (b) grupo sanguíneo ABO; (c) número de consultas de pré-natal; (d) glicemia de jejum (mg/dL); (e) estadiamento TNM; (f) temperatura axilar (°C).

2. O tempo de espera, em minutos, de sete pacientes em um pronto-atendimento foi: 12, 15, 15, 18, 20, 22, 45. Calcule à mão e confira no R: (a) média, mediana e moda; (b) variância e desvio padrão amostrais; (c) quartis pelo método padrão do R (tipo 7) e a AIQ; (d) as cercas do boxplot. Algum valor seria sinalizado como potencialmente atípico?

3. Explique, com suas palavras, por que a soma $\sum (x_i - \bar{x})^2$ subestima, em média, $\sum (x_i - \mu)^2$, e como a divisão por $n - 1$ corrige esse problema.

4. Um artigo relata, para 80 pacientes, concentração sérica de PCR de 8,2 $\pm$ 11,5 mg/L. O que esses números sugerem sobre a distribuição da variável? Como você recomendaria relatá-la?

5. Em um estudo com $n = 25$ pacientes, a média da pressão arterial diastólica foi de 82 mmHg, com desvio padrão de 10 mmHg. (a) Calcule o erro padrão da média. (b) Qual das duas medidas você usaria para descrever a variabilidade da pressão entre os pacientes? (c) O que aconteceria, aproximadamente, com cada medida se o estudo tivesse incluído 100 pacientes da mesma população?

6. Dois ambulatórios atenderam, respectivamente, 30 pacientes com hemoglobina glicada média de 7,0% e 10 pacientes com média de 9,0%. Qual é a média dos 40 pacientes? Por que a média simples das duas médias (8,0%) está errada?

7. Compare a variabilidade relativa da massa corporal de adultos (média de 70 kg, DP de 10 kg) com a do peso ao nascer (média de 3,2 kg, DP de 0,5 kg). Por que comparar diretamente os desvios padrão seria inadequado?

8. Usando o objeto `anscombe` do R: (a) confira que os quatro conjuntos têm médias, variâncias e correlações praticamente iguais; (b) faça os gráficos de dispersão; (c) para cada conjunto, descreva em uma frase o que o gráfico revela e o que as medidas resumo esconderam.

5.9 Respostas dos exercícios

1. (a) Ordinal (é comum tratá-la como quantitativa discreta, mas a igualdade das distâncias entre pontos da escala é uma suposição); (b)

nominal; (c) quantitativa discreta, de razão; (d) quantitativa contínua, de razão; (e) ordinal; (f) quantitativa contínua, intervalar.

2. Os dados já foram apresentados em ordem crescente.

   a) Média $= 147/7 = 21$ min; mediana $= x_{(4)} = 18$ min; moda $= 15$ min.
   b) Desvios: $-9, -6, -6, -3, -1, 1, 24$; soma dos quadrados $= 81 + 36 + 36 + 9 + 1 + 1 + 576 = 740$; $s^2 = 740/6 \approx 123{,}3$ min²; $s \approx 11{,}1$ min.
   c) Q_1: $h = 2{,}5$, entre 15 e 15, logo $Q_1 = 15$; Q_3: $h = 5{,}5$, entre 20 e 22, logo $Q_3 = 21$; AIQ $= 6$ min.
   d) Cercas: $15 - 9 = 6$ e $21 + 9 = 30$. O valor 45 está acima da cerca superior e seria sinalizado. Note que ele, sozinho, puxa a média 3 minutos acima da mediana e responde por 576 dos 740 da soma de quadrados.

```
espera <- c(12, 15, 15, 18, 20, 22, 45)
c(media = mean(espera), mediana = median(espera), variancia =
 ↪  var(espera), dp = sd(espera))
```

```
##     media   mediana variancia        dp
##  21.00000  18.00000 123.33333  11.10555
```

```
quantile(espera); IQR(espera)
```

```
##   0%  25%  50%  75% 100%
##   12   15   18   21   45

## [1] 6
```

```
boxplot.stats(espera)$out
```

```
## [1] 45
```

3. A média amostral $\bar{x}$ é, por construção, o número que torna a soma dos quadrados dos desvios a menor possível. Qualquer outro valor, incluindo a média populacional μ, produz uma soma maior ou igual. Assim, medir os desvios em relação a $\bar{x}$ faz os dados parecerem menos dispersos do que realmente são em relação a μ. Em média, a "perda" corresponde exatamente a uma variância (σ^2), de modo que a soma esperada é $(n-1)\sigma^2$; dividindo por $n-1$, recupera-se σ^2 em média.

4. Como a PCR não pode ser negativa e a média (8,2) é menor que o dobro do desvio padrão (23,0), o intervalo média $-$ 2 DP seria negativo. Isso indica forte assimetria à direita: a maioria dos pacientes tem valores baixos e alguns têm valores muito altos. Recomenda-se relatar mediana e quartis (ou AIQ), e, se for necessário um resumo baseado em média, considerar a média geométrica.

5. (a) EP $= 10/\sqrt{25} = 2$ mmHg. (b) O desvio padrão (10 mmHg), pois descreve a variabilidade entre os pacientes. (c) Com $n = 100$, o desvio padrão continuaria em torno de 10 mmHg (é uma característica da população), enquanto o erro padrão cairia para cerca de $10/\sqrt{100} = 1$ mmHg, refletindo uma estimativa mais precisa da média.

6. $\bar{x}_w = (30 \times 7{,}0 + 10 \times 9{,}0)/40 = 300/40 = 7{,}5\%$. A média simples atribui o mesmo peso aos dois ambulatórios, como se ambos tivessem o mesmo número de pacientes; como o primeiro tem três vezes mais pacientes, sua média deve pesar três vezes mais.

7. CV dos adultos $= 10/70 \approx 14{,}3\%$; CV do peso ao nascer $= 0{,}5/3{,}2 \approx 15{,}6\%$. A variabilidade relativa é semelhante, ligeiramente maior no peso ao nascer. Comparar os desvios padrão diretamente (10 kg contra 0,5 kg) seria inadequado porque as médias são de ordens de grandeza muito diferentes: um desvio de 0,5 kg é pequeno para adultos, mas considerável para recém-nascidos.

8. (a) Ver o código da seção *Representações gráficas*: médias de x iguais a 9 e de y próximas de 7,50, variâncias de x iguais a 11 e de y próximas de 4,12, e correlação próxima de 0,82 nos quatro conjuntos. (c) Conjunto 1: relação linear com dispersão aleatória, compatível com os resumos; conjunto 2: relação curva (não linear), que a correlação linear descreve mal; conjunto 3: relação linear quase perfeita, com um único ponto atípico que reduz a correlação; conjunto 4: x praticamente constante, e a correlação depende inteiramente de um único ponto. As medidas resumo esconderam a forma da relação e a influência de pontos isolados.

Capítulo 6

Bioestatística inferencial

Hércules Rezende Freitas, Ph.D.[1]

[1]Universidade do Estado do Rio de Janeiro (UERJ), Faculdade de Ciências Médicas, Departamento de Ciências Médicas Integradas, Laboratório de Informática em Saúde (LabInfoS), Cabo Frio/RJ, Brasil.

No capítulo anterior, descrevemos amostras. Mas raramente o interesse de uma pesquisa está nos 120 pacientes que foram efetivamente estudados. O que se quer saber é algo sobre todos os pacientes com aquela condição: qual é a pressão arterial média de adultos hipertensos tratados, qual é a proporção de complicações após uma cirurgia, se um medicamento reduz a mortalidade. A **inferência estatística** é o conjunto de métodos que permite passar da amostra observada para a população de interesse, quantificando a incerteza envolvida nessa passagem.

Essa incerteza existe porque amostras diferentes, retiradas da mesma população, produzem resultados diferentes. Se repetíssemos um estudo com outros 120 pacientes, a média da pressão arterial não seria exatamente a mesma. A inferência não elimina essa variação; ela a descreve com a linguagem da probabilidade. Por isso, este capítulo começa pelos conceitos de probabilidade, passa pelas distribuições que modelam a variação aleatória e chega às duas ferramentas centrais da inferência: os **intervalos de confiança** e os **testes de hipóteses**.

6.1 População, amostra e variabilidade amostral

A **população** é o conjunto de todas as unidades sobre as quais se deseja concluir algo: todos os adultos com diabetes tipo 2 no Brasil, todas as gestantes atendidas na rede pública de um município, todos os joelhos com osteoartrite grau III. Uma característica numérica da população, como a média μ ou a proporção π, é um **parâmetro**. Parâmetros são fixos, mas desconhecidos.

A **amostra** é o subconjunto da população que é efetivamente observado. Uma característica calculada na amostra, como $\bar{x}$ ou $\hat{p}$, é uma **estatística**. Quando usada para aproximar um parâmetro, a estatística é chamada de **estimador**, e o valor obtido em uma amostra específica, de **estimativa**.

A validade da inferência depende de como a amostra foi obtida. Os métodos deste capítulo partem da suposição de que as observações são uma **amostra aleatória**: cada unidade foi selecionada por um mecanismo que envolve o acaso e que não favorece sistematicamente nenhum subgrupo, e as observações são **independentes** entre si. Na pesquisa clínica, essa suposição raramente é satisfeita de forma literal (pacientes de um único hospital não são um sorteio de todos os pacientes do país), e a pergunta que o pesquisador deve fazer é se a amostra pode ser considerada representativa da população para a qual deseja generalizar. Nenhum método estatístico corrige uma amostra enviesada. Os erros sistemáticos de seleção e de medida são tratados no capítulo *Desenhos de pesquisa*; aqui nos ocupamos do **erro aleatório**.

O erro aleatório se manifesta como **variabilidade amostral**. A simulação a seguir retira cinco amostras de 30 pessoas de uma mesma população (pressão arterial sistólica com média de 130 mmHg e desvio padrão de 15 mmHg) e calcula a média de cada uma.

```
set.seed(10)
medias <- replicate(5, mean(rnorm(30, mean = 130, sd = 15)))
round(medias, 1)
```

```
## [1] 124.8 128.3 129.8 132.5 128.4
```

Nenhuma das médias é igual a 130, e elas diferem entre si, embora venham da mesma população. Toda a inferência estatística consiste em entender o comportamento dessa variação para, a partir de uma única amostra, dizer algo sobre o parâmetro.

6.2 Conceitos de probabilidade

6.2.1 Experimentos aleatórios, eventos e interpretações da probabilidade

Um **experimento aleatório** é um processo cujo resultado não pode ser previsto com certeza, mas cujos resultados possíveis são conhecidos: lançar um dado, sortear um paciente de um cadastro, observar se um recém-nascido terá baixo peso. O conjunto de todos os resultados possíveis é o **espaço amostral** (Ω), e qualquer subconjunto dele é um **evento**. A **probabilidade** de um evento A, $P(A)$, é um número entre 0 e 1 que mede sua chance de ocorrer.

Há duas interpretações principais do que esse número significa. Na **interpretação frequentista**, $P(A)$ é a proporção de vezes que A ocorreria se o experimento fosse repetido indefinidamente nas mesmas condições. Na **interpretação bayesiana**, $P(A)$ representa o grau de crença em A, dado o conhecimento disponível, e pode ser atribuída mesmo a eventos que não se repetem. Os métodos apresentados neste capítulo (intervalos de confiança e valores p) pertencem à tradição frequentista e só podem ser entendidos corretamente nessa interpretação. Os métodos bayesianos são mencionados no capítulo *Tópicos avançados em bioestatística*.

6.2.2 Regras básicas

Qualquer que seja a interpretação, as probabilidades obedecem às mesmas regras, derivadas dos axiomas formulados por Kolmogorov em 1933: (i) $P(A) \geq 0$ para todo evento A; (ii) $P(\Omega) = 1$; (iii) se A e B são **mutuamente exclusivos** (não podem ocorrer juntos), $P(A \cup B) = P(A) + P(B)$. Dessas três regras decorrem as demais.

Complemento. A probabilidade de A não ocorrer é $P(\bar{A}) = 1 - P(A)$. Se a prevalência de hipertensão em uma população é de 25%, a probabilidade de uma pessoa sorteada não ser hipertensa é de 75%.

Adição. Para dois eventos quaisquer,

$$P(A \cup B) = P(A) + P(B) - P(A \cap B).$$

O termo subtraído evita contar duas vezes os indivíduos que pertencem aos dois eventos. Se 25% de uma população têm hipertensão, 10% têm diabetes e 6% têm ambas, a proporção com pelo menos uma das duas doenças é $0{,}25 + 0{,}10 - 0{,}06 = 0{,}29$.

Probabilidade condicional. A probabilidade de A **dado que** B ocorreu é

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)}, \qquad P(B) > 0.$$

Condicionar significa restringir o espaço amostral ao evento B. No exemplo acima, a probabilidade de uma pessoa ter hipertensão, sabendo que tem diabetes, é $0{,}06/0{,}10 = 0{,}60$, bem maior que a probabilidade não condicional de 0,25.

Multiplicação e independência. Reorganizando a definição, $P(A \cap B) = P(A \mid B)\, P(B)$. Dois eventos são **independentes** quando a ocorrência de um não altera a probabilidade do outro, isto é, $P(A \mid B) = P(A)$; nesse caso, e somente nesse caso, $P(A \cap B) = P(A)\, P(B)$. No exemplo, hipertensão e diabetes **não** são independentes, pois $0{,}25 \times 0{,}10 = 0{,}025 \neq 0{,}06$. A suposição de independência entre observações, presente em quase todos os métodos deste capítulo,

é desse tipo: saber o valor de um paciente não deve alterar a distribuição do valor de outro.

> **Cuidado com a inversão do condicional.** $P(A \mid B)$ e $P(B \mid A)$ são, em geral, muito diferentes. A probabilidade de um paciente ter febre dado que tem dengue é alta; a probabilidade de ter dengue dado que tem febre é muito menor. Confundir as duas é um dos erros de raciocínio mais comuns em medicina, e é exatamente o erro de interpretar um valor p como "a probabilidade de a hipótese nula ser verdadeira", como veremos adiante.

6.2.3 Teorema de Bayes e testes diagnósticos

O teorema de Bayes permite inverter probabilidades condicionais:

$$P(A \mid B) = \frac{P(B \mid A)\,P(A)}{P(B)} = \frac{P(B \mid A)\,P(A)}{P(B \mid A)\,P(A) + P(B \mid \bar{A})\,P(\bar{A})}.$$

A aplicação mais importante na prática clínica é a interpretação de testes diagnósticos. Seja D o evento "ter a doença" e T^+ o evento "teste positivo". As propriedades do teste são definidas condicionalmente ao estado de doença:

- **sensibilidade**: $P(T^+ \mid D)$, a proporção de doentes com teste positivo;
- **especificidade**: $P(T^- \mid \bar{D})$, a proporção de não doentes com teste negativo.

O clínico, porém, precisa da probabilidade inversa: dado que o teste deu positivo, qual a chance de o paciente estar doente? Essa é o **valor preditivo positivo** (VPP), $P(D \mid T^+)$, e depende também da **prevalência** $P(D)$.

Considere um teste com sensibilidade de 90% e especificidade de 95%, aplicado em uma população com prevalência de 2%. Pelo teorema de Bayes,

$$\text{VPP} = \frac{0{,}90 \times 0{,}02}{0{,}90 \times 0{,}02 + 0{,}05 \times 0{,}98} = \frac{0{,}018}{0{,}018 + 0{,}049} \approx 0{,}269.$$

Apenas 27% dos positivos estão de fato doentes, apesar de o teste parecer "bom". O mesmo resultado fica mais intuitivo com **frequências naturais** (Tabela 6.1). Em 10.000 pessoas, 200 têm a doença; 90% delas (180) testam positivo. Das 9.800 sem a doença, 5% (490) também testam positivo. Entre os 670 positivos, 180 estão doentes: $180/670 \approx 26{,}9\%$.

O **valor preditivo negativo**, $P(\bar{D} \mid T^-) = 9.310/9.330 \approx 99{,}8\%$, é muito alto. Esse padrão é típico de doenças raras: um teste negativo é tranquilizador, mas um positivo exige confirmação. Se o mesmo teste for aplicado a pacientes com

Tabela 6.1: Teste com sensibilidade de 90% e especificidade de 95% aplicado a 10.000 pessoas com prevalência de 2%.

	Com a doença	Sem a doença	Total
Teste positivo	180	490	670
Teste negativo	20	9.310	9.330
Total	200	9.800	10.000

alta suspeita clínica (prevalência de, digamos, 40%), o VPP sobe para cerca de 92%. Sensibilidade e especificidade são propriedades do teste; os valores preditivos dependem também da população em que ele é usado.

```
vpp <- function(sens, espec, prev) (sens * prev) / (sens * prev + (1 -
 ↪  espec) * (1 - prev))
vpp(0.90, 0.95, prev = c(0.02, 0.10, 0.40))
```

```
## [1] 0.2686567 0.6666667 0.9230769
```

6.2.4 Variáveis aleatórias, esperança e variância

Uma **variável aleatória** é uma regra que associa um número a cada resultado de um experimento aleatório: o número de pacientes com infecção entre 20 operados, a pressão arterial de um adulto sorteado. Usamos letras maiúsculas (X) para a variável aleatória e minúsculas (x) para os valores que ela assume. As variáveis aleatórias são **discretas** ou **contínuas**, como as variáveis do capítulo anterior.

O comportamento de uma variável aleatória é descrito por sua **distribuição de probabilidade**. Duas quantidades resumem essa distribuição e correspondem, na população, à média e à variância que calculamos nas amostras:

- a **esperança** (ou valor esperado), $E(X) = \mu$, é a média de longo prazo de X; para uma variável discreta, $E(X) = \sum_x x\,P(X = x)$;
- a **variância**, $\mathrm{Var}(X) = \sigma^2 = E[(X - \mu)^2]$, e o desvio padrão $\sigma = \sqrt{\mathrm{Var}(X)}$.

Três propriedades serão usadas repetidamente. Para constantes a e b:

1. $E(a + bX) = a + b\,E(X)$ e $\mathrm{Var}(a + bX) = b^2\,\mathrm{Var}(X)$;
2. $E(X + Y) = E(X) + E(Y)$, sempre;
3. $\mathrm{Var}(X + Y) = \mathrm{Var}(X) + \mathrm{Var}(Y)$, **se X e Y forem independentes**.

Da terceira propriedade decorre um resultado central. Se $X_1, \ldots, X_n$ são independentes, todas com variância σ^2, então a média $\bar{X} = \frac{1}{n}\sum X_i$ tem variância

$$\mathrm{Var}(\bar{X}) = \frac{1}{n^2}\sum_{i=1}^{n}\mathrm{Var}(X_i) = \frac{1}{n^2}\cdot n\sigma^2 = \frac{\sigma^2}{n}.$$

O desvio padrão da média amostral, $\sigma/\sqrt{n}$, é o **erro padrão da média**, anunciado no capítulo anterior. Ele mede quanto a média varia de amostra para amostra, e diminui com a raiz quadrada do tamanho amostral: para reduzir o erro padrão à metade, é preciso quadruplicar a amostra.

6.3 Distribuições de probabilidade

Uma distribuição de probabilidade descreve todos os valores que uma variável aleatória pode assumir e com que probabilidade. Para variáveis discretas, ela é dada pela **função de probabilidade**, $P(X = x)$. Para variáveis contínuas, a probabilidade de qualquer valor exato é zero (a chance de a pressão ser exatamente 130,000… mmHg é nula), e a distribuição é dada por uma **função densidade** $f(x)$: a probabilidade de X cair em um intervalo é a **área** sob a curva nesse intervalo. Em ambos os casos, a **função de distribuição acumulada**, $F(x) = P(X \leq x)$, informa a probabilidade de a variável ser menor ou igual a x.

O R oferece quatro funções para cada distribuição, identificadas por um prefixo:

- `d` (densidade ou função de probabilidade), por exemplo `dnorm()`, `dbinom()`;
- `p` (probabilidade acumulada, $F(x)$), por exemplo `pnorm()`;
- `q` (quantil, a função inversa de F), por exemplo `qnorm()`;
- `r` (geração de números aleatórios), por exemplo `rnorm()`.

6.3.1 Distribuição binomial

Muitos desfechos em saúde são binários: óbito ou sobrevivência, cura ou não, presença ou ausência de uma complicação. Considere n tentativas independentes, cada uma com a mesma probabilidade π de "sucesso" (o termo é técnico e pode designar um evento indesejável, como uma infecção). O número X de sucessos segue uma **distribuição binomial**, $X \sim \mathrm{Bin}(n, \pi)$, com

$$P(X = k) = \binom{n}{k}\pi^k(1-\pi)^{n-k}, \qquad k = 0, 1, \ldots, n,$$

em que $\binom{n}{k} = \frac{n!}{k!\,(n-k)!}$ conta de quantas maneiras os k sucessos podem se distribuir entre as n tentativas. A esperança é $n\pi$ e a variância, $n\pi(1-\pi)$.

Se a taxa de infecção de sítio cirúrgico em um serviço é de 5%, qual a probabilidade de, em 20 cirurgias, ocorrerem 3 ou mais infecções?

```
1 - pbinom(2, size = 20, prob = 0.05)   # P(X >= 3) = 1 - P(X <= 2)
```

```
## [1] 0.07548367
```

A probabilidade é de cerca de 7,5%. Observar três infecções em 20 cirurgias não é, portanto, um evento extraordinário, mesmo que a taxa verdadeira seja de 5%. Esse tipo de raciocínio ("quão surpreendente seria este resultado se…") é exatamente a lógica dos testes de hipóteses.

6.3.2 Distribuição normal

A **distribuição normal** (ou gaussiana) é a distribuição contínua mais importante da estatística. Sua densidade tem a forma de sino, simétrica em torno da média:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left[-\frac{(x-\mu)^2}{2\sigma^2}\right], \qquad -\infty < x < \infty.$$

A distribuição fica inteiramente determinada por dois parâmetros, a média μ e o desvio padrão σ, e escrevemos $X \sim N(\mu, \sigma^2)$. A média, a mediana e a moda coincidem em μ; o desvio padrão é a distância entre a média e os pontos de inflexão da curva.

Toda variável normal pode ser convertida na **normal padrão**, $Z \sim N(0,1)$, pela **padronização**

$$Z = \frac{X - \mu}{\sigma},$$

que expressa cada valor como o número de desvios padrão acima ou abaixo da média (o "escore z"). As probabilidades da normal padrão dão origem à regra empírica vista no capítulo anterior: cerca de 68,3% da área está entre -1 e 1, 95% entre $-1{,}96$ e 1,96 e 99,7% entre -3 e 3.

Suponha que a pressão sistólica de adultos de uma população siga aproximadamente $N(120, 15^2)$ mmHg. A proporção com pressão acima de 140 mmHg corresponde a $z = (140-120)/15 \approx 1{,}33$, e a proporção entre 100 e 140 mmHg corresponde a $-1{,}33 < z < 1{,}33$:

```r
1 - pnorm(140, mean = 120, sd = 15)                                    # P(X > 140)
```

```
## [1] 0.09121122
```

```r
pnorm(140, mean = 120, sd = 15) - pnorm(100, mean = 120, sd = 15)  #
 ↪  P(100 < X < 140)
```

```
## [1] 0.8175776
```

```r
qnorm(0.975)                                                           # quantil
 ↪  97,5% da normal padrão
```

```
## [1] 1.959964
```

Cerca de 9,1% da população teria pressão acima de 140 mmHg, e 81,8% estaria entre 100 e 140 mmHg. O valor 1,96, que reaparecerá muitas vezes, é o quantil que deixa 2,5% da área em cada cauda da normal padrão.

Por que a normal é tão importante? Não porque a maioria das variáveis biológicas seja normal. Muitas não são: concentrações de biomarcadores, tempos de internação e custos são, em geral, assimétricos. A importância da normal vem de outro lugar: ela descreve a distribuição de **médias** e de muitas outras estatísticas calculadas em amostras suficientemente grandes, como mostra o teorema a seguir.

6.3.2.1 Avaliando a normalidade dos dados

Quando um método supõe normalidade, a ferramenta mais informativa para avaliá-la é o **gráfico quantil-quantil** (Q-Q plot), que compara os quantis observados com os quantis esperados de uma normal. Se os dados forem aproximadamente normais, os pontos se alinham ao longo de uma reta; caudas pesadas ou assimetria aparecem como curvaturas nas extremidades (Figura 6.1).

```r
set.seed(3)
x_normal <- rnorm(100, mean = 120, sd = 15)
x_assim  <- rlnorm(100, meanlog = log(5), sdlog = 0.7)
op <- par(mfrow = c(1, 2), mar = c(4, 4, 2, 1))
qqnorm(x_normal, main = "Normal", pch = 19, col = "grey30");
 ↪  qqline(x_normal)
qqnorm(x_assim, main = "Assimétrica", pch = 19, col = "grey30");
 ↪  qqline(x_assim)
```

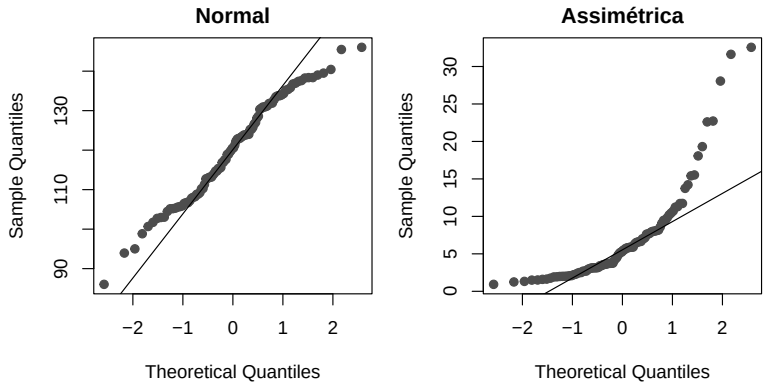


Figura 6.1: Gráficos quantil-quantil para uma amostra simulada de distribuição normal (esquerda) e de distribuição assimétrica à direita (direita).

```
par(op)
```

Testes formais de normalidade (Shapiro–Wilk, Kolmogorov–Smirnov) existem, mas devem ser usados com cautela. Em amostras pequenas, eles têm pouco poder e raramente rejeitam a normalidade, mesmo quando ela é questionável; em amostras grandes, rejeitam desvios mínimos, que não têm consequência prática alguma, justamente quando o teorema central do limite torna a suposição menos importante. Por fim, usar um teste de normalidade para decidir entre um teste paramétrico e um não paramétrico altera as taxas de erro do procedimento como um todo (Rochon et al. 2012). A decisão deve ser tomada preferencialmente antes de ver os dados, com base no conhecimento sobre a variável e no desenho do estudo.

6.3.3 O teorema central do limite

O **teorema central do limite** (TCL) afirma que, se $X_1, \ldots, X_n$ são observações independentes de uma população com média μ e variância finita σ^2, a distribuição da média amostral $\bar{X}$ se aproxima de uma normal à medida que n cresce:

$$\bar{X} \;\approx\; N\left(\mu,\, \frac{\sigma^2}{n}\right) \quad \text{para } n \text{ grande},$$

qualquer que seja a forma da distribuição original. A distribuição de uma estatística ao longo de todas as amostras possíveis é chamada de **distribuição amostral** dessa estatística, e o TCL diz que a distribuição amostral da média é aproximadamente normal.

A Figura 6.2 ilustra o teorema com uma população fortemente assimétrica (distribuição exponencial com média 5, que poderia representar o tempo até um evento). Para cada tamanho amostral, sorteamos 10.000 amostras e construímos o histograma das 10.000 médias.

```
set.seed(42)
op <- par(mfrow = c(1, 3), mar = c(4, 4, 2, 1))
for (n_tcl in c(1, 5, 30)) {
  medias_tcl <- replicate(10000, mean(rexp(n_tcl, rate = 1/5)))
  hist(medias_tcl, breaks = 40, freq = FALSE, col = "grey85", border =
   ↪  "white",
       main = paste("n =", n_tcl), xlab = "Média amostral", ylab =
        ↪  "Densidade")
  if (n_tcl > 1) curve(dnorm(x, mean = 5, sd = 5 / sqrt(n_tcl)), add =
   ↪  TRUE, lwd = 2)
}
```

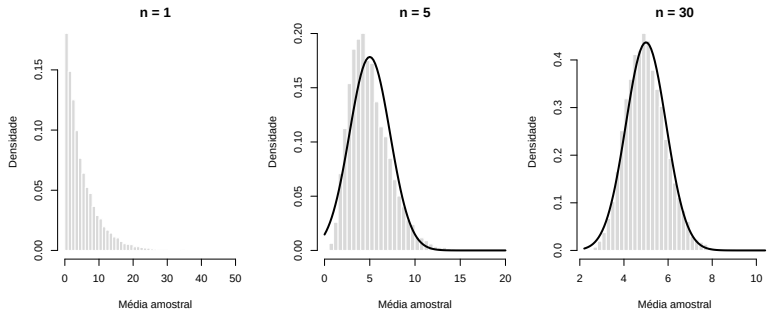


Figura 6.2: Teorema central do limite. Histogramas de 10.000 médias amostrais de uma população exponencial (média 5). Com n = 1, o histograma reproduz a população; à medida que n cresce, as médias se concentram em torno de 5 e sua distribuição se aproxima da normal (curva).

```
par(op)
```

Três observações sobre o teorema evitam interpretações equivocadas.

1. **O TCL fala da distribuição da média, não dos dados.** Aumentar a amostra não torna os dados "mais normais"; um histograma de 10.000 tempos de internação continuará assimétrico. O que se torna normal é a distribuição das médias de amostras repetidas.
2. **"Grande" depende da população.** A regra popular de "$n \geq 30$" é uma aproximação grosseira. Para populações simétricas, amostras pequenas já bastam; para populações muito assimétricas ou com caudas pesadas, podem ser necessárias centenas de observações.

3. **O TCL não protege contra amostras enviesadas ou observações dependentes.** Ele supõe independência e trata apenas do erro aleatório.

O TCL é o que justifica o uso de métodos baseados na normal (e na distribuição t) para fazer inferência sobre médias e proporções, mesmo quando os dados originais não são normais.

6.3.4 Distribuição t de Student

Para usar o TCL na prática, precisaríamos conhecer σ, o desvio padrão da população, para calcular o erro padrão $\sigma/\sqrt{n}$. Quase sempre σ é desconhecido e o substituímos pelo desvio padrão amostral s. Essa substituição acrescenta incerteza, porque s também varia de amostra para amostra, e a estatística padronizada deixa de ter distribuição normal.

O problema foi resolvido em 1908 por William Sealy Gosset, químico da cervejaria Guinness em Dublin, que publicou sob o pseudônimo "Student" (Student 1908). Se as observações vêm de uma distribuição normal, a estatística

$$T = \frac{\bar{X} - \mu}{s/\sqrt{n}}$$

segue uma **distribuição t de Student com $n-1$ graus de liberdade**, denotada t_{n-1}. A quantidade $s/\sqrt{n}$ é o **erro padrão estimado** da média.

A distribuição t é simétrica em torno de zero, como a normal padrão, mas tem **caudas mais pesadas**: valores extremos são mais prováveis, refletindo a incerteza adicional sobre σ. Ela depende de um único parâmetro, os graus de liberdade (gl). Quanto maior o número de graus de liberdade, mais s se aproxima de σ e mais a t se aproxima da normal padrão (Figura 6.3).

```
curve(dnorm(x), from = -4, to = 4, lwd = 2, ylab = "Densidade", xlab =
 ↪  "Valor")
curve(dt(x, df = 2), add = TRUE, lwd = 2, lty = 3)
curve(dt(x, df = 10), add = TRUE, lwd = 2, lty = 2, col = "grey50")
legend("topright", bty = "n", lwd = 2, lty = c(1, 2, 3), col = c("black",
 ↪  "grey50", "black"),
       legend = c("Normal padrão", "t com 10 gl", "t com 2 gl"))
```

O efeito prático aparece nos quantis usados para construir intervalos de 95%. Na normal, usamos 1,96; na t, o valor é maior, especialmente com amostras pequenas:

```
gl <- c(2, 5, 10, 30, 100)
data.frame(gl = gl, quantil_t_97.5 = round(qt(0.975, df = gl), 3))
```

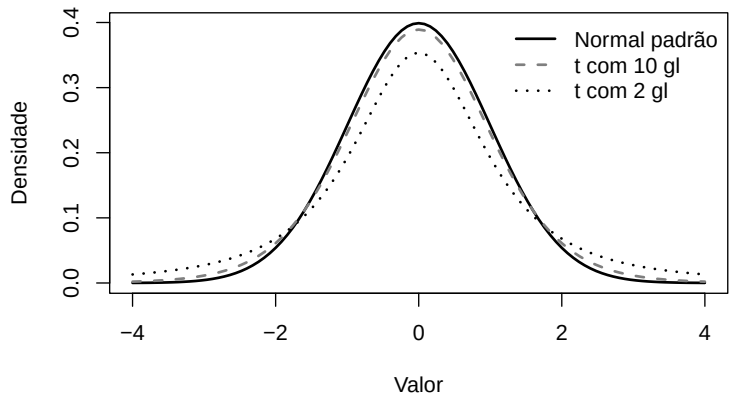


Figura 6.3: Densidades da distribuição t de Student para 2 e 10 graus de liberdade, comparadas com a normal padrão. Com poucos graus de liberdade, as caudas são mais pesadas.

```
##    gl quantil_t_97.5
## 1   2          4.303
## 2   5          2.571
## 3  10          2.228
## 4  30          2.042
## 5 100          1.984
```

Com 5 graus de liberdade (amostra de 6 observações), o quantil é 2,571; com 100 graus de liberdade, já é praticamente igual ao da normal.

A distribuição t é exata quando os dados são normais. Quando não são, ela continua sendo uma boa aproximação para inferência sobre médias se a amostra for moderada ou grande (graças ao TCL) e se a assimetria não for extrema. Com amostras muito pequenas de dados claramente assimétricos, os métodos baseados na t podem ser enganosos.

6.3.5 Distribuição qui-quadrado

Se $Z_1, \ldots, Z_k$ são variáveis normais padrão independentes, a soma de seus quadrados,

$$Q = Z_1^2 + Z_2^2 + \cdots + Z_k^2,$$

segue uma **distribuição qui-quadrado com k graus de liberdade**, χ^2_k. Como é uma soma de quadrados, só assume valores positivos. Sua média é k e sua variância é $2k$. Com poucos graus de liberdade, é fortemente assimétrica à direita; à medida que k cresce, torna-se mais simétrica (Figura 6.4).

```
curve(dchisq(x, df = 1), from = 0.05, to = 20, ylim = c(0, 0.5), lwd =
↪  2,
      xlab = "Valor", ylab = "Densidade")
curve(dchisq(x, df = 3), add = TRUE, lwd = 2, lty = 2)
curve(dchisq(x, df = 5), add = TRUE, lwd = 2, lty = 3)
curve(dchisq(x, df = 10), add = TRUE, lwd = 2, col = "grey50")
legend("topright", bty = "n", lwd = 2, lty = c(1, 2, 3, 1), col =
↪  c(rep("black", 3), "grey50"),
       legend = paste(c(1, 3, 5, 10), "gl"))
```

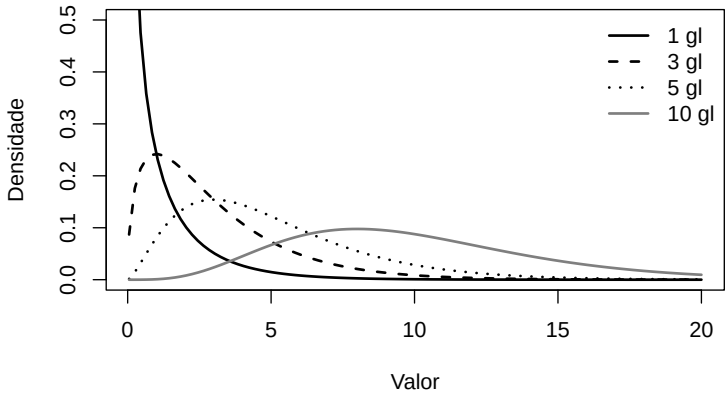


Figura 6.4: Densidades da distribuição qui-quadrado com 1, 3, 5 e 10 graus de liberdade.

A distribuição qui-quadrado aparece em dois contextos neste livro. O primeiro é a inferência sobre variâncias: se os dados são normais, $(n-1)s^2/\sigma^2 \sim \chi^2_{n-1}$. O segundo, mais frequente na pesquisa em saúde, é o **teste qui-quadrado de Pearson** para tabelas de contingência, apresentado na seção de testes paramétricos. A distribuição F, usada na análise de variância, é construída a partir da razão de duas qui-quadrado e é apresentada no capítulo *Análise de dados*.

6.4 Estimação e intervalos de confiança

6.4.1 Estimação pontual

Um **estimador pontual** produz um único número como aproximação do parâmetro: $\bar{x}$ para μ, s^2 para σ^2, $\hat{p}$ para π. Um bom estimador deve ter duas propriedades:

- **ausência de viés**: em média, ao longo de amostras repetidas, acerta o parâmetro. Formalmente, $E(\hat{\theta}) = \theta$. Vimos no capítulo anterior que s^2, com divisor $n-1$, é não viesado para σ^2;
- **precisão**: varia pouco de amostra para amostra, ou seja, tem erro padrão pequeno.

Uma estimativa pontual sozinha, porém, não diz nada sobre a sua confiabilidade. Uma média de 132 mmHg calculada com 10 pacientes merece muito menos confiança do que a mesma média calculada com 10.000. Por isso, toda estimativa deve vir acompanhada de uma medida da sua incerteza, de preferência um intervalo de confiança.

6.4.2 Intervalo de confiança para a média

Pelo resultado da seção anterior, se os dados são normais (ou a amostra é grande o suficiente),

$$P\left(-t_{n-1;\,0{,}975} \leq \frac{\bar{X}-\mu}{s/\sqrt{n}} \leq t_{n-1;\,0{,}975}\right) = 0{,}95,$$

em que $t_{n-1;\,0{,}975}$ é o quantil 97,5% da distribuição t com $n-1$ graus de liberdade. Isolando μ dentro das desigualdades, obtém-se o **intervalo de confiança (IC) de 95% para a média**:

$$\bar{x} \pm t_{n-1;\,0{,}975}\,\frac{s}{\sqrt{n}}. \tag{6.1}$$

A quantidade $t_{n-1;\,0{,}975}\,s/\sqrt{n}$ é a **margem de erro**. Para outros níveis de confiança, troca-se o quantil: para 90%, usa-se o quantil 95%; para 99%, o quantil 99,5%.

Exemplo resolvido. Em 16 pacientes hipertensos tratados, a pressão sistólica média foi de 132 mmHg, com desvio padrão de 12 mmHg. O erro padrão é $12/\sqrt{16} = 3$ mmHg. Com 15 graus de liberdade, $t_{15;\,0{,}975} = 2{,}131$. A margem de erro é $2{,}131 \times 3 = 6{,}39$ mmHg, e o IC de 95% vai de $132 - 6{,}39 = 125{,}6$ a $132 + 6{,}39 = 138{,}4$ mmHg.

```
xbar <- 132; s <- 12; n_ic <- 16
ep <- s / sqrt(n_ic)
xbar + c(-1, 1) * qt(0.975, df = n_ic - 1) * ep
```

```
## [1] 125.6057 138.3943
```

Com os dados brutos, a função `t.test()` calcula o intervalo diretamente: `t.test(x)$conf.int`.

6.4.3 Como interpretar (e como não interpretar) um intervalo de confiança

A interpretação correta do IC de 95% é sutil. Na abordagem frequentista, o parâmetro μ é fixo; o que varia de amostra para amostra é o intervalo. O "95%" é uma propriedade do **procedimento**: se o estudo fosse repetido muitas vezes e, em cada repetição, um intervalo fosse calculado pela Equação (6.1), cerca de 95% desses intervalos conteriam o verdadeiro valor de μ. Essa proporção de longo prazo é a **cobertura** do intervalo.

A Figura 6.5 mostra essa ideia com 100 amostras simuladas de uma população com $\mu = 130$ mmHg.

```
set.seed(2025)
ics <- t(replicate(100, t.test(rnorm(20, mean = 130, sd = 15))$conf.int))
cobre <- ics[, 1] <= 130 & ics[, 2] >= 130
plot(NA, xlim = range(ics), ylim = c(1, 100), yaxt = "n",
     xlab = "Pressão arterial sistólica (mmHg)", ylab = "Amostras")
segments(ics[, 1], 1:100, ics[, 2], 1:100,
         col = ifelse(cobre, "black", "grey55"), lwd = ifelse(cobre, 1,
          ↪ 3))
abline(v = 130, lty = 2)
```

```
sum(cobre)
```

```
## [1] 97
```

Nesta simulação, 97 dos 100 intervalos contêm a média verdadeira. Em uma pesquisa real, temos apenas um desses intervalos e não sabemos se ele é um dos que acertaram. O que sabemos é que ele foi produzido por um método que acerta em 95% das vezes.

Algumas interpretações comuns são **incorretas** (Greenland et al. 2016):

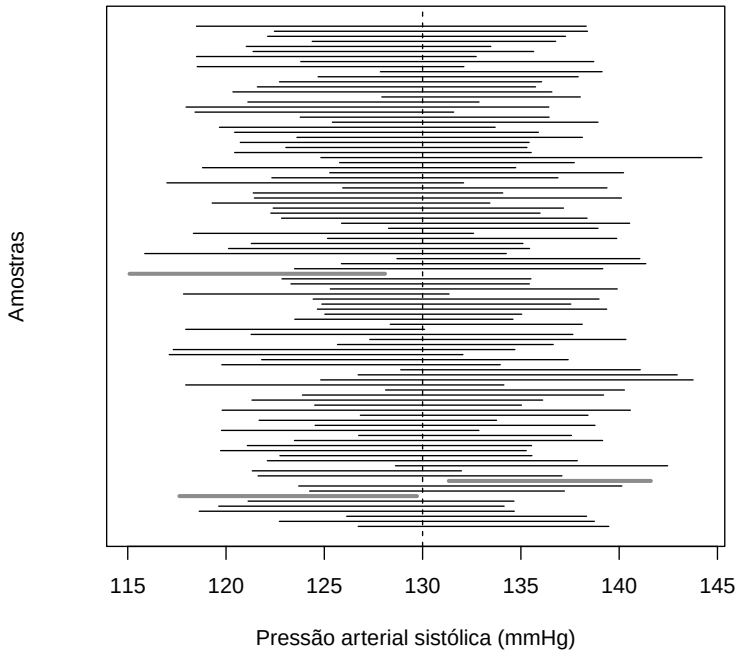


Figura 6.5: Intervalos de confiança de 95% calculados em 100 amostras simuladas (n = 20) de uma população com média 130 mmHg (linha vertical). Os intervalos em preto contêm a média verdadeira; os destacados com linha mais espessa e cinza, não.

- "Há 95% de probabilidade de μ estar no intervalo calculado." Depois que os dados foram coletados, o intervalo calculado contém ou não contém μ; na abordagem frequentista, não se atribui probabilidade a um parâmetro fixo. (Essa interpretação é possível na abordagem bayesiana, com intervalos de credibilidade, que exigem outro tipo de cálculo.)
- "95% dos pacientes têm valores dentro do intervalo." O IC é sobre a **média**, não sobre os indivíduos. A faixa que contém a maioria dos indivíduos é muito mais larga e depende do desvio padrão, não do erro padrão.
- "Valores dentro do intervalo são igualmente plausíveis." Valores próximos da estimativa pontual são mais compatíveis com os dados do que valores próximos dos limites.

Uma leitura útil e correta é a seguinte: o IC de 95% é o conjunto de valores do parâmetro que são razoavelmente **compatíveis com os dados**, sob as suposições do modelo. Isso se conecta diretamente aos testes de hipóteses, como veremos adiante.

Largura do intervalo. Pela Equação (6.1), a largura depende de três fatores: aumenta com o nível de confiança, aumenta com a variabilidade dos dados (s) e diminui com o tamanho da amostra, na proporção de $1/\sqrt{n}$. Um intervalo estreito indica estimativa precisa; um intervalo largo indica que os dados são compatíveis com valores muito diferentes do parâmetro e, portanto, que o estudo informa pouco.

6.4.4 Intervalo de confiança para uma proporção

Para uma variável binária, o parâmetro é a proporção populacional π, estimada por $\hat{p} = x/n$, em que x é o número de eventos. O erro padrão estimado de $\hat{p}$ é $\sqrt{\hat{p}(1-\hat{p})/n}$, e o intervalo mais conhecido, chamado **intervalo de Wald**, é

$$\hat{p} \pm 1{,}96\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}.$$

Apesar de estar em muitos livros, o intervalo de Wald tem desempenho ruim: sua cobertura real pode ficar muito abaixo de 95%, sobretudo quando n é pequeno ou $\hat{p}$ está perto de 0 ou de 1, e ele pode produzir limites negativos ou maiores que 1 (Brown et al. 2001). Quando $x = 0$, o intervalo de Wald tem largura zero, uma conclusão absurda. Recomenda-se o **intervalo de Wilson** (Wilson 1927; Agresti and Coull 1998), que não tem essas deficiências e é o que a função `prop.test()` do R calcula (com `correct = FALSE`, para dispensar a correção de continuidade). O intervalo **exato de Clopper–Pearson**, calculado por `binom.test()`, garante cobertura de pelo menos 95%, mas tende a ser mais largo que o necessário.

Exemplo. Em 80 pacientes operados, 12 tiveram complicação: $\hat{p} = 12/80 = 0{,}15$.

```r
x_ev <- 12; n_prop <- 80
p_hat <- x_ev / n_prop
p_hat + c(-1, 1) * qnorm(0.975) * sqrt(p_hat * (1 - p_hat) / n_prop)  # Wald
```

```
## [1] 0.07175471 0.22824529
```

```r
prop.test(x_ev, n_prop, correct = FALSE)$conf.int                      # Wilson
```

```
## [1] 0.08794041 0.24413229
## attr(,"conf.level")
## [1] 0.95
```

```r
binom.test(x_ev, n_prop)$conf.int                                      # Clopper-Pearson
```

```
## [1] 0.07998156 0.24736411
## attr(,"conf.level")
## [1] 0.95
```

Os três intervalos são, respectivamente, de 7,2% a 22,8% (Wald), de 8,8% a 24,4% (Wilson) e de 8,0% a 24,7% (Clopper–Pearson). Note que o intervalo de Wilson não é simétrico em torno de 15%: como as proporções são limitadas em zero, a incerteza se estende mais para cima do que para baixo, o que é mais realista.

6.5 Testes de hipóteses

6.5.1 A lógica do teste

Um teste de hipóteses avalia se os dados são compatíveis com uma afirmação específica sobre a população. A estrutura é a de um argumento por contradição: supomos que uma hipótese seja verdadeira e verificamos se os dados observados seriam surpreendentes sob essa suposição.

1. **Hipótese nula** (H_0): a afirmação que será testada, em geral de "ausência de efeito" ou "ausência de diferença" (por exemplo, $\mu_1 = \mu_2$, ou a diferença de risco entre dois grupos é zero).
2. **Hipótese alternativa** (H_1): o que se aceita como plausível se H_0 for rejeitada (por exemplo, $\mu_1 \neq \mu_2$).

Tabela 6.2: Decisões e erros em um teste de hipóteses.

Decisão	H0 verdadeira	H0 falsa
Rejeitar H0	Erro tipo I (probabilidade α)	Decisão correta: poder $(1-\beta)$
Não rejeitar H0	Decisão correta $(1-\alpha)$	Erro tipo II (probabilidade β)

3. **Estatística de teste**: um número calculado a partir dos dados que mede o afastamento entre o que foi observado e o que H_0 prevê, em geral na forma

$$\text{estatística} = \frac{\text{estimativa} - \text{valor sob } H_0}{\text{erro padrão da estimativa}}.$$

4. **Distribuição nula**: a distribuição da estatística de teste se H_0 for verdadeira (normal, t, qui-quadrado…).

5. **Valor *p***: a probabilidade, calculada supondo H_0 verdadeira e todas as demais suposições do modelo corretas, de obter uma estatística de teste **tão extrema quanto, ou mais extrema que,** a observada.

Um valor p pequeno indica que os dados seriam incomuns se H_0 (e o modelo) fossem verdadeiros; um valor p grande indica que os dados são compatíveis com H_0, o que **não** é o mesmo que demonstrar que H_0 é verdadeira.

Hipóteses bilaterais e unilaterais. Na hipótese alternativa bilateral ($\mu_1 \neq \mu_2$), afastamentos nas duas direções contam como evidência contra H_0, e o valor p soma as duas caudas da distribuição nula. Na unilateral ($\mu_1 > \mu_2$), apenas uma direção conta. Testes unilaterais só se justificam quando um efeito na direção oposta seria tratado exatamente como ausência de efeito, e essa decisão precisa ser registrada antes da coleta de dados. Na pesquisa clínica, o padrão é o teste bilateral.

6.5.2 Erros, nível de significância e poder

Na abordagem de decisão proposta por Neyman e Pearson, fixa-se de antemão um **nível de significância** α (tradicionalmente 0,05) e rejeita-se H_0 quando $p \leq \alpha$. Como a decisão é tomada com dados sujeitos a erro aleatório, dois tipos de erro são possíveis (Tabela 6.2).

- O **erro tipo I** é rejeitar H_0 quando ela é verdadeira (um "falso positivo"). Sua probabilidade é controlada pelo pesquisador e é igual a α.

- O **erro tipo II** é não rejeitar H_0 quando ela é falsa (um "falso negativo"). Sua probabilidade, β, depende do tamanho real do efeito, da variabilidade dos dados, do tamanho da amostra e de α.
- O **poder** do teste, $1 - \beta$, é a probabilidade de detectar um efeito de determinado tamanho, se ele existir.

O poder deve ser planejado antes do estudo, e essa é a base do cálculo de tamanho amostral. Por exemplo, para detectar com poder de 80% e $\alpha = 0{,}05$ uma diferença de 5 mmHg entre as médias de dois grupos, quando o desvio padrão é de 12 mmHg:

```
power.t.test(delta = 5, sd = 12, sig.level = 0.05, power = 0.80)
```

```
##
##      Two-sample t test power calculation
##
##               n = 91.38944
##           delta = 5
##              sd = 12
##       sig.level = 0.05
##           power = 0.8
##     alternative = two.sided
##
## NOTE: n is number in *each* group
```

São necessários cerca de 92 pacientes por grupo. Um estudo com poder baixo tem alta probabilidade de não detectar efeitos reais e, quando detecta um efeito "significativo", tende a superestimar seu tamanho.

6.5.3 O que o valor *p* não é

O valor p é provavelmente a quantidade mais mal interpretada da estatística aplicada. Em 2016, a American Statistical Association publicou uma declaração com seis princípios sobre o tema (Wasserstein and Lazar 2016), e Greenland e colaboradores (2016) catalogaram dezenas de interpretações equivocadas. As mais importantes são:

1. **O valor *p* não é a probabilidade de H_0 ser verdadeira.** Ele é calculado *supondo* que H_0 é verdadeira; é uma probabilidade sobre os dados, dada a hipótese, e não sobre a hipótese, dados os dados. Confundir as duas é o mesmo erro de inverter o condicional discutido na seção de probabilidade.
2. **O valor *p* não mede o tamanho nem a importância de um efeito.** Com uma amostra grande, uma diferença clinicamente irrelevante (1 mmHg na pressão arterial) pode produzir $p < 0{,}001$; com uma amostra pequena, uma diferença clinicamente importante pode produzir $p = 0{,}30$.

3. $p > 0{,}05$ **não demonstra ausência de efeito.** "Ausência de evidência não é evidência de ausência." Um resultado não significativo com intervalo de confiança largo é inconclusivo, não negativo.
4. **O limiar de 0,05 é uma convenção.** Um resultado com $p = 0{,}049$ e outro com $p = 0{,}051$ fornecem praticamente a mesma evidência. Relatar o valor p exato (por exemplo, $p = 0{,}04$, e não "$p < 0{,}05$" ou "NS") e não tratar o limiar como uma fronteira entre verdade e falsidade são boas práticas.
5. **O valor *p* depende de todas as suposições do modelo**, não apenas de H_0. Violação de independência, dados enviesados ou análises escolhidas depois de ver os dados (testar várias variáveis e relatar apenas as significativas) invalidam o valor p.

Por essas razões, a recomendação atual é relatar sempre a **estimativa do efeito com seu intervalo de confiança**, usando o valor p como informação complementar.

Relação entre testes e intervalos. Há uma correspondência exata entre o teste bilateral com nível α e o IC de $100(1-\alpha)\%$ construído pelo mesmo método: $H_0\colon \mu = \mu_0$ é rejeitada a 5% se, e somente se, μ_0 estiver fora do IC de 95%. O intervalo, porém, informa mais: mostra todos os valores compatíveis com os dados, e não apenas se um valor específico foi ou não rejeitado.

Comparações múltiplas. Se forem realizados 20 testes independentes, cada um com $\alpha = 0{,}05$, e todas as hipóteses nulas forem verdadeiras, a probabilidade de pelo menos um resultado "significativo" por acaso é $1-0{,}95^{20} \approx 64\%$. Quando muitos testes são realizados, é preciso definir de antemão o desfecho principal ou ajustar os valores p (por exemplo, pelo método de Bonferroni, que compara cada valor p com α/m, sendo m o número de testes, ou por métodos menos conservadores, como o de Holm, disponíveis na função `p.adjust()`).

6.5.4 Testes paramétricos

Testes **paramétricos** supõem que os dados (ou as estatísticas calculadas a partir deles) seguem uma distribuição de forma conhecida, caracterizada por parâmetros, como a normal. Apresentamos a seguir os testes mais usados para comparar médias e proporções. A comparação de três ou mais médias (análise de variância) e a análise da associação entre variáveis quantitativas (correlação e regressão) são tratadas no capítulo *Análise de dados*.

6.5.4.1 Teste t para uma amostra e para amostras pareadas

O **teste t para uma amostra** compara a média de uma população com um valor de referência μ_0. A estatística é

Tabela 6.3: Pressão arterial sistólica (mmHg) antes e depois da intervenção (dados fictícios).

Paciente	Antes	Depois	Diferença
1	152	144	8
2	148	146	2
3	160	151	9
4	145	148	-3
5	170	158	12
6	158	151	7
7	150	149	1
8	165	152	13

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}},$$

que, sob $H_0 : \mu = \mu_0$, segue a distribuição t_{n-1}.

O **teste t pareado** se aplica quando cada observação de um grupo está naturalmente ligada a uma observação do outro: o mesmo paciente medido antes e depois de um tratamento, os dois olhos de um mesmo paciente, gêmeos. O pareamento é aproveitado calculando, para cada par, a diferença d_i, e aplicando o teste t para uma amostra às diferenças, com $H_0 : \mu_d = 0$. Ignorar o pareamento e analisar os dados como dois grupos independentes desperdiça informação e, em geral, reduz o poder.

Exemplo resolvido. A pressão sistólica de 8 pacientes foi medida antes e depois de quatro semanas de uma intervenção (Tabela 6.3).

As diferenças são $8, 2, 9, -3, 12, 7, 1, 13$. Então:

- média das diferenças: $\bar{d} = 49/8 = 6{,}125$ mmHg;
- soma dos quadrados dos desvios: $\sum (d_i - \bar{d})^2 = 220{,}875$; variância $s_d^2 = 220{,}875/7 \approx 31{,}55$; desvio padrão $s_d \approx 5{,}617$ mmHg;
- erro padrão: $s_d/\sqrt{8} \approx 1{,}986$ mmHg;
- estatística: $t = 6{,}125/1{,}986 \approx 3{,}08$, com 7 graus de liberdade.

O valor crítico bilateral a 5% é $t_{7;\,0{,}975} = 2{,}365$. Como $3{,}08 > 2{,}365$, rejeita-se H_0; o valor p exato é cerca de 0,018. O IC de 95% para a redução média é $6{,}125 \pm 2{,}365 \times 1{,}986$, isto é, de 1,4 a 10,8 mmHg.

```
t.test(antes, depois, paired = TRUE)
```

```
##
```

```
##  Paired t-test
##
## data:  antes and depois
## t = 3.0841, df = 7, p-value = 0.01771
## alternative hypothesis: true mean difference is not equal to 0
## 95 percent confidence interval:
##   1.428856 10.821144
## sample estimates:
## mean difference
##           6.125
```

O resultado deve ser relatado com o efeito em primeiro lugar: "a pressão sistólica diminuiu em média 6,1 mmHg (IC 95%: 1,4 a 10,8; $p = 0{,}018$)". O intervalo largo mostra que, com apenas 8 pacientes, os dados são compatíveis tanto com uma redução pequena, de pouca relevância clínica, quanto com uma redução importante. Lembre-se, também, de que sem um grupo controle não é possível atribuir a redução à intervenção: regressão à média, efeito placebo e a própria evolução natural poderiam explicá-la. Essa é uma questão de desenho, não de estatística.

6.5.4.2 Teste t para duas amostras independentes

Para comparar as médias de dois grupos independentes (por exemplo, tratamento e controle), a estatística é

$$t = \frac{\bar{x}_1 - \bar{x}_2}{\text{EP}(\bar{x}_1 - \bar{x}_2)}.$$

Há duas versões, que diferem no cálculo do erro padrão:

- O **teste t de Student clássico** supõe que as duas populações têm a **mesma variância** e combina as duas variâncias amostrais em uma estimativa única, a variância combinada $s_p^2 = \frac{(n_1-1)s_1^2+(n_2-1)s_2^2}{n_1+n_2-2}$, com $\text{EP} = s_p\sqrt{1/n_1 + 1/n_2}$ e $n_1 + n_2 - 2$ graus de liberdade.
- O **teste t de Welch** (Welch 1947) não supõe variâncias iguais: usa $\text{EP} = \sqrt{s_1^2/n_1 + s_2^2/n_2}$ e um número aproximado (em geral não inteiro) de graus de liberdade.

Quando as variâncias são iguais, os dois testes dão resultados quase idênticos. Quando são diferentes, especialmente se os tamanhos dos grupos também forem diferentes, o teste de Student clássico pode ter taxa de erro tipo I muito distante de α. Por isso, recomenda-se usar o **teste de Welch como padrão** (Delacre et al. 2017), que é, aliás, o padrão da função `t.test()` do R (`var.equal = FALSE`). Testar a igualdade de variâncias antes, para escolher entre os dois, não é recomendado, pelas mesmas razões discutidas para os testes de normalidade.

```r
set.seed(7)
controle   <- round(rnorm(40, mean = 140, sd = 14))
tratamento <- round(rnorm(35, mean = 133, sd = 18))
t.test(tratamento, controle)          # Welch (padrão)
```

```
##
##  Welch Two Sample t-test
##
## data:  tratamento and controle
## t = -2.2955, df = 70.578, p-value = 0.02468
## alternative hypothesis: true difference in means is not equal to 0
## 95 percent confidence interval:
##  -14.996364  -1.053636
## sample estimates:
## mean of x mean of y
##   135.800   143.825
```

```r
t.test(tratamento, controle, var.equal = TRUE)$p.value  # Student
 ↪  clássico, para comparação
```

```
## [1] 0.02411136
```

Nesse exemplo simulado, a diferença entre as médias (tratamento menos controle) foi de -8,0 mmHg, com IC de 95% de -15,0 a -1,1 mmHg e $p = 0{,}025$.

As suposições do teste t para amostras independentes são: (i) observações independentes dentro e entre os grupos; (ii) distribuição aproximadamente normal das médias amostrais, garantida pelo TCL em amostras moderadas, ou dados aproximadamente normais em amostras pequenas; (iii) no teste clássico, variâncias iguais. A primeira é a mais importante e a única que nenhum procedimento estatístico simples corrige.

6.5.4.3 Teste qui-quadrado para tabelas de contingência

Para comparar proporções entre grupos, ou avaliar a associação entre duas variáveis categóricas, os dados são organizados em uma **tabela de contingência**. A hipótese nula é de **independência**: a distribuição de uma variável é a mesma em todas as categorias da outra.

> **Nota sobre a classificação.** Apresentamos o teste qui-quadrado entre os testes paramétricos porque ele se baseia em um modelo probabilístico explícito para as contagens (multinomial ou binomial, com probabilidades de célula como parâmetros) e em uma aproximação assintótica cuja validade depende do tamanho das frequências

Tabela 6.4: Complicações pós-operatórias segundo o tabagismo (dados fictícios). Entre parênteses, as frequências esperadas sob a hipótese de independência.

	Com complicação	Sem complicação	Total
Fumantes	12 (E = 8)	28 (E = 32)	40
Não fumantes	8 (E = 12)	52 (E = 48)	60
Total	20	80	100

esperadas. Essa classificação não é unânime: muitos textos o tratam como teste não paramétrico, por não supor nenhuma forma específica de distribuição para uma variável contínua subjacente e por se aplicar a dados nominais. É o caso do manual clássico de Siegel e Castellan (1988), que inclui os testes qui-quadrado entre os métodos não paramétricos. Mais importante que o rótulo é conhecer as suposições do teste: observações independentes e frequências esperadas suficientemente grandes.

O **teste qui-quadrado de Pearson** compara as frequências **observadas** (O) em cada célula com as frequências **esperadas** (E) se H_0 fosse verdadeira. A frequência esperada de cada célula é

$$E = \frac{\text{total da linha} \times \text{total da coluna}}{\text{total geral}},$$

e a estatística de teste é

$$X^2 = \sum_{\text{células}} \frac{(O-E)^2}{E},$$

que, sob H_0 e com frequências esperadas suficientemente grandes, segue aproximadamente a distribuição χ^2 com $(r-1)(c-1)$ graus de liberdade, em que r e c são os números de linhas e de colunas.

Exemplo resolvido. Em um estudo, 100 pacientes foram acompanhados após uma cirurgia; 40 eram fumantes. A Tabela 6.4 mostra as frequências observadas de complicação.

A frequência esperada de fumantes com complicação é $40 \times 20/100 = 8$; as demais são obtidas da mesma forma. Então,

$$\begin{aligned} X^2 &= \frac{(12-8)^2}{8} + \frac{(28-32)^2}{32} + \frac{(8-12)^2}{12} + \frac{(52-48)^2}{48} \\ &= 2 + 0{,}5 + 1{,}333 + 0{,}333 = 4{,}17, \end{aligned}$$

com $(2-1)(2-1) = 1$ grau de liberdade, o que corresponde a $p \approx 0{,}041$.

```
tab_comp <- matrix(c(12, 28, 8, 52), nrow = 2, byrow = TRUE,
                   dimnames = list(Tabagismo = c("Fumante", "Não
                    ↪  fumante"),
                                   Complicação = c("Sim", "Não")))
chisq.test(tab_comp, correct = FALSE)
```

```
##
##  Pearson's Chi-squared test
##
## data:  tab_comp
## X-squared = 4.1667, df = 1, p-value = 0.04123
```

```
chisq.test(tab_comp, correct = FALSE)$expected
```

```
##              Complicação
## Tabagismo     Sim Não
##   Fumante       8  32
##   Não fumante  12  48
```

Três observações práticas:

1. Para tabelas 2×2, a função `chisq.test()` aplica por padrão a **correção de continuidade de Yates**, que torna o teste mais conservador (aqui, $p \approx 0{,}074$). Há debate sobre a conveniência dessa correção; o importante é declarar qual versão foi usada.
2. A aproximação pela distribuição qui-quadrado é ruim quando as **frequências esperadas** são pequenas. A regra usual, derivada de Cochran (1954), recomenda que nenhuma frequência esperada seja menor que 1 e que no máximo 20% delas sejam menores que 5. Fora dessas condições, usa-se o **teste exato de Fisher** (`fisher.test()`), que calcula o valor p sem recorrer à aproximação. Note que a regra se refere às frequências **esperadas**, não às observadas.
3. O teste qui-quadrado informa se há associação, não o seu tamanho. O resultado deve vir acompanhado de uma medida de efeito: no exemplo, o risco de complicação foi de $12/40 = 30\%$ nos fumantes e de $8/60 = 13{,}3\%$ nos não fumantes, uma **diferença de risco** de 16,7 pontos percentuais e um **risco relativo** de $0{,}30/0{,}133 = 2{,}25$, ambos com seus intervalos de confiança. Essas medidas são discutidas no capítulo *Aplicações práticas e estudos de caso*.

6.5.5 Testes não paramétricos

Os testes **não paramétricos** fazem menos suposições sobre a forma da distribuição dos dados. Muitos deles substituem os valores observados por seus

postos (*ranks*), isto é, por suas posições na amostra ordenada, o que os torna robustos a valores extremos e aplicáveis a variáveis ordinais. "Não paramétrico" não significa "livre de suposições": a independência das observações continua essencial, e cada teste tem suposições próprias que determinam o que exatamente ele testa.

São indicados especialmente para variáveis ordinais (escores, escalas de Likert), para amostras pequenas com distribuição claramente não normal e para dados com valores extremos que não podem ser descartados. Em amostras grandes e dados aproximadamente simétricos, os testes paramétricos são mais poderosos e ainda fornecem estimativas de efeito diretamente interpretáveis (diferenças de médias). A perda de poder dos testes de postos em relação ao teste t, quando os dados são de fato normais, é pequena (da ordem de 5%), e o ganho pode ser grande quando as caudas são pesadas.

6.5.5.1 Teste de Wilcoxon–Mann–Whitney

O **teste de Wilcoxon da soma dos postos** (Wilcoxon 1945), equivalente ao **teste U de Mann–Whitney** (Mann and Whitney 1947), é a alternativa não paramétrica ao teste t para duas amostras independentes. O procedimento é:

1. reunir as observações dos dois grupos e ordená-las;
2. atribuir postos de 1 (menor) a n_1+n_2 (maior); valores empatados recebem a média dos postos que ocupariam;
3. somar os postos de um dos grupos, R_1, e calcular $W = R_1 - n_1(n_1+1)/2$ (o valor que o R chama de `W` e que é igual ao U de Mann–Whitney);
4. comparar W com sua distribuição sob H_0.

Exemplo resolvido. Um escore de dor foi medido em 3 pacientes do grupo A (3, 5, 8) e em 4 do grupo B (6, 9, 10, 12). Ordenando os 7 valores, os postos são: $3 \to 1$, $5 \to 2$, $6 \to 3$, $8 \to 4$, $9 \to 5$, $10 \to 6$, $12 \to 7$. A soma dos postos do grupo A é $R_A = 1+2+4 = 7$, e $W = 7 - 3\times 4/2 = 1$. O valor mínimo possível de W é 0 (todos os valores de A menores que todos os de B) e o máximo é $n_A \times n_B = 12$. O valor observado está perto do mínimo, mas, com amostras tão pequenas, a evidência é limitada:

```
grupo_a <- c(3, 5, 8)
grupo_b <- c(6, 9, 10, 12)
wilcox.test(grupo_a, grupo_b)
```

```
##
##  Wilcoxon rank sum exact test
##
## data:  grupo_a and grupo_b
## W = 1, p-value = 0.1143
## alternative hypothesis: true location shift is not equal to 0
```

O valor p exato é de 0,11. W tem uma interpretação direta: é o número de pares (um paciente de A, um de B) em que o valor de A supera o de B. Aqui, dos $3 \times 4 = 12$ pares possíveis, apenas um ($8 > 6$) tem o valor de A maior.

O que o teste realmente testa. É comum ler que o teste de Mann–Whitney "compara medianas". Isso só é verdade sob uma suposição adicional: a de que as duas distribuições têm a mesma forma e diferem apenas por um deslocamento. Sem essa suposição, o teste avalia se $P(X_A > X_B) = 0{,}5$, isto é, se um valor sorteado de um grupo tende a ser maior que um valor sorteado do outro, e pode rejeitar H_0 com medianas iguais ou não rejeitá-la com medianas diferentes (Divine et al. 2018). A medida de efeito natural é justamente a estimativa de $P(X_A > X_B)$, que no exemplo é $1/12 \approx 0{,}08$.

6.5.5.2 Teste dos postos sinalizados de Wilcoxon

O **teste dos postos sinalizados de Wilcoxon** é a alternativa não paramétrica ao teste t pareado. Calculam-se as diferenças d_i de cada par, descartam-se as diferenças iguais a zero, atribuem-se postos aos **valores absolutos** das diferenças, e somam-se os postos das diferenças positivas (V). Sob H_0, as diferenças positivas e negativas têm a mesma distribuição de tamanhos.

No exemplo da pressão antes e depois, os valores absolutos das diferenças, em ordem crescente, são 1, 2, 3, 7, 8, 9, 12, 13, com postos de 1 a 8. Apenas a diferença -3 (posto 3) é negativa, de modo que $V = 36 - 3 = 33$, em que 36 é a soma de todos os postos de 1 a 8.

```
wilcox.test(antes, depois, paired = TRUE)
```

```
##
##  Wilcoxon signed rank exact test
##
## data:  antes and depois
## V = 33, p-value = 0.03906
## alternative hypothesis: true location shift is not equal to 0
```

O valor p exato é de 0,039, consistente com o do teste t pareado.

6.5.5.3 Outros testes e um guia de escolha

Para três ou mais grupos independentes, a alternativa à análise de variância é o **teste de Kruskal–Wallis** (`kruskal.test()`); para três ou mais medidas repetidas, o **teste de Friedman** (`friedman.test()`). A correlação de postos de Spearman é apresentada no capítulo *Análise de dados*. A Tabela 6.5 resume a correspondência entre os testes mais usados.

Tabela 6.5: Guia de escolha de testes para situações comuns.

Situação	Paramétrico	Não paramétrico / alternativa	Função no R
Uma amostra vs. valor de referência	t para uma amostra	Postos sinalizados de Wilcoxon	t.test(x, mu =)
Dois grupos independentes	t de Welch (ou de Student)	Wilcoxon–Mann–Whitney	t.test(x, y)
Dois grupos pareados	t pareado	Postos sinalizados de Wilcoxon	t.test(x, y, paired = TRUE)
Três ou mais grupos independentes	ANOVA de uma via	Kruskal–Wallis	aov(), oneway.test()
Três ou mais medidas repetidas	ANOVA de medidas repetidas	Friedman	—
Duas variáveis categóricas	Qui-quadrado de Pearson	Exato de Fisher (amostras pequenas)	chisq.test(), fisher.test()

A escolha do teste deve ser guiada pela pergunta de pesquisa, pelo tipo de variável e pelo desenho do estudo (grupos independentes ou pareados), e definida no plano de análise, antes de os dados serem examinados. Escolher o teste depois de ver qual deles produz o menor valor p invalida a inferência.

6.6 Resumo do capítulo

- A inferência estatística quantifica o erro aleatório ao generalizar da amostra para a população. Ela supõe amostragem aleatória e observações independentes, e não corrige vieses de seleção ou de medida.
- $P(A \mid B)$ e $P(B \mid A)$ são diferentes. O teorema de Bayes mostra que o valor preditivo de um teste depende da prevalência, e não apenas da sensibilidade e da especificidade.
- O erro padrão da média é $\sigma/\sqrt{n}$: a precisão aumenta com a raiz quadrada do tamanho amostral.
- O teorema central do limite garante que a distribuição das **médias** se aproxima da normal em amostras grandes, mesmo que os dados não sejam normais.
- A distribuição t substitui a normal quando σ é estimado por s; tem caudas mais pesadas e se aproxima da normal à medida que os graus de liberdade aumentam. A qui-quadrado é a distribuição de somas de quadrados de

normais padrão.

- O IC de 95% é produzido por um procedimento que, em amostras repetidas, contém o parâmetro em 95% das vezes. Ele indica os valores do parâmetro compatíveis com os dados. Para proporções, prefira o intervalo de Wilson ao de Wald.
- O valor p é a probabilidade de dados tão extremos quanto os observados, supondo H_0 e o modelo verdadeiros. Não é a probabilidade de H_0 ser verdadeira, não mede o tamanho do efeito, e $p > 0{,}05$ não demonstra ausência de efeito.
- Relate sempre a estimativa do efeito com seu intervalo de confiança.
- Use o teste t de Welch como padrão para dois grupos independentes e o teste pareado quando houver pareamento. No teste qui-quadrado, verifique as frequências esperadas e relate uma medida de efeito.
- Testes não paramétricos fazem menos suposições sobre a forma da distribuição, mas não são livres de suposições. O teste de Mann–Whitney não é, em geral, um teste de medianas.

6.7 Exercícios

1. Em uma população, 30% das pessoas são sedentárias, 20% são obesas e 12% são sedentárias e obesas. (a) Qual a probabilidade de uma pessoa sorteada ser sedentária ou obesa? (b) Qual a probabilidade de ser obesa, sabendo que é sedentária? (c) Sedentarismo e obesidade são independentes nessa população?

2. Um teste rápido tem sensibilidade de 95% e especificidade de 90%. Calcule o valor preditivo positivo quando a prevalência é de 1% e quando é de 30%. Explique a diferença.

3. A hemoglobina de mulheres adultas saudáveis segue aproximadamente uma distribuição normal com média de 13,5 g/dL e desvio padrão de 1,0 g/dL. (a) Que proporção tem valores abaixo de 12,0 g/dL? (b) Entre quais valores, simétricos em torno da média, estão 95% das mulheres? (c) Se forem sorteadas amostras de 25 mulheres, entre quais valores estarão 95% das médias amostrais?

4. Uma amostra de 25 recém-nascidos teve peso médio de 3.150 g, com desvio padrão de 450 g. Construa o IC de 95% para o peso médio da população (use $t_{24;\,0{,}975} = 2{,}064$). O que aconteceria, aproximadamente, com a largura do intervalo se a amostra tivesse 100 recém-nascidos com o mesmo desvio padrão?

5. Um artigo relata: “a diferença entre os grupos não foi estatisticamente significativa ($p = 0{,}21$); portanto, o tratamento não tem efeito”. A diferença média observada foi de 8 mmHg (IC 95%: $-4{,}6$ a $20{,}6$). Critique a conclusão.

6. Em 50 pacientes, nenhum apresentou um evento adverso grave. Calcule o intervalo de Wald e o intervalo de Wilson para a proporção de eventos. Qual deles é razoável? (Dica: use `prop.test(0, 50, correct = FALSE)`.)

7. Uma tabela 2 × 2 tem frequências observadas 3, 7, 9 e 11 (linhas: exposto, não exposto; colunas: doente, não doente). Calcule as frequências esperadas. O teste qui-quadrado é apropriado? Qual alternativa você usaria?

8. Usando simulação no R, verifique o TCL para uma população com distribuição binomial com $n = 1$ e $\pi = 0{,}1$ (uma variável binária com prevalência de 10%). Para amostras de tamanho 10, 50 e 500, faça o histograma de 10.000 proporções amostrais. A partir de que tamanho a distribuição parece aproximadamente normal?

6.8 Respostas dos exercícios

1. (a) $0{,}30 + 0{,}20 - 0{,}12 = 0{,}38$. (b) $0{,}12/0{,}30 = 0{,}40$. (c) Não: se fossem independentes, teríamos $P(\text{obesa} \mid \text{sedentária}) = P(\text{obesa}) = 0{,}20$, mas ela é 0,40; equivalentemente, $0{,}30 \times 0{,}20 = 0{,}06 \neq 0{,}12$.

2. Com prevalência de 1%: VPP $= (0{,}95 \times 0{,}01)/(0{,}95 \times 0{,}01 + 0{,}10 \times 0{,}99) = 0{,}0095/0{,}1085 \approx 8{,}8\%$. Com prevalência de 30%: $0{,}285/(0{,}285 + 0{,}07) \approx 80{,}3\%$. Quando a doença é rara, a maioria dos positivos vem dos 10% de falsos positivos entre a grande massa de pessoas sadias. O teste é o mesmo; muda a probabilidade pré-teste.

3. (a) $z = (12{,}0 - 13{,}5)/1{,}0 = -1{,}5$; `pnorm(12, 13.5, 1)` $\approx 0{,}067$, ou seja, cerca de 6,7%. (b) $13{,}5 \pm 1{,}96 \times 1{,}0$: de 11,5 a 15,5 g/dL. (c) O erro padrão é $1{,}0/\sqrt{25} = 0{,}2$ g/dL; 95% das médias estarão em $13{,}5 \pm 1{,}96 \times 0{,}2$, de 13,1 a 13,9 g/dL. Compare com (b): a distribuição das médias é cinco vezes mais estreita que a dos indivíduos.

4. EP $= 450/\sqrt{25} = 90$ g; margem $= 2{,}064 \times 90 \approx 185{,}8$ g; IC 95%: de 2.964 a 3.336 g. Com $n = 100$, o erro padrão cairia para $450/10 = 45$ g e o quantil para cerca de 1,98, de modo que a largura cairia aproximadamente à metade (margem de cerca de 89 g).

5. A conclusão confunde ausência de evidência com evidência de ausência. O intervalo de confiança mostra que os dados são compatíveis desde um efeito ligeiramente desfavorável (−4,6 mmHg) até um benefício grande (20,6 mmHg). O estudo é inconclusivo, provavelmente por falta de poder. A conclusão correta seria algo como: "a diferença observada foi de 8 mmHg (IC 95%: −4,6 a 20,6), estimativa imprecisa que não permite confirmar nem excluir um efeito clinicamente relevante".

6. Com $\hat{p} = 0$, o intervalo de Wald é 0 ± 0, ou seja, de 0 a 0, o que afirmaria, absurdamente, certeza de que a proporção verdadeira é zero. O intervalo de Wilson vai de 0 a cerca de 7,1%, indicando que, mesmo sem eventos observados, os dados são compatíveis com uma proporção de até 7%. (Uma aproximação útil para esse caso é a "regra de três": com zero eventos em n pacientes, o limite superior do IC de 95% é aproximadamente $3/n$, aqui $3/50 = 6\%$.)

7. Totais: linhas 10 e 20; colunas 12 e 18; total 30. Esperadas: $10 \times 12/30 = 4$, $10 \times 18/30 = 6$, $20 \times 12/30 = 8$, $20 \times 18/30 = 12$. Uma das quatro células (25%) tem frequência esperada menor que 5, acima do limite de 20% da regra de Cochran. Recomenda-se o teste exato de Fisher (`fisher.test(matrix(c(3, 7, 9, 11), 2, byrow = TRUE))`).

8. Uma possível solução:

```r
par(mfrow = c(1, 3))
for (n in c(10, 50, 500)) {
  props <- replicate(10000, mean(rbinom(n, size = 1, prob = 0.1)))
  hist(props, breaks = 30, main = paste("n =", n), xlab =
   ↪  "Proporção amostral")
}
```

   Com $n = 10$, a distribuição é discreta e muito assimétrica (há grande chance de observar zero eventos). Com $n = 50$, ainda há assimetria visível. Com $n = 500$, a distribuição é aproximadamente normal. Uma regra prática é exigir $n\pi \geq 10$ e $n(1 - \pi) \geq 10$, o que aqui corresponde a $n \geq 100$. O exercício mostra que, para proporções pequenas, o "tamanho grande" exigido pelo TCL pode ser bem maior que 30.

Capítulo 7

Análise de dados

Hércules Rezende Freitas, Ph.D.[1]

[1]Universidade do Estado do Rio de Janeiro (UERJ), Faculdade de Ciências Médicas, Departamento de Ciências Médicas Integradas, Laboratório de Informática em Saúde (LabInfoS), Cabo Frio/RJ, Brasil.

Os capítulos anteriores trataram, em geral, de uma variável de cada vez, ou da comparação de uma variável entre dois grupos. A maior parte das perguntas de pesquisa, porém, envolve **relações** entre variáveis: a pressão arterial aumenta com o índice de massa corporal? Essa relação persiste quando se leva em conta a idade? Três esquemas de tratamento produzem respostas diferentes? O efeito de um medicamento é o mesmo em homens e mulheres? Que padrões emergem quando dezenas de biomarcadores são analisados em conjunto?

Este capítulo apresenta os métodos clássicos para responder a essas perguntas. Começamos pela **correlação**, que mede a intensidade da associação entre duas variáveis quantitativas, e pela **regressão linear**, que modela como uma variável muda em função de outras. Em seguida, tratamos da **análise de variância** (ANOVA), que compara médias de vários grupos e que, como veremos, é um caso particular da regressão. Por fim, introduzimos dois métodos de **análise multivariada** exploratória: a análise de componentes principais e a análise de agrupamentos.

Um aviso vale para todo o capítulo: os métodos aqui descritos quantificam **associações**. Se uma associação reflete uma relação de causa e efeito depende do desenho do estudo (capítulo *Desenhos de pesquisa*), do controle de fatores de confusão e de conhecimento externo aos dados, e não do método estatístico empregado.

Tabela 7.1: Índice de massa corporal e pressão arterial sistólica de seis adultos (dados fictícios).

Indivíduo	IMC (kg/m²)	PAS (mmHg)
1	20	118
2	22	124
3	24	122
4	26	130
5	28	129
6	30	133

7.1 Correlação e regressão

Usaremos um exemplo pequeno para acompanhar todos os cálculos à mão. A Tabela 7.1 mostra o índice de massa corporal (IMC, x) e a pressão arterial sistólica (PAS, y) de seis adultos (dados fictícios).

As médias são $\bar{x} = 150/6 = 25$ kg/m² e $\bar{y} = 756/6 = 126$ mmHg.

7.1.1 Correlação de Pearson e Spearman

7.1.1.1 Covariância

O ponto de partida é a **covariância**, que mede se as duas variáveis tendem a se afastar de suas médias no mesmo sentido:

$$\operatorname{cov}(x, y) = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y}).$$

Quando um indivíduo tem IMC acima da média e PAS também acima da média, o produto dos desvios é positivo; quando um está acima e o outro abaixo, o produto é negativo. Se predominam produtos positivos, a covariância é positiva (associação positiva); se predominam negativos, é negativa. Note que a variância é a covariância de uma variável com ela mesma.

Para facilitar a notação, definimos as somas

$$S_{xx} = \sum (x_i - \bar{x})^2, \qquad S_{yy} = \sum (y_i - \bar{y})^2, \qquad S_{xy} = \sum (x_i - \bar{x})(y_i - \bar{y}).$$

A Tabela 7.2 mostra o cálculo para o exemplo.

Temos $S_{xy} = 98$, $S_{xx} = 70$ e $S_{yy} = 158$, e a covariância é $98/5 = 19{,}6$ (kg/m²) $\cdot$ mmHg. O problema da covariância é que ela depende das unidades:

Tabela 7.2: Desvios, produtos e quadrados para o cálculo da correlação e da regressão.

i	$x_i - \bar{x}$	$y_i - \bar{y}$	$(x_i - \bar{x})(y_i - \bar{y})$	$(x_i - \bar{x})^2$	$(y_i - \bar{y})^2$
1	-5	-8	40	25	64
2	-3	-2	6	9	4
3	-1	-4	4	1	16
4	1	4	4	1	16
5	3	3	9	9	9
6	5	7	35	25	49
Soma	0	0	98	70	158

se a PAS fosse medida em kPa, o valor mudaria, embora a associação fosse a mesma. Por isso, ela é pouco interpretável por si só.

7.1.1.2 Coeficiente de correlação de Pearson

O **coeficiente de correlação de Pearson** padroniza a covariância dividindo-a pelo produto dos desvios padrão:

$$r = \frac{\operatorname{cov}(x, y)}{s_x \, s_y} = \frac{S_{xy}}{\sqrt{S_{xx} \, S_{yy}}}. \tag{7.1}$$

No exemplo, $r = 98/\sqrt{70 \times 158} = 98/\sqrt{11.060} \approx 98/105{,}17 \approx 0{,}932$.

```
cor(imc6, pas6)
```

```
## [1] 0.9318554
```

Propriedades do coeficiente de Pearson:

1. Varia de -1 a $+1$. O valor $+1$ indica que todos os pontos estão sobre uma reta crescente; -1, sobre uma reta decrescente; 0, ausência de associação **linear**.
2. Não tem unidade e não se altera se as variáveis forem transformadas linearmente com coeficientes positivos (trocar mmHg por kPa ou kg/m² por qualquer múltiplo não muda r).
3. É simétrico: a correlação entre x e y é igual à correlação entre y e x. Não há variável dependente ou independente.
4. Mede apenas associação **linear**. Uma relação perfeita em forma de U pode ter $r \approx 0$. O quarteto de Anscombe, apresentado no capítulo *Bioestatística descritiva*, mostra quatro conjuntos com $r \approx 0{,}82$ e padrões completamente diferentes. Por isso, a correlação deve sempre ser acompanhada do gráfico de dispersão.

5. É sensível a valores extremos, porque se baseia em médias e desvios.

O quadrado do coeficiente, r^2, é chamado de **coeficiente de determinação** e será interpretado na seção de regressão. No exemplo, $r^2 \approx 0{,}868$.

Não existe uma escala universal para classificar a correlação como "fraca", "moderada" ou "forte". As classificações publicadas variam entre áreas, e o que é uma correlação alta para dois questionários psicométricos pode ser baixo para duas medidas da mesma substância por métodos diferentes. É preferível relatar o valor com seu intervalo de confiança e interpretá-lo no contexto.

Inferência sobre ρ. O coeficiente amostral r estima a correlação populacional ρ. Para testar $H_0\colon \rho = 0$, usa-se a estatística

$$t = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}},$$

que segue a distribuição t com $n-2$ graus de liberdade se os dados vierem de uma distribuição normal bivariada. No exemplo, $t = 0{,}932\sqrt{4}/\sqrt{1-0{,}868} \approx 5{,}14$, com $p \approx 0{,}007$. O intervalo de confiança é obtido pela transformação z de Fisher, $z = \frac{1}{2}\ln\frac{1+r}{1-r}$, cuja distribuição é aproximadamente normal com erro padrão $1/\sqrt{n-3}$. A função `cor.test()` faz os dois cálculos:

```
cor.test(imc6, pas6)
```

```
##
##  Pearson's product-moment correlation
##
## data:  imc6 and pas6
## t = 5.1366, df = 4, p-value = 0.006807
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  0.4935299 0.9926884
## sample estimates:
##       cor
## 0.9318554
```

O IC de 95% vai de 0,49 a 0,99. Com apenas seis observações, a estimativa é muito imprecisa: os dados são compatíveis tanto com uma correlação moderada quanto com uma quase perfeita.

7.1.1.3 Coeficiente de correlação de Spearman

O **coeficiente de correlação de postos de Spearman** (Spearman 1904), r_s, é simplesmente o coeficiente de Pearson calculado sobre os **postos** das observações, em vez dos valores originais. Ao trabalhar com postos, ele mede a

intensidade de uma associação **monotônica** (sempre crescente ou sempre decrescente, mas não necessariamente linear), é robusto a valores extremos e se aplica a variáveis ordinais.

Quando não há empates, existe uma fórmula equivalente e simples. Sendo d_i a diferença entre os postos de x_i e de y_i,

$$r_s = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)}.$$

No exemplo, os postos do IMC são 1, 2, 3, 4, 5, 6 e os postos da PAS são 1, 3, 2, 5, 4, 6. As diferenças são $0, -1, 1, -1, 1, 0$, e $\sum d_i^2 = 4$. Então $r_s = 1 - 6 \times 4/(6 \times 35) = 1 - 24/210 \approx 0{,}886$.

```
rank(pas6)
```

```
## [1] 1 3 2 5 4 6
```

```
cor(imc6, pas6, method = "spearman")
```

```
## [1] 0.8857143
```

```
cor(rank(imc6), rank(pas6))   # Pearson sobre os postos: mesmo resultado
```

```
## [1] 0.8857143
```

A Figura 7.1 mostra quando os dois coeficientes divergem.

```
set.seed(11)
xa <- rnorm(40); ya <- xa + rnorm(40, sd = 0.6)
xb <- runif(40, 0, 5); yb <- exp(xb)
xc <- rnorm(30); yc <- rnorm(30); xc[30] <- 6; yc[30] <- 6
op <- par(mfrow = c(1, 3), mar = c(4, 4, 3, 1))
for (k in list(list(xa, ya, "Linear"), list(xb, yb, "Monotônica"),
 ↪  list(xc, yc, "Valor extremo"))) {
  plot(k[[1]], k[[2]], pch = 19, col = "grey30", xlab = "x", ylab = "y",
       main = sprintf("%s\nPearson = %s; Spearman = %s", k[[3]],
                      num(cor(k[[1]], k[[2]]), 2), num(cor(k[[1]],
                       ↪  k[[2]], method = "spearman"), 2)),
       cex.main = 0.9)
}
```

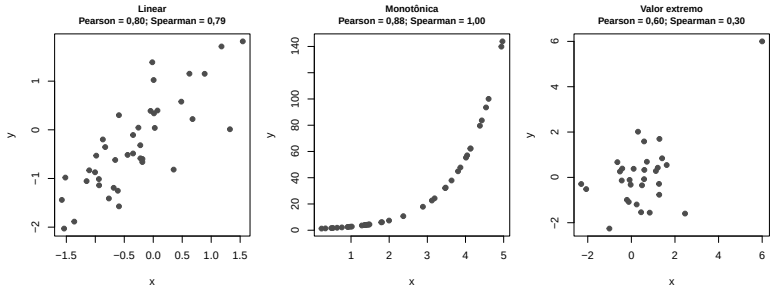


Figura 7.1: Pearson e Spearman em três situações simuladas. À esquerda, relação linear: os coeficientes são semelhantes. No centro, relação monotônica não linear: Spearman vale 1 (associação perfeita de postos), enquanto Pearson, que mede apenas a componente linear, é menor. À direita, um único valor extremo infla o coeficiente de Pearson.

```
par(op)
```

7.1.1.4 Cinco armadilhas na interpretação da correlação

1. **Correlação não é causalidade.** Duas variáveis podem estar correlacionadas porque uma causa a outra, porque ambas são causadas por um terceiro fator (confusão) ou por acaso. O número de afogamentos e as vendas de sorvete são correlacionados porque ambos aumentam no verão.
2. **Restrição de amplitude.** A correlação depende da variabilidade das variáveis na amostra. Se um estudo inclui apenas adultos com IMC entre 24 e 26 kg/m², a correlação entre IMC e pressão será muito menor do que na população geral, embora a relação biológica seja a mesma.
3. **Mistura de grupos.** Combinar grupos com médias diferentes pode criar uma correlação inexistente dentro de cada grupo, ou mascarar uma existente. Correlações calculadas com dados agregados (por município, por país) não podem ser transferidas para indivíduos: é a **falácia ecológica**.
4. **Dados repetidos.** Várias medidas do mesmo indivíduo não são observações independentes. Calcular a correlação como se fossem infla artificialmente a precisão.
5. **Correlação não é concordância.** Para comparar dois métodos de medida da mesma grandeza (dois aparelhos de pressão, por exemplo), a correlação é inadequada: dois métodos podem ter $r = 0{,}99$ e um deles medir sistematicamente 20 mmHg a mais que o outro. A concordância deve ser avaliada pelo método de Bland e Altman (1986), que analisa as diferenças entre os métodos em função de sua média.

7.1.2 Regressão linear simples e múltipla

A correlação mede a intensidade da associação, mas não diz **quanto** y muda quando x muda. Para isso, usamos a **regressão linear**. O termo "regressão" vem de Francis Galton (1886), que observou que filhos de pais muito altos tendiam a ser altos, mas menos extremos que os pais: suas estaturas "regrediam" em direção à média da população. O fenômeno, conhecido como **regressão à média**, é importante por si só na pesquisa clínica: pacientes selecionados por terem valores extremos (pressão muito alta, por exemplo) tendem a apresentar valores menos extremos em uma segunda medida, mesmo sem nenhum tratamento.

7.1.2.1 O modelo de regressão linear simples

Na regressão, as variáveis têm papéis diferentes: Y é a **variável resposta** (ou desfecho, ou dependente) e X é a **variável explicativa** (ou preditora, ou independente). O modelo de regressão linear simples supõe que

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i, \tag{7.2}$$

em que:

- β_0 é o **intercepto**: o valor esperado de Y quando $X = 0$;
- β_1 é a **inclinação** (ou coeficiente angular): a variação esperada em Y para cada aumento de uma unidade em X;
- ε_i é o **erro aleatório**, que representa tudo o que faz o valor individual se afastar da reta (outras variáveis, variação biológica, erro de medida). Supõe-se que os erros tenham média zero, variância constante σ^2 e sejam independentes.

O modelo diz que a **média** de Y, para um dado valor de X, está sobre uma reta: $E(Y \mid X = x) = \beta_0 + \beta_1 x$. Os indivíduos se distribuem em torno dessa reta.

7.1.2.2 Estimação por mínimos quadrados

Os parâmetros β_0 e β_1 são desconhecidos e precisam ser estimados. Para qualquer reta candidata $\hat{y} = b_0 + b_1 x$, a diferença entre o valor observado e o valor previsto pela reta, $e_i = y_i - \hat{y}_i$, é o **resíduo**. O **método dos mínimos quadrados** escolhe a reta que minimiza a soma dos quadrados dos resíduos,

$$\text{SQRes} = \sum_{i=1}^{n} (y_i - b_0 - b_1 x_i)^2.$$

É a mesma ideia que, no capítulo *Bioestatística descritiva*, mostrou que a média é o valor que minimiza a soma dos quadrados dos desvios. Igualando a zero as derivadas parciais de SQRes em relação a b_0 e b_1, obtêm-se as soluções

$$b_1 = \frac{S_{xy}}{S_{xx}}, \qquad b_0 = \bar{y} - b_1 \bar{x}. \tag{7.3}$$

A segunda equação mostra que a reta de mínimos quadrados sempre passa pelo ponto $(\bar{x}, \bar{y})$. Comparando com a Equação (7.1), vê-se ainda que $b_1 = r\, s_y / s_x$: a inclinação é a correlação reescalada para as unidades das variáveis.

Exemplo resolvido. Com os valores da Tabela 7.2:

$$b_1 = \frac{98}{70} = 1{,}4 \text{ mmHg por kg/m}^2, \qquad b_0 = 126 - 1{,}4 \times 25 = 91{,}0 \text{ mmHg}.$$

A reta ajustada é $\widehat{\text{PAS}} = 91{,}0 + 1{,}4 \times \text{IMC}$. **Interpretação:** em média, cada aumento de 1 kg/m² no IMC está associado a uma PAS 1,4 mmHg mais alta. O intercepto, literalmente, seria a PAS esperada para IMC igual a zero, uma extrapolação sem sentido biológico; ele apenas posiciona a reta. Para tornar o intercepto interpretável, pode-se **centralizar** a variável explicativa (usar $x - \bar{x}$), caso em que o intercepto passa a ser a PAS esperada para o IMC médio.

```
modelo1 <- lm(pas6 ~ imc6)
coef(modelo1)
```

```
## (Intercept)        imc6
##        91.0         1.4
```

7.1.2.3 Decomposição da variabilidade e coeficiente de determinação

A variabilidade total de y em torno de sua média pode ser decomposta em uma parte explicada pela reta e uma parte residual:

$$\underbrace{\sum (y_i - \bar{y})^2}_{\text{SQTotal}} = \underbrace{\sum (\hat{y}_i - \bar{y})^2}_{\text{SQRegressão}} + \underbrace{\sum (y_i - \hat{y}_i)^2}_{\text{SQRes}}.$$

No exemplo, SQTotal $= S_{yy} = 158$. A soma explicada pela regressão é $b_1^2 S_{xx} = 1{,}4^2 \times 70 = 137{,}2$, e a residual é $158 - 137{,}2 = 20{,}8$. O **coeficiente de determinação** é a fração explicada:

$$R^2 = \frac{\text{SQRegressão}}{\text{SQTotal}} = \frac{137{,}2}{158} \approx 0{,}868.$$

Na regressão simples, $R^2 = r^2$. A interpretação é: 86,8% da variabilidade da PAS **nesta amostra** é explicada pela relação linear com o IMC. Um R^2 alto não garante que o modelo esteja correto (o conjunto 2 de Anscombe tem $R^2 = 0{,}67$ com uma relação claramente curva), e um R^2 baixo não torna o coeficiente irrelevante: em estudos epidemiológicos, um fator de risco importante pode explicar uma fração pequena da variabilidade individual.

A variância residual é estimada por $s^2 = \text{SQRes}/(n-2) = 20{,}8/4 = 5{,}2$, e o **erro padrão residual** é $s = \sqrt{5{,}2} \approx 2{,}28$ mmHg. O divisor é $n-2$ porque dois parâmetros foram estimados. O erro padrão residual informa, na unidade de y, o afastamento típico entre os valores observados e a reta.

7.1.2.4 Inferência sobre a inclinação

A inclinação estimada b_1 varia de amostra para amostra, e seu erro padrão é

$$\text{EP}(b_1) = \frac{s}{\sqrt{S_{xx}}} = \frac{2{,}28}{\sqrt{70}} \approx 0{,}273.$$

Para testar $H_0\colon \beta_1 = 0$ (ausência de associação linear), usa-se $t = b_1/\text{EP}(b_1) = 1{,}4/0{,}273 \approx 5{,}14$, com $n-2 = 4$ graus de liberdade, que produz $p \approx 0{,}007$ (o mesmo valor do teste para a correlação, como deve ser). O IC de 95% é $b_1 \pm t_{4;\,0{,}975}\,\text{EP}(b_1) = 1{,}4 \pm 2{,}776 \times 0{,}273$, isto é, de 0,64 a 2,16 mmHg por kg/m².

```
summary(modelo1)
```

```
##
## Call:
## lm(formula = pas6 ~ imc6)
##
## Residuals:
##          1          2          3          4          5          6
## -1.000e+00  2.200e+00 -2.600e+00  2.600e+00 -1.200e+00  8.374e-15
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)  91.0000     6.8772  13.232 0.000188 ***
## imc6          1.4000     0.2726   5.137 0.006807 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 2.28 on 4 degrees of freedom
## Multiple R-squared:  0.8684, Adjusted R-squared:  0.8354
## F-statistic: 26.38 on 1 and 4 DF,  p-value: 0.006807
```

```
confint(modelo1)
```

```
##                  2.5 %     97.5 %
## (Intercept) 71.9059613 110.094039
## imc6         0.6432686   2.156731
```

A saída de `summary()` reúne tudo o que calculamos: as estimativas dos coeficientes, seus erros padrão, as estatísticas t e os valores p, o erro padrão residual (`Residual standard error`), o R^2 e o R^2 ajustado, discutido adiante.

Intervalo de confiança e intervalo de predição. Há duas perguntas diferentes que a reta pode responder para um valor de x. Qual é a PAS **média** de todas as pessoas com IMC de 25 kg/m²? E qual será a PAS de **uma pessoa** com IMC de 25 kg/m²? A estimativa pontual é a mesma (126 mmHg), mas a incerteza é muito diferente: a segunda pergunta precisa incorporar também a variação individual em torno da reta. O intervalo de predição é, por isso, sempre mais largo que o intervalo de confiança.

```
novo <- data.frame(imc6 = 25)
predict(modelo1, novo, interval = "confidence")   # média de pessoas com
 ↪  IMC = 25
```

```
##   fit      lwr      upr
## 1 126 123.4153 128.5847
```

```
predict(modelo1, novo, interval = "prediction")   # uma nova pessoa com
 ↪  IMC = 25
```

```
##   fit      lwr      upr
## 1 126 119.1614 132.8386
```

Previsões fora da amplitude dos valores de x observados (**extrapolação**) não são sustentadas pelos dados: nada garante que a relação continue linear além do intervalo estudado.

7.1.2.5 Suposições e diagnóstico do modelo

As conclusões da regressão dependem de quatro suposições, frequentemente lembradas pelo acrônimo inglês LINE:

1. **Linearidade**: a média de Y varia linearmente com X.
2. **Independência**: os erros (e, portanto, as observações) são independentes.

3. **Normalidade**: os erros têm distribuição normal. Isso importa sobretudo para testes e intervalos em amostras pequenas; em amostras grandes, o TCL garante a validade aproximada da inferência sobre os coeficientes. Note que a suposição é sobre os **erros**, e não sobre X ou Y.
4. **Variância constante** (homocedasticidade): a dispersão dos erros é a mesma para todos os valores de X.

Como os erros não são observáveis, as suposições são avaliadas por meio dos **resíduos**. A função `plot()` aplicada a um objeto `lm` produz quatro gráficos diagnósticos. Para ilustrá-los com dados mais realistas, simulamos 200 adultos em que a PAS depende da idade, do IMC e do sexo:

```
set.seed(2026)
n_sim <- 200
adultos <- data.frame(idade = round(runif(n_sim, 30, 80)),
                      sexo  = factor(sample(c("Feminino", "Masculino"),
                       ↪  n_sim, replace = TRUE)))
adultos$imc <- round(20 + 0.10 * adultos$idade + rnorm(n_sim, 0, 3), 1)
adultos$pas <- round(90 + 0.50 * adultos$idade + 0.60 * adultos$imc +
                       5 * (adultos$sexo == "Masculino") + rnorm(n_sim,
                        ↪  0, 10))
head(adultos)
```

```
##   idade      sexo  imc pas
## 1    65 Masculino 25.2 156
## 2    58  Feminino 27.2 141
## 3    37  Feminino 23.0 112
## 4    44 Masculino 18.8 126
## 5    58 Masculino 24.9 130
## 6    31 Masculino 28.4 108
```

```
modelo_mult <- lm(pas ~ idade + imc + sexo, data = adultos)
op <- par(mfrow = c(2, 2), mar = c(4, 4, 2, 1))
plot(modelo_mult, pch = 19, col = adjustcolor("grey20", alpha.f = 0.5))
```

```
par(op)
```

Como ler os quatro painéis da Figura 7.2:

- **Resíduos versus valores ajustados** (superior esquerdo): os pontos devem se espalhar aleatoriamente em torno de zero, sem curvatura (que indicaria não linearidade) e sem forma de funil (que indicaria variância não constante).
- **Q-Q plot dos resíduos** (superior direito): os pontos devem seguir a reta; desvios nas extremidades indicam caudas mais pesadas que a normal.

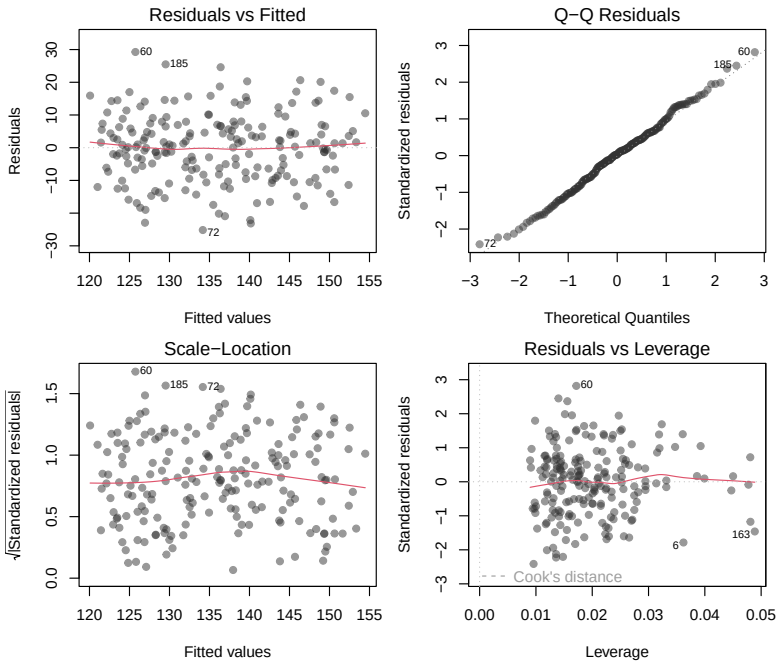


Figura 7.2: Gráficos diagnósticos do modelo de regressão da PAS em função da idade, do IMC e do sexo (dados simulados).

- **Escala-locação** (inferior esquerdo): a raiz dos resíduos padronizados em valor absoluto não deve ter tendência; uma linha crescente indica variância que aumenta com o valor ajustado.
- **Resíduos versus alavancagem** (inferior direito): identifica observações **influentes**, isto é, aquelas cuja remoção mudaria substancialmente os coeficientes. Pontos além das curvas da distância de Cook merecem investigação.

Nos dados simulados, que satisfazem as suposições por construção, os gráficos não mostram padrões. Em dados reais, a violação de linearidade pode ser tratada com transformações ou termos não lineares (polinômios, *splines*); a variância não constante, com transformações da resposta ou erros padrão robustos; e a dependência entre observações (medidas repetidas, pacientes agrupados por hospital), com modelos mistos, assunto do capítulo *Tópicos avançados em bioestatística*.

7.1.2.6 Regressão linear múltipla

Na **regressão linear múltipla**, a resposta é modelada em função de várias variáveis explicativas:

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \cdots + \beta_p X_{pi} + \varepsilon_i.$$

Os coeficientes continuam sendo estimados por mínimos quadrados, agora resolvidos com álgebra matricial, mas a interpretação muda:β_j **é a variação esperada em Y para cada aumento de uma unidade em X_j, mantidas constantes as demais variáveis do modelo**. Diz-se que o coeficiente é **ajustado** para as outras variáveis.

```
summary(modelo_mult)
```

```
##
## Call:
## lm(formula = pas ~ idade + imc + sexo, data = adultos)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -25.1660  -6.8338   0.3462   6.5497  29.2567
##
## Coefficients:
##               Estimate Std. Error t value Pr(>|t|)
## (Intercept)   91.51003    5.96497  15.341   <2e-16 ***
## idade          0.55845    0.05609   9.957   <2e-16 ***
## imc            0.53341    0.25414   2.099   0.0371 *
## sexoMasculino  2.38308    1.49299   1.596   0.1121
```

```
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 10.47 on 196 degrees of freedom
## Multiple R-squared:  0.4339, Adjusted R-squared:  0.4252
## F-statistic: 50.08 on 3 and 196 DF,  p-value: < 2.2e-16
```

Na saída, o coeficiente do IMC (0,53 mmHg por kg/m²) é a diferença média de PAS entre pessoas que diferem em 1 kg/m² no IMC, **mas têm a mesma idade e o mesmo sexo**. O coeficiente de `sexoMasculino` (2,4 mmHg) é a diferença média entre homens e mulheres de mesma idade e mesmo IMC.

Variáveis categóricas. Uma variável categórica com k categorias entra no modelo como $k-1$ **variáveis indicadoras** (*dummies*), cada uma valendo 1 para uma categoria e 0 para as outras. A categoria sem indicadora é a **referência**, e cada coeficiente compara a sua categoria com ela. O R faz isso automaticamente para variáveis do tipo `factor`; a referência é o primeiro nível (aqui, "Feminino") e pode ser trocada com `relevel()`.

Confusão e ajuste. Por que ajustar? Nos dados simulados, a idade aumenta tanto o IMC quanto a PAS. Uma regressão simples da PAS sobre o IMC atribui ao IMC parte do efeito da idade:

```
coef(lm(pas ~ imc, data = adultos))["imc"]              # sem ajuste
```

```
##     imc
## 1.58647
```

```
coef(lm(pas ~ imc + idade + sexo, data = adultos))["imc"]  # ajustado
```

```
##       imc
## 0.5334136
```

Sem ajuste, a inclinação do IMC é 1,59 mmHg por kg/m²; ajustada, é 0,53, próxima do valor 0,60 usado na simulação. A idade é um **fator de confusão**: está associada à exposição (IMC) e ao desfecho (PAS) e não está no caminho causal entre eles. A regressão múltipla permite ajustar para fatores de confusão **medidos**; nenhum método estatístico ajusta para os que não foram medidos.

A decisão sobre quais variáveis incluir deve ser tomada com base no conhecimento do problema, idealmente antes da análise, e não por procedimentos automáticos. Métodos como a seleção *stepwise* (incluir e excluir variáveis conforme seus valores p) produzem coeficientes enviesados, erros padrão subestimados e modelos que não se reproduzem em novos dados (Harrell 2015). Ajustar para uma variável que está no caminho causal (um **mediador**) ou que é consequência do desfecho pode introduzir viés em vez de removê-lo.

R^2 ajustado. O R^2 nunca diminui quando se acrescenta uma variável ao modelo, mesmo que ela seja ruído. O R^2 **ajustado**, $1 - (1 - R^2)\frac{n-1}{n-p-1}$, penaliza o número de variáveis p e é mais apropriado para comparar modelos de tamanhos diferentes.

Interação. O modelo acima supõe que o efeito do IMC é o mesmo para homens e mulheres. Se houver razão para suspeitar que não é, inclui-se um termo de **interação** (`pas ~ imc * sexo`), cujo coeficiente mede a diferença entre as inclinações dos dois grupos. A interação é discutida em mais detalhe na seção sobre ANOVA fatorial.

Colinearidade. Quando duas variáveis explicativas são muito correlacionadas entre si (peso e IMC, por exemplo), o modelo tem dificuldade em separar seus efeitos: os coeficientes ficam instáveis e com erros padrão grandes. O **fator de inflação da variância** (VIF) quantifica o problema; valores muito acima de 5 a 10 sugerem colinearidade importante. A solução, em geral, é não incluir no mesmo modelo variáveis que medem essencialmente a mesma coisa.

Tamanho amostral. Cada coeficiente estimado consome informação. Modelos com muitas variáveis em relação ao número de observações se ajustam ao ruído da amostra (**sobreajuste**) e funcionam mal em dados novos. Para a regressão linear, simulações sugerem que cerca de duas observações por parâmetro bastam para estimar os coeficientes com viés pequeno (Austin and Steyerberg 2015), mas a precisão das estimativas e a capacidade preditiva exigem amostras bem maiores; em modelos de predição, são recomendados métodos formais de cálculo de tamanho amostral.

7.2 Análise de variância (ANOVA)

Quando se quer comparar as médias de três ou mais grupos, a tentação é realizar testes t para todos os pares. Com três grupos são três comparações; com cinco grupos, dez. Como vimos no capítulo *Bioestatística inferencial*, a realização de muitos testes aumenta a probabilidade de pelo menos um falso positivo. A **análise de variância** (ANOVA), desenvolvida por Ronald Fisher na década de 1920, testa a hipótese de igualdade de todas as médias em um único teste, controlando a taxa de erro tipo I.

7.2.1 A distribuição F

A estatística de teste da ANOVA segue a **distribuição F**, que é a distribuição da razão de duas variáveis qui-quadrado independentes, cada uma dividida pelos seus graus de liberdade:

$$F = \frac{Q_1/k_1}{Q_2/k_2}, \qquad Q_1 \sim \chi^2_{k_1}, \quad Q_2 \sim \chi^2_{k_2}.$$

A distribuição tem dois parâmetros, os graus de liberdade do numerador (k_1) e do denominador (k_2), só assume valores positivos e é assimétrica à direita. Como cada variância amostral de dados normais é proporcional a uma qui-quadrado, a distribuição F descreve a razão de duas variâncias. Um fato útil: o quadrado de uma variável t com k graus de liberdade tem distribuição F com 1 e k graus de liberdade, o que explica por que, na regressão simples, a estatística F é o quadrado da estatística t da inclinação ($5{,}14^2 \approx 26{,}4$).

7.2.2 ANOVA de uma via

7.2.2.1 O modelo e a lógica do teste

Na **ANOVA de uma via** (ou de um fator), há k grupos definidos por uma única variável categórica, com n_j observações no grupo j e $N = \sum n_j$ observações no total. As hipóteses são

$$H_0 \colon \mu_1 = \mu_2 = \cdots = \mu_k \qquad \text{versus} \qquad H_1 \colon \text{pelo menos uma média é diferente.}$$

A ideia, que dá nome ao método, é comparar **duas estimativas da variância**:

- a variabilidade **dentro** dos grupos, que reflete apenas a variação aleatória entre indivíduos, qualquer que seja a verdade sobre H_0;
- a variabilidade **entre** os grupos (das médias dos grupos em torno da média geral), que reflete a variação aleatória **mais** eventuais diferenças reais entre as médias.

Se H_0 for verdadeira, as duas estimativas devem ser parecidas e sua razão deve ficar perto de 1. Se as médias forem diferentes, a variabilidade entre grupos será maior, e a razão, grande.

Formalmente, sendo $\bar{y}_j$ a média do grupo j e $\bar{y}$ a média geral, a soma de quadrados total se decompõe em

$$\underbrace{\sum_j \sum_i (y_{ij} - \bar{y})^2}_{\text{SQTotal}} = \underbrace{\sum_j n_j (\bar{y}_j - \bar{y})^2}_{\text{SQEntre}} + \underbrace{\sum_j \sum_i (y_{ij} - \bar{y}_j)^2}_{\text{SQDentro}} .$$

Dividindo cada soma de quadrados por seus graus de liberdade, obtêm-se os **quadrados médios**: $\text{QMEntre} = \text{SQEntre}/(k-1)$ e $\text{QMDentro} = \text{SQDentro}/(N-k)$. A estatística de teste é

$$F = \frac{\text{QMEntre}}{\text{QMDentro}},$$

Tabela 7.3: Redução no escore de dor em três esquemas de analgesia (dados fictícios).

Esquema	Observações	Média
A	3, 5, 4, 4	4
B	6, 7, 5, 6	6
C	8, 9, 7, 8	8

que, sob H_0, segue a distribuição F com $k-1$ e $N-k$ graus de liberdade. O QMDentro é a generalização, para k grupos, da variância combinada do teste t de Student; de fato, com $k=2$ grupos, a ANOVA é equivalente ao teste t com variâncias iguais, e $F = t^2$.

7.2.2.2 Exemplo resolvido

Doze pacientes com dor crônica foram distribuídos em três esquemas de analgesia (A, B e C), quatro em cada, e registrou-se a redução no escore de dor após duas semanas (dados fictícios, Tabela 7.3).

A média geral é $\bar{y} = 72/12 = 6$. Então:

- SQEntre $= 4(4-6)^2 + 4(6-6)^2 + 4(8-6)^2 = 16 + 0 + 16 = 32$, com $k-1 = 2$ graus de liberdade, e QMEntre $= 16$;
- SQDentro: no grupo A, os desvios em relação à média 4 são $-1, 1, 0, 0$, com soma de quadrados 2; nos grupos B e C, a soma também é 2. Assim, SQDentro $= 6$, com $N-k = 9$ graus de liberdade, e QMDentro $= 6/9 \approx 0{,}667$;
- $F = 16/0{,}667 = 24$, com 2 e 9 graus de liberdade.

O valor crítico de $F_{2,9}$ a 5% é cerca de 4,26, e o valor p é aproximadamente 0,0002. Os resultados costumam ser apresentados em uma **tabela de ANOVA**:

```r
modelo_aov <- aov(reducao ~ esquema)
summary(modelo_aov)
```

```
##             Df Sum Sq Mean Sq F value   Pr(>F)
## esquema      2     32  16.000      24 0.000247 ***
## Residuals    9      6   0.667
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```r
qf(0.95, df1 = 2, df2 = 9)   # valor crítico
```

```
## [1] 4.256495
```

Uma medida de tamanho de efeito é o **eta-quadrado**, $\eta^2 = \text{SQEntre}/\text{SQTotal} = 32/38 \approx 0{,}84$: 84% da variabilidade na redução da dor está associada ao esquema. É o equivalente do R^2 da regressão.

7.2.2.3 Comparações múltiplas *post hoc*

Um F significativo indica que nem todas as médias são iguais, mas não diz quais diferem. Para isso, realizam-se **comparações múltiplas**, com algum controle da taxa de erro do conjunto de comparações. O método mais usado para comparar todos os pares é o de Tukey (Tukey 1949), conhecido como HSD (*honestly significant difference*), que fornece intervalos de confiança simultâneos para todas as diferenças:

```
TukeyHSD(modelo_aov)
```

```
##   Tukey multiple comparisons of means
##     95% family-wise confidence level
##
## Fit: aov(formula = reducao ~ esquema)
##
## $esquema
##     diff       lwr      upr     p adj
## B-A    2 0.3880348 3.611965 0.0176260
## C-A    4 2.3880348 5.611965 0.0001809
## C-B    2 0.3880348 3.611965 0.0176260
```

As três diferenças (2, 4 e 2 pontos) têm intervalos que não incluem zero. Quando o interesse é apenas comparar cada tratamento com um controle, o método de Dunnett é mais poderoso. Comparações planejadas antes do estudo, em pequeno número e justificadas pela pergunta de pesquisa, são preferíveis a comparar todos os pares por rotina.

7.2.2.4 Suposições e alternativas

A ANOVA supõe observações independentes, distribuição aproximadamente normal dos erros em cada grupo e variâncias iguais entre os grupos. Assim como o teste t, ela é razoavelmente robusta à falta de normalidade em amostras moderadas, mas sensível a variâncias diferentes quando os grupos têm tamanhos diferentes. A **ANOVA de Welch** (`oneway.test(y ~ grupo)`, com `var.equal = FALSE`, o padrão) não supõe variâncias iguais. Quando os dados são ordinais ou muito assimétricos, a alternativa não paramétrica é o teste de Kruskal–Wallis (`kruskal.test()`).

```r
oneway.test(reducao ~ esquema)
```

```
##
##  One-way analysis of means (not assuming equal variances)
##
## data:  reducao and esquema
## F = 21.6, num df = 2, denom df = 6, p-value = 0.001814
```

ANOVA é regressão. A ANOVA de uma via é exatamente uma regressão linear em que a variável explicativa é categórica, codificada com indicadoras. O intercepto é a média do grupo de referência, e cada coeficiente é a diferença entre a média de um grupo e a da referência. Por isso, `summary(lm(reducao ~ esquema))` produz a mesma estatística F e o mesmo valor p da tabela de ANOVA. Essa equivalência unifica os métodos deste capítulo: ANOVA, teste t e regressão são casos particulares do **modelo linear geral**.

```r
coef(lm(reducao ~ esquema))
```

```
## (Intercept)    esquemaB    esquemaC
##           4           2           4
```

7.2.3 ANOVA fatorial

Na **ANOVA fatorial**, a resposta é analisada em função de dois ou mais fatores ao mesmo tempo. O caso mais simples é o desenho 2×2: por exemplo, um ensaio que compara um anti-hipertensivo com placebo e analisa separadamente homens e mulheres. O desenho fatorial permite responder a três perguntas:

1. **Efeito principal do fator A**: em média, considerando ambos os níveis de B, a resposta difere entre os níveis de A?
2. **Efeito principal do fator B**: idem, para B.
3. **Interação A $\times$ B**: o efeito de A é o mesmo em todos os níveis de B?

A interação é frequentemente a pergunta mais interessante. Há interação quando o efeito do tratamento **depende** do sexo, por exemplo, quando o medicamento reduz mais a pressão em homens do que em mulheres. Na presença de interação importante, os efeitos principais deixam de ter interpretação simples, porque não existe "o" efeito do tratamento, mas um efeito para cada sexo.

O modelo para dois fatores com interação é

$$Y_{ijk} = \mu + \alpha_i + \beta_j + (\alpha\beta)_{ij} + \varepsilon_{ijk},$$

em que α_i é o efeito do nível i do fator A, β_j o efeito do nível j do fator B e $(\alpha\beta)_{ij}$ o termo de interação. A soma de quadrados total se decompõe em quatro partes (A, B, interação e resíduo), cada uma com sua estatística F.

Simulamos um ensaio com 30 participantes em cada combinação de tratamento e sexo, em que o medicamento reduz a pressão em 10 mmHg nos homens e em 4 mmHg nas mulheres:

```
set.seed(99)
ensaio <- expand.grid(rep = 1:30, tratamento = c("Placebo", "Ativo"),
 ↪  sexo = c("Feminino", "Masculino"))
ensaio$tratamento <- factor(ensaio$tratamento, levels = c("Placebo",
 ↪  "Ativo"))
efeito <- ifelse(ensaio$tratamento == "Ativo", ifelse(ensaio$sexo ==
 ↪  "Masculino", -10, -4), 0)
ensaio$variacao_pas <- round(-2 + efeito + rnorm(nrow(ensaio), 0, 6), 1)
modelo_fat <- aov(variacao_pas ~ tratamento * sexo, data = ensaio)
summary(modelo_fat)
```

```
##                  Df Sum Sq Mean Sq F value   Pr(>F)
## tratamento        1   2248  2248.1  68.745 2.26e-13 ***
## sexo              1     94    94.0   2.874  0.09270 .
## tratamento:sexo   1    316   315.6   9.650  0.00238 **
## Residuals       116   3793    32.7
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

A fórmula `tratamento * sexo` é uma abreviação de `tratamento + sexo + tratamento:sexo`, isto é, os dois efeitos principais e a interação. O **gráfico de interação** (Figura 7.3) mostra as médias de cada combinação. Linhas paralelas indicam ausência de interação; linhas que divergem ou se cruzam indicam interação.

```
medias_fat <- with(ensaio, tapply(variacao_pas, list(tratamento, sexo),
 ↪  mean))
op <- par(mar = c(4, 4.5, 1, 1))
matplot(1:2, medias_fat, type = "b", pch = c(19, 17), lty = c(1, 2), lwd
 ↪  = 2,
        col = c("black", "grey45"), xaxt = "n", xlim = c(0.8, 2.2),
        ylim = range(medias_fat) + c(-1, 1),
        xlab = "Tratamento", ylab = "Variação média da PAS (mmHg)")
axis(1, at = 1:2, labels = rownames(medias_fat))
legend("bottomleft", title = "Sexo", legend = colnames(medias_fat), pch =
 ↪  c(19, 17),
       lty = c(1, 2), lwd = 2, col = c("black", "grey45"), bty = "n",
        ↪  inset = 0.02)
```

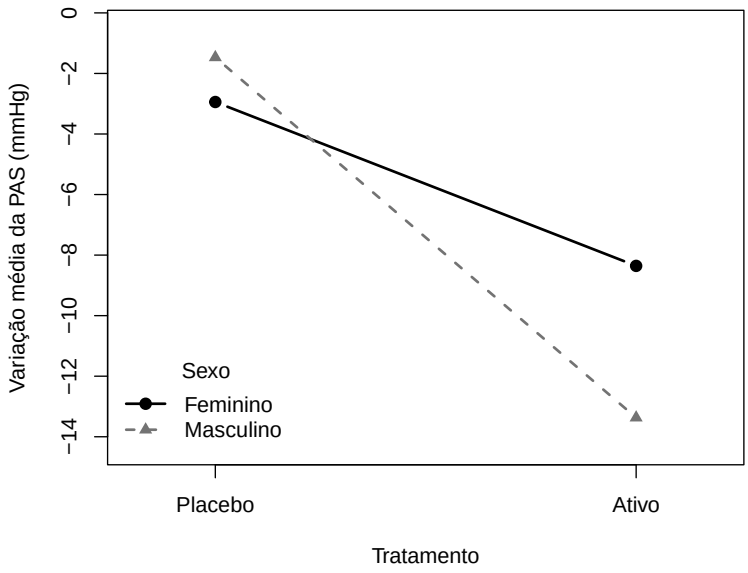


Figura 7.3: Gráfico de interação: variação média da PAS (mmHg) em cada combinação de tratamento e sexo (dados simulados). As linhas não paralelas indicam que o efeito do tratamento difere entre os sexos.

```
par(op)
```

A função `interaction.plot()` do R produz o mesmo gráfico com uma única linha de código; aqui o desenhamos com `matplot()` para controlar a posição da legenda.

```
with(ensaio, tapply(variacao_pas, list(Sexo = sexo, Tratamento =
 ↪  tratamento), mean))
```

```
##           Tratamento
## Sexo          Placebo      Ativo
##   Feminino  -2.943333  -8.356667
##   Masculino -1.470000 -13.370000
```

Duas observações finais sobre a ANOVA fatorial:

- **Poder para interações.** Detectar uma interação exige amostras muito maiores do que detectar um efeito principal de mesmo tamanho. Por isso, ensaios clínicos raramente têm poder para análises de subgrupo, e diferenças de efeito entre subgrupos relatadas sem planejamento prévio devem ser vistas com ceticismo.

- **Desenhos desbalanceados.** Quando os grupos têm tamanhos diferentes, as somas de quadrados deixam de ser únicas: a função `aov()` usa somas de quadrados sequenciais (tipo I), cujo resultado depende da ordem dos fatores na fórmula. Em desenhos desbalanceados, o pesquisador deve decidir conscientemente qual tipo de soma de quadrados usar (tipos II ou III, disponíveis, por exemplo, no pacote `car`) e declará-lo.

7.3 Análise multivariada

Os métodos multivariados analisam simultaneamente muitas variáveis medidas nos mesmos indivíduos. São indispensáveis quando há dezenas ou milhares de variáveis (painéis de biomarcadores, dados de expressão gênica, imagens, questionários com muitos itens). Esta seção apresenta dois métodos **exploratórios**, isto é, que buscam descrever estruturas nos dados sem testar hipóteses previamente formuladas: a análise de componentes principais, que reduz o número de variáveis, e a análise de agrupamentos, que reúne indivíduos semelhantes.

Para os exemplos, simulamos um painel metabólico de 150 adultos com oito variáveis. Por construção, as variáveis dependem de dois fatores latentes (não observados): um de **adiposidade** (que afeta peso, cintura, IMC e, em parte, triglicerídeos e HDL) e um **glicêmico** (que afeta glicemia, insulina e HbA1c).

```
set.seed(123)
n_p <- 150
adip <- rnorm(n_p); glic <- rnorm(n_p)
painel <- data.frame(
  peso    = 75 + 12 * adip + rnorm(n_p, 0, 4),
  cintura = 92 + 10 * adip + rnorm(n_p, 0, 4),
  imc     = 27 + 4 * adip + rnorm(n_p, 0, 1.2),
  trig    = 140 + 25 * adip + 15 * glic + rnorm(n_p, 0, 25),
  hdl     = 50 - 6 * adip + rnorm(n_p, 0, 6),
  glicemia = 100 + 12 * glic + rnorm(n_p, 0, 6),
  insulina = 12 + 4 * glic + 2 * adip + rnorm(n_p, 0, 2.5),
  hba1c   = 5.8 + 0.5 * glic + rnorm(n_p, 0, 0.25)
)
round(cor(painel), 2)
```

```
##           peso cintura   imc  trig   hdl glicemia insulina hba1c
## peso      1.00    0.87  0.87  0.51 -0.59    -0.14     0.24 -0.14
## cintura   0.87    1.00  0.88  0.58 -0.62    -0.12     0.24 -0.12
## imc       0.87    0.88  1.00  0.59 -0.63    -0.10     0.28 -0.06
## trig      0.51    0.58  0.59  1.00 -0.43     0.22     0.44  0.24
## hdl      -0.59   -0.62 -0.63 -0.43  1.00     0.06    -0.18  0.04
## glicemia -0.14   -0.12 -0.10  0.22  0.06     1.00     0.67  0.80
## insulina  0.24    0.24  0.28  0.44 -0.18     0.67     1.00  0.64
## hba1c    -0.14   -0.12 -0.06  0.24  0.04     0.80     0.64  1.00
```

7.3.1 Componentes principais

7.3.1.1 A ideia

Com oito variáveis correlacionadas, boa parte da informação é redundante: peso, cintura e IMC medem essencialmente a mesma coisa. A **análise de componentes principais** (ACP, ou PCA, do inglês *principal component analysis*) substitui as variáveis originais por novas variáveis, os **componentes principais**, com três propriedades (Jolliffe and Cadima 2016):

1. cada componente é uma **combinação linear** das variáveis originais: $\text{CP}_1 = a_{11}X_1 + a_{12}X_2 + \cdots + a_{1p}X_p$;
2. os componentes são **não correlacionados** entre si;
3. os componentes são ordenados pela **variância** que explicam: o primeiro componente é a combinação linear com a maior variância possível; o segundo, a de maior variância entre as não correlacionadas com o primeiro; e assim por diante.

Geometricamente, a ACP gira os eixos do espaço das variáveis para que o primeiro eixo aponte na direção de maior dispersão da nuvem de pontos. Se os primeiros dois ou três componentes concentram a maior parte da variância, eles resumem os dados com pouca perda de informação, e podem ser representados em um gráfico.

Os coeficientes a_{jk} são os **autovetores** da matriz de covariâncias (ou de correlações), e a variância de cada componente é o **autovalor** correspondente. Os autovetores são chamados de **cargas** (*loadings*) e indicam quanto cada variável contribui para o componente.

7.3.1.2 Padronização

A ACP é sensível às escalas: uma variável medida em unidades com valores grandes (triglicerídeos, em mg/dL) dominaria a variância total em relação a outra com valores pequenos (HbA1c, em %). Quando as variáveis estão em unidades diferentes, elas devem ser **padronizadas** (média zero e desvio padrão um) antes da análise, o que equivale a fazer a ACP sobre a matriz de **correlações**. Na função `prcomp()`, isso se faz com `scale. = TRUE`.

```
acp <- prcomp(painel, scale. = TRUE)
summary(acp)
```

```
## Importance of components:
##                           PC1    PC2     PC3     PC4     PC5
## Standard deviation     1.9505 1.5801 0.72171 0.68133 0.52831
```

```
## Proportion of Variance 0.4755 0.3121 0.06511 0.05803 0.03489
## Cumulative Proportion  0.4755 0.7876 0.85276 0.91078 0.94567
##                            PC6     PC7     PC8
## Standard deviation     0.44767 0.35400 0.32999
## Proportion of Variance 0.02505 0.01566 0.01361
## Cumulative Proportion  0.97072 0.98639 1.00000
```

```
round(acp$rotation[, 1:2], 2)   # cargas dos dois primeiros componentes
```

```
##             PC1   PC2
## peso       0.46 -0.14
## cintura    0.47 -0.13
## imc        0.48 -0.10
## trig       0.38  0.16
## hdl       -0.38  0.08
## glicemia   0.02  0.59
## insulina   0.22  0.49
## hba1c      0.03  0.58
```

7.3.1.3 Interpretação

O primeiro componente explica 47,6% da variância total, e o segundo, 31,2%; juntos, 78,8%. As cargas mostram que o primeiro componente reúne principalmente peso, cintura, IMC e HDL (este com sinal oposto), recuperando o fator de adiposidade, e que o segundo reúne glicemia, insulina e HbA1c, recuperando o fator glicêmico. Triglicerídeos e insulina, que na simulação dependem dos dois fatores, têm cargas nos dois componentes. O sinal das cargas é arbitrário: inverter todos os sinais de um componente produz uma solução equivalente.

Para decidir quantos componentes reter, examina-se o **gráfico de sedimentação** (*scree plot*), que mostra a variância de cada componente, e procura-se o ponto a partir do qual a curva se achata. Critérios auxiliares incluem reter componentes com autovalor maior que 1 (quando se usa a matriz de correlações) ou que expliquem, acumuladamente, uma fração preestabelecida da variância. O **biplot** representa simultaneamente os indivíduos (pontos) e as variáveis (setas) no plano dos dois primeiros componentes.

```
op <- par(mfrow = c(1, 2), mar = c(4, 4, 2, 1))
plot(100 * var_exp, type = "b", pch = 19, xlab = "Componente", ylab =
 ↪  "Variância explicada (%)")
# Biplot desenhado manualmente para controlar a posição dos rótulos
cargas <- acp$rotation[, 1:2]
escores <- acp$x[, 1:2]
escores <- escores / max(abs(escores)) * max(abs(cargas))   # escores na
 ↪  escala das cargas
plot(escores, pch = 19, cex = 0.5, col = "grey70", asp = 1,
     xlim = c(-0.75, 0.95), ylim = c(-0.45, 0.85),
```

```
     xlab = sprintf("CP1 (%s%%)", num(100 * var_exp[1])),
     ylab = sprintf("CP2 (%s%%)", num(100 * var_exp[2])))
abline(h = 0, v = 0, col = "grey85", lty = 3)
arrows(0, 0, cargas[, 1], cargas[, 2], length = 0.08, lwd = 1.5)
# Variáveis com setas quase coincidentes recebem um único rótulo
 ↪  empilhado
grupos_set <- cutree(hclust(dist(cargas)), h = 0.08)
rotulos <- c(peso = "Peso", cintura = "Cintura", imc = "IMC", trig =
 ↪  "Triglicerídeos",
             hdl = "HDL", glicemia = "Glicemia", insulina = "Insulina",
              ↪  hba1c = "HbA1c")
for (g in unique(grupos_set)) {
  idx <- which(grupos_set == g)
  ponta <- colMeans(cargas[idx, , drop = FALSE])
  txt <- paste(rotulos[rownames(cargas)[idx]], collapse = "\n")
  ang <- atan2(ponta[2], ponta[1])
  # rótulo além da ponta da seta, ancorado pelo lado voltado para a seta
  x_t <- ponta[1] + 0.07 * cos(ang); y_t <- ponta[2] + 0.07 * sin(ang)
  aj <- c((1 - cos(ang)) / 2, (1 - sin(ang)) / 2)
  w <- strwidth(txt, cex = 0.8); h <- strheight(txt, cex = 0.8)
  rect(x_t - aj[1] * w - 0.01, y_t - aj[2] * h - 0.01,
       x_t + (1 - aj[1]) * w + 0.01, y_t + (1 - aj[2]) * h + 0.01, col =
 ↪  "white", border = NA)
  text(x_t, y_t, txt, cex = 0.8, adj = aj)
}
```

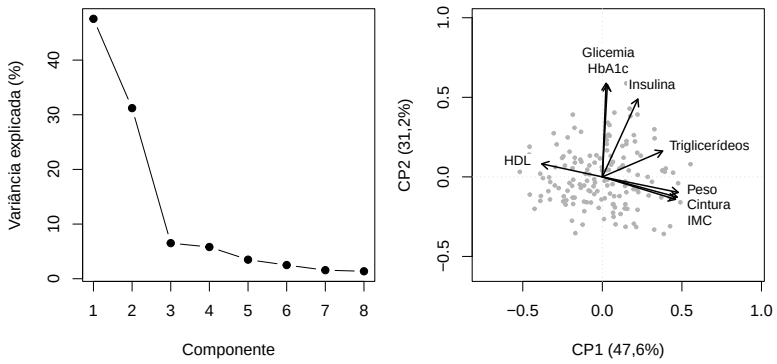


Figura 7.4: Análise de componentes principais do painel metabólico simulado. À esquerda, variância explicada por componente (gráfico de sedimentação). À direita, biplot: os pontos são indivíduos e as setas indicam a direção e o peso de cada variável nos dois primeiros componentes. Variáveis com setas praticamente coincidentes compartilham um rótulo.

```
par(op)
```

Cuidados com a ACP: (i) ela captura apenas relações lineares; (ii) componentes são construções estatísticas, e dar-lhes nomes ("fator de adiposidade") é uma interpretação que precisa de respaldo substantivo; (iii) a ACP é um método de redução de dimensão, diferente da **análise fatorial**, que postula um modelo explícito de fatores latentes e erros, embora as duas sejam frequentemente confundidas.

7.3.2 Clusterização

A **análise de agrupamentos** (*cluster analysis*, ou clusterização) busca dividir os indivíduos em grupos de modo que os de um mesmo grupo sejam parecidos entre si e diferentes dos de outros grupos. Em saúde, é usada, por exemplo, para propor subtipos de doenças a partir de perfis clínicos ou moleculares. Ao contrário dos métodos de classificação supervisionada, não há um rótulo verdadeiro conhecido: os grupos emergem dos dados.

7.3.2.1 Medindo a semelhança

Todo método de agrupamento depende de uma medida de **distância** entre indivíduos. A mais comum é a **distância euclidiana**, $d(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_j (x_j - y_j)^2}$. Assim como na ACP, variáveis em escalas diferentes devem ser padronizadas antes; caso contrário, a distância será dominada pelas variáveis com valores maiores. Para variáveis categóricas ou mistas, existem outras distâncias (por exemplo, a de Gower).

7.3.2.2 Agrupamento hierárquico

O **agrupamento hierárquico aglomerativo** começa com cada indivíduo em seu próprio grupo e, a cada passo, une os dois grupos mais próximos, até restar um único grupo. A distância entre grupos é definida pelo **método de ligação**: ligação completa (maior distância entre membros), simples (menor distância), média, ou o método de Ward, que une os grupos cuja fusão menos aumenta a variância interna. O resultado é um **dendrograma**, uma árvore em que a altura de cada junção indica a distância entre os grupos unidos. Cortar a árvore em uma altura define os grupos.

7.3.2.3 Método das k-médias

O **método das k-médias** (*k-means*) exige que se defina antecipadamente o número k de grupos e procede assim:

1. escolhem-se k centros iniciais (em geral, aleatoriamente);
2. cada indivíduo é atribuído ao centro mais próximo;
3. cada centro é recalculado como a média dos indivíduos atribuídos a ele;
4. repetem-se os passos 2 e 3 até que as atribuições não mudem.

O algoritmo minimiza a soma dos quadrados das distâncias de cada indivíduo ao centro do seu grupo, mas pode convergir para soluções diferentes conforme os centros iniciais. Por isso, deve ser executado com várias inicializações (argumento `nstart` da função `kmeans()`), retendo-se a melhor.

7.3.2.4 Exemplo e validação

Simulamos dois biomarcadores em 150 pacientes pertencentes a três subgrupos verdadeiros e aplicamos os dois métodos:

```
set.seed(5)
centros <- cbind(c(0, 3, 0), c(0, 0, 3))
grupo_real <- rep(1:3, each = 50)
bio <- data.frame(marcador1 = centros[grupo_real, 1] + rnorm(150, 0,
 ↪  0.8),
                  marcador2 = centros[grupo_real, 2] + rnorm(150, 0,
                   ↪  0.8))
bio_p <- scale(bio)

km <- kmeans(bio_p, centers = 3, nstart = 25)
hc <- hclust(dist(bio_p), method = "ward.D2")
grupos_hc <- cutree(hc, k = 3)

table(Real = grupo_real, kmeans = km$cluster)
```

```
##     kmeans
## Real  1  2  3
##    1  2  2 46
##    2  0 49  1
##    3 50  0  0
```

```
op <- par(mfrow = c(1, 2), mar = c(4, 4, 2, 1))
plot(bio_p, pch = c(19, 17, 15)[km$cluster], col = adjustcolor("grey25",
 ↪  alpha.f = 0.7),
     xlab = "Marcador 1 (padronizado)", ylab = "Marcador 2
      ↪  (padronizado)", main = "k-médias")
points(km$centers, pch = 4, cex = 2.5, lwd = 3)
plot(hc, labels = FALSE, hang = -1, main = "Hierárquico (Ward)", xlab =
 ↪  "", sub = "", ylab = "Altura")
abline(h = mean(rev(hc$height)[2:3]), lty = 2)
```

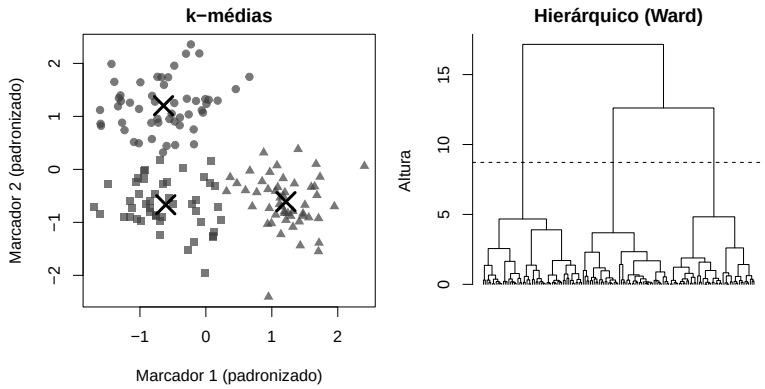


Figura 7.5: Análise de agrupamentos de dados simulados com três subgrupos. À esquerda, grupos encontrados pelo método das k-médias (símbolos) e centros (×). À direita, dendrograma do agrupamento hierárquico com ligação de Ward; o corte em três grupos está indicado pela linha tracejada.

```
par(op)
```

Neste exemplo, os grupos são bem separados e ambos os métodos recuperam quase perfeitamente os subgrupos reais. Na pesquisa real, porém, não se conhece a resposta. Duas questões tornam a clusterização delicada.

Quantos grupos? Não há resposta definitiva. Uma ferramenta comum é a **largura média da silhueta** (Rousseeuw 1987). Para cada indivíduo, a silhueta compara a distância média aos membros do próprio grupo (a) com a distância média aos membros do grupo vizinho mais próximo (b): $s = (b - a)/\max(a, b)$. Valores próximos de 1 indicam indivíduos bem alocados; próximos de 0, indivíduos na fronteira entre grupos; negativos, provavelmente mal alocados. Escolhe-se o k com maior silhueta média.

```
library(cluster)
sil_media <- sapply(2:6, function(k) {
  cl <- kmeans(bio_p, centers = k, nstart = 25)$cluster
  mean(silhouette(cl, dist(bio_p))[, "sil_width"])
})
data.frame(k = 2:6, silhueta_media = round(sil_media, 2))
```

```
##   k silhueta_media
## 1 2           0.47
## 2 3           0.52
## 3 4           0.46
## 4 5           0.40
## 5 6           0.37
```

Os grupos existem? Todo algoritmo de agrupamento produz grupos, mesmo quando os dados não têm estrutura alguma. O exemplo a seguir aplica as k-médias a pontos distribuídos uniformemente em um quadrado, sem nenhum agrupamento real:

```
set.seed(8)
ruido <- matrix(runif(300), ncol = 2)
km_ruido <- kmeans(ruido, centers = 3, nstart = 25)
table(km_ruido$cluster)
```

```
##
##  1  2  3
## 53 47 50
```

```
sil_ruido <- mean(silhouette(km_ruido$cluster, dist(ruido))[,
 ↪  "sil_width"])
sil_ruido
```

```
## [1] 0.4081073
```

O algoritmo divide os pontos em três grupos de tamanhos semelhantes, e a silhueta média (0,41) não fica muito distante da obtida com os subgrupos reais (0,52), embora os "grupos" sejam apenas uma partição arbitrária de uma nuvem homogênea. Por isso, grupos obtidos por clusterização devem ser tratados como **hipóteses**: precisam ser avaliados quanto à estabilidade (repetir a análise em subamostras), reproduzidos em dados independentes e validados por variáveis externas que não foram usadas para formá-los (prognóstico, resposta a tratamento). Uma prática a evitar é formar grupos com um conjunto de variáveis e depois "demonstrar" que os grupos diferem nessas mesmas variáveis com testes de hipóteses: as diferenças são garantidas pela construção, e os valores p não têm significado.

7.4 Resumo do capítulo

- A covariância indica o sentido da associação entre duas variáveis, mas depende das unidades. O coeficiente de Pearson a padroniza e mede a intensidade da associação **linear**; o de Spearman, calculado sobre postos, mede associação **monotônica** e é robusto a valores extremos.
- Correlação não é causalidade, depende da amplitude dos dados, pode ser criada ou mascarada pela mistura de grupos e não serve para avaliar concordância entre métodos de medida.
- A regressão linear simples estima por mínimos quadrados a reta $\hat{y} = b_0 + b_1 x$, com $b_1 = S_{xy}/S_{xx}$. A inclinação é a variação esperada em y por unidade de x; R^2 é a fração da variabilidade explicada.

- O intervalo de predição (para um indivíduo) é sempre mais largo que o intervalo de confiança (para a média).
- As suposições da regressão (linearidade, independência, normalidade e variância constante dos erros) são avaliadas pelos resíduos.
- Na regressão múltipla, cada coeficiente é ajustado para as demais variáveis do modelo. O ajuste controla fatores de confusão medidos, e a escolha das variáveis deve se basear em conhecimento substantivo, não em seleção automática.
- A ANOVA compara três ou mais médias com um único teste, baseado na razão entre a variabilidade entre e dentro dos grupos, que segue a distribuição F. Comparações *post hoc* (Tukey, Dunnett) identificam quais grupos diferem. ANOVA, teste t e regressão são casos do modelo linear geral.
- A ANOVA fatorial avalia efeitos principais e interações. Na presença de interação, o efeito de um fator depende do nível do outro.
- A análise de componentes principais resume variáveis correlacionadas em poucos componentes não correlacionados; exige padronização quando as unidades diferem.
- A clusterização sempre produz grupos, mesmo em dados sem estrutura. Os grupos encontrados são hipóteses a validar.

7.5 Exercícios

1. Para os dados $x = (1, 2, 3, 4, 5)$ e $y = (2, 4, 5, 4, 5)$, calcule à mão: (a) S_{xx}, S_{yy} e S_{xy}; (b) o coeficiente de Pearson; (c) o coeficiente de Spearman (atenção aos empates em y: use `cor(x, y, method = "spearman")` para conferir); (d) a reta de mínimos quadrados e o R^2.

2. Um estudo encontrou correlação de 0,85 entre as medidas de glicemia obtidas por um glicosímetro portátil e pelo laboratório central, e concluiu que "os métodos são concordantes". Critique a conclusão e indique uma análise mais adequada.

3. Em uma regressão da PAS (mmHg) sobre a idade (anos), obteve-se $\hat{y} = 98{,}5 + 0{,}62 \times \text{idade}$, com EP da inclinação igual a 0,08 e $n = 250$. (a) Interprete a inclinação. (b) Calcule um IC de 95% aproximado para a inclinação. (c) Qual a PAS média esperada aos 60 anos? (d) Seria apropriado usar o modelo para prever a PAS de uma criança de 8 anos?

4. Em um modelo de regressão múltipla para o peso ao nascer (g), o coeficiente da variável "tabagismo materno" (1 = sim, 0 = não) foi -180 g, ajustado para idade gestacional e paridade. Interprete esse coeficiente. Seria correto ajustar também para o peso da placenta? Justifique.

5. Complete a tabela de ANOVA: quatro grupos com 10 observações cada; SQEntre = 120; SQTotal = 480. Calcule os graus de liberdade, os quadra-

dos médios, a estatística F e o η^2. Use `pf(F, gl1, gl2, lower.tail = FALSE)` para obter o valor p.

6. Explique por que realizar todos os testes t entre pares de cinco grupos, cada um com $\alpha = 0{,}05$, é problemático. Quantas comparações seriam feitas?

7. Em um ensaio fatorial 2×2 (tratamento $\times$ presença de diabetes), as médias de redução da HbA1c foram: placebo sem diabetes, 0,1; ativo sem diabetes, 0,2; placebo com diabetes, 0,1; ativo com diabetes, 1,0. Desenhe o gráfico de interação e descreva o resultado. Faz sentido relatar apenas "o efeito principal do tratamento"?

8. Usando o conjunto `painel` deste capítulo, refaça a ACP **sem** padronizar as variáveis (`prcomp(painel)`). Compare as cargas do primeiro componente com as da análise padronizada e explique a diferença.

7.6 Respostas dos exercícios

1. $\bar{x} = 3$, $\bar{y} = 4$. Desvios de x: $-2, -1, 0, 1, 2$; desvios de y: $-2, 0, 1, 0, 1$.

   a) $S_{xx} = 10$; $S_{yy} = 4 + 0 + 1 + 0 + 1 = 6$; $S_{xy} = 4 + 0 + 0 + 0 + 2 = 6$.
   b) $r = 6/\sqrt{10 \times 6} = 6/\sqrt{60} \approx 0{,}775$.
   c) Postos de y com empates: $2 \to 1$; os dois valores 4 ocupam as posições 2 e 3 e recebem 2,5; os dois valores 5 ocupam 4 e 5 e recebem 4,5. Postos: 1; 2,5; 4,5; 2,5; 4,5. O Pearson desses postos com $1, \ldots, 5$ é $r_s \approx 0{,}74$. A fórmula simplificada com $\sum d_i^2$ não é exata quando há empates.
   d) $b_1 = 6/10 = 0{,}6$; $b_0 = 4 - 0{,}6 \times 3 = 2{,}2$; $\hat{y} = 2{,}2 + 0{,}6x$; $R^2 = r^2 = 36/60 = 0{,}6$.

```r
x <- 1:5; y <- c(2, 4, 5, 4, 5)
c(pearson = cor(x, y), spearman = cor(x, y, method = "spearman"))
```

```
##   pearson  spearman
## 0.7745967 0.7378648
```

```r
coef(lm(y ~ x)); summary(lm(y ~ x))$r.squared
```

```
## (Intercept)           x
##         2.2         0.6
```

```
## [1] 0.6
```

2. Correlação mede associação linear, não concordância. Dois métodos podem ter correlação alta e diferir sistematicamente (por exemplo, o glicosímetro marcar 15 mg/dL a mais em todos os pacientes) ou proporcionalmente (diferença maior em glicemias altas). O valor de r também depende da amplitude dos valores incluídos. A análise adequada é a de Bland e Altman: gráfico das diferenças entre os métodos versus a média dos dois, com o viés médio e os limites de concordância (viés $\pm$ 1,96 DP das diferenças), julgados à luz de uma diferença clinicamente aceitável definida antes.

3. (a) A cada ano a mais de idade, a PAS média é 0,62 mmHg mais alta (ou 6,2 mmHg por década). (b) Com $n = 250$, o quantil t é praticamente 1,97: $0{,}62 \pm 1{,}97 \times 0{,}08$, de 0,46 a 0,78 mmHg por ano. (c) $98{,}5 + 0{,}62 \times 60 = 135{,}7$ mmHg. (d) Não: seria extrapolação muito além da faixa de idades presumivelmente estudada (adultos), e a relação entre idade e pressão em crianças é diferente.

4. Filhos de mães fumantes nasceram, em média, 180 g mais leves do que filhos de mães não fumantes com a mesma idade gestacional e a mesma paridade. Não seria correto ajustar para o peso da placenta se o tabagismo reduzir o peso ao nascer em parte por prejudicar a placenta: o peso placentário estaria no caminho causal (seria um mediador), e ajustar para ele removeria parte do efeito que se quer estimar.

5. gl entre $= 4-1 = 3$; gl dentro $= 40-4 = 36$; SQDentro $= 480-120 = 360$; QMEntre $= 120/3 = 40$; QMDentro $= 360/36 = 10$; $F = 4{,}0$ com 3 e 36 gl; $p \approx 0{,}015$ (`pf(4, 3, 36, lower.tail = FALSE)`); $\eta^2 = 120/480 = 0{,}25$.

6. Com cinco grupos há $\binom{5}{2} = 10$ comparações. Se todas as hipóteses nulas forem verdadeiras e os testes fossem independentes, a probabilidade de ao menos um falso positivo seria $1 - 0{,}95^{10} \approx 40\%$ (os testes não são independentes, mas a taxa continua muito acima de 5%). O correto é usar a ANOVA seguida de um método de comparações múltiplas, como o de Tukey, ou planejar previamente um pequeno número de comparações.

7. O tratamento praticamente não tem efeito em pessoas sem diabetes (0,2 contra 0,1) e tem efeito grande nas com diabetes (1,0 contra 0,1): há interação importante (linhas não paralelas no gráfico). Relatar apenas o efeito principal, a média dos efeitos nos dois grupos (cerca de 0,5), descreveria um efeito que não ocorre em nenhum dos dois grupos. Os efeitos devem ser relatados separadamente para cada estrato.

8. Sem padronização, o primeiro componente é dominado pelas variáveis com maior variância em suas unidades originais (triglicerídeos, em mg/dL, e, em menor grau, peso e cintura), enquanto variáveis como HbA1c e IMC, de variância numericamente pequena, quase não contribuem. O componente passa a refletir as escalas de medida, e não a estrutura de correlação. Quando as variáveis estão em unidades diferentes, a padronização é necessária.

Capítulo 8

Uso de *softwares* estatísticos

Hércules Rezende Freitas, Ph.D.[1]

[1]Universidade do Estado do Rio de Janeiro (UERJ), Faculdade de Ciências Médicas, Departamento de Ciências Médicas Integradas, Laboratório de Informática em Saúde (LabInfoS), Cabo Frio/RJ, Brasil.

8.1 *Softwares* "no-code" e "low-code"

Nem toda análise estatística exige programação. Programas com interface gráfica, em que as análises são feitas por menus e caixas de diálogo, são chamados de *no-code* (sem código); outros combinam menus com a possibilidade de registrar ou editar comandos, e são chamados de *low-code*. Eles reduzem a barreira de entrada e são adequados para muitas análises simples. Conhecer suas vantagens e limitações ajuda a escolher a ferramenta certa para cada tarefa.

8.1.1 Planilhas eletrônicas

Planilhas como Microsoft Excel, LibreOffice Calc e Google Planilhas são, de longe, as ferramentas mais usadas para registrar dados de pesquisa. São excelentes para a **entrada** de dados, mas arriscadas como ferramenta de **análise**:

- **as operações não deixam registro**: ordenar uma coluna sem as demais, apagar uma linha por engano ou arrastar uma fórmula para o intervalo errado altera os dados sem deixar rastro;
- **conversões automáticas** corrompem dados. O exemplo mais conhecido é a conversão de nomes de genes em datas (*SEPT2* virando "2-set", *MARCH1* virando "1-mar"); um levantamento encontrou o problema em cerca de 20% dos artigos de genômica com listas de genes em arquivos

suplementares (Ziemann et al. 2016). Números com zeros à esquerda (códigos de municípios, CEPs) também são frequentemente alterados;
- **erros de fórmula** passam despercebidos. Um caso célebre é o de um influente estudo econômico sobre dívida pública e crescimento, cuja planilha omitia, por um erro de intervalo, cinco países da média calculada; a correção, junto com outras escolhas analíticas questionadas, alterou substancialmente as conclusões (Herndon et al. 2014).

Se a planilha for usada para registrar dados, algumas regras evitam a maior parte dos problemas (Broman and Woo 2018): uma linha por observação e uma coluna por variável; uma única informação por célula; nomes de variáveis curtos, sem espaços nem acentos; datas no formato ano-mês-dia (2026-10-20); nenhuma informação codificada por cor ou formatação; células vazias, e não zeros ou traços, para dados faltantes (ou um código explícito, como `NA`); um dicionário de dados, em outra aba ou arquivo, descrevendo cada variável, sua unidade e seus códigos; e nenhum cálculo nos dados brutos. Feito isso, a análise deve ser realizada em um programa estatístico, lendo o arquivo da planilha sem alterá-lo.

8.1.2 Programas com interface gráfica

- **SPSS** (IBM): muito usado em ciências da saúde e sociais, com menus para a maioria das análises clássicas. Cada análise feita pelos menus pode gerar a sintaxe correspondente (botão "Colar"), que deve ser guardada para documentar e reproduzir a análise. É um programa pago.
- **Stata**: combina menus e uma linguagem de comandos concisa, muito usado em epidemiologia e economia; pago.
- **GraphPad Prism**: popular em laboratórios de ciências biológicas, voltado a análises de experimentos e à produção de gráficos; pago.
- **JASP** e **jamovi**: programas gratuitos e de código aberto, com interfaces semelhantes às do SPSS, construídos sobre o R. Os resultados são atualizados automaticamente quando as opções são alteradas, e o jamovi permite visualizar o código R equivalente. O JASP oferece também análises bayesianas pela interface.
- **Epi Info**: programa gratuito do CDC (Centros de Controle e Prevenção de Doenças dos Estados Unidos), voltado à epidemiologia de campo, com criação de questionários, entrada de dados e análises básicas.
- **PSPP**: alternativa gratuita ao SPSS, com interface e sintaxe semelhantes.

8.1.3 Vantagens e limitações

As ferramentas com interface gráfica têm vantagens claras: curva de aprendizado curta, menor chance de erros de sintaxe e acesso rápido a análises padronizadas. Suas limitações aparecem quando a análise cresce em complexidade ou precisa ser repetida:

1. **Reprodutibilidade.** Sequências de cliques não ficam registradas, a menos que o programa gere sintaxe e ela seja guardada. Meses depois, é difícil saber exatamente quais opções foram escolhidas, quais casos foram excluídos e em que ordem as transformações foram feitas.
2. **Escalabilidade.** Repetir a mesma análise para 50 desfechos, ou atualizá-la quando chegam novos dados, exige refazer todos os cliques.
3. **Flexibilidade.** Métodos recentes, gráficos personalizados e procedimentos não padronizados frequentemente não estão disponíveis nos menus.
4. **Ilusão de facilidade.** A facilidade de obter um resultado não garante que a análise seja adequada. Um menu oferece um teste t a quem não verificou se as observações são independentes. O conhecimento dos capítulos de bioestatística deste livro é necessário em qualquer ferramenta.

Uma estratégia razoável é usar as ferramentas gráficas para aprender e para análises exploratórias rápidas, e uma linguagem de programação (R ou Python, apresentados a seguir) para as análises que serão publicadas. Programas como o jamovi, que mostram o código R correspondente às escolhas feitas nos menus, são uma boa ponte entre as duas abordagens.

8.2 R para análise estatística

8.2.1 Aprendendo a programar

Aprender a programar, especialmente em uma linguagem voltada à análise de dados como o R, traz dificuldades próprias. Para muitos iniciantes, o maior obstáculo não é a complexidade dos conceitos nem a sintaxe da linguagem, e sim a frustração diante de erros e *bugs*. Essa frustração faz parte do aprendizado; o objetivo não é evitá-la, mas aprender a lidar com ela de modo produtivo.

8.2.1.1 A importância de lidar com a frustração

A frustração costuma indicar que você está enfrentando problemas novos. Diante de um erro no código, é fácil desanimar ou duvidar da própria capacidade. Mas mesmo programadores experientes encontram erros e *bugs* com frequência; a diferença está em como reagem a eles.

Uma habilidade subestimada na programação é a capacidade de ler e interpretar mensagens de erro. Em R, como em muitas outras linguagens de programação, as mensagens de erro são projetadas para guiar o programador na identificação e correção de problemas. Elas parecem crípticas no início, mas, com a prática, você passa a reconhecer padrões comuns e a entender o que indicam. Algumas sugestões para lidar com as dificuldades iniciais:

1. **Aceitação**: aceite que a frustração é uma parte normal do processo de aprendizado. Reconheça seus sentimentos, mas não permita que eles dominem sua motivação para aprender;

2. **Pausas estratégicas**: quando se sentir sobrecarregado, faça uma pausa. Distanciar-se temporariamente do problema pode ajudar a clarear sua mente e trazer novas perspectivas;

3. **Comunidade e suporte**: não hesite em buscar ajuda. A comunidade R é grande e acolhedora, com fóruns e grupos que ajudam programadores de todos os níveis. Descrever sua dificuldade a outras pessoas e pedir orientação costuma resolver o problema mais depressa. Ao pedir ajuda, inclua um **exemplo reprodutível mínimo**: o menor trecho de código, com dados de exemplo, que reproduz o erro;

4. **Prática e persistência**: pratique com regularidade. Quanto mais problemas e erros você enfrenta, mais preparado estará para os próximos;

5. **Registro do que foi aprendido**: cada erro corrigido é algo aprendido. Anotar os erros encontrados e a forma como foram resolvidos cria uma referência para as próximas vezes.

Com o tempo, a maior parte das mensagens de erro se torna familiar, e corrigi-las passa a ser parte rotineira do trabalho.

8.2.2 Visão geral do R e suas aplicações

R é uma linguagem de programação e um ambiente de software para análise estatística e gráfica. A história do R remonta à década de 1970 com o desenvolvimento da linguagem S no Bell Labs por John Chambers e outros (Chambers 1980). A linguagem S foi projetada para ser eficiente e fácil de usar, com foco em análise de dados e gráficos estatísticos.

Na década de 1990, Ross Ihaka e Robert Gentleman, da Universidade de Auckland, na Nova Zelândia, iniciaram o desenvolvimento do R como um projeto de pesquisa. Eles foram influenciados pela linguagem S e pelo Scheme, uma linguagem de programação com semântica de escopo léxico. O R foi concebido como um dialeto da linguagem S, com a intenção de melhorar e ampliar a análise estatística e as capacidades gráficas (Ihaka and Gentleman 1996).

R é uma linguagem de programação interpretada, o que significa que o código é executado diretamente, sem a necessidade de compilação prévia. Isso facilita a depuração e o desenvolvimento iterativo. O R também é dinamicamente tipado: o tipo de dado de uma variável é definido e pode ser alterado em tempo de execução.

Uma das principais características do R é a sua extensibilidade. A comunidade de usuários e desenvolvedores contribuiu com milhares de pacotes que estendem

a funcionalidade básica do R, disponíveis no *Comprehensive R Archive Network (CRAN)* (Hornik 2012) e, para a bioinformática, no Bioconductor. Esses pacotes cobrem técnicas estatísticas, modelos gráficos, métodos de aprendizado de máquina (*machine learning*) e muitas outras áreas.

O R também é conhecido pelos gráficos de alta qualidade, usados tanto na análise exploratória quanto na apresentação de resultados. A linguagem oferece diversas funções e pacotes para a criação de gráficos, entre eles o *ggplot2*, que constrói gráficos complexos por camadas (Wickham 2011).

A comunidade de usuários do R é ativa e colaborativa. Os usuários de R frequentemente compartilham seu código e experiências, ajudando uns aos outros a resolver problemas e a melhorar suas habilidades de programação. Isso é facilitado por fóruns de discussão, listas de e-mail e conferências.

No mercado de trabalho, o R é usado em diversos setores, sobretudo nos que dependem de análise de dados, estatística e modelagem preditiva. Cientistas de dados, analistas de mercado, pesquisadores em saúde e biologia e especialistas em aprendizado de máquina são alguns dos profissionais que o utilizam. A linguagem é valorizada pela capacidade de manipular grandes conjuntos de dados, realizar análises estatísticas complexas, criar visualizações avançadas e desenvolver modelos de aprendizado de máquina.

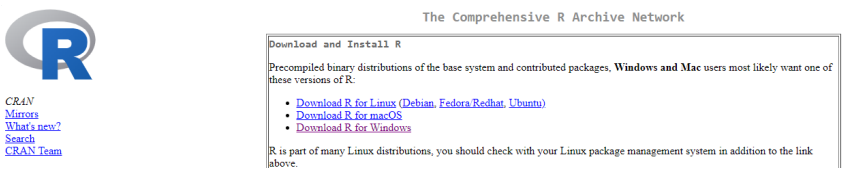
A demanda por profissionais que dominam o R tende a crescer à medida que mais setores passam a tomar decisões com base em dados e que a inteligência artificial (IA) e a análise de dados se integram ao trabalho. Áreas emergentes, como *big data* e a cibersegurança apoiada em aprendizado de máquina, também podem se beneficiar do R.

8.2.3 Instalando o R e o RStudio

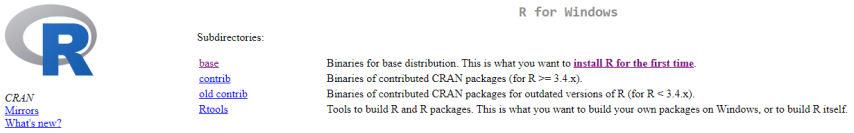
Para instalar o R e o RStudio em computadores com sistemas operacionais Windows ou Mac, siga os passos abaixo. O R deve ser instalado **antes** do RStudio, que é apenas um ambiente de trabalho (uma interface) para o R.

8.2.3.1 Instalação do R no Windows

1. Acesse o site do CRAN (Comprehensive R Archive Network), que é uma rede de servidores que armazena versões atualizadas do R;
2. Em "*Download and Install R*", clique em "*Download R for Windows*";



3. Clique em "*...install R for the first time*";



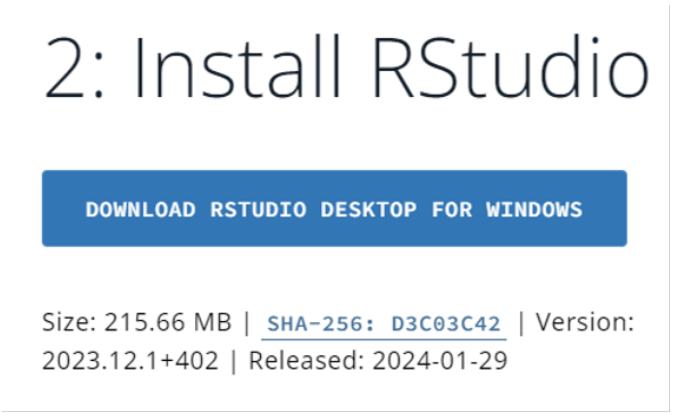
4. Clique em "*Download R x.x.x for Windows*", onde "x.x.x" é o número da versão mais recente;



5. Após o *download*, execute o arquivo baixado e siga as instruções do instalador. Durante a instalação, você pode aceitar as configurações padrão, que são adequadas para a maioria dos usuários.

8.2.3.2 Instalação do RStudio no Windows

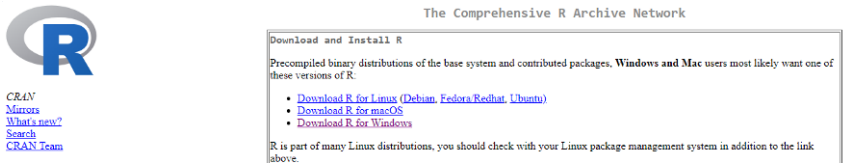
1. Após instalar o R, acesse o site do RStudio (Posit);
2. Desça a página e clique em "*Download RStudio Desktop for Windows*";



3. Execute o arquivo baixado e siga as instruções para concluir a instalação.

8.2.3.3 Instalação do R no Mac

1. Acesse o site do CRAN;
2. Clique em "*Download R for macOS*";



3. Escolha a versão do R adequada ao processador do seu computador: Apple Silicon (M1 ou posteriores) ou Intel (modelos mais antigos). A informação está em "Sobre este Mac", no menu Apple;



4. Após o *download*, abra o arquivo ".pkg" baixado e siga as instruções para instalar o R.

8.2.3.4 Instalação do RStudio no Mac

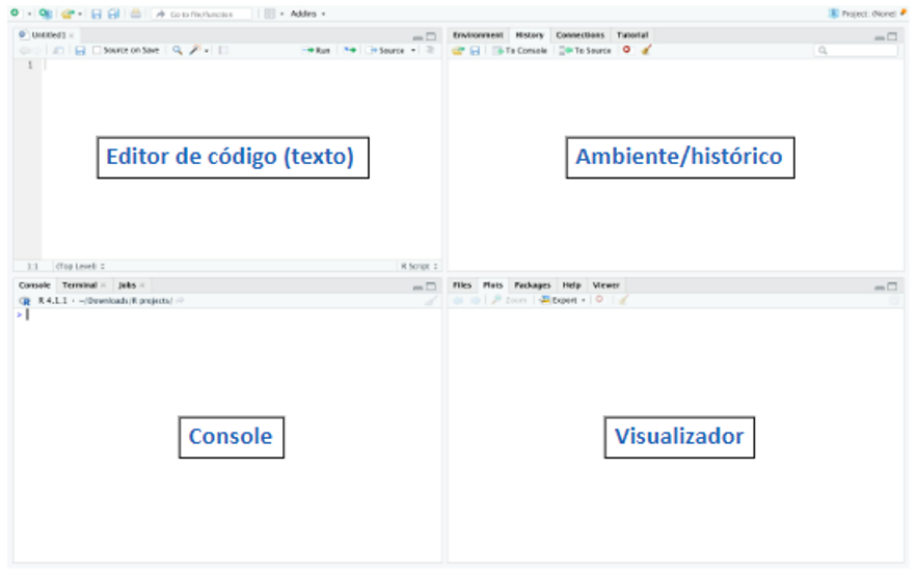
1. Visite o site do RStudio (Posit) após instalar o R;

2. Clique em "*Download RStudio*";

3. Na seção *RStudio Desktop*, clique em "*Download RStudio Desktop for Mac*";

4. Abra o arquivo baixado e arraste o RStudio para a pasta Aplicativos.

Após a instalação, o R pode ser usado por meio da interface do RStudio, que se divide em quatro painéis: o editor de código, onde os *scripts* são escritos e salvos; o console, onde o código é executado e os resultados aparecem; o ambiente, que lista os objetos criados na sessão; e o visualizador, que mostra gráficos, arquivos, pacotes e a ajuda.

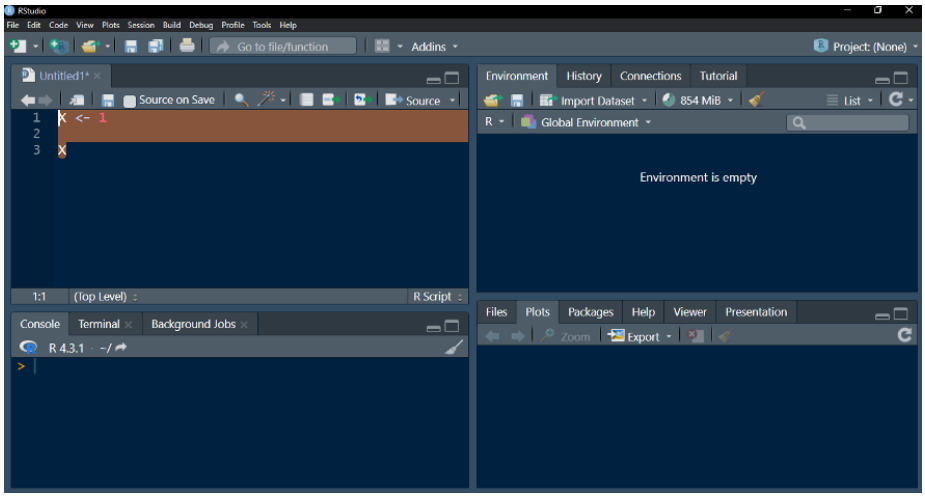


8.2.4 Sintaxe básica e operações no R

8.2.4.1 Sintaxe básica

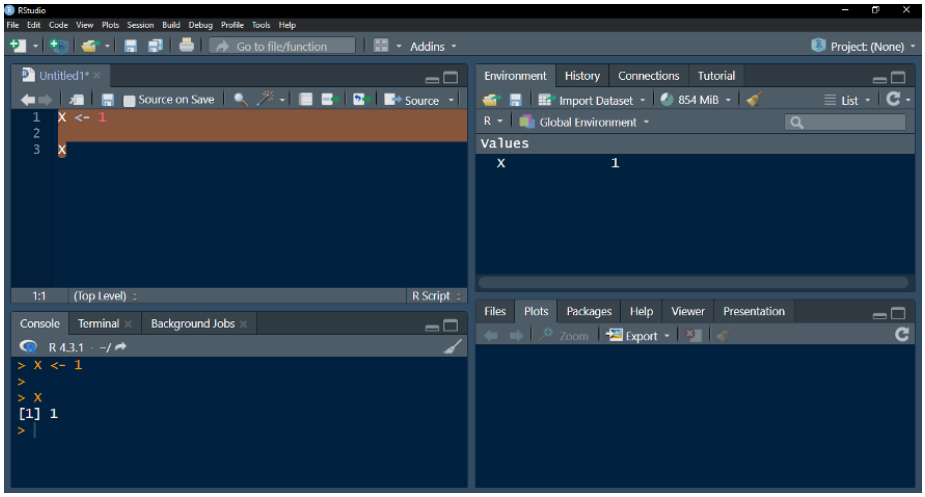
A sintaxe do R é simples. A linguagem faz distinção entre maiúsculas e minúsculas, portanto, "A" e "a" são considerados símbolos diferentes e podem se referir a variáveis diferentes. Os comandos no R são expressões ou atribuições. Se um comando é uma expressão, seu valor é calculado e visualizado, mas é perdido em seguida. Uma atribuição, por outro lado, calcula a expressão e atribui o resultado a uma variável, que é salva no ambiente de trabalho do R. O operador de atribuição recomendado é `<-` (o sinal `=` também funciona na maioria dos casos, mas `<-` é a convenção). Veja um exemplo de atribuição no R ("X <- 1", ou "X recebe o valor 1"):

Passo 1: digite o código desejado no editor



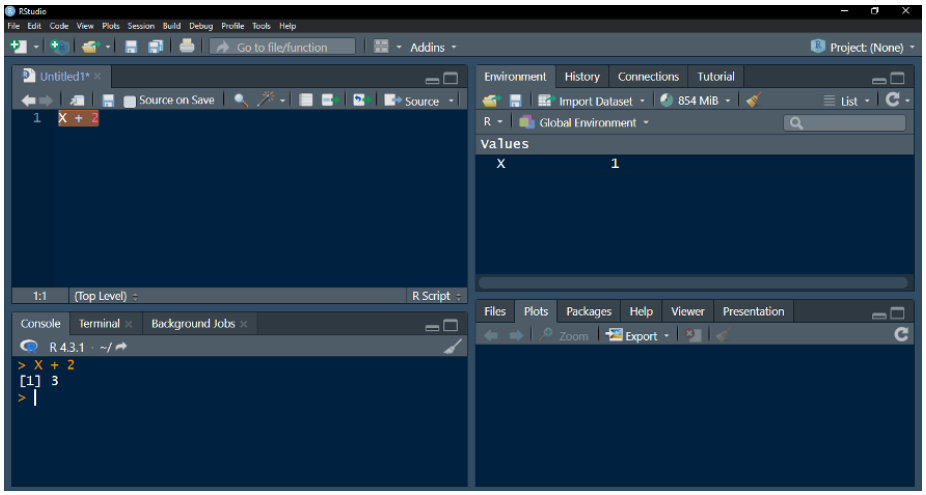
* O código acima indica, na primeira linha, "X contém o valor 1". A segunda linha "pede" ao programa que indique o valor de "X".

Passo 2: selecione o código a ser executado e aperte "Ctrl + Enter" (no Mac, "Cmd + Enter")



*O resultado é apresentado no Console (i.e., "[1] 1" ou "X contém um valor, e esse valor é 1"). O "[1]" indica que o valor exibido é o primeiro elemento do resultado.

Passo 3: use o objeto X gerado em outros códigos



*"X" é um objeto de valor 1. Se somado a 2, retorna o valor 3.

No restante do livro, os códigos e seus resultados são apresentados como no bloco abaixo: primeiro o código, depois a saída, com as linhas de resultado precedidas por **##**. Você pode copiar o código e executá-lo no seu RStudio.

```
X <- 1
X
```

```
## [1] 1
```

```
X + 2
```

```
## [1] 3
```

As principais estruturas de dados do R são os vetores, as matrizes, as listas e os *data frames* (quadros de dados):

```
v <- c(1, 2, 3, 4, 5)                                    # vetor
m <- matrix(1:9, nrow = 3, ncol = 3)                      # matriz
l <- list(nome = "João", idade = 30, altura = 1.75)       # lista
df <- data.frame(nome = c("João", "Maria"), idade = c(30, 25))   # data
 ↪  frame
m
```

```
##      [,1] [,2] [,3]
## [1,]    1    4    7
## [2,]    2    5    8
## [3,]    3    6    9
```

```
l$idade
```

```
## [1] 30
```

```
df
```

```
##    nome idade
## 1  João    30
## 2 Maria    25
```

```
str(df)
```

```
## 'data.frame':    2 obs. of  2 variables:
## $ nome : chr "João" "Maria"
## $ idade: num 30 25
```

O vetor é a estrutura mais básica: uma sequência de valores do mesmo tipo (numérico, texto ou lógico). A matriz organiza valores do mesmo tipo em linhas e colunas. A lista reúne elementos de tipos diferentes, acessados pelo nome com o operador `$`. O *data frame* é a estrutura usada para conjuntos de dados: cada coluna é uma variável, que pode ter um tipo diferente das demais, e cada linha é uma observação. A função `str()` mostra a estrutura de um objeto, com o tipo de cada coluna.

8.2.4.2 Operações básicas

O R pode ser usado como uma calculadora, com os operadores aritméticos de adição (`+`), subtração (`-`), multiplicação (`*`), divisão (`/`) e potenciação (`^`), e com os operadores relacionais menor (`<`), menor ou igual (`<=`), maior (`>`), maior ou igual (`>=`), igual (`==`) e diferente (`!=`), que produzem valores lógicos (`TRUE` ou `FALSE`).

```
3 + 2
```

```
## [1] 5
```

```
5 - 2
```

```
## [1] 3
```

```
3 * 2
```

```
## [1] 6
```

```
6 / 2
```

```
## [1] 3
```

```
2^3
```

```
## [1] 8
```

```
5 > 3
```

```
## [1] TRUE
```

```
5 == 3
```

```
## [1] FALSE
```

As operações também valem para vetores, elemento a elemento. Se dois vetores têm o mesmo comprimento, podem ser somados diretamente:

```
c(1, 2, 3) + c(4, 5, 6)
```

```
## [1] 5 7 9
```

```
c(1, 2, 3) * 10
```

```
## [1] 10 20 30
```

8.2.4.3 Manipulação de dados

Os elementos de um vetor são acessados com colchetes (`[]`), pela posição (que começa em 1) ou por uma condição lógica:

```
x <- c(10, 20, 30, 40, 50)
x[3]
```

```
## [1] 30
```

```r
x[c(1, 5)]
```

```
## [1] 10 50
```

```r
x[x > 25]
```

```
## [1] 30 40 50
```

```r
df[df$idade > 26, ]      # linhas do data frame com idade maior que 26
```

```
##   nome idade
## 1 João    30
```

O R também manipula *strings* (cadeias de caracteres):

```r
nome <- "Maria"
sobrenome <- "Silva"
paste(nome, sobrenome)
```

```
## [1] "Maria Silva"
```

```r
toupper(nome)
```

```
## [1] "MARIA"
```

```r
nchar(sobrenome)
```

```
## [1] 5
```

```r
substr(nome, 1, 1) == substr(sobrenome, 1, 1)   # as iniciais são
 ↪  iguais?
```

```
## [1] FALSE
```

Valores ausentes são representados por `NA`. Muitas funções retornam `NA` quando há algum valor ausente, a menos que se peça explicitamente para ignorá-los:

```r
pressao <- c(120, 135, NA, 128)
mean(pressao)
```

```
## [1] NA
```

```r
mean(pressao, na.rm = TRUE)
```

```
## [1] 127.6667
```

```r
sum(is.na(pressao))      # quantos valores ausentes
```

```
## [1] 1
```

8.2.4.4 Pacotes e ajuda

Funções adicionais são distribuídas em pacotes. Um pacote é **instalado** uma única vez, com `install.packages()`, e **carregado** em cada nova sessão do R, com `library()`. A documentação de qualquer função é aberta com `?` seguido do nome da função.

```r
install.packages("ggplot2")   # instala (uma vez por computador)
library(ggplot2)              # carrega (uma vez por sessão)
?mean                         # abre a ajuda da função mean()
```

8.2.4.5 Importando dados

Dados de pesquisa costumam estar em planilhas ou arquivos de texto. Para arquivos CSV, a função `read.csv()` lê arquivos com vírgula como separador de colunas e ponto decimal; a função `read.csv2()` lê o padrão brasileiro, com ponto e vírgula como separador e vírgula decimal. Para planilhas do Excel, usa-se o pacote `readxl`.

```r
dados <- read.csv("dados.csv")                  # separador ",", decimal
 ↪  "."
dados <- read.csv2("dados.csv")                 # separador ";", decimal
 ↪  ","
dados <- readxl::read_excel("dados.xlsx", sheet = 1)
head(dados)      # primeiras linhas
str(dados)       # estrutura e tipos das variáveis
summary(dados)   # resumo de cada variável
```

Depois de importar, verifique sempre se o número de linhas e colunas está correto e se cada variável foi lida com o tipo esperado (números como números, e não como texto). Os cuidados com a organização de dados em planilhas estão na seção *Softwares "no-code" e "low-code"*.

Esses são apenas alguns exemplos da sintaxe básica e das operações no R. Não se preocupe se encontrou erros ou se ainda não conseguiu executar todos os códigos de exemplo: continue a leitura e pratique, que é a forma mais eficaz de aprender a linguagem.

8.2.5 Escrevendo código eficiente e legível

Código eficiente e legível é mais fácil de manter, de entender e de compartilhar com colaboradores. A seguir estão algumas recomendações práticas, com exemplos, para escrever código mais limpo em R. Um guia de estilo amplamente adotado é o do *tidyverse* (https://style.tidyverse.org), e o pacote `styler` formata o código automaticamente segundo ele.

8.2.5.1 Convenções de nomenclatura

Utilize nomes significativos e autoexplicativos para variáveis e funções, e adote uma única convenção. A mais usada em R é a de palavras em minúsculas separadas por sublinhado (*snake_case*):

```
# Ruim: nome que não informa o conteúdo
df1 <- read.csv("dados.csv")

# Bom: nome descritivo, em snake_case
dados_clientes <- read.csv("dados_clientes.csv")
```

8.2.5.2 Formatação consistente

Mantenha um padrão de recuo, espaçamento e formatação: espaços em torno de operadores e após vírgulas, e recuo de dois espaços dentro de chaves.

```
# Ruim
soma<-function(x,y){
return(x+y)
}

# Bom
soma <- function(x, y) {
  x + y
}
soma(2, 3)
```

```
## [1] 5
```

Em R, a última expressão avaliada dentro de uma função é retornada automaticamente; o `return()` explícito é necessário apenas para sair da função antes do fim.

8.2.5.3 Comentários e documentação

Inclua comentários que expliquem **por que** algo é feito, e não apenas **o que** é feito, o que o próprio código já mostra. Evite comentários óbvios e mantenha-os atualizados:

```
valores <- c(4.2, 5.1, NA, 6.3)

# Ruim: repete o que o código já diz
# Calcula a média dos valores
media <- mean(valores)

# Bom: explica uma decisão
# Exclui o valor ausente (amostra perdida no transporte; ver protocolo,
 ↪  seção 4.2)
media <- mean(valores, na.rm = TRUE)
media
```

```
## [1] 5.2
```

8.2.5.4 Simplicidade e modularidade

Evite complexidade desnecessária e divida o código em funções pequenas e reutilizáveis. Um erro comum é usar a função `ifelse()`, que é vetorizada (aplica a condição a cada elemento de um vetor), quando a decisão envolve uma única condição; nesse caso, a estrutura adequada é `if ... else`:

```
classifica_pressao <- function(pas) {
  if (length(pas) != 1) stop("Informe um único valor de pressão.")
  if (pas >= 140) {
    "hipertensão"
  } else {
    "normal ou limítrofe"
  }
}
classifica_pressao(150)
```

```
## [1] "hipertensão"
```

```r
# Para classificar um vetor inteiro, ifelse() é a ferramenta certa
ifelse(c(118, 152, 139) >= 140, "hipertensão", "normal ou limítrofe")
```

```
## [1] "normal ou limítrofe" "hipertensão"
## [3] "normal ou limítrofe"
```

8.2.5.5 Tratamento de erros

Verifique as condições que poderiam levar a resultados errados ou falhas inesperadas, e interrompa a execução com uma mensagem clara quando elas ocorrerem:

```r
# Ruim: não verifica a entrada; log(-5) produz NaN com um aviso pouco
↪  informativo
log_seguro_ruim <- function(valor) log(valor)

# Bom: verifica a entrada antes de calcular
log_seguro <- function(valor) {
  if (!is.numeric(valor) || any(valor <= 0, na.rm = TRUE)) {
    stop("O valor deve ser numérico e positivo.")
  }
  log(valor)
}
log_seguro_ruim(-5)
```

```
## Warning in log(valor): NaNs produzidos
```

```
## [1] NaN
```

```r
log_seguro(10)
```

```
## [1] 2.302585
```

```r
log_seguro(-5)
```

```
## Error in `log_seguro()`:
## ! O valor deve ser numérico e positivo.
```

8.2.5.6 Evitar duplicações de código

Quando o mesmo trecho de código aparece repetido com pequenas variações, transforme-o em uma função. Isso reduz erros (uma correção feita em um lugar vale para todos) e torna o código mais curto:

```r
grupo1 <- c(5.1, 4.8, 5.6, 5.0)
grupo2 <- c(6.2, 5.9, 6.4, 6.1)

# Ruim: o mesmo cálculo repetido
resumo1 <- c(media = mean(grupo1), dp = sd(grupo1), n = length(grupo1))
resumo2 <- c(media = mean(grupo2), dp = sd(grupo2), n = length(grupo2))

# Bom: uma função reutilizável, aplicada a uma lista de grupos
resume <- function(x) c(media = mean(x), dp = sd(x), n = length(x))
sapply(list(grupo1 = grupo1, grupo2 = grupo2), resume)
```

```
##         grupo1    grupo2
## media 5.125000 6.1500000
## dp    0.340343 0.2081666
## n     4.000000 4.0000000
```

8.2.5.7 Vetorização

R é uma linguagem vetorizada: muitas operações se aplicam a todos os elementos de um vetor de uma só vez, sem o uso explícito de laços (*loops*). O código vetorizado é mais curto, mais legível e, em geral, mais rápido:

```r
numeros <- 1:10

# Ruim: laço for para calcular o quadrado de cada número
quadrados <- numeric(length(numeros))
for (i in seq_along(numeros)) {
  quadrados[i] <- numeros[i]^2
}

# Bom: operação vetorizada
quadrados_vet <- numeros^2
identical(quadrados, quadrados_vet)
```

```
## [1] TRUE
```

```r
quadrados_vet
```

```
##  [1]   1   4   9  16  25  36  49  64  81 100
```

Laços não são proibidos em R: são a escolha natural quando cada passo depende do anterior (como em uma simulação sequencial). Mas, para operações que se aplicam independentemente a cada elemento, a forma vetorizada é preferível.

Essas práticas beneficiam tanto o autor do código, quando volta a ele meses depois, quanto outras pessoas que venham a trabalhar com ele.

8.2.6 Depuração e tratamento de erros em R

Escrever código que funcione corretamente é apenas uma parte do desenvolvimento de software; a outra é garantir que ele continue funcionando e que possa ser corrigido quando surgirem problemas. A seguir estão algumas estratégias e ferramentas para depuração e tratamento de erros em R, com exemplos práticos.

8.2.6.1 Depuração interativa

A depuração interativa permite que você inspecione o estado do seu programa R enquanto ele está sendo executado. A função `traceback()`, executada logo após um erro, lista a sequência de chamadas que levaram a ele, da mais recente para a mais antiga:

```
f <- function(x) g(x)
g <- function(x) h(x)
h <- function(x) stop("Erro intencional")
f(10)
traceback()
```

No console, a saída é:

```
Error in h(x) : Erro intencional
4: stop("Erro intencional")
3: h(x)
2: g(x)
1: f(10)
```

A leitura é feita de baixo para cima: `f(10)` chamou `g()`, que chamou `h()`, onde o erro ocorreu. Dependendo de como o código foi executado, o R pode acrescentar a cada linha a referência ao arquivo e à linha de origem. Para inspecionar os valores das variáveis no momento do erro, o RStudio oferece a opção “Rerun with Debug”, e o comando `options(error = recover)` abre uma sessão interativa no ponto em que o erro ocorreu. A função `browser()`, inserida dentro de uma função, interrompe a execução naquele ponto e permite examinar os objetos linha a linha.

8.2.6.2 Tratamento de erros com tryCatch

A função `tryCatch()` permite especificar o que deve acontecer quando um erro ou um aviso ocorre, em vez de interromper a execução. É útil, por exemplo, quando uma análise é repetida para muitos conjuntos de dados e uma falha em um deles não deve impedir as demais:

```
log_tolerante <- function(x) {
  tryCatch(
    log(x),
    warning = function(w) {
      message("Aviso capturado: ", conditionMessage(w))
      NA
    },
    error = function(e) {
      message("Erro capturado: ", conditionMessage(e))
      NA
    }
  )
}
log_tolerante(100)
```

```
## [1] 4.60517
```

```
log_tolerante(-1)      # gera um aviso (logaritmo de número negativo)
```

```
## Aviso capturado: NaNs produzidos
```

```
## [1] NA
```

```
log_tolerante("a")     # gera um erro (argumento não numérico)
```

```
## Erro capturado: argumento não numérico para função matemática
```

```
## [1] NA
```

Note a diferença entre os dois casos: `log(-1)` não produz um erro, mas um **aviso** (*warning*) e o valor `NaN`; já `log("a")` produz um **erro**. A função `tryCatch()` trata cada tipo de condição com um manipulador diferente.

8.2.6.3 Logging de erros

Registrar erros em um arquivo (*logging*) é uma prática padrão no desenvolvimento de software, especialmente útil em processos automatizados, aplicativos Shiny ou rotinas executadas sem supervisão. Em R, há pacotes dedicados (como `logger`), mas um registro simples pode ser feito com funções básicas. O exemplo grava cada erro em uma nova linha, com data e hora, sem apagar os registros anteriores:

```
arquivo_log <- tempfile(fileext = ".log")   # em um projeto real:
 ↪  "erros.log"

registra_erro <- function(e) {
  linha <- paste(format(Sys.time(), "%Y-%m-%d %H:%M:%S"),
 ↪  conditionMessage(e))
  cat(linha, "\n", file = arquivo_log, append = TRUE)
}

tryCatch(stop("Falha na leitura do arquivo de entrada"), error =
 ↪  registra_erro)
tryCatch(stop("Variável 'idade' não encontrada"), error = registra_erro)
length(readLines(arquivo_log))   # duas linhas registradas
```

```
## [1] 2
```

8.2.6.4 Debugging com print

Se as ferramentas de depuração não ajudarem, uma alternativa simples é inserir comandos `message()` ou `print()` em pontos estratégicos para acompanhar o fluxo de execução e os valores das variáveis. É um método rudimentar, mas eficaz para localizar onde o problema ocorre:

```
f <- function(x) {
  message("Iniciando f com x = ", x)
  g(x)
}
g <- function(x) {
  message("Iniciando g com x = ", x)
  stop("Erro intencional")
}
f(10)
```

```
## Iniciando f com x = 10

## Iniciando g com x = 10

## Error in `g()`:
## ! Erro intencional
```

As mensagens mostram que a execução passou por `f()` e chegou a `g()`, onde o erro ocorreu. A função `message()` é preferível a `print()` para esse fim, porque suas mensagens podem ser suprimidas (com `suppressMessages()`) sem alterar o código.

Ao escrever suas próprias funções, crie mensagens de erro claras e informativas e documente o significado dos erros que elas podem gerar. Isso economiza tempo de depuração e ajuda a evitar a perda de dados ou de resultados.

8.2.7 Documentando e compartilhando seu código

Documentar e compartilhar o código facilita a colaboração e a revisão por outras pessoas e ajuda o próprio autor a entender e manter o código ao longo do tempo. Para quem está começando a aprender R, é um hábito que vale adquirir cedo.

8.2.7.1 Documentação de código

A documentação é a primeira linha de comunicação entre o programador e quem vai ler o código depois, seja o próprio autor em um momento futuro ou outros programadores. Em R, a documentação pode ser feita diretamente no código, usando comentários, e de forma mais estruturada, usando pacotes como o "roxygen2" (Wickham et al. 2024). No formato do roxygen2, comentários iniciados por `#'` acima de uma função descrevem o que ela faz, seus parâmetros, o que retorna e exemplos de uso; em um pacote, esses comentários são convertidos automaticamente no manual de ajuda acessado com `?`:

```
#' Calcula o índice de massa corporal
#'
#' @param peso Massa corporal, em quilogramas.
#' @param altura Estatura, em metros.
#' @return O IMC, em kg/m².
#' @examples
#' imc(70, 1.75)
imc <- function(peso, altura) {
  peso / altura^2
}
imc(70, 1.75)
```

```
## [1] 22.85714
```

Mesmo fora de um pacote, esse formato é uma forma organizada de documentar as funções de um projeto.

8.2.7.2 Compartilhamento de código

O compartilhamento de código em R pode ser feito de várias maneiras. Uma das mais comuns é através de scripts, que são arquivos de texto com extensão ".R". Esses scripts podem ser compartilhados por e-mail, repositórios de código como GitHub ou plataformas como RPubs, onde é possível publicar análises e códigos para que outros possam ver e usar. Para que o código funcione em outro computador, informe as versões do R e dos pacotes usados (a função `sessionInfo()` as lista) e evite caminhos de arquivo absolutos, específicos do seu computador; os projetos do RStudio (arquivos `.Rproj`) ajudam nisso, porque definem a pasta do projeto como diretório de trabalho.

8.2.7.3 R Markdown

Uma ferramenta muito usada para documentar e compartilhar análises em R é o R Markdown (Baumer and Udwin 2015). Com ele, é possível combinar texto com código R que, ao ser executado, gera resultados incluídos automaticamente no documento. Isso é útil em relatórios, onde a análise e os resultados precisam ser apresentados de forma clara e reproduzível. Este livro é escrito em R Markdown. Um bloco de código em um documento R Markdown tem a seguinte forma:

````
```{r histograma-idade, echo=TRUE, fig.cap="Distribuição da idade dos
↪  participantes."}
# Este código gera um histograma da idade
hist(dados$idade, main = "", xlab = "Idade (anos)")
```
````

O bloco começa com três crases seguidas de `{r}`, em que se podem informar um rótulo (`histograma-idade`) e opções (como `echo`, que define se o código aparece no documento, e `fig.cap`, a legenda da figura), e termina com três crases. Ao compilar o documento, o código é executado e o histograma é inserido no lugar do bloco. Números também podem ser inseridos no meio do texto com código *inline*, escrevendo, por exemplo, "a idade média foi de `` `r round(mean(dados$idade), 1)` `` anos". O Quarto, sucessor do R Markdown, usa a mesma lógica.

8.2.8 Introdução à análise estatística com R

O R foi desenvolvido com foco em estatística e análise de dados. Ele inclui técnicas como regressão linear e não linear, análise de séries temporais, classificação e agrupamento, e pode ser estendido por pacotes, bibliotecas de funções desenvolvidas pela comunidade. Esta seção apresenta as funções básicas para cada etapa de uma análise. Os exemplos usam dois vetores com medidas de temperatura (em °C) registradas em oito horários de um dia:

```
hora <- c(12.08, 13.10, 14.01, 15.07, 16.12, 17.05, 18.10, 19.15)
temperatura <- c(23.1, 22.4, 23.5, 24.2, 25.1, 23.3, 24.0, 23.2)
```

8.2.8.1 Estatística descritiva

A estatística descritiva é a primeira etapa na análise de dados. Ela envolve resumir e organizar os dados de maneira que possam ser facilmente compreendidos. As funções básicas do R para estatística descritiva incluem `mean()` para calcular a média, `median()` para a mediana, `sd()` para o desvio padrão, `var()`

para a variância, `min()` e `max()` para os valores mínimo e máximo, respectivamente, e `summary()` para obter um resumo estatístico dos dados:

```
mean(temperatura)
```

```
## [1] 23.6
```

```
median(temperatura)
```

```
## [1] 23.4
```

```
sd(temperatura)
```

```
## [1] 0.821149
```

```
summary(temperatura)
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   22.40   23.18   23.40   23.60   24.05   25.10
```

As funções são detalhadas na seção *Usando R para estatísticas descritivas*, adiante, e no capítulo *Bioestatística descritiva*. Tente aplicar essas funções em um novo exemplo (ex.: `vet1 <- c(1, 4, 8, 3, 4, 6, 7, 8, 2, 6, 8, 9, 2, 1)`).

8.2.8.2 Visualização de dados

A visualização de dados é uma parte importante da análise estatística. As funções gráficas básicas do R incluem `plot()` para gráficos de dispersão, `hist()` para histogramas, `boxplot()` para boxplots e `barplot()` para gráficos de barras. O pacote `ggplot2` oferece uma estrutura flexível para criar gráficos complexos e será apresentado na seção *Fundamentos da visualização de dados em R*.

Exemplo: usando a função `plot()`

```
plot(temperatura ~ hora, xlab = "Hora", ylab = "Temperatura (°C)")
```

A sintaxe `plot(temperatura ~ hora)` equivale a dizer "temperatura em função da hora"; o mesmo resultado é obtido informando qual vetor ocupa cada eixo: `plot(x = hora, y = temperatura)`.

Exemplo: criando um histograma com a função `hist()`

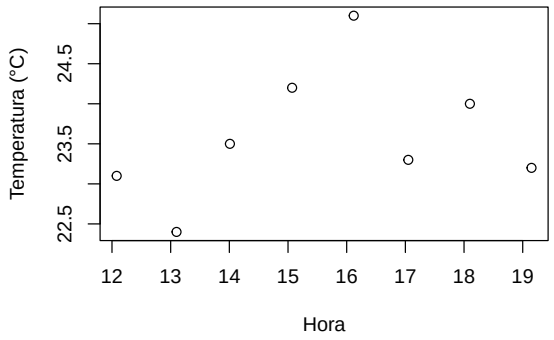


Figura 8.1: Temperatura em função da hora do dia.

```
hist(temperatura, main = "", xlab = "Temperatura (°C)", ylab =
 ↪  "Frequência", col = "grey85")
```

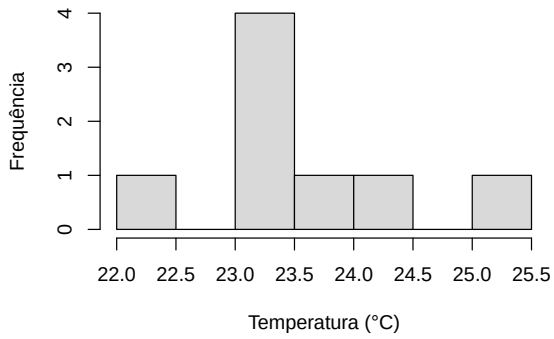


Figura 8.2: Histograma das temperaturas.

Note como temperaturas entre 23,0 e 23,5 °C são mais frequentes do que as demais no período avaliado. Com apenas oito medidas, porém, a forma do histograma depende muito da escolha das classes (veja o capítulo *Bioestatística descritiva*).

Exemplo: criando um boxplot com a função `boxplot()`

```
boxplot(temperatura, ylab = "Temperatura (°C)", col = "grey90")
```

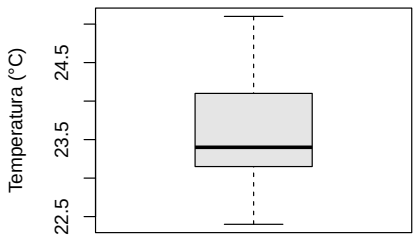


Figura 8.3: Boxplot das temperaturas.

O diagrama de caixa mostra a mediana (linha central), o primeiro e o terceiro quartis (limites da caixa) e a amplitude dos dados que não são considerados atípicos (hastes). Sua construção e interpretação estão detalhadas no capítulo *Bioestatística descritiva*.

8.2.8.3 Estatística inferencial

A estatística inferencial é o processo de usar os dados de uma amostra para inferir propriedades da população. As funções básicas do R para estatística inferencial incluem `t.test()` para o teste t, `chisq.test()` para o teste do qui-quadrado, `cor.test()` para o teste de correlação e `lm()` para a regressão linear.

Exemplo: comparando a temperatura média de duas lâmpadas com o teste t

```
t_lampada1 <- c(38.2, 39.1, 37.8, 38.9, 39.4, 38.5, 38.7)
t_lampada2 <- c(35.1, 34.8, 36.0, 35.6, 34.9, 35.3, 35.7)
teste_lamp <- t.test(t_lampada1, t_lampada2)
teste_lamp
```

```
##
##  Welch Two Sample t-test
##
## data:  t_lampada1 and t_lampada2
## t = 12.496, df = 11.525, p-value = 4.721e-08
```

```
## alternative hypothesis: true difference in means is not equal to 0
## 95 percent confidence interval:
##  2.733773 3.894799
## sample estimates:
## mean of x mean of y
##  38.65714  35.34286
```

Suponhamos que as temperaturas superficiais (°C) de duas lâmpadas tenham sido medidas repetidas vezes. A função `t.test()`, que por padrão aplica o teste de Welch, testa a hipótese de que a diferença entre as médias verdadeiras é igual a 0. A diferença observada foi de 3,31 °C (IC 95%: 2,73 a 3,89 °C), com valor p menor que 0,001: se as temperaturas médias das duas lâmpadas fossem iguais, seria muito improvável observar uma diferença entre as médias amostrais tão grande quanto a observada. Em outras palavras, os dados fornecem forte evidência de que as temperaturas médias das duas lâmpadas são distintas, e o intervalo de confiança indica a magnitude provável dessa diferença.

8.2.8.4 Modelagem estatística

A modelagem estatística é o processo de desenvolver um modelo matemático que descreve a relação entre variáveis. O R fornece várias funções para isso, incluindo `lm()` para regressão linear, `glm()` para modelos lineares generalizados, `aov()` para análise de variância (a função `anova()` produz a tabela de análise de variância de um modelo já ajustado, como em `anova(lm(...))`) e `arima()` para modelagem de séries temporais.

Exemplo: avaliando a relação entre estatura e massa corporal com a função `lm()`

```
estatura <- c(170, 172, 174, 177, 179, 181, 182)
massa_corporal <- c(60, 62, 66, 70, 74, 81, 83)
modelo_massa <- lm(massa_corporal ~ estatura)
plot(massa_corporal ~ estatura, xlab = "Estatura (cm)", ylab = "Massa
 ↪  corporal (kg)", pch = 19)
abline(modelo_massa, lty = 2)
```

```
summary(modelo_massa)
```

```
##
## Call:
## lm(formula = massa_corporal ~ estatura)
##
## Residuals:
##       1       2       3       4       5       6       7
##  1.5398 -0.3170 -0.1739 -1.9591 -1.8159  1.3273  1.3989
```

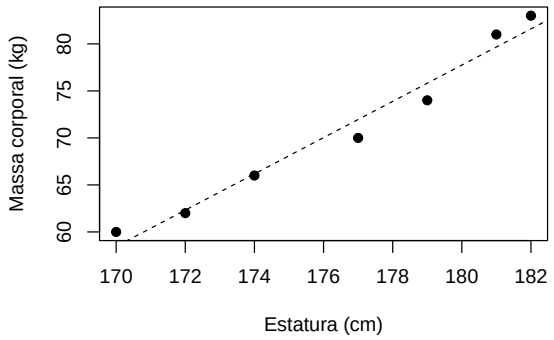


Figura 8.4: Massa corporal em função da estatura, com a reta de mínimos quadrados.

```
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -269.3693    25.7247  -10.47 0.000137 ***
## estatura       1.9284     0.1458   13.23 4.41e-05 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.634 on 5 degrees of freedom
## Multiple R-squared:  0.9722, Adjusted R-squared:  0.9667
## F-statistic:   175 on 1 and 5 DF,  p-value: 4.409e-05
```

Dados de estatura e massa corporal de sete pessoas foram armazenados em vetores. O gráfico mostra a relação entre as duas variáveis, e a função `abline()`, aplicada ao modelo ajustado por `lm()`, desenha a reta de mínimos quadrados. Segundo o modelo, cada centímetro a mais de estatura está associado a 1,93 kg a mais de massa corporal, e o R^2 (`Multiple R-squared`) indica que 97% da variação na massa corporal desta amostra é explicada pela relação linear com a estatura. A interpretação completa dessa saída está no capítulo *Análise de dados*.

8.2.9 Usando R para estatísticas descritivas

As estatísticas descritivas resumem e organizam um conjunto de dados de modo que ele possa ser facilmente compreendido. A seguir, mostramos como calculá-las no R, usando como exemplo o vetor de números de 1 a 5. Outros exemplos

estão no capítulo *Bioestatística descritiva*; é recomendável praticar os códigos desta seção no RStudio.

8.2.9.1 Medidas de tendência central

As medidas de tendência central são estatísticas que indicam onde os dados estão centrados. As principais medidas de tendência central são a média, a mediana e a moda.

1. **Média**: a média de um conjunto de dados é a soma de todos os valores dividida pelo número de valores. No R, é calculada com a função `mean()`.
2. **Mediana**: a mediana é o valor que divide os dados ao meio quando estão ordenados. No R, é calculada com a função `median()`.
3. **Moda**: a moda é o valor mais frequente em um conjunto de dados. O R não tem uma função embutida para a moda (a função `mode()` informa o tipo de armazenamento de um objeto, o que é outra coisa), mas ela pode ser obtida com a função `table()` ou com uma função própria, como mostrado no capítulo *Bioestatística descritiva*.

```
mean(c(1, 2, 3, 4, 5))
```

```
## [1] 3
```

```
median(c(1, 2, 3, 4, 5))
```

```
## [1] 3
```

```
contagens <- table(c(1, 2, 2, 3, 4, 5))
names(contagens)[contagens == max(contagens)]   # moda
```

```
## [1] "2"
```

8.2.9.2 Medidas de dispersão

As medidas de dispersão são estatísticas que indicam o quanto os dados estão espalhados. As principais medidas de dispersão são a variância, o desvio padrão e a amplitude.

1. **Variância**: indica o quanto os valores se desviam da média. No R, é calculada com a função `var()`, que usa o divisor $n-1$ (variância amostral).

2. **Desvio padrão**: é a raiz quadrada da variância e está na mesma unidade dos dados. No R, é calculado com a função `sd()`.
3. **Amplitude**: é a diferença entre o maior e o menor valor. No R, pode ser calculada com `max() - min()` ou com `diff(range())`.

```
var(c(1, 2, 3, 4, 5))
```

```
## [1] 2.5
```

```
sd(c(1, 2, 3, 4, 5))
```

```
## [1] 1.581139
```

```
max(c(1, 2, 3, 4, 5)) - min(c(1, 2, 3, 4, 5))
```

```
## [1] 4
```

```
IQR(c(1, 2, 3, 4, 5))   # amplitude interquartil
```

```
## [1] 2
```

8.2.9.3 Resumo dos dados

A função `summary()` fornece um resumo estatístico dos dados, com o mínimo, o primeiro quartil, a mediana, a média, o terceiro quartil e o máximo. Aplicada a um *data frame*, resume cada coluna:

```
summary(c(1, 2, 3, 4, 5))
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##       1       2       3       3       4       5
```

```
summary(data.frame(hora, temperatura))
```

```
##       hora        temperatura
##  Min.   :12.08   Min.   :22.40
##  1st Qu.:13.78   1st Qu.:23.18
##  Median :15.60   Median :23.40
##  Mean   :15.59   Mean   :23.60
##  3rd Qu.:17.31   3rd Qu.:24.05
##  Max.   :19.15   Max.   :25.10
```

8.2.10 Estatísticas inferenciais com R

As estatísticas inferenciais permitem fazer generalizações sobre uma população com base em uma amostra de dados. São a base da pesquisa científica quantitativa e da tomada de decisões baseada em dados.

8.2.10.1 Conceitos básicos

Antes de realizar a inferência estatística, é preciso conhecer alguns conceitos básicos, como população, amostra, parâmetro e estimativa. A população é o conjunto completo de observações que estão sendo estudadas, enquanto uma amostra é um subconjunto dessa população. Um parâmetro é uma medida resumida da população, como a média populacional, e uma estimativa é o correspondente calculado a partir da amostra.

8.2.10.2 Testes de hipóteses

Um dos pilares da inferência estatística é o teste de hipóteses. O objetivo é testar uma afirmação (hipótese) sobre um parâmetro populacional. No R, funções como `t.test()`, `chisq.test()` e `aov()` são usadas para realizar diferentes tipos de testes de hipóteses.

Por exemplo, o `t.test()` é usado para comparar as médias de duas amostras. O teste do qui-quadrado (`chisq.test()`) é frequentemente usado para testar a independência entre duas variáveis categóricas. A análise de variância (ANOVA), realizada com a função `aov()` (ou com `anova()` aplicada a um modelo ajustado com `lm()`), é usada para comparar as médias de três ou mais grupos. Os capítulos *Bioestatística inferencial* e *Análise de dados* apresentam esses testes com exemplos resolvidos.

8.2.10.3 Intervalos de confiança

Outra ferramenta importante na inferência estatística é o intervalo de confiança, que indica a faixa de valores do parâmetro populacional compatíveis com os dados. No R, o `t.test()` e outras funções de teste fornecem intervalos de confiança como parte de seus resultados, e a função `confint()` os extrai de modelos ajustados:

```
t.test(temperatura)$conf.int      # IC 95% para a temperatura média
```

```
## [1] 22.9135 24.2865
## attr(,"conf.level")
## [1] 0.95
```

```
confint(modelo_massa)            # IC 95% para os coeficientes da
 ↪  regressão
```

```
##                   2.5 %      97.5 %
## (Intercept) -335.496698 -203.241938
## estatura       1.553706    2.303112
```

8.2.10.4 Regressão e correlação

A análise de regressão é usada para entender a relação entre variáveis. No R, a função `lm()` é usada para realizar regressão linear, que modela a relação entre uma variável dependente e uma ou mais variáveis independentes. A correlação, que mede a força e a direção da relação linear entre duas variáveis, pode ser calculada com a função `cor()` e testada com `cor.test()`:

```
cor(estatura, massa_corporal)
```

```
## [1] 0.9860148
```

```
cor(estatura, massa_corporal, method = "spearman")
```

```
## [1] 1
```

8.2.10.5 Análise de séries temporais

A análise de séries temporais trata de dados coletados ao longo do tempo, em que observações próximas tendem a ser correlacionadas. No R, a função `ts()` cria objetos de séries temporais e a função `arima()` ajusta modelos autorregressivos integrados de médias móveis (ARIMA), usados para descrever a série e prever valores futuros.

Exemplo: utilizando a função `arima()` para prever uma série temporal

```
preco <- c(23.1, 22.4, 23.5, 24.2, 25.1, 23.3, 24.0, 23.2)
serie <- ts(preco, start = 1, frequency = 1)
modelo_ar <- arima(serie, order = c(1, 0, 0))   # modelo autorregressivo
 ↪  de ordem 1
previsao <- predict(modelo_ar, n.ahead = 3)
previsao
```

```
## $pred
## Time Series:
## Start = 9
```

```
## End = 11
## Frequency = 1
## [1] 23.51242 23.56640 23.57572
##
## $se
## Time Series:
## Start = 9
## End = 11
## Frequency = 1
## [1] 0.7548991 0.7660829 0.7664142
```

```
horas_previsao <- max(hora) + mean(diff(hora)) * 1:3
plot(hora, preco, type = "o", pch = 1, xlim = c(min(hora),
 ↪  max(horas_previsao)),
     ylim = range(preco, previsao$pred), xlab = "Hora", ylab = "Preço")
lines(c(max(hora), horas_previsao), c(preco[length(preco)],
 ↪  previsao$pred), lty = 2)
points(horas_previsao, previsao$pred, pch = 19)
legend("topleft", legend = c("Observado", "Previsão"), lty = c(1, 2), pch
 ↪  = c(1, 19), bty = "n")
```

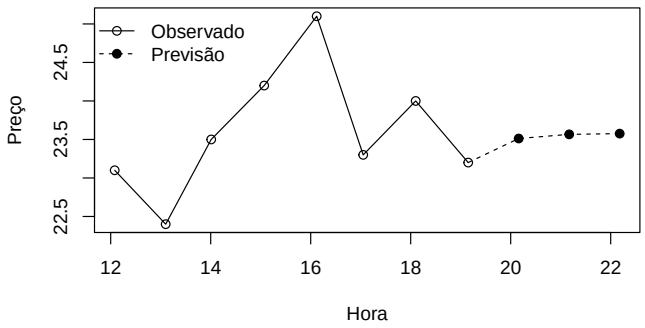


Figura 8.5: Série de preços com a previsão de um modelo AR(1) para os três períodos seguintes (pontos preenchidos).

Usando os dados de variação do preço de uma ação ao longo de um dia, ajustou-se um modelo autorregressivo de ordem 1, AR(1), e foram previstos os valores para os três períodos seguintes. Note que as previsões se aproximam rapidamente da média da série: com um único termo autorregressivo e uma série curta, o modelo tem pouca informação para prever além dela. O objeto `previsao$se` contém os erros padrão das previsões, que devem sempre acompanhá-las. Uma série de apenas oito observações é útil para ilustrar a sintaxe, mas insuficiente para ajustar e validar um modelo ARIMA em uma análise real.

As funções do R tornam a execução dessas análises simples, mas escolher o método adequado e interpretar os resultados exige conhecimento de teoria estatística, tema dos capítulos de bioestatística deste livro.

8.2.11 Fundamentos da visualização de dados em R

A visualização ajuda a entender e interpretar os dados e a comunicar os resultados. O R tem várias ferramentas e pacotes dedicados a ela, cujos fundamentos são apresentados a seguir. Os princípios de construção de figuras científicas estão na seção *Visualização de dados e figuras científicas*, ao final deste capítulo.

8.2.11.1 Gráficos base do R

O R possui um sistema de gráficos base que permite criar diversos tipos de gráficos, como gráficos de linhas, barras, histogramas, boxplots e gráficos de dispersão. Esses gráficos são gerados usando funções simples, como `plot()`, `hist()`, `barplot()` e `boxplot()`. Por exemplo, a função `plot()` pode ser usada para criar gráficos de dispersão ou de linhas, dependendo dos argumentos fornecidos. Veja, abaixo, uma lista de gráficos comuns em *Base R*:

1. **Gráficos de dispersão (scatter plots)**: utilizados para visualizar a relação entre duas variáveis numéricas. A função `plot()` é a mais comum para criar esses gráficos.

2. **Histogramas**: usados para representar a distribuição de uma única variável numérica. A função `hist()` é utilizada para gerar histogramas.

3. **Gráficos de linhas**: úteis para visualizar dados ao longo do tempo ou sequências ordenadas. A função `plot()` cria gráficos de linhas com o argumento `type = "l"` (apenas linhas) ou `type = "o"` (linhas e pontos).

4. **Gráficos de barras**: permitem comparar quantidades entre diferentes grupos. A função `barplot()` é usada para criar gráficos de barras (a função `hist()`, embora também desenhe barras, produz histogramas de variáveis numéricas).

5. **Boxplots**: fornecem uma representação visual da distribuição de uma variável numérica, destacando a mediana, os quartis e os valores discrepantes. A função `boxplot()` é usada para criar boxplots.

Exemplo: criando um gráfico de barras com a função `barplot()`

```r
frequencias <- c("Categoria A" = 25, "Categoria B" = 17, "Categoria C" =
 ↪  30, "Categoria D" = 45)
barplot(frequencias,
        main = "Frequência por categoria",
        xlab = "Categorias",
        ylab = "Frequência",
        col = c("#E69F00", "#56B4E9", "#009E73", "#CC79A7"),
        ylim = c(0, 50))
```

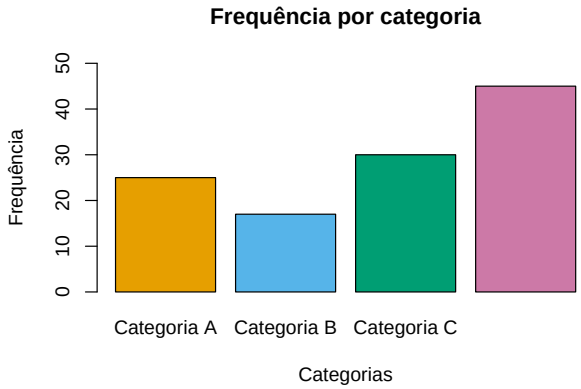


Figura 8.6: Gráfico de barras das frequências de quatro categorias.

Considerando um vetor nomeado com as frequências de quatro categorias, o gráfico de barras é gerado com a função `barplot()`. Os argumentos personalizam o gráfico: `main` é o título; `xlab` e `ylab`, os títulos dos eixos; `col`, as cores de preenchimento das barras (aqui, uma paleta segura para pessoas com deficiência na percepção de cores); e `ylim`, os limites do eixo vertical. Como as categorias já estão identificadas no eixo horizontal, as cores, neste caso, são apenas decorativas, e uma única cor seria igualmente adequada.

8.2.11.2 Personalização de gráficos

Os gráficos base do R podem ser personalizados com argumentos adicionais nas funções gráficas, que modificam títulos, rótulos dos eixos, cores, tipos de linhas e pontos, entre outros elementos. O argumento `main` adiciona um título; `xlab` e `ylab`, rótulos aos eixos X e Y; `col` altera a cor de pontos ou linhas; `pch` define o símbolo dos pontos; `lty`, o tipo de linha; e `lwd`, a espessura da linha.

Também é possível sobrepor elementos gráficos. Funções como `lines()`, `points()`, `abline()`, `text()` e `legend()` acrescentam elementos a um gráfico já criado.

Exemplo: sobrepondo elementos gráficos em R base

```
plot(temperatura ~ hora, pch = 19, xlab = "Hora", ylab = "Temperatura
 ↪  (°C)")
lines(temperatura ~ hora, col = "grey40")
legend("topleft", legend = "Temperatura (°C)", col = "grey40", lty = 1,
 ↪  pch = 19, lwd = 2, bty = "n")
```

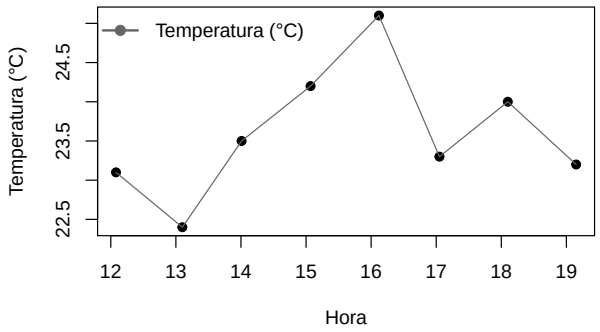


Figura 8.7: Gráfico de dispersão com linha e legenda sobrepostas.

No exemplo, um gráfico de dispersão foi criado com a função `plot()`. Em seguida, a função `lines()` acrescentou uma linha que conecta os pontos, e a função `legend()` criou uma legenda. Note que, na legenda, os argumentos `lty` (tipo de linha, de 1 a 6) e `pch` (símbolo do ponto) devem corresponder aos usados no gráfico.

8.2.11.3 O pacote ggplot2

Uma alternativa ao sistema de gráficos base é o pacote `ggplot2`, baseado nos princípios da "Gramática dos Gráficos". O `ggplot2` constrói gráficos de maneira incremental, adicionando camadas de elementos gráficos. Um gráfico começa com a função `ggplot()`, que recebe os dados e as estéticas (`aes()`, que associam variáveis a eixos, cores, tamanhos), e as camadas são adicionadas com o operador `+`, como `geom_point()` para um gráfico de dispersão ou `geom_histogram()` para um histograma. Lembre-se de que pacotes devem ser instalados no primeiro uso e carregados em cada nova sessão.

Exemplo: criando um gráfico básico com a função `ggplot()`

```
library(ggplot2)
df_temp <- data.frame(hora, temperatura)

ggplot(data = df_temp, aes(x = hora, y = temperatura)) +
  geom_point() +
  labs(x = "Hora", y = "Temperatura (°C)")
```

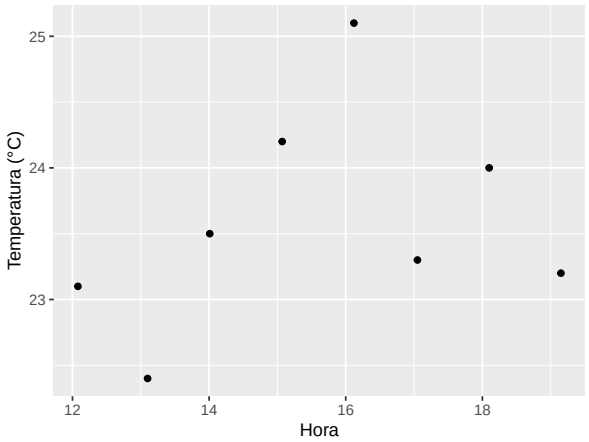


Figura 8.8: Gráfico de dispersão construído com o ggplot2.

Primeiro, o pacote `ggplot2` foi carregado. Em seguida, um *data frame* (`df_temp`) foi criado a partir dos vetores `hora` e `temperatura`. O gráfico é construído com `ggplot(data = df_temp, aes(x = hora, y = temperatura))`, que define os dados e os eixos; o `+` acrescenta a camada `geom_point()`, que desenha os pontos, e outra camada, `labs()`, que define os rótulos dos eixos.

Múltiplos gráficos do `ggplot2` podem ser organizados em uma mesma figura. Uma forma de fazê-lo é com a função `ggarrange()`, do pacote `ggpubr`, que permite especificar o número de colunas e linhas e criar uma legenda comum para vários gráficos (por exemplo, `ggarrange(g1, g2, ncol = 2, common.legend = TRUE)`). O pacote `patchwork` é uma alternativa popular, em que os gráficos são combinados com operadores (`g1 + g2`, `g1 / g2`).

Exemplo: organizando mais de um gráfico por figura com `ggarrange()`

```
library(ggpubr)
a <- ggplot(df_temp, aes(x = hora, y = temperatura)) +
  geom_point() +
  labs(x = "Hora", y = "Temperatura (°C)")
b <- ggplot(df_temp, aes(x = temperatura)) +
  geom_histogram(binwidth = 0.5, boundary = 22, fill = "grey70", colour =
  ↪  "white") +
```

```
  labs(x = "Temperatura (°C)", y = "Frequência")
ggarrange(a, b, ncol = 2, labels = c("A", "B"))
```

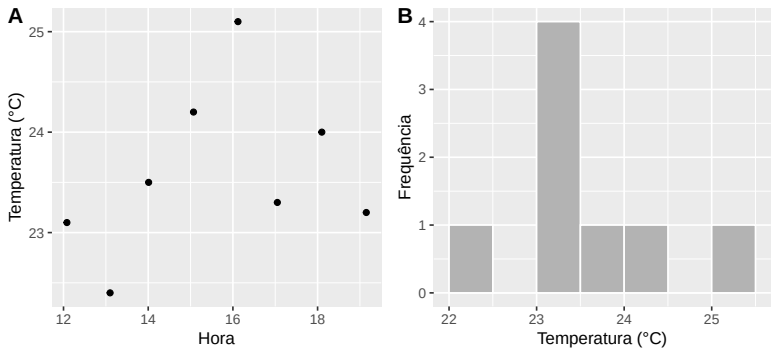


Figura 8.9: Dois gráficos do ggplot2 organizados lado a lado com a função ggarrange().

Um segundo gráfico (um histograma, criado com `geom_histogram()`) foi construído. Os dois gráficos foram atribuídos aos objetos `a` e `b`, e a função `ggarrange()` os organizou lado a lado, com rótulos "A" e "B". Tente inverter a ordem dos objetos (`ggarrange(b, a)`) ou dispô-los em uma coluna (`ncol = 1`).

8.2.11.4 Visualização de dados multivariados

Tanto o sistema de gráficos base quanto o `ggplot2` oferecem opções para visualizar dados multivariados. Por exemplo, você pode usar cores, formas ou tamanhos de pontos para representar variáveis adicionais em um gráfico de dispersão. No `ggplot2`, isso é feito especificando estéticas adicionais dentro da função `aes()`.

A facetação, no `ggplot2`, divide os dados em subconjuntos e desenha cada subconjunto em seu próprio painel dentro do gráfico, o que facilita a comparação entre subgrupos. Ela é feita com as funções `facet_wrap()` ou `facet_grid()`.

Exemplo: utilizando `facet_grid()` para dividir um gráfico em painéis

```
dados_vendas <- data.frame(
  produto = rep(c("Produto A", "Produto B"), each = 12),
  regiao = rep(rep(c("Norte", "Sul", "Leste"), each = 4), times = 2),
  trimestre = rep(c("T1", "T2", "T3", "T4"), times = 6),
  vendas = c(200, 180, 160, 220, 210, 150, 190, 230, 170, 190, 180, 210,
             220, 190, 200, 240, 230, 200, 200, 250, 180, 210, 210, 220)
)
```

```
head(dados_vendas)
```

```
##     produto regiao trimestre vendas
## 1 Produto A  Norte        T1    200
## 2 Produto A  Norte        T2    180
## 3 Produto A  Norte        T3    160
## 4 Produto A  Norte        T4    220
## 5 Produto A    Sul        T1    210
## 6 Produto A    Sul        T2    150
```

```
ggplot(dados_vendas, aes(x = trimestre, y = vendas, group = produto,
                         colour = produto, shape = produto)) +
  geom_line() +
  geom_point(size = 2) +
  scale_colour_manual(values = c("Produto A" = "#D55E00", "Produto B" =
   ↪  "#0072B2")) +
  facet_grid(regiao ~ .) +
  labs(title = "Vendas por produto e região", x = "Trimestre", y =
   ↪  "Vendas",
       colour = "Produto", shape = "Produto") +
  theme_minimal()
```

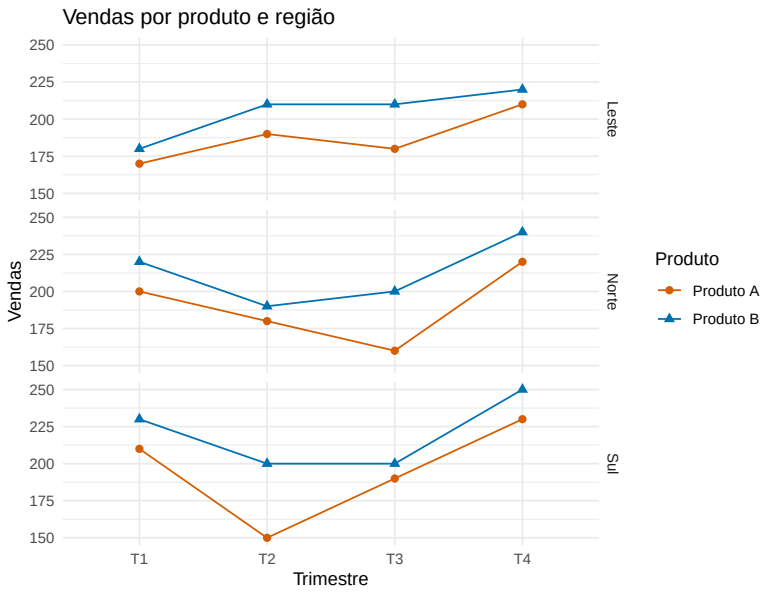


Figura 8.10: Vendas trimestrais de dois produtos em três regiões, com um painel por região.

O código cria um conjunto de dados com quatro variáveis: `produto`, que repete

"Produto A" e "Produto B" doze vezes cada; `regiao`, com as três regiões, cada uma com quatro trimestres, para cada produto; `trimestre`, que repete a sequência dos quatro trimestres seis vezes; e `vendas`, com os valores de cada combinação. A função `head()` mostra as primeiras linhas, para conferir que a estrutura está correta: é sempre recomendável verificar a correspondência entre as variáveis criadas com `rep()`. No gráfico, o eixo x representa os trimestres e o eixo y as vendas; as linhas e os pontos são agrupados e diferenciados por cor **e** por forma de acordo com o produto (de modo que a distinção não depende apenas da cor), e o gráfico é dividido em painéis por região com a função `facet_grid()`. Por fim, são definidas cores manuais (de uma paleta segura para daltônicos), títulos e um tema visual (`theme_minimal()`).

8.2.11.5 Extensões do ggplot2

Existem vários pacotes que estendem as capacidades do `ggplot2`, adicionando novos tipos de gráficos ou funcionalidades. Por exemplo, a função `ggplotly()`, do pacote `plotly`, converte gráficos do `ggplot2` em gráficos interativos, e o pacote `gganimate` cria animações a partir de gráficos do `ggplot2`.

Exemplo: criando um gráfico interativo a partir de um ggplot com `ggplotly()`

```
library(plotly)
grafico_vendas <- ggplot(dados_vendas, aes(x = trimestre, y = vendas,
 ↪  group = produto,
                                           colour = produto)) +
  geom_line() +
  geom_point() +
  facet_grid(regiao ~ .) +
  labs(x = "Trimestre", y = "Vendas", colour = "Produto") +
  theme_minimal()
ggplotly(grafico_vendas)
```

Para criar o gráfico interativo, basta carregar o pacote `plotly`, atribuir o gráfico do `ggplot2` a um objeto (aqui, `grafico_vendas`) e fornecê-lo à função `ggplotly()`. O gráfico resultante permite ampliar regiões, ocultar séries clicando na legenda, ver os valores ao passar o cursor sobre os pontos e salvar a imagem. Gráficos interativos funcionam apenas em documentos HTML; por isso, este exemplo aparece somente na versão *online* deste livro.

8.2.11.6 Visualização de dados geoespaciais

A visualização de dados geoespaciais é outra técnica que pode ser realizada em R, utilizando o `ggplot2` em conjunto com o pacote `sf` (Pebesma et al. 2024) para criar mapas. Esses mapas podem representar desde a distribuição geográfica de eventos até análises espaciais complexas, como agrupamentos ou padrões

de movimento. Para mapas do Brasil com divisões administrativas (estados, municípios, setores censitários), o pacote `geobr`, desenvolvido pelo Instituto de Pesquisa Econômica Aplicada (Ipea), fornece os limites oficiais.

Exemplo: criando um mapa a partir de dados geoespaciais com o pacote `sf`

```
library(sf)
geo_brasil <- rnaturalearth::ne_countries(scale = "large", country =
 ↪  "Brazil",
                                          returnclass = "sf")
ggplot(data = geo_brasil) +
  geom_sf(colour = "darkgreen", fill = "gold") +
  theme_minimal() +
  labs(title = "Mapa do Brasil")
```

O código utiliza os pacotes `ggplot2`, `sf` e `rnaturalearth` para criar um mapa do Brasil. A função `ne_countries()` obtém os limites geográficos do país em alta resolução (`scale = "large"`, que exige o pacote complementar `rnaturalearthhires`) no formato `sf`, o padrão para dados espaciais no R. O objeto resultante é passado para a função `ggplot()`, e a camada `geom_sf()` desenha o polígono, com a cor da borda e do preenchimento definidas pelos argumentos `colour` e `fill`. O tema `theme_minimal()` e a função `labs()` completam o gráfico. O mesmo princípio vale para mapas temáticos (*choropleth*), em que o preenchimento de cada região representa o valor de uma variável, como uma taxa de incidência por município.

8.2.11.7 Animações com gganimate

O pacote `gganimate` (Pedersen and Robinson 2024) estende as capacidades do `ggplot2`, permitindo criar animações a partir de gráficos. Isso é útil para visualizar mudanças nos dados ao longo do tempo, como tendências econômicas, padrões climáticos ou o progresso de uma epidemia.

Exemplo: criando um gráfico animado com o pacote `gganimate`

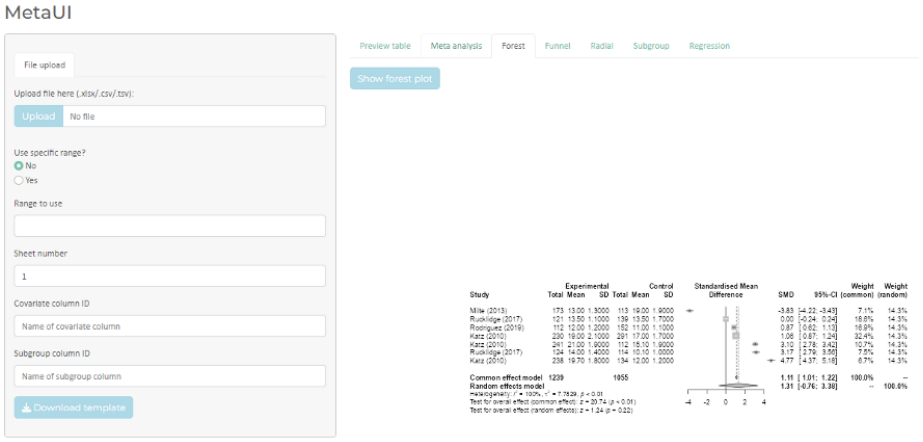
```
library(gapminder)
library(gganimate)
ggplot(gapminder, aes(gdpPercap, lifeExp, size = pop, colour = country))
 ↪  +
  geom_point(alpha = 0.7, show.legend = FALSE) +
  scale_colour_manual(values = country_colors) +
  scale_size(range = c(2, 12)) +
  scale_x_log10() +
  facet_wrap(~continent) +
  labs(title = "Ano: {frame_time}", x = "PIB per capita (escala log)",
       y = "Expectativa de vida (anos)") +
  transition_time(year) +
  ease_aes("linear")
```

O exemplo usa os dados do pacote `gapminder` (Bryan 2023), que reúne, para diferentes países e anos, o PIB per capita, a expectativa de vida e o tamanho da população. A função `ggplot()` define as variáveis dos eixos, o tamanho dos pontos (população) e a cor (país); `geom_point()` desenha os pontos com transparência e sem legenda; `scale_colour_manual()` usa a paleta de cores por país fornecida pelo pacote (`country_colors`); `scale_size()` ajusta o intervalo de tamanhos; `scale_x_log10()` coloca o eixo x em escala logarítmica; e `facet_wrap()` divide o gráfico por continente. As funções específicas do `gganimate` são `transition_time()`, que define a variável que conduz a animação (o ano), e `ease_aes()`, que controla a transição entre os quadros; no título, `{frame_time}` é substituído pelo ano de cada quadro. A animação é gerada como um arquivo GIF (o que exige o pacote `gifski`) e, por isso, aparece apenas na versão *online* deste livro.

8.2.11.8 Dashboards interativos com Shiny

O pacote `shiny` (Chang et al. 2024) permite criar aplicativos web interativos diretamente em R. Esses *dashboards* podem incluir diversos elementos de entrada e saída, com os quais os usuários interagem com os dados e as visualizações em tempo real.

Exemplo: aplicação shiny para metanálises criada em RStudio



*A produção de aplicações e *dashboards shiny* é um processo mais complexo do que os exemplos vistos anteriormente. Sua utilização, porém, permite a criação de ferramentas especializadas para pesquisa, trabalho e negócios. Depois de criadas, essas aplicações podem poupar muitas horas de trabalho de um analista ou até mesmo permitir que pessoas sem o conhecimento de programação possam realizar as análises necessárias.

Um aplicativo Shiny tem duas partes: a **interface** (`ui`), que define os elementos que o usuário vê e com os quais interage, e o **servidor** (`server`), que define como

as saídas são calculadas a partir das entradas. O exemplo mínimo a seguir cria um aplicativo com um controle deslizante que define o número de classes de um histograma:

```
library(shiny)

ui <- fluidPage(
  titlePanel("Histograma interativo"),
  sliderInput("classes", "Número de classes:", min = 2, max = 30, value =
   ↪  10),
  plotOutput("histograma")
)

server <- function(input, output) {
  output$histograma <- renderPlot({
    hist(faithful$waiting, breaks = input$classes, col = "grey80", border
     ↪  = "white",
         main = "", xlab = "Tempo entre erupções (min)")
  })
}

shinyApp(ui = ui, server = server)
```

Ao executar esse código no RStudio, o aplicativo abre em uma janela; a cada movimento do controle, o histograma é redesenhado. O conjunto de dados `faithful`, que acompanha o R, registra o tempo entre erupções de um gêiser e é usado aqui apenas como exemplo.

8.2.11.9 Tabelas e quadros em R

Para criar tabelas no R, podemos usar a função `table()` para tabular dados e a função `View()` (com "V" maiúsculo) para visualizar *data frames* em formato de planilha. Uma forma de visualizar seus dados sem a utilização da função `View()` é clicar no ícone de uma tabela ou uma lupa:



que aparecem na aba "Environment" da janela superior direita.

```
table(dados_vendas$regiao, dados_vendas$produto)
```

```
##
##         Produto A Produto B
##   Leste         4         4
```

Tabela 8.1: Vendas no primeiro trimestre, por produto e região.

produto	regiao	trimestre	vendas
Produto A	Norte	T1	200
Produto A	Sul	T1	210
Produto A	Leste	T1	170
Produto B	Norte	T1	220
Produto B	Sul	T1	230
Produto B	Leste	T1	180

```
##   Norte         4         4
##   Sul           4         4
```

O pacote `knitr` (Xie 2024) oferece ainda a função `kable()`, que cria tabelas formatadas para relatórios e documentos, e o pacote `kableExtra` acrescenta opções de estilo.

Exemplo: criando uma tabela com a função `kable()`

```
library(knitr)
vendas_t1 <- subset(dados_vendas, trimestre == "T1")
kable(vendas_t1, caption = "Vendas no primeiro trimestre, por produto e
 ↪  região.",
      row.names = FALSE)
```

Usando os dados do exemplo anterior, filtrados para o primeiro trimestre com a função `subset()`, a função `kable()` produziu uma tabela formatada, com legenda. Em documentos HTML, a função `kable_classic()`, do pacote `kableExtra`, aplica um estilo clássico à tabela:

```
kableExtra::kable_classic(kable(vendas_t1))
```

O prefixo `kableExtra::` permite chamar a função sem carregar o pacote inteiro com `library()`. Para tabelas mais elaboradas, como a "Tabela 1" de características da amostra, pacotes como `gtsummary` e `flextable` são boas opções.

8.3 Python para análise estatística

8.3.1 Visão geral

Python é uma linguagem de programação de uso geral, criada por Guido van Rossum no início da década de 1990, que se tornou uma das mais populares do

mundo. Ao contrário do R, que nasceu para a estatística, o Python foi concebido como linguagem genérica, e sua capacidade para análise de dados vem de um conjunto de bibliotecas desenvolvidas pela comunidade:

- **NumPy** (Harris et al. 2020): vetores e matrizes numéricas e operações matemáticas eficientes; é a base das demais;
- **pandas** (McKinney 2010): estruturas de dados tabulares (*data frames*), leitura de arquivos, limpeza, transformação e agregação de dados;
- **SciPy** (Virtanen et al. 2020): funções científicas, incluindo distribuições de probabilidade e testes estatísticos clássicos (módulo `scipy.stats`);
- **statsmodels** (Seabold and Perktold 2010): modelos estatísticos (regressão linear, modelos lineares generalizados, modelos mistos, análise de sobrevivência, séries temporais), com saídas semelhantes às do R e especificação por fórmulas;
- **matplotlib** (Hunter 2007) e **seaborn**: gráficos;
- **scikit-learn**: aprendizado de máquina (classificação, regressão, agrupamento, validação cruzada).

As seções a seguir percorrem o mesmo caminho da seção sobre o R: instalação, sintaxe, manipulação de dados, boas práticas, estatística descritiva e inferencial, modelos, gráficos e relatórios reprodutíveis. Os blocos de código desta seção **não** são executados durante a compilação do livro, que é feita em R; eles foram executados separadamente, com as versões indicadas abaixo, e a saída de cada bloco é reproduzida logo após o código. Sempre que possível, os exemplos usam os mesmos dados dos capítulos de bioestatística, para que o leitor compare os resultados com os obtidos no R.

8.3.2 R ou Python?

A pergunta é frequente e a resposta depende do contexto. O R tem a maior coleção de métodos estatísticos especializados (bioestatística, epidemiologia, análise de sobrevivência, metanálise, modelos mistos), muitos dos quais aparecem primeiro no CRAN ou no Bioconductor, e uma tradição forte em gráficos estatísticos e relatórios reprodutíveis. O Python é mais forte em aprendizado de máquina e aprendizado profundo, processamento de imagens e textos, integração com sistemas e programação de uso geral. Para a maioria das análises de pesquisa clínica e epidemiológica deste livro, as duas linguagens são adequadas. O mais importante é escolher uma, aprendê-la bem e escrever código reprodutível. É possível, também, combinar as duas: no R, o pacote `reticulate` executa código Python; no Python, o pacote `rpy2` executa código R.

8.3.3 Instalando o Python e o ambiente de trabalho

Há dois caminhos principais para instalar o Python com as bibliotecas científicas.

1. **Distribuições Anaconda ou Miniconda.** Incluem o Python, um gerenciador de pacotes e ambientes (`conda`) e, no caso da Anaconda, centenas de bibliotecas científicas já instaladas. São a opção mais simples para iniciantes em Windows e Mac. A Miniconda instala apenas o essencial, e as bibliotecas são acrescentadas conforme a necessidade.
2. **Instalador oficial** de https://www.python.org e o gerenciador de pacotes `pip`. No Mac e no Linux, o Python frequentemente já vem instalado, mas essa versão do sistema não deve ser usada para análises: instale uma versão própria.

Em qualquer dos casos, recomenda-se trabalhar em **ambientes virtuais**: cada projeto tem seu próprio conjunto de bibliotecas, com versões fixas, isolado dos demais. Isso evita que a atualização de uma biblioteca para um projeto quebre outro, e permite registrar exatamente o que foi usado. Com o `pip`:

```
python -m venv ambiente_estatistica
source ambiente_estatistica/bin/activate     # no Windows:
 ↪  ambiente_estatistica\Scripts\activate
pip install numpy pandas scipy statsmodels matplotlib seaborn
 ↪  scikit-learn jupyter
pip freeze > requirements.txt                # registra as versões
 ↪  instaladas
```

Com o `conda`, o equivalente é `conda create -n estatistica python numpy pandas scipy statsmodels matplotlib seaborn scikit-learn jupyterlab` seguido de `conda activate estatistica`.

Para escrever e executar código, as opções mais usadas são:

- **JupyterLab** ou **Jupyter Notebook**: ambiente no navegador em que código, resultados, gráficos e texto ficam no mesmo documento (*notebook*), ótimo para análises exploratórias e para o ensino;
- **Visual Studio Code**: editor gratuito com extensões para Python e para *notebooks*, adequado tanto a *scripts* quanto a projetos maiores;
- **Spyder**: ambiente semelhante ao RStudio, com editor, console e painel de variáveis, que acompanha a Anaconda;
- **RStudio**: também executa código Python, por meio do pacote `reticulate`, o que é conveniente para quem já trabalha em R.

Para verificar a instalação e registrar as versões em uso:

```
import sys
import numpy as np
import pandas as pd
import scipy
```

```
import statsmodels
import matplotlib
import seaborn as sns
import sklearn

print("Python", sys.version.split()[0])
for nome, modulo in [("numpy", np), ("pandas", pd), ("scipy", scipy),
                     ("statsmodels", statsmodels), ("matplotlib",
 ↪  matplotlib),
                     ("seaborn", sns), ("scikit-learn", sklearn)]:
    print(f"{nome:12s} {modulo.__version__}")
```

Saída:

```
Python 3.13.16
numpy        2.5.3
pandas       3.0.5
scipy        1.18.1
statsmodels  0.15.0
matplotlib   3.11.2
seaborn      0.13.2
scikit-learn 1.9.1
```

Os exemplos desta seção foram executados com essas versões. Versões diferentes podem produzir pequenas diferenças na formatação das saídas e, ocasionalmente, nos argumentos padrão das funções; por isso, registrar as versões é parte da reprodutibilidade.

8.3.4 Sintaxe básica e operações em Python

8.3.4.1 Tipos de dados e operações

Algumas diferenças em relação ao R surpreendem quem conhece as duas linguagens:

- os índices começam em **0**, e não em 1: o primeiro elemento de uma lista `x` é `x[0]`;
- a **indentação** (o recuo das linhas) faz parte da sintaxe: define os blocos de código dentro de funções, laços e condicionais;
- o operador de atribuição é `=`, e a potência é `**` (e não `^`, que em Python é outra operação);
- as funções das bibliotecas são chamadas pelo nome da biblioteca, ou de uma abreviação definida na importação, como em `np.mean(x)` ou em `pd.read_csv("dados.csv")`;

- texto entre aspas simples ou duplas é uma *string*; os valores lógicos são `True` e `False`, com inicial maiúscula; a ausência de valor é `None`.

```
idade = 54                  # número inteiro (int)
imc = 27.3                  # número real (float)
sexo = "Feminino"           # texto (str)
hipertensa = True           # valor lógico (bool)

print(type(idade), type(imc), type(sexo), type(hipertensa))
print(7 / 2, 7 // 2, 7 % 2, 2 ** 10)   # divisão, divisão inteira, resto,
 ↪ potência
print(f"Paciente de {idade} anos com IMC de {imc:.1f} kg/m²")
```

Saída:

```
<class 'int'> <class 'float'> <class 'str'> <class 'bool'>
3.5 3 1 1024
Paciente de 54 anos com IMC de 27.3 kg/m²
```

A última linha usa uma ***f-string***: o `f` antes das aspas permite inserir valores entre chaves, com formatação opcional (`:.1f` indica uma casa decimal).

8.3.4.2 Listas, dicionários e laços

As estruturas de dados básicas do Python são as **listas** (sequências ordenadas e modificáveis, entre colchetes), as **tuplas** (sequências que não podem ser modificadas, entre parênteses) e os **dicionários** (pares de chave e valor, entre chaves).

```
tempos = [3, 4, 4, 5, 6, 8, 19]          # lista
print(tempos[0], tempos[-1], tempos[1:3])  # primeiro, último e fatia
 ↪ (posições 1 e 2)

paciente = {"id": 101, "idade": 54, "pas": 142}   # dicionário
print(paciente["pas"])

for t in tempos:                          # laço
    if t > 7:
        print("Internação longa:", t, "dias")

longos = [t for t in tempos if t > 7]     # compreensão de lista
print(longos)
```

Saída:

```
3 19 [4, 4]
```

```
142
Internação longa: 8 dias
Internação longa: 19 dias
[8, 19]
```

Note dois detalhes: a fatia `tempos[1:3]` inclui a posição 1 e **exclui** a posição 3; e o índice `-1` indica o último elemento. A **compreensão de lista** da última linha é uma forma concisa e muito usada de construir uma lista a partir de outra.

8.3.4.3 Funções

Funções são definidas com `def`, e o corpo da função é delimitado pela indentação. Uma *docstring* (texto entre aspas triplas logo após a definição) documenta o que a função faz.

```
def coeficiente_variacao(valores):
    """Calcula o coeficiente de variação (%), com desvio padrão
    ↪ amostral."""
    n = len(valores)
    media = sum(valores) / n
    variancia = sum((v - media) ** 2 for v in valores) / (n - 1)
    return 100 * variancia ** 0.5 / media

print(round(coeficiente_variacao(tempos), 1))
```

Saída:

```
79.1
```

8.3.4.4 Vetores com NumPy

Listas do Python não fazem operações vetorizadas: `tempos * 2` repete a lista duas vezes, em vez de multiplicar cada elemento. Para cálculos numéricos, usam-se os *arrays* do NumPy, que se comportam como os vetores do R.

```
import numpy as np

pressao = np.array([118, 124, 122, 130, 129, 133])
print(pressao * 2)
print(pressao - pressao.mean())
print(pressao.mean(), np.median(pressao), pressao.std(ddof=1))
print(pressao[pressao > 125])     # seleção por condição lógica
```

Saída:

```
[236 248 244 260 258 266]
[-8. -2. -4.  4.  3.  7.]
126.0 126.5 5.621387729022079
[130 129 133]
```

Note o argumento `ddof=1` ("graus de liberdade delta"): por padrão, a função `std()` do NumPy calcula o desvio padrão com divisor n; para obter o desvio padrão amostral, com divisor $n-1$ (capítulo *Bioestatística descritiva*), é preciso especificar `ddof=1`. A função `std()` do pandas, ao contrário, usa $n-1$ por padrão. Diferenças como essa são uma fonte comum de discrepâncias entre programas, e conhecê-las faz parte do uso responsável de qualquer ferramenta.

8.3.5 Manipulação de dados com pandas

8.3.5.1 Criando e importando dados

O objeto central do pandas é o `DataFrame`, uma tabela em que cada coluna é uma variável, equivalente ao `data.frame` do R. Dados reais são lidos de arquivos com funções como `pd.read_csv()`, `pd.read_excel()` e `pd.read_stata()`. Para os exemplos, simulamos um conjunto de 200 pacientes, com um gerador de números aleatórios com semente fixa, para que os resultados sejam reproduzíveis.

```
import pandas as pd

rng = np.random.default_rng(2024)        # gerador com semente fixa
n = 200
pacientes = pd.DataFrame({
    "id": np.arange(1, n + 1),
    "sexo": rng.choice(["Feminino", "Masculino"], size=n, p=[0.55,
    ↪  0.45]),
    "idade": rng.normal(61, 12, size=n).round(),
    "imc": rng.normal(27.5, 4.5, size=n).round(1),
    "tabagismo": rng.choice(["Nunca", "Ex-fumante", "Atual"], size=n,
    ↪  p=[0.5, 0.3, 0.2]),
})
pacientes["pas"] = (95 + 1.4 * pacientes["imc"] + 0.2 *
↪  pacientes["idade"]
                    + rng.normal(0, 12, size=n)).round()
pacientes.loc[rng.choice(n, size=6, replace=False), "imc"] = np.nan   #
↪  alguns valores faltantes

print(pacientes.shape)
print(pacientes.head())
```

Saída:

```
(200, 6)
   id       sexo  idade   imc   tabagismo    pas
0   1  Masculino   44.0  31.2  Ex-fumante  143.0
1   2   Feminino   54.0  25.7       Atual  142.0
2   3   Feminino   63.0  26.5       Nunca  136.0
3   4  Masculino   49.0  32.7       Nunca  167.0
4   5  Masculino   41.0  27.1  Ex-fumante  161.0
```

A leitura de um arquivo real seria feita, por exemplo, com o comando abaixo, em que os argumentos `sep` e `decimal` permitem ler arquivos no padrão brasileiro, com ponto e vírgula como separador e vírgula como separador decimal:

```
pacientes = pd.read_csv("pacientes.csv", sep=";", decimal=",")
```

8.3.5.2 Selecionando, filtrando e criando variáveis

```
print(pacientes["idade"].head(3))                          # uma coluna
print(pacientes[["idade", "pas"]].head(3))                 # várias colunas
idosos = pacientes[pacientes["idade"] >= 65]               # filtro por
 ↪  condição
print(len(idosos))
fumantes_idosos = pacientes.query("idade >= 65 and tabagismo == 'Atual'")
print(len(fumantes_idosos))

pacientes["hipertenso"] = pacientes["pas"] >= 140          # nova variável
 ↪  lógica
pacientes["faixa_imc"] = pd.cut(pacientes["imc"], bins=[0, 18.5, 25, 30,
 ↪  np.inf],
                                labels=["Baixo peso", "Eutrofia",
 ↪  "Sobrepeso", "Obesidade"],
                                right=False)
print(pacientes[["imc", "faixa_imc"]].head())
```

Saída:

```
0    44.0
1    54.0
2    63.0
Name: idade, dtype: float64
   idade    pas
0   44.0  143.0
1   54.0  142.0
2   63.0  136.0
70
19
```

```
    imc  faixa_imc
0  31.2  Obesidade
1  25.7  Sobrepeso
2  26.5  Sobrepeso
3  32.7  Obesidade
4  27.1  Sobrepeso
```

A função `pd.cut()` agrupa uma variável contínua em classes; com `right=False`, os intervalos são fechados à esquerda e abertos à direita, como na convenção $[a, b)$ do capítulo *Bioestatística descritiva*. Note que o valor faltante de IMC continua faltante na nova variável.

8.3.5.3 Agrupando e resumindo

A combinação `groupby()` e `agg()` corresponde ao `group_by()` e `summarise()` do *tidyverse* no R.

```
resumo = (pacientes
          .groupby("tabagismo")
          .agg(n=("id", "size"),
               idade_media=("idade", "mean"),
               pas_media=("pas", "mean"),
               pas_dp=("pas", "std"),
               prop_hipertensos=("hipertenso", "mean"))
          .round(2))
print(resumo)
```

Saída:

```
             n  idade_media  pas_media  pas_dp  prop_hipertensos
tabagismo
Atual       49        61.33     147.04   13.39              0.69
Ex-fumante  58        58.88     144.69   14.18              0.66
Nunca       93        61.54     149.14   14.36              0.80
```

Os parênteses em volta da expressão permitem encadear operações em várias linhas, uma por linha, o que facilita a leitura. Como `hipertenso` é uma variável lógica, sua média é a proporção de valores verdadeiros.

8.3.5.4 Dados faltantes e variáveis categóricas

```
print(pacientes.isna().sum())                    # número de faltantes
 ↪  por coluna
print(pacientes["imc"].mean())                   # pandas ignora
 ↪  faltantes por padrão
```

```
print(np.mean(pacientes["imc"].to_numpy()))       # NumPy não: o
 ↪  resultado é nan

pacientes["tabagismo"] = pd.Categorical(pacientes["tabagismo"],
                                        categories=["Nunca",
 ↪  "Ex-fumante", "Atual"],
                                        ordered=True)
print(pacientes["tabagismo"].value_counts(sort=False))
```

Saída:

```
id            0
sexo          0
idade         0
imc           6
tabagismo     0
pas           0
hipertenso    0
faixa_imc     6
dtype: int64
27.833505154639173
nan
tabagismo
Nunca         93
Ex-fumante    58
Atual         49
Name: count, dtype: int64
```

Aqui há outra diferença de comportamento a conhecer: o pandas ignora valores faltantes (`NaN`) por padrão ao calcular médias e outras estatísticas, o equivalente a `na.rm = TRUE` no R, enquanto o NumPy os propaga. Ignorar faltantes silenciosamente pode esconder problemas; por isso, verifique sempre quantos valores faltam (`isna().sum()`) antes de resumir os dados. A conversão para `Categorical`, com as categorias na ordem desejada, é o equivalente ao `factor` do R.

8.3.6 Escrevendo código legível e reprodutível

Os princípios apresentados para o R valem igualmente para o Python. Alguns aspectos específicos:

- **Estilo.** A comunidade Python segue um guia de estilo oficial, o **PEP 8**: nomes de variáveis e funções em minúsculas separadas por sublinhado (`pressao_sistolica`, `calcula_imc`), quatro espaços de indentação, linhas de até 79 caracteres, espaços em torno de operadores. Ferramentas como `black` e `ruff` formatam e verificam o código automaticamente.

- **Documentação.** Funções devem ter *docstrings* que descrevam o que fazem, seus argumentos e o que retornam.
- **Sementes aleatórias.** Use um gerador explícito com semente fixa, `rng = np.random.default_rng(semente)`, e passe esse gerador para as funções que sorteiam valores. Isso torna simulações e reamostragens reproduzíveis. Note que as sementes não são compatíveis entre linguagens: `set.seed(2024)` no R e `default_rng(2024)` no Python produzem sequências diferentes, e por isso os dados simulados desta seção não são os mesmos dos capítulos anteriores.
- **Ambientes e versões.** Registre as versões das bibliotecas (`pip freeze > requirements.txt` ou `conda env export > environment.yml`), porque mudanças de versão podem alterar resultados e argumentos padrão.
- **Controle de versões.** Use o Git para registrar a história do código, como no R.

Erros e exceções. Quando algo dá errado, o Python interrompe a execução e mostra um ***traceback***: a sequência de chamadas que levou ao erro, terminando com o tipo do erro e uma mensagem. A informação mais útil está na **última linha**. Erros previsíveis podem ser tratados com `try` e `except`, o equivalente ao `tryCatch()` do R:

```
def converte_numero(texto):
    """Converte texto em número, aceitando vírgula decimal; devolve None
    ↪ se não for possível."""
    try:
        return float(texto.replace(",", "."))
    except ValueError:
        print(f"Valor inválido: {texto!r}")
        return None

valores = ["12,5", "13.1", "não informado", "14"]
print([converte_numero(v) for v in valores])
```

Saída:

```
Valor inválido: 'não informado'
[12.5, 13.1, None, 14.0]
```

8.3.7 Estatística descritiva com Python

As medidas do capítulo *Bioestatística descritiva* estão disponíveis no NumPy, no pandas e no módulo `scipy.stats`. Retomamos o exemplo do tempo de internação de sete pacientes daquele capítulo:

```
from scipy import stats

tempo7 = np.array([3, 4, 4, 5, 6, 8, 19])
print("média:", tempo7.mean(), " mediana:", np.median(tempo7))
print("moda:", stats.mode(tempo7).mode)
print("variância:", round(tempo7.var(ddof=1), 3), " DP:",
 ↪  round(tempo7.std(ddof=1), 3))
print("quartis (padrão, 'linear'):", np.quantile(tempo7, [0.25, 0.5,
 ↪  0.75]))
print("quartis (método 'weibull'):", np.quantile(tempo7, [0.25, 0.5,
 ↪  0.75], method="weibull"))
print("AIQ:", stats.iqr(tempo7))
print("MAD bruto:", stats.median_abs_deviation(tempo7),
      " MAD escalado:", round(stats.median_abs_deviation(tempo7,
       ↪  scale="normal"), 4))
```

Saída:

```
média: 7.0  mediana: 5.0
moda: 4
variância: 30.667  DP: 5.538
quartis (padrão, 'linear'): [4. 5. 7.]
quartis (método 'weibull'): [4. 5. 8.]
AIQ: 3.0
MAD bruto: 1.0  MAD escalado: 1.4826
```

Os resultados coincidem com os do R: média 7, mediana 5, moda 4, variância 30,67 e desvio padrão 5,54. Os quartis mostram de novo que existem várias definições de quantil amostral. O método padrão do NumPy (`"linear"`) é o tipo 7 do R e produz $Q_3 = 7$; o método `"weibull"` corresponde ao tipo 6 (o padrão do SPSS) e produz $Q_3 = 8$, exatamente como discutido naquele capítulo. O MAD bruto é 1; com `scale="normal"`, a função multiplica pelo fator que torna o MAD comparável ao desvio padrão em dados normais, como faz a função `mad()` do R por padrão.

Para um `DataFrame`, o método `describe()` produz um resumo de todas as variáveis numéricas, e a função `pd.crosstab()` constrói tabelas de frequências:

```
print(pacientes[["idade", "imc", "pas"]].describe().round(1))
print(pd.crosstab(pacientes["tabagismo"], pacientes["sexo"],
 ↪  margins=True))
print(pd.crosstab(pacientes["tabagismo"], pacientes["sexo"],
 ↪  normalize="columns").round(3))
```

Saída:

```
       idade    imc    pas
```

```
count  200.0  194.0  200.0
mean    60.7   27.8  147.3
std     12.1    4.5   14.1
min     26.0   12.4  108.0
25%     54.0   24.9  138.0
50%     61.0   27.8  146.0
75%     69.0   30.6  157.0
max     98.0   41.5  187.0
sexo        Feminino  Masculino  All
tabagismo
Nunca             56         37   93
Ex-fumante        40         18   58
Atual             26         23   49
All              122         78  200
sexo        Feminino  Masculino
tabagismo
Nunca          0.459      0.474
Ex-fumante     0.328      0.231
Atual          0.213      0.295
```

A linha `count` do `describe()` mostra 194 valores de IMC, e não 200, por causa dos valores faltantes. Com `normalize="columns"`, a tabela cruzada apresenta proporções dentro de cada coluna (aqui, a distribuição do tabagismo em cada sexo).

8.3.8 Estatística inferencial com Python

8.3.8.1 Comparação de médias e testes de postos

As funções do `scipy.stats` reproduzem os testes do capítulo *Bioestatística inferencial*. Começamos pelos exemplos resolvidos daquele capítulo:

```python
# Teste t pareado
antes = np.array([152, 148, 160, 145, 170, 158, 150, 165])
depois = np.array([144, 146, 151, 148, 158, 151, 149, 152])
res = stats.ttest_rel(antes, depois)
ic = res.confidence_interval(confidence_level=0.95)
print(f"t = {res.statistic:.3f}, p = {res.pvalue:.4f}, IC 95%:
 ↪  {ic.low:.2f} a {ic.high:.2f}")

# Teste dos postos sinalizados de Wilcoxon
w = stats.wilcoxon(antes, depois)
print(f"W = {w.statistic:.0f}, p = {w.pvalue:.4f}")

# Teste de Wilcoxon-Mann-Whitney
grupo_a = [3, 5, 8]
grupo_b = [6, 9, 10, 12]
```

```
mw = stats.mannwhitneyu(grupo_a, grupo_b, alternative="two-sided")
print(f"U = {mw.statistic:.0f}, p = {mw.pvalue:.4f}")
```

Saída:

```
t = 3.084, p = 0.0177, IC 95%: 1.43 a 10.82
W = 3, p = 0.0391
U = 1, p = 0.1143
```

Os resultados são os mesmos do R: $t = 3{,}08$ e $p = 0{,}018$ no teste pareado; $p = 0{,}039$ no teste de Wilcoxon pareado; e, no Mann–Whitney, $U = 1$ (o `W` do R) e $p = 0{,}114$. Note que a estatística do teste de Wilcoxon pareado é apresentada de forma diferente: o SciPy relata a menor das somas de postos (3, a dos postos negativos), enquanto o R relata a soma dos postos positivos ($V = 33$); as duas formas são equivalentes, porque as somas totalizam $8 \times 9/2 = 36$.

Para duas amostras independentes, o argumento `equal_var` escolhe entre o teste t de Student clássico e o de Welch. **Atenção**: o padrão do SciPy é `equal_var=True` (Student), ao contrário do padrão do R, que é o teste de Welch. Como recomendado no capítulo *Bioestatística inferencial*, especifique `equal_var=False`:

```
controle = rng.normal(140, 14, size=40).round()
tratamento = rng.normal(133, 18, size=35).round()
welch = stats.ttest_ind(tratamento, controle, equal_var=False)
ic_w = welch.confidence_interval()
print(f"diferença = {tratamento.mean() - controle.mean():.2f}, "
      f"t = {welch.statistic:.3f}, gl = {welch.df:.1f}")
print(f"p = {welch.pvalue:.4f}, IC 95%: {ic_w.low:.2f} a
 ↪  {ic_w.high:.2f}")
```

Saída:

```
diferença = -5.79, t = -1.620, gl = 63.5
p = 0.1101, IC 95%: -12.94 a 1.35
```

Os graus de liberdade não inteiros indicam a aproximação de Welch.

8.3.8.2 Análise de variância e comparações múltiplas

O exemplo da ANOVA de uma via do capítulo *Análise de dados* (redução da dor em três esquemas de analgesia) fica assim:

```
from statsmodels.stats.multicomp import pairwise_tukeyhsd

reducao = np.array([3, 5, 4, 4, 6, 7, 5, 6, 8, 9, 7, 8])
esquema = np.repeat(["A", "B", "C"], 4)
anova = stats.f_oneway(reducao[esquema == "A"], reducao[esquema == "B"],
                       reducao[esquema == "C"])
print(f"F = {anova.statistic:.2f}, p = {anova.pvalue:.5f}")
print(pairwise_tukeyhsd(reducao, esquema))
```

Saída:

```
F = 24.00, p = 0.00025
Multiple Comparison of Means - Tukey HSD, FWER=0.05
=============================================
group1 group2 meandiff p-adj  lower upper reject
---------------------------------------------
     A      B      2.0 0.0176 0.388 3.612   True
     A      C      4.0 0.0002 2.388 5.612   True
     B      C      2.0 0.0176 0.388 3.612   True
---------------------------------------------
```

A estatística $F = 24$ e as comparações de Tukey coincidem com as do R. Para a ANOVA de Welch, que não supõe variâncias iguais, há a função `anova_oneway()` do módulo `statsmodels.stats.oneway`; para o teste de Kruskal–Wallis, `stats.kruskal()`.

8.3.8.3 Proporções e tabelas de contingência

```
from statsmodels.stats.proportion import proportion_confint

# Qui-quadrado sem correção de Yates (exemplo do capítulo Bioestatística
↪  inferencial)
tabela = np.array([[12, 28], [8, 52]])
qui2, p, gl, esperados = stats.chi2_contingency(tabela, correction=False)
print(f"X2 = {qui2:.3f}, gl = {gl}, p = {p:.4f}")
print(esperados)

# Teste exato de Fisher (exercício 7 do mesmo capítulo)
fisher = stats.fisher_exact([[3, 7], [9, 11]])
print(f"OR = {fisher.statistic:.3f}, p = {fisher.pvalue:.4f}")

# Intervalos de confiança para uma proporção: 12 eventos em 80 pacientes
for metodo in ["normal", "wilson", "beta"]:
    print(metodo, np.round(proportion_confint(12, 80, alpha=0.05,
    ↪  method=metodo), 4))
```

Saída:

```
X2 = 4.167, gl = 1, p = 0.0412
[[ 8. 32.]
 [12. 48.]]
OR = 0.524, p = 0.6942
normal [0.0718 0.2282]
wilson [0.0879 0.2441]
beta [0.08   0.2474]
```

Assim como a função `chisq.test()` do R, a `chi2_contingency()` aplica a correção de Yates por padrão em tabelas 2×2, e é preciso desativá-la explicitamente (`correction=False`) para reproduzir o cálculo sem correção. Na função `proportion_confint()`, o método `"normal"` é o intervalo de Wald, `"wilson"` é o de Wilson (o recomendado) e `"beta"` é o exato de Clopper–Pearson; os três reproduzem os intervalos calculados no R. A razão de chances que o `fisher_exact()` relata é a estimativa amostral simples, $(3 \times 11)/(7 \times 9)$; o R relata uma estimativa condicional de máxima verossimilhança, ligeiramente diferente, embora o valor p seja o mesmo.

8.3.8.4 Correlação e regressão

O módulo `statsmodels.formula.api` permite especificar modelos com fórmulas na mesma notação do R (`resposta ~ preditor1 + preditor2`).

```
import statsmodels.formula.api as smf

imc6 = np.array([20, 22, 24, 26, 28, 30])
pas6 = np.array([118, 124, 122, 130, 129, 133])
r = stats.pearsonr(imc6, pas6)
print(f"Pearson: r = {r.statistic:.4f}, p = {r.pvalue:.4f}, IC 95%:
 ↪  {np.round(r.confidence_interval(), 4)}")
print(f"Spearman: rs = {stats.spearmanr(imc6, pas6).statistic:.4f}")

dados6 = pd.DataFrame({"imc": imc6, "pas": pas6})
modelo = smf.ols("pas ~ imc", data=dados6).fit()
print(modelo.params)
print(modelo.conf_int())
print(f"R2 = {modelo.rsquared:.3f}")
```

Saída:

```
Pearson: r = 0.9319, p = 0.0068, IC 95%: [0.4935 0.9927]
Spearman: rs = 0.8857
Intercept    91.0
imc           1.4
```

```
dtype: float64
                    0           1
Intercept  71.905961  110.094039
imc         0.643269    2.156731
R2 = 0.868
```

Os resultados coincidem com os do capítulo *Análise de dados*: $r = 0{,}932$ (IC 95% de 0,49 a 0,99, pela transformação z de Fisher), $r_s = 0{,}886$, $\hat{y} = 91{,}0 + 1{,}4x$, IC da inclinação de 0,64 a 2,16 e $R^2 = 0{,}868$.

Na regressão múltipla, variáveis categóricas são indicadas com `C()`, e a categoria de referência pode ser escolhida com `Treatment(reference=...)`. O método `summary()` produz um relatório completo, semelhante ao do R; abaixo, usamos `summary2()` para extrair apenas a tabela de coeficientes:

```
modelo_mult = smf.ols("pas ~ idade + imc + C(sexo,
 ↪  Treatment(reference='Feminino'))",
                      data=pacientes).fit()
# Tabela de coeficientes, com nome mais curto para o termo de sexo
termo_sexo = "C(sexo, Treatment(reference='Feminino'))[T.Masculino]"
coefs = modelo_mult.summary2().tables[1].round(3)
print(coefs.rename(index={termo_sexo: "sexo: Masculino"}))
print(f"n usado = {int(modelo_mult.nobs)}, R2 ajustado =
 ↪  {modelo_mult.rsquared_adj:.3f}")
```

Saída:

```
                   Coef.  Std.Err.       t  P>|t|  [0.025   0.975]
Intercept        101.121     7.556  13.382  0.000  86.216  116.026
sexo: Masculino    0.056     1.869   0.030  0.976  -3.631    3.743
idade              0.150     0.075   2.006  0.046   0.002    0.298
imc                1.343     0.205   6.556  0.000   0.939    1.748
n usado = 194, R2 ajustado = 0.182
```

O modelo usou 194 observações: as seis com IMC faltante foram excluídas automaticamente (análise de casos completos), o que deve ser sempre verificado e relatado. Os coeficientes estimados de idade e IMC ficam próximos dos valores usados na simulação (0,2 e 1,4); o de sexo, que não tem efeito na simulação, tem intervalo de confiança que inclui zero.

8.3.8.5 Poder e tamanho amostral

```
from statsmodels.stats.power import TTestIndPower, NormalIndPower
from statsmodels.stats.proportion import proportion_effectsize
```

```
n_t = TTestIndPower().solve_power(effect_size=5 / 12, alpha=0.05,
 ↪  power=0.80)
print(f"teste t, diferença de 5 mmHg com DP de 12: {n_t:.1f} por grupo")

h = proportion_effectsize(0.30, 0.20)
n_p = NormalIndPower().solve_power(effect_size=h, alpha=0.05, power=0.80)
print(f"proporções 30% vs 20% (arcoseno): {n_p:.1f} por grupo")
```

Saída:

```
teste t, diferença de 5 mmHg com DP de 12: 91.4 por grupo
proporções 30% vs 20% (arcoseno): 291.7 por grupo
```

O primeiro resultado reproduz o da função `power.t.test()` do R (cerca de 92 por grupo). O segundo difere ligeiramente do obtido com `power.prop.test()` (cerca de 294 por grupo, no capítulo *Aplicações práticas e estudos de caso*), porque o `statsmodels` usa uma aproximação baseada na transformação arcoseno das proporções. Diferenças desse tipo são comuns entre programas de cálculo amostral, e o método usado deve ser informado no protocolo.

8.3.9 Modelos avançados com statsmodels

Os modelos do capítulo *Tópicos avançados em bioestatística* também estão disponíveis no `statsmodels`. Os exemplos a seguir usam dados simulados.

Regressão logística. O resultado é apresentado como razões de chances, exponenciando os coeficientes e os limites dos intervalos:

```
import statsmodels.api as sm

n_c = 600
cirurgia = pd.DataFrame({"idade": rng.uniform(30, 85, n_c).round(),
                         "fumante": rng.binomial(1, 0.25, n_c),
                         "diabetes": rng.binomial(1, 0.20, n_c)})
lp = -6 + 0.06 * cirurgia["idade"] + 0.8 * cirurgia["fumante"] + 0.6 *
 ↪  cirurgia["diabetes"]
cirurgia["complicacao"] = rng.binomial(1, 1 / (1 + np.exp(-lp)))

logit = smf.logit("complicacao ~ idade + fumante + diabetes",
 ↪  data=cirurgia).fit(disp=False)
or_tab = np.exp(pd.concat([logit.params, logit.conf_int()], axis=1))
or_tab.columns = ["OR", "IC 2,5%", "IC 97,5%"]
print(or_tab.round(3))
```

Saída:

```
              OR  IC 2,5%  IC 97,5%
Intercept  0.001    0.000     0.006
idade      1.068    1.047     1.090
fumante    2.335    1.367     3.990
diabetes   1.866    1.042     3.344
```

Regressão de Poisson com termo de compensação (*offset*) e modelo binomial negativo, para contagens com tempos de acompanhamento diferentes:

```
n_q = 200
quedas = pd.DataFrame({"intervencao": np.repeat([0, 1], n_q // 2),
                       "meses": rng.integers(6, 13, n_q)})
mu = np.where(quedas["intervencao"] == 1, 0.07, 0.10) * quedas["meses"]
quedas["n_quedas"] = rng.negative_binomial(1.5, 1.5 / (1.5 + mu))

poisson = smf.glm("n_quedas ~ intervencao", data=quedas,
 ↪  family=sm.families.Poisson(),
                  offset=np.log(quedas["meses"])).fit()
print(f"dispersão de Pearson: {poisson.pearson_chi2 /
 ↪  poisson.df_resid:.2f}")
binneg = smf.negativebinomial("n_quedas ~ intervencao", data=quedas,

 ↪  offset=np.log(quedas["meses"])).fit(disp=False)
for nome, m in [("Poisson", poisson), ("Binomial negativa", binneg)]:
    rt = np.exp(m.params["intervencao"])
    lim = np.exp(m.conf_int().loc["intervencao"])
    print(f"{nome}: razão de taxas = {rt:.2f} (IC 95%: {lim.iloc[0]:.2f}
     ↪  a {lim.iloc[1]:.2f}), "
          f"p = {m.pvalues['intervencao']:.3f}")
```

Saída:

```
dispersão de Pearson: 1.34
Poisson: razão de taxas = 0.65 (IC 95%: 0.47 a 0.90), p = 0.009
Binomial negativa: razão de taxas = 0.65 (IC 95%: 0.45 a 0.93), p = 0.019
```

A distribuição binomial negativa do NumPy é parametrizada pelo número de "sucessos" e pela probabilidade; a expressão `1.5 / (1.5 + mu)` produz contagens com média `mu` e parâmetro de dispersão 1,5, como no exemplo em R. Assim como lá, a dispersão maior que 1 indica que o modelo de Poisson subestima os erros padrão.

Modelo misto com intercepto aleatório por paciente, para medidas repetidas:

```
ids = np.repeat(np.arange(30), 4)
visita = np.tile(np.arange(4), 30)
tratado = (ids >= 15).astype(int)
```

```
b_i = rng.normal(0, 8, 30)
longit = pd.DataFrame({"id": ids, "visita": visita, "tratado": tratado,
                       "pas": 140 + b_i[ids] - 1 * visita - 3 * visita *
                        ↪ tratado
                            + rng.normal(0, 4, len(ids))})
misto = smf.mixedlm("pas ~ visita * tratado", data=longit,
 ↪ groups=longit["id"]).fit()
print(misto.summary().tables[1])
tau2 = misto.cov_re.iloc[0, 0]
print(f"CCI = {tau2 / (tau2 + misto.scale):.2f}")
```

Saída:

```
                Coef. Std.Err.       z  P>|z|   [0.025   0.975]
Intercept      143.520    2.919  49.163  0.000  137.799  149.242
visita          -1.002    0.407  -2.463  0.014   -1.800   -0.205
tratado         -3.934    4.128  -0.953  0.341  -12.026    4.157
visita:tratado  -2.619    0.575  -4.550  0.000   -3.746   -1.491
Group Var      119.138   10.644
CCI = 0.91
```

Análise de sobrevivência. O estimador de Kaplan–Meier está na classe `SurvfuncRight` e o modelo de Cox, na `PHReg`. Retomamos os oito pacientes do exemplo resolvido no capítulo *Tópicos avançados em bioestatística*:

```
from statsmodels.duration.survfunc import SurvfuncRight

tempo_km = np.array([3, 5, 6, 8, 8, 10, 12, 15])
evento_km = np.array([1, 0, 1, 1, 1, 0, 1, 0])
km = SurvfuncRight(tempo_km, evento_km)
print(km.summary().round(3))
```

Saída:

```
      Surv prob  Surv prob SE  num at risk  num events
Time
3         0.875         0.117            8         1.0
6         0.729         0.165            6         1.0
8         0.438         0.188            5         2.0
12        0.219         0.181            2         1.0
```

As estimativas (0,875; 0,729; 0,438; 0,219) são as mesmas calculadas à mão e com o pacote `survival` do R. O teste log-rank está na função `survdiff()` do módulo `statsmodels.duration.survfunc`, e o modelo de Cox, em `smf.phreg()`. A biblioteca `lifelines` é uma alternativa popular, com interface mais voltada à análise de sobrevivência.

8.3.10 Visualização de dados com Python

A biblioteca **matplotlib** é a base dos gráficos em Python. A forma recomendada de usá-la é a interface "orientada a objetos": cria-se uma figura (`fig`) com um ou mais eixos (`ax`), e cada elemento é desenhado chamando métodos dos eixos. A **seaborn**, construída sobre a matplotlib, oferece gráficos estatísticos prontos e trabalha diretamente com `DataFrame`s, em uma lógica próxima à do `ggplot2`.

O código a seguir reproduz, em Python, gráficos dos capítulos anteriores: um histograma, boxplots com os pontos individuais e um gráfico de dispersão.

```
import matplotlib.pyplot as plt
import seaborn as sns

fig, axes = plt.subplots(1, 3, figsize=(10, 3.4))

axes[0].hist(pacientes["pas"], bins="sturges", color="0.8",
 ↪  edgecolor="white")
axes[0].set(xlabel="PAS (mmHg)", ylabel="Frequência", title="Histograma")

sns.boxplot(data=pacientes, x="tabagismo", y="pas", color="0.9",
 ↪  showfliers=False, ax=axes[1])
sns.stripplot(data=pacientes, x="tabagismo", y="pas", color="0.25",
 ↪  alpha=0.5,
              size=3, jitter=0.15, ax=axes[1])
axes[1].set(xlabel="Tabagismo", ylabel="PAS (mmHg)", title="Boxplot com
 ↪  pontos")

axes[2].scatter(pacientes["imc"], pacientes["pas"], s=12, color="0.25",
 ↪  alpha=0.6)
axes[2].set(xlabel="IMC (kg/m²)", ylabel="PAS (mmHg)", title="Dispersão")

fig.tight_layout()
fig.savefig("images/python_graficos.png", dpi=150)
```

A seaborn também simplifica figuras com paletas acessíveis. A paleta `"colorblind"` é segura para pessoas com deficiência na percepção de cores, e a função `catplot()` combina pontos e médias com intervalos de confiança, como a figura feita com `ggplot2` na seção de visualização:

```
sns.set_theme(style="ticks", palette="colorblind")
g = sns.catplot(data=pacientes, x="faixa_imc", y="pas", kind="point",
                errorbar=("ci", 95), capsize=0.15, color="black",
 ↪  linestyle="none",
                height=3.5, aspect=1.4)
sns.stripplot(data=pacientes, x="faixa_imc", y="pas", hue="faixa_imc",
 ↪  alpha=0.4,
              size=3, jitter=0.15, legend=False, ax=g.ax, zorder=0)
```

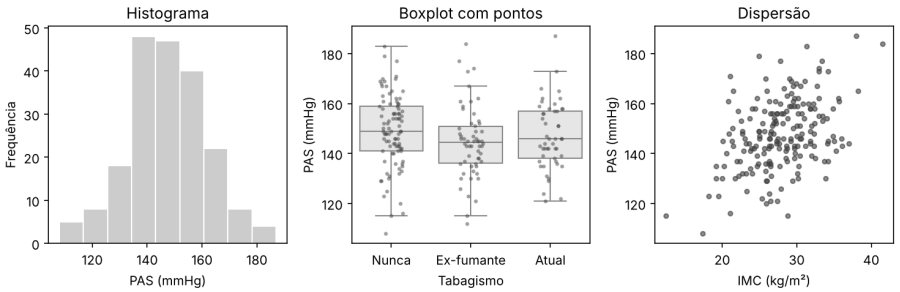


Figura 8.11: Gráficos produzidos com matplotlib e seaborn a partir dos dados simulados desta seção: histograma da pressão arterial sistólica, boxplots com os pontos individuais por categoria de tabagismo e gráfico de dispersão entre IMC e pressão.

```
g.set_axis_labels("Faixa de IMC", "PAS (mmHg)")
g.savefig("images/python_catplot.png", dpi=150)
```

Na faixa de baixo peso há apenas dois pacientes, e por isso o intervalo de confiança é muito largo; mostrar os pontos individuais torna essa limitação visível, o que um gráfico só com médias esconderia.

Para publicação, defina o tamanho final da figura (argumento `figsize`, em polegadas) e salve-a em formato vetorial ou, para imagens matriciais, com a resolução exigida pelo periódico. Por exemplo, `fig.savefig("figura.pdf")` gera um arquivo vetorial, e `fig.savefig("figura.png", dpi=600)`, uma imagem com 600 pontos por polegada. Os princípios da seção de visualização de dados valem integralmente.

8.3.11 Aprendizado de máquina com scikit-learn

A biblioteca **scikit-learn** oferece uma interface uniforme para centenas de métodos de aprendizado de máquina. Mesmo quem não pretende usar métodos complexos se beneficia de suas ferramentas de **validação**, que implementam corretamente os cuidados discutidos no capítulo *Tópicos avançados em bioestatística*.

O exemplo a seguir retoma a simulação de sobreajuste daquele capítulo: 100 observações, 1.000 preditores sem nenhuma relação com o desfecho. Comparamos uma validação cruzada **incorreta**, em que as 10 variáveis mais associadas ao desfecho são selecionadas usando todos os dados antes da validação, com a validação **correta**, em que a seleção é refeita dentro de cada divisão, como parte de um *pipeline*:

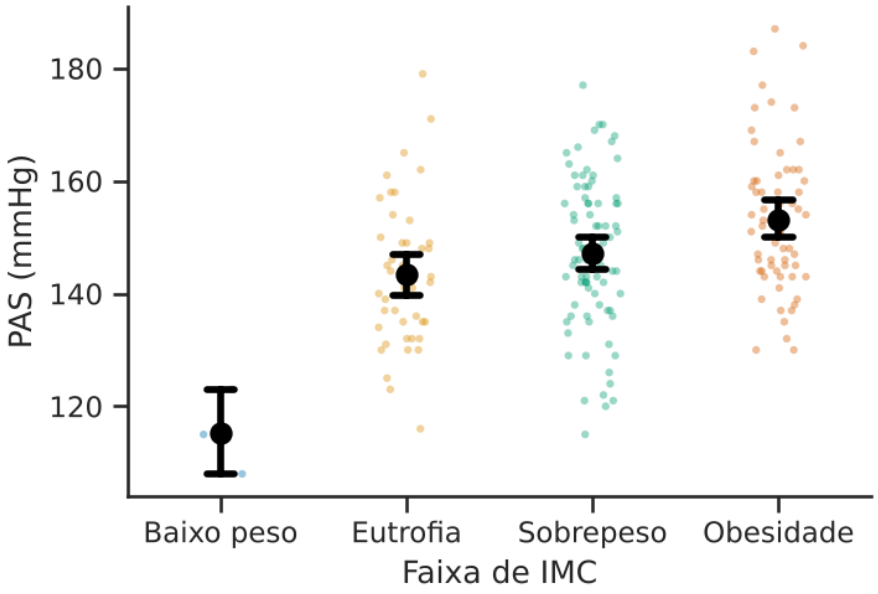


Figura 8.12: Média e intervalo de confiança de 95% da pressão arterial sistólica por faixa de IMC (pontos pretos), com as observações individuais ao fundo, produzidos com seaborn.

```
from sklearn.feature_selection import SelectKBest, f_regression
from sklearn.linear_model import LinearRegression
from sklearn.model_selection import cross_val_score, KFold
from sklearn.pipeline import make_pipeline

X = rng.normal(size=(100, 1000))
y = rng.normal(size=100)
cv = KFold(n_splits=5, shuffle=True, random_state=1)

# Incorreto: seleção com todos os dados, antes da validação cruzada
selecionadas = SelectKBest(f_regression, k=10).fit(X, y).get_support()
r2_errado = cross_val_score(LinearRegression(), X[:, selecionadas], y,
 ↪  cv=cv, scoring="r2")

# Correto: seleção dentro de cada divisão da validação cruzada
pipeline = make_pipeline(SelectKBest(f_regression, k=10),
 ↪  LinearRegression())
r2_certo = cross_val_score(pipeline, X, y, cv=cv, scoring="r2")

print(f"R2 médio, seleção fora da validação: {r2_errado.mean():.2f}")
print(f"R2 médio, seleção dentro da validação: {r2_certo.mean():.2f}")
```

Saída:

```
R2 médio, seleção fora da validação: 0.31
R2 médio, seleção dentro da validação: -0.64
```

Com a seleção feita antes da validação cruzada, o modelo parece prever o desfecho, com R^2 positivo, embora os dados sejam puro ruído. Com a seleção dentro do *pipeline*, o R^2 é negativo, isto é, o modelo prevê pior do que simplesmente usar a média do desfecho, que é a conclusão correta. A classe `Pipeline` garante que todas as etapas (padronização, seleção de variáveis, ajuste) sejam refeitas em cada divisão, e é a forma recomendada de construir modelos preditivos no scikit-learn.

8.3.12 Notebooks e relatórios reprodutíveis

Assim como o R Markdown no R, o Python dispõe de formatos que reúnem código, resultados e texto:

- **Jupyter Notebooks** (arquivos `.ipynb`) são o formato mais difundido. São excelentes para exploração e ensino, mas exigem disciplina: as células podem ser executadas fora de ordem, e um *notebook* só é reprodutível se, depois de reiniciado o *kernel*, todas as células rodarem em sequência e produzirem os mesmos resultados. Antes de compartilhar um *notebook*, use a opção “Reiniciar e executar tudo”;

- **Quarto** produz relatórios, artigos, apresentações, livros e sites a partir de documentos com blocos de Python, R ou ambos, e também converte *notebooks* do Jupyter;
- no próprio R Markdown, com o pacote `reticulate`, blocos ```` ```{python} ```` são executados por um interpretador Python, e objetos podem ser trocados entre as duas linguagens.

Independentemente do formato, as recomendações são as mesmas do R: guarde o código junto com o relatório, gere os números do texto a partir do código, fixe as sementes aleatórias e registre as versões das bibliotecas.

8.4 Visualização de dados e figuras científicas

As seções anteriores mostraram como produzir gráficos em R. Esta seção trata de uma pergunta anterior: como decidir **que** gráfico fazer e como construí-lo para que comunique os dados de forma honesta e clara. Os princípios valem para qualquer programa.

8.4.1 Começar pela pergunta

Um gráfico científico existe para responder a uma pergunta ou apoiar uma afirmação. Antes de escolher o tipo de gráfico, defina a mensagem: comparar grupos? Mostrar uma distribuição? Uma relação entre duas variáveis? Uma evolução no tempo? A escolha segue a pergunta:

- **distribuição de uma variável quantitativa**: histograma, gráfico de densidade, boxplot com os pontos;
- **comparação de uma variável quantitativa entre grupos**: pontos individuais com uma medida resumo, boxplots, gráficos de violino; com muitos grupos, gráficos de pontos ordenados;
- **comparação de proporções ou contagens entre categorias**: gráficos de barras (com o eixo começando em zero) ou de pontos;
- **relação entre duas variáveis quantitativas**: gráfico de dispersão;
- **evolução no tempo**: gráfico de linhas, com os pontos medidos indicados quando forem poucos;
- **estimativas com incerteza** (por exemplo, coeficientes de modelos ou resultados de metanálises): pontos com intervalos de confiança (gráfico de floresta).

8.4.2 Como percebemos os gráficos

Cleveland e McGill (1984) estudaram experimentalmente a precisão com que as pessoas decodificam diferentes elementos gráficos. A **posição ao longo de**

uma escala comum é julgada com mais precisão; seguem-se, em ordem decrescente, a posição em escalas não alinhadas, o comprimento, o ângulo e a inclinação, a área, o volume e a cor. Daí decorrem orientações práticas: comparações importantes devem ser codificadas por posição (pontos alinhados em um mesmo eixo); gráficos de pizza, que codificam por ângulo e área, permitem comparações imprecisas e devem ser evitados, sobretudo com muitas categorias; efeitos tridimensionais distorcem comprimentos e áreas e nunca devem ser usados para dados bidimensionais.

8.4.3 Mostrar os dados

O gráfico de barras com a média e uma barra de erro (o *dynamite plot*) ainda é muito comum para comparar grupos com variáveis contínuas, mas esconde a distribuição dos dados (Weissgerber et al. 2015). A Figura 8.13 mostra dois grupos com médias semelhantes e distribuições muito diferentes: no grupo B, a média é puxada por três valores altos, e a mediana fica abaixo da do grupo A. O gráfico de barras é praticamente idêntico para os dois grupos; o gráfico de pontos revela a diferença.

```
set.seed(12)
grupo_a <- round(rnorm(12, mean = 50, sd = 6), 1)
grupo_b <- round(c(rnorm(9, mean = 40, sd = 4), rnorm(3, mean = 80, sd =
 ↪  6)), 1)
medias <- c(mean(grupo_a), mean(grupo_b))
eps <- c(sd(grupo_a), sd(grupo_b)) / sqrt(12)
op <- par(mfrow = c(1, 2), mar = c(4, 4, 1, 1))
centros <- barplot(medias, names.arg = c("A", "B"), ylim = c(0, 100), col
 ↪  = "grey80",
                   ylab = "Resposta", xlab = "Grupo")
arrows(centros, medias, centros, medias + eps, angle = 90, length = 0.1)
stripchart(list(A = grupo_a, B = grupo_b), vertical = TRUE, method =
 ↪  "jitter", jitter = 0.1,
           pch = 19, col = adjustcolor("grey20", alpha.f = 0.7), ylim =
            ↪  c(0, 100),
           ylab = "Resposta", xlab = "Grupo")
segments(c(0.8, 1.8), c(median(grupo_a), median(grupo_b)), c(1.2, 2.2),
 ↪  lwd = 3)
```

```
par(op)
```

Com amostras pequenas ou moderadas, mostre todos os pontos. Com amostras grandes, use boxplots, gráficos de violino ou de densidade, e indique o tamanho de cada grupo.

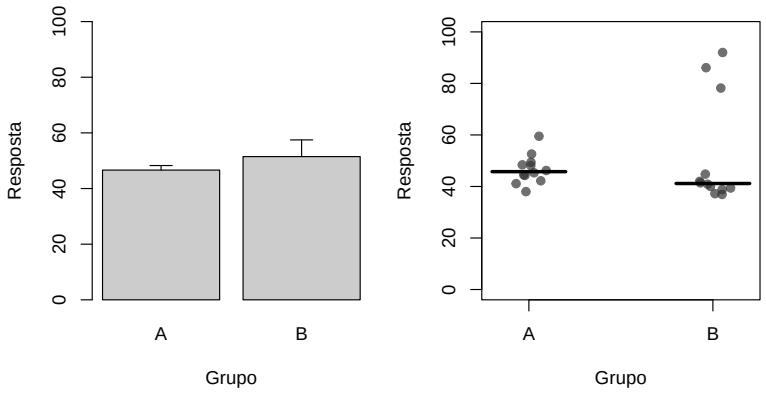


Figura 8.13: Os mesmos dados (simulados) em um gráfico de barras com média e erro padrão (esquerda) e em um gráfico de pontos com a mediana (direita). O gráfico de barras esconde a assimetria do grupo B.

8.4.4 Cor

A cor deve ter uma função: distinguir grupos, codificar uma variável ou destacar um elemento. Algumas orientações:

- **acessibilidade**: uma fração considerável dos homens (em torno de 8% em populações de origem europeia) tem alguma deficiência na percepção de cores, mais frequentemente na distinção entre vermelho e verde. Use paletas seguras para daltônicos, como a de Okabe e Ito para categorias e a família *viridis* para escalas contínuas, e combine cor com outro elemento (forma do símbolo, tipo de linha) quando possível;
- **escalas contínuas** devem variar de forma perceptualmente uniforme; a paleta "arco-íris" (*jet*) cria fronteiras artificiais e deve ser evitada;
- **escalas divergentes** (por exemplo, azul–branco–vermelho) são apropriadas apenas quando há um ponto central com significado, como o zero de uma diferença;
- verifique se a figura continua legível impressa em tons de cinza.

8.4.5 Uma figura para publicação com ggplot2

O exemplo a seguir constrói, com o `ggplot2`, uma figura que compara três grupos mostrando os pontos individuais, a média e o intervalo de confiança de 95% da média, com uma paleta segura para daltônicos, rótulos com unidades e um tema limpo.

```r
library(ggplot2)
set.seed(30)
dados_fig <- data.frame(
  grupo = factor(rep(c("Placebo", "Dose baixa", "Dose alta"), each = 15),
                 levels = c("Placebo", "Dose baixa", "Dose alta")),
  reducao = c(rnorm(15, 2, 4), rnorm(15, 6, 4), rnorm(15, 9, 4))
)
resumo_fig <- aggregate(reducao ~ grupo, data = dados_fig, FUN =
 ↪  function(x)
  c(media = mean(x), inf = t.test(x)$conf.int[1], sup =
   ↪  t.test(x)$conf.int[2]))
resumo_fig <- data.frame(grupo = resumo_fig$grupo, resumo_fig$reducao)
okabe_ito <- c("#E69F00", "#56B4E9", "#009E73")

ggplot(dados_fig, aes(x = grupo, y = reducao, colour = grupo)) +
  geom_hline(yintercept = 0, linetype = "dashed", colour = "grey60") +
  geom_jitter(width = 0.12, alpha = 0.6, size = 2) +
  geom_pointrange(data = resumo_fig, aes(y = media, ymin = inf, ymax =
   ↪  sup),
                  colour = "black", size = 0.6, position =
                   ↪  position_nudge(x = 0.3)) +
  scale_colour_manual(values = okabe_ito, guide = "none") +
  labs(x = NULL, y = "Redução da pressão sistólica (mmHg)") +
  theme_classic(base_size = 12)
```

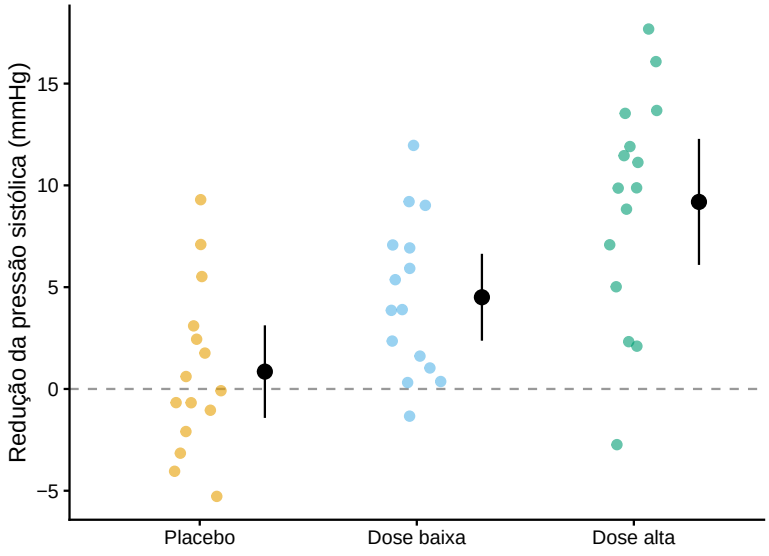


Figura 8.14: Exemplo de figura para publicação: pontos individuais, média e intervalo de confiança de 95% da média em três grupos (dados simulados).

Alguns detalhes desse código ilustram princípios gerais: a linha tracejada em zero dá uma referência para interpretar as reduções; os pontos são deslocados horizontalmente (*jitter*) para não se sobreporem; a média e o intervalo são deslocados para o lado dos pontos, para não escondê-los; a legenda de cores foi removida porque os grupos já estão identificados no eixo; o eixo vertical tem a variável e a unidade. A legenda da figura, no texto, deve informar o que os pontos, as médias e as barras representam, e o tamanho de cada grupo.

8.4.6 Formatos e resolução

- **Gráficos vetoriais** (PDF, SVG, EPS) descrevem a figura por formas geométricas e podem ser ampliados sem perda de qualidade; são o formato preferido para gráficos de dados.
- **Imagens matriciais** (PNG, TIFF, JPEG) são formadas por pixels; para impressão, os periódicos costumam exigir pelo menos 300 pontos por polegada (dpi) no tamanho final para fotografias e de 600 a 1.200 dpi para gráficos de linhas. O formato JPEG, com compressão com perdas, deve ser evitado para gráficos.
- Crie a figura **no tamanho final** em que será publicada (por exemplo, 8,5 cm para uma coluna ou 17,5 cm para a página inteira, conforme o periódico), para que o tamanho das fontes fique legível; reduzir depois uma figura grande deixa os textos minúsculos.

No `ggplot2`, a função `ggsave()` exporta a figura com dimensões e resolução definidas:

```
ggsave("figura1.pdf", width = 12, height = 9, units = "cm")
ggsave("figura1.tiff", width = 12, height = 9, units = "cm", dpi = 600,
 ↪  compression = "lzw")
```

8.4.7 Lista de verificação

Antes de submeter uma figura, verifique:

1. a figura responde a uma pergunta clara e é necessária (não repete uma tabela)?
2. os dados individuais ou sua distribuição estão visíveis, e não apenas médias?
3. os eixos têm rótulos com unidades, e as escalas são adequadas (eixos de barras começam em zero; escalas logarítmicas estão indicadas)?
4. as barras de erro estão identificadas na legenda (desvio padrão, erro padrão ou intervalo de confiança)?
5. a figura é legível no tamanho final e em tons de cinza, e acessível a pessoas com deficiência na percepção de cores?

6. os tamanhos amostrais de cada grupo estão informados?
7. não há elementos decorativos (sombras, efeitos tridimensionais, grades pesadas) que não carreguem informação?
8. a figura é reproduzível a partir do código e dos dados?

Rougier e colaboradores (2014) e o livro de Wilke (2019) aprofundam esses princípios.

Capítulo 9

Comunicação científica

Hércules Rezende Freitas, Ph.D.[1]

[1]Universidade do Estado do Rio de Janeiro (UERJ), Faculdade de Ciências Médicas, Departamento de Ciências Médicas Integradas, Laboratório de Informática em Saúde (LabInfoS), Cabo Frio/RJ, Brasil.

Uma pesquisa que não é comunicada não existe para a ciência. Os resultados só entram no conhecimento coletivo quando são publicados de forma que outros possam entendê-los, avaliá-los, reproduzi-los e usá-los. Comunicar bem não é um acessório da pesquisa, mas parte dela: um artigo que omite detalhes dos métodos impede a replicação; um resumo que exagera os resultados engana leitores que não lerão o texto completo; uma figura mal construída esconde o que os dados mostram.

Este capítulo trata da redação de artigos científicos, da estrutura de relatórios de pesquisa (incluindo dissertações e teses), das apresentações orais e de pôsteres, e do processo de publicação e revisão por pares.

9.1 Redação de artigos científicos

9.1.1 A estrutura IMRaD

A grande maioria dos artigos originais em ciências da saúde segue a estrutura **IMRaD**: **I**ntrodução, **M**étodos, **R**esultados **a**nd **D**iscussão. Ela se consolidou ao longo do século XX e se tornou predominante nos principais periódicos médicos a partir das décadas de 1970 e 1980 (Sollaci and Pereira 2004). Cada seção responde a uma pergunta:

- **Introdução**: por que o estudo foi feito?
- **Métodos**: como foi feito?

- **Resultados**: o que foi encontrado?
- **Discussão**: o que os resultados significam?

A estrutura não é apenas uma convenção: ela separa o que foi **observado** (resultados) do que é **interpretado** (discussão), permitindo que o leitor avalie os dados independentemente das conclusões dos autores. Uma boa prática é escrever na ordem que facilita a coerência, e não na ordem em que as seções aparecem: muitos autores começam pelos métodos e resultados (o que foi feito e encontrado), depois a discussão e a introdução, e por último o resumo e o título.

9.1.2 Título e resumo

O título e o resumo são as partes mais lidas de um artigo, e frequentemente as únicas. O **título** deve identificar o tema, a população e, quando possível, o desenho do estudo ("Exercício aeróbico e memória em idosos com comprometimento cognitivo leve: ensaio clínico randomizado"). Títulos que anunciam conclusões ("O exercício aeróbico melhora a memória…") são aceitos por alguns periódicos, mas tendem a simplificar resultados que raramente se resumem a uma frase.

O **resumo estruturado** (objetivo, métodos, resultados, conclusões) é exigido pela maioria dos periódicos de saúde. Ele deve conter os números principais: o tamanho da amostra, a estimativa do efeito no desfecho principal com seu intervalo de confiança, e não apenas a afirmação de que "houve diferença significativa". Deve ser coerente com o texto completo: o resumo é o lugar mais frequente de **distorção interpretativa** (*spin*), isto é, a apresentação de resultados de forma mais favorável do que os dados permitem. Em uma amostra de ensaios randomizados com desfecho principal sem diferença estatisticamente significativa, Boutron e colaboradores (2010) encontraram algum tipo de distorção na maioria dos resumos, como a ênfase em desfechos secundários ou em análises de subgrupo favoráveis.

9.1.3 Introdução

A introdução deve ser curta e organizada como um **funil**: parte do contexto geral (a relevância do problema), passa pelo que se sabe e pelo que não se sabe (a lacuna identificada na revisão da literatura, capítulo *Formulação de problemas e hipóteses*) e termina com o **objetivo** do estudo, de preferência no último parágrafo. Não é uma revisão exaustiva da literatura: cada parágrafo deve conduzir o leitor até a pergunta que o estudo responde.

9.1.4 Métodos

Os métodos devem ser descritos com detalhe suficiente para que outro pesquisador possa **reproduzir** o estudo. Isso inclui: desenho; local e período; critérios de elegibilidade; como os participantes foram recrutados; definição precisa e forma de medida da exposição, do desfecho e das covariáveis; cálculo do tamanho amostral; métodos estatísticos, com o programa e a versão utilizados; e aspectos éticos (aprovação pelo comitê de ética, consentimento, registro do estudo).

A descrição da análise estatística deve permitir que um leitor com acesso aos dados reproduza os resultados: que modelos foram ajustados, com quais variáveis, como se lidou com dados faltantes, quais análises foram planejadas e quais foram exploratórias. Frases genéricas como "os dados foram analisados com testes estatísticos apropriados" não informam nada.

Para cada tipo de estudo há uma **diretriz de relato** que lista os itens essenciais, reunidas pela rede EQUATOR (*Enhancing the QUAlity and Transparency Of health Research*). As principais são:

- **CONSORT**: ensaios clínicos randomizados (capítulo *Desenhos de pesquisa*);
- **SPIRIT**: protocolos de ensaios clínicos;
- **STROBE**: estudos observacionais (coorte, caso-controle, transversal);
- **PRISMA**: revisões sistemáticas e metanálises;
- **STARD**: estudos de acurácia diagnóstica;
- **TRIPOD**: modelos de predição;
- **ARRIVE**: pesquisas com animais;
- **CARE**: relatos de caso;
- **SRQR** e **COREQ**: pesquisas qualitativas.

Muitos periódicos exigem que a lista de verificação da diretriz correspondente seja preenchida e enviada com o manuscrito. Usá-la desde o planejamento do estudo, e não apenas na redação, evita descobrir tarde demais que uma informação essencial não foi coletada.

9.1.5 Resultados

Os resultados apresentam os achados **sem interpretá-los**. A ordem usual é: fluxo de participantes (quantos foram avaliados, incluídos, perdidos e analisados, frequentemente em um diagrama), características da amostra (a "Tabela 1", capítulo *Bioestatística descritiva*), resultado do desfecho principal, desfechos secundários e análises adicionais.

O texto não deve repetir tudo o que está nas tabelas; deve destacar os achados principais e remeter às tabelas e figuras para os detalhes. Algumas regras de apresentação numérica:

- relate o **tamanho do efeito com seu intervalo de confiança**, e não apenas o valor p: "a pressão sistólica diminuiu em média 6,1 mmHg (IC 95%: 1,4 a 10,8; $p = 0{,}018$)", e não "houve redução significativa da pressão ($p < 0{,}05$)";
- informe os **valores p exatos**, com duas ou três casas decimais, e use "$p < 0{,}001$" apenas para valores muito pequenos;
- use precisão compatível com os dados: porcentagens com uma casa decimal, médias com no máximo uma casa a mais que a precisão da medida;
- informe sempre os **denominadores**, especialmente quando houver dados faltantes;
- relate os resultados de **todos** os desfechos pré-especificados, inclusive os negativos.

As diretrizes SAMPL, discutidas no capítulo *Bioestatística descritiva*, detalham essas recomendações.

9.1.6 Discussão

Uma discussão bem estruturada costuma conter, nesta ordem:

1. **o achado principal**, em uma ou duas frases, respondendo à pergunta do estudo;
2. **a comparação com a literatura**: os resultados concordam ou discordam de estudos anteriores, e por quê? Explicações possíveis para as discordâncias (populações, métodos, tamanhos amostrais) são mais úteis do que listas de estudos concordantes;
3. **os mecanismos plausíveis**, quando relevante, deixando claro o que é especulação;
4. **as limitações**, de forma honesta e específica: não basta escrever "o estudo tem limitações, como o tamanho amostral"; é preciso discutir qual a provável direção e magnitude de cada viés e como ele afeta a interpretação;
5. **os pontos fortes**;
6. **as implicações** para a prática e para a pesquisa futura;
7. **a conclusão**, que deve decorrer diretamente dos resultados, sem extrapolá-los.

Três tipos de extrapolação são frequentes e devem ser evitados: concluir causalidade a partir de estudos observacionais sem discutir confusão ("o consumo de X **causa** Y"); generalizar para populações muito diferentes da estudada; e interpretar a ausência de significância estatística como prova de ausência de efeito (capítulo *Bioestatística inferencial*).

9.1.7 Autoria

Ser autor de um artigo significa assumir **responsabilidade** pelo seu conteúdo, e não apenas receber crédito. As recomendações do **ICMJE** (*International Committee of Medical Journal Editors*), adotadas pela maioria dos periódicos médicos, estabelecem que um autor deve atender aos quatro critérios a seguir:

1. contribuição substancial para a concepção ou o desenho do trabalho, ou para a aquisição, análise ou interpretação dos dados;
2. redação do trabalho ou revisão crítica de seu conteúdo intelectual importante;
3. aprovação final da versão a ser publicada;
4. concordância em ser responsável por todos os aspectos do trabalho, garantindo que questões sobre a exatidão ou a integridade de qualquer parte sejam adequadamente investigadas e resolvidas.

Quem contribuiu sem atender aos quatro critérios (por exemplo, obtendo financiamento, coletando dados ou chefiando o laboratório) deve ser mencionado nos agradecimentos. A taxonomia **CRediT** (*Contributor Roles Taxonomy*) (Brand et al. 2015) padroniza a descrição das contribuições de cada autor em 14 papéis (conceituação, curadoria de dados, análise formal, obtenção de financiamento, investigação, metodologia, administração do projeto, recursos, *software*, supervisão, validação, visualização, redação do rascunho original e revisão e edição), e é adotada por muitos periódicos. A autoria "presenteada" (incluir quem não contribuiu) e a autoria "fantasma" (omitir quem contribuiu substancialmente, como redatores pagos pela indústria) são violações da integridade científica (capítulo *Ética e boas práticas em pesquisa*).

9.1.8 Estilo

A redação científica busca **clareza** e **precisão**, não ornamento. Algumas orientações:

- prefira frases curtas e diretas, com uma ideia principal por frase;
- use a mesma palavra para o mesmo conceito ao longo do texto: se o desfecho é "evento cardiovascular maior", não alterne com "complicação cardíaca" e "evento coronariano" por variedade estilística;
- evite termos vagos ("vários", "alguns", "significativamente" no sentido não estatístico) quando um número pode ser dado;
- distinga o uso estatístico de "significativo" do uso cotidiano; na dúvida, escreva "estatisticamente significativo" ou, melhor, apresente a estimativa e o intervalo;
- use abreviaturas com parcimônia, definindo-as na primeira ocorrência;

- revise o texto várias vezes, de preferência depois de alguns dias de distância, e peça a colegas de fora da área que o leiam.

O uso de ferramentas de inteligência artificial para auxiliar a redação deve seguir as políticas do periódico. Em geral, essas ferramentas não podem ser listadas como autoras, porque não podem assumir responsabilidade pelo trabalho, e seu uso deve ser declarado. Os autores continuam integralmente responsáveis por todo o conteúdo, inclusive por verificar a exatidão de afirmações e referências.

9.2 Estrutura de relatórios de pesquisa

Além dos artigos, a pesquisa é comunicada em outros formatos, cada um com convenções próprias.

9.2.1 Dissertações e teses

Os programas de pós-graduação brasileiros admitem, em geral, dois formatos:

- **formato tradicional**: introdução, revisão da literatura, objetivos, métodos, resultados, discussão e conclusões, como uma monografia extensa;
- **formato de artigos**: introdução geral e objetivos, seguidos de um ou mais artigos (publicados, submetidos ou em preparação) e de uma discussão geral que integra os achados.

As regras de cada programa e as normas da ABNT para trabalhos acadêmicos, citações e referências definem a formatação. Independentemente do formato, a dissertação ou tese deve permitir ao leitor avaliar o trabalho como um todo: os métodos podem ser descritos com mais detalhe do que nos artigos, e análises complementares que não couberam nos artigos podem ser apresentadas.

9.2.2 Protocolos e planos de análise estatística

O **protocolo** é o documento que descreve o estudo antes de sua realização: justificativa, objetivos, desenho, população, intervenções, desfechos, tamanho amostral, análise e aspectos éticos. É exigido pelos comitês de ética e, para ensaios clínicos, deve seguir a diretriz SPIRIT.

O **plano de análise estatística** (PAE, ou SAP, do inglês *statistical analysis plan*) detalha as análises de forma a eliminar a flexibilidade depois que os dados são conhecidos: definição exata das populações de análise, dos desfechos e de como serão derivados, dos modelos, do tratamento de dados faltantes, das análises de sensibilidade e de subgrupo, e do formato das tabelas. Para ensaios

clínicos, há diretrizes específicas sobre o conteúdo mínimo do plano (Gamble et al. 2017). Em estudos observacionais, um plano escrito antes do acesso aos dados oferece proteção semelhante contra a escolha seletiva de análises.

9.2.3 Relatórios técnicos e relatórios reprodutíveis

Relatórios técnicos para instituições, gestores ou financiadores priorizam a utilidade prática: um resumo executivo no início, com as principais conclusões e recomendações, seguido do detalhamento dos métodos e dos resultados.

Para qualquer relatório que envolva análise de dados, uma prática que aumenta muito a confiabilidade é produzi-lo como um **documento reprodutível**: o texto, o código e os resultados ficam no mesmo arquivo (R Markdown ou Quarto, por exemplo; capítulo *Uso de softwares estatísticos*), e os números citados no texto são gerados diretamente pelo código, e não copiados à mão. Este livro é escrito dessa forma. Assim, se os dados forem corrigidos, o relatório inteiro é atualizado ao ser recompilado, e erros de transcrição deixam de existir.

9.3 Apresentações orais e pôsteres

9.3.1 Apresentações orais

Uma apresentação oral não é um artigo lido em voz alta. O público não pode voltar atrás para reler uma frase, e a atenção é limitada. Algumas orientações:

- **conheça o tempo e respeite-o**: como referência, conte cerca de um minuto por slide de conteúdo; uma apresentação de 10 minutos comporta em torno de 8 a 10 slides;
- **conte uma história**: qual era o problema, o que foi feito, o que foi encontrado, por que importa. Uma mensagem principal clara, repetida no início e no final, vale mais do que muitos detalhes;
- **um slide, uma ideia**: o título do slide pode ser a própria mensagem ("O treinamento aeróbico melhorou a memória em 3 pontos"), e o conteúdo, a evidência que a sustenta;
- **pouco texto**: o slide apoia a fala, não a substitui. Listas longas de tópicos levam o público a ler em vez de ouvir;
- **figuras em vez de tabelas**: tabelas extensas são ilegíveis em projeção. Mostre os números essenciais, em fonte grande, e as figuras simplificadas para a projeção;
- **legibilidade**: fontes sem serifa, de tamanho suficiente para serem lidas do fundo da sala, e alto contraste. Cerca de 8% dos homens têm alguma forma de deficiência na percepção de cores, por isso a informação não deve depender apenas da distinção entre vermelho e verde;
- **ensaie** em voz alta, com cronômetro, e prepare-se para perguntas.

9.3.2 Pôsteres

O pôster é lido em pé, em poucos minutos, frequentemente à distância. O erro mais comum é colocar nele o artigo inteiro. Um bom pôster:

- tem um **título curto e informativo**, legível a alguns metros de distância;
- organiza o conteúdo em **colunas**, lidas de cima para baixo e da esquerda para a direita, com seções curtas;
- dá destaque à **mensagem principal**, que pode ser escrita em uma frase em fonte grande, no centro ou no topo;
- usa **figuras** como elemento principal, com legendas autoexplicativas;
- deixa **espaço em branco**: um pôster congestionado afasta os leitores;
- inclui o contato dos autores e, se desejado, um código QR que leve ao resumo, ao artigo ou aos materiais suplementares.

Os princípios de construção de figuras científicas estão no capítulo *Uso de softwares estatísticos*. Rougier e colaboradores (2014) resumem dez regras práticas, entre elas conhecer o público, adaptar a figura ao meio (artigo, slide, pôster), evitar os padrões automáticos dos programas e não enganar o leitor.

9.4 Publicação e revisão por pares

9.4.1 Escolhendo o periódico

A escolha do periódico deve ser feita cedo, porque define o formato, o limite de palavras e o público. Critérios a considerar:

- **escopo**: o periódico publica estudos sobre o tema e com o tipo de desenho? Ler alguns artigos recentes e as instruções aos autores responde a essa pergunta;
- **público**: quem precisa ler o resultado? Clínicos, gestores, pesquisadores de uma área específica?
- **indexação**: o periódico está indexado nas bases relevantes (MEDLINE, Scopus, Web of Science, SciELO, LILACS)?
- **acesso e custos**: o periódico é de acesso aberto? Cobra taxa de processamento de artigos (APC)? Há acordos institucionais que isentam os autores? Os acordos transformativos negociados pela CAPES com algumas editoras permitem a autores de instituições brasileiras publicar em acesso aberto em determinados periódicos híbridos sem pagar a taxa; as condições mudam e devem ser verificadas no Portal de Periódicos;
- **tempo de avaliação e taxa de aceitação**, frequentemente informados pelo próprio periódico;

- **métricas de impacto**: indicadores como o fator de impacto ou o CiteScore medem citações médias do periódico, não a qualidade de um artigo específico, e devem ser apenas um dos critérios.

9.4.2 Periódicos predatórios

Periódicos predatórios são publicações que cobram taxas dos autores sem oferecer os serviços editoriais que anunciam, em particular uma revisão por pares real. Uma definição de consenso os descreve como entidades que priorizam o interesse próprio em detrimento da erudição, caracterizadas por informações falsas ou enganosas, desvio das melhores práticas editoriais, falta de transparência e solicitações agressivas e indiscriminadas (Grudniewicz et al. 2019). Sinais de alerta incluem: convites por e-mail para submeter a periódicos de que o autor nunca ouviu falar, frequentemente fora de sua área; promessa de aceitação ou publicação muito rápida; corpo editorial falso ou não verificável; métricas de impacto inventadas; indexação alegada que não se confirma nas bases. Publicar em um periódico predatório desperdiça o trabalho de pesquisa, porque o artigo terá pouca visibilidade e credibilidade, e pode prejudicar a carreira do autor.

9.4.3 Submissão

A submissão é feita pelo sistema eletrônico do periódico e inclui, em geral: o manuscrito formatado segundo as instruções aos autores; as figuras e tabelas; a **carta ao editor** (*cover letter*), que explica brevemente o que o estudo encontrou, por que é relevante para os leitores daquele periódico e declara que o manuscrito não está submetido em outro lugar; as declarações de conflitos de interesse, financiamento, aprovação ética e contribuições dos autores; a lista de verificação da diretriz de relato; e, cada vez mais, a declaração de disponibilidade dos dados e do código.

9.4.4 Revisão por pares

O editor faz uma primeira avaliação e pode rejeitar o manuscrito sem enviá-lo a revisores (*desk rejection*), em geral por estar fora do escopo, ter problemas metodológicos evidentes ou baixa prioridade para o periódico. Se o manuscrito prosseguir, é enviado a dois ou mais **revisores**, especialistas na área, que avaliam sua validade, originalidade e clareza. Os modelos de revisão incluem:

- **simples-cego**: os revisores conhecem a identidade dos autores, mas não o contrário;
- **duplo-cego**: nenhuma das partes conhece a identidade da outra;
- **aberta**: as identidades são conhecidas e, em alguns periódicos, os pareceres são publicados com o artigo.

Com base nos pareceres, o editor decide: aceitar (raro na primeira rodada), solicitar revisões menores ou maiores, ou rejeitar.

Respondendo aos revisores. A resposta deve ser feita em uma **carta ponto a ponto**, reproduzindo cada comentário e explicando o que foi alterado (com indicação de página e linha) ou, quando o autor discordar, por que não foi alterado. A discordância é legítima, desde que fundamentada e cortês. Mesmo comentários que parecem resultar de uma leitura equivocada indicam que o texto não estava claro para pelo menos um leitor qualificado, e merecem uma alteração no texto, e não apenas uma explicação na carta.

Rejeição. A rejeição é parte normal da vida científica, inclusive para pesquisadores experientes. Os pareceres recebidos devem ser usados para melhorar o manuscrito antes de submetê-lo a outro periódico.

Atuando como revisor. Revisar manuscritos é uma contribuição importante à comunidade. Um bom parecer resume o estudo, avalia se as conclusões decorrem dos métodos e resultados, identifica problemas metodológicos de forma específica e construtiva, e distingue questões essenciais de sugestões menores. O revisor deve declarar conflitos de interesse e manter a confidencialidade do manuscrito.

9.4.5 Pré-prints, acesso aberto e o depois da publicação

Pré-prints são versões de manuscritos disponibilizadas publicamente antes da revisão por pares, em servidores como medRxiv, bioRxiv e SciELO Preprints. Aceleram a disseminação e permitem receber comentários, mas não foram avaliados por pares, o que deve ser considerado por quem os lê. A maioria dos periódicos aceita manuscritos que foram previamente divulgados como pré-print, mas é preciso verificar a política de cada um.

O **acesso aberto** torna o artigo gratuitamente disponível a qualquer leitor. Na via **dourada**, o próprio periódico publica em acesso aberto (às vezes mediante taxa); na via **verde**, o autor deposita uma versão do manuscrito em um repositório institucional ou temático; periódicos **diamante** são de acesso aberto e não cobram taxas de autores nem de leitores, sendo financiados por instituições, como muitos periódicos da coleção SciELO.

Depois da publicação, o artigo continua sujeito ao escrutínio da comunidade, por meio de cartas ao editor, comentários em plataformas e tentativas de replicação. Erros honestos devem ser corrigidos por meio de **errata**; erros graves que invalidam as conclusões, ou má conduta, levam à **retratação** do artigo, tema do capítulo *Ética e boas práticas em pesquisa*. Compartilhar dados e código em repositórios públicos (como Zenodo, OSF ou repositórios institucionais), respeitando a privacidade dos participantes, permite que outros verifiquem e reaproveitem o trabalho.

9.5 Resumo do capítulo

- A estrutura IMRaD separa o que foi feito e observado (métodos e resultados) do que é interpretado (discussão).
- O resumo deve conter as estimativas principais com seus intervalos e ser fiel ao texto; é o local mais frequente de distorção interpretativa.
- Os métodos devem permitir a reprodução do estudo. Use a diretriz de relato correspondente (CONSORT, STROBE, PRISMA, STARD, ARRIVE, entre outras) desde o planejamento.
- Nos resultados, relate tamanhos de efeito com intervalos de confiança, valores p exatos e denominadores, para todos os desfechos pré-especificados.
- A discussão apresenta o achado principal, compara com a literatura, discute limitações de forma específica e não extrapola as conclusões.
- Autoria exige responsabilidade e o cumprimento dos quatro critérios do ICMJE. A taxonomia CRediT descreve as contribuições.
- Planos de análise escritos antes do acesso aos dados e relatórios reprodutíveis aumentam a confiabilidade.
- Apresentações orais e pôsteres exigem síntese: uma mensagem principal, poucas palavras, figuras legíveis.
- Escolha o periódico pelo escopo, público, indexação e custos; evite periódicos predatórios. Responda aos revisores ponto a ponto, com cortesia e fundamentação.

9.6 Exercícios

1. Reescreva a frase a seguir para um resumo, seguindo as recomendações deste capítulo: “O grupo que recebeu o tratamento apresentou melhora significativa em relação ao controle ($p < 0{,}05$).” Invente números plausíveis, se necessário.

2. Identifique os problemas nesta conclusão de um estudo transversal com 200 adultos: “Concluímos que o consumo de café previne a depressão, e recomendamos que a população consuma ao menos três xícaras por dia.”

3. Um pesquisador coletou dados, outro realizou a análise estatística e redigiu os resultados, um terceiro conseguiu o financiamento e chefia o laboratório, e um quarto revisou criticamente o manuscrito e aprovou sua versão final, mas não participou de nenhuma outra etapa. Quem deve ser autor segundo os critérios do ICMJE? Como as contribuições poderiam ser descritas com a taxonomia CRediT?

4. Você recebeu um e-mail convidando-o a submeter um artigo a um periódico com “fator de impacto 5,8”, com promessa de publicação em sete dias mediante taxa de 300 dólares. Que verificações você faria antes de considerar o convite?

5. Um revisor afirma que seu estudo não considerou a idade como confundidor, mas a idade está incluída no modelo, como descrito na seção de métodos. Como você responderia?

9.7 Respostas dos exercícios

1. Por exemplo: "Após 12 semanas, a pressão sistólica foi em média 6,1 mmHg menor no grupo tratado do que no grupo controle (IC 95%: 1,4 a 10,8; $p = 0{,}018$)." A versão reescrita informa o desfecho, o momento, a direção e a magnitude do efeito, sua precisão e o valor p exato.

2. (a) Linguagem causal ("previne") a partir de um estudo transversal, que não estabelece a ordem temporal (pessoas deprimidas podem consumir menos café) nem controla confusão não medida. (b) A recomendação populacional extrapola muito o que o estudo permite, e não considera possíveis efeitos adversos. (c) A precisão das estimativas não depende apenas do total de 200 participantes, mas sobretudo do número de pessoas com depressão, que pode ser pequeno; sem a estimativa de efeito e seu intervalo de confiança, não é possível julgar se a associação foi estimada com precisão. Uma conclusão adequada seria: "o consumo de café foi associado a menor prevalência de sintomas depressivos; estudos longitudinais são necessários para avaliar se a associação é causal".

3. Pelos critérios do ICMJE, um autor precisa atender aos quatro critérios. O pesquisador que realizou a análise e redigiu os resultados atende ao critério 1 (análise e interpretação) e ao 2 (redação) e, se aprovar a versão final e aceitar a responsabilidade, aos critérios 3 e 4. Quem apenas coletou dados, quem apenas obteve financiamento e quem apenas revisou e aprovou não atendem ao critério 1 ou ao 2 de forma completa, a menos que tenham participado também de outras etapas; se não participaram, devem constar nos agradecimentos. Pela CRediT: análise formal e redação do rascunho original (segundo pesquisador); investigação ou curadoria de dados (primeiro); obtenção de financiamento e supervisão (terceiro); revisão e edição (quarto). Note que a CRediT descreve contribuições, mas não substitui os critérios de autoria.

4. Verificar se o periódico está indexado nas bases que ele alega (MEDLINE, Scopus, Web of Science) consultando as próprias bases, e não o site do periódico; se o fator de impacto aparece no Journal Citation Reports; se os membros do corpo editorial existem e confirmam o vínculo; se o periódico consta do DOAJ (para periódicos de acesso aberto); se os artigos publicados são de qualidade e da sua área; se há informações claras sobre o processo de revisão. A promessa de publicação em sete dias é incompatível com uma revisão por pares real.

5. Com cortesia, agradecer o comentário, indicar que a idade foi incluída no modelo ajustado e onde isso está descrito, e, reconhecendo que a informação pode não ter ficado clara, explicitá-la melhor no texto (por exemplo, listando as covariáveis do modelo na legenda da tabela e no texto dos métodos), indicando página e linha da alteração.

Capítulo 10

Ética e boas práticas em pesquisa

Hércules Rezende Freitas, Ph.D.[1]

[1]Universidade do Estado do Rio de Janeiro (UERJ), Faculdade de Ciências Médicas, Departamento de Ciências Médicas Integradas, Laboratório de Informática em Saúde (LabInfoS), Cabo Frio/RJ, Brasil.

A ética na pesquisa tem duas faces. A primeira diz respeito aos **participantes**: as pessoas e os animais envolvidos em um estudo não podem ser tratados como meios para um fim, e seus direitos, sua segurança e seu bem-estar têm precedência sobre os interesses da ciência. A segunda diz respeito à **integridade** do próprio conhecimento: a confiança que a sociedade deposita na ciência depende de que os pesquisadores registrem, analisem e comuniquem seus resultados com honestidade. Este capítulo trata das duas, da regulamentação que as concretiza no Brasil e da responsabilidade social de quem faz ciência.

As informações sobre legislação apresentadas aqui refletem as normas vigentes no momento da redação. Normas mudam, e o pesquisador deve sempre consultar as versões atualizadas e as orientações do comitê de ética de sua instituição.

10.1 Consentimento informado e conformidade ética

10.1.1 Uma breve história

As normas atuais de ética em pesquisa nasceram de abusos.

- **O Código de Nuremberg (1947).** No julgamento dos médicos nazistas que conduziram experimentos em prisioneiros de campos de concentração, o tribunal formulou dez princípios para a pesquisa com seres humanos.

O primeiro afirma que o **consentimento voluntário** do participante é absolutamente essencial.

- **A Declaração de Helsinque (1964).** A Associação Médica Mundial adotou uma declaração de princípios para a pesquisa médica, revisada várias vezes; a versão mais recente, de outubro de 2024, passou a usar o termo "participantes" em vez de "sujeitos" e reforçou temas como a proteção de pessoas vulneráveis, a equidade na distribuição de riscos e benefícios e a transparência (World Medical Association 2025).
- **O artigo de Beecher (1966).** Henry Beecher, anestesiologista de Harvard, descreveu 22 estudos publicados em periódicos de prestígio que expunham participantes a riscos sem consentimento adequado (Beecher 1966), mostrando que os abusos não eram exclusividade de regimes totalitários.
- **O estudo de Tuskegee (1932–1972).** O Serviço de Saúde Pública dos Estados Unidos acompanhou centenas de homens negros com sífilis para observar a evolução natural da doença, sem informá-los do diagnóstico e sem tratá-los, mesmo depois de a penicilina se tornar o tratamento de escolha. A denúncia pública do estudo, em 1972, levou à criação de uma comissão nacional que produziu o Relatório Belmont.
- **O Relatório Belmont (1979)** sintetizou três princípios éticos fundamentais:

    1. **respeito às pessoas**: os indivíduos devem ser tratados como agentes autônomos, e pessoas com autonomia reduzida têm direito a proteção adicional. Daí deriva o consentimento informado;
    2. **beneficência**: não causar dano e maximizar os benefícios possíveis, minimizando os riscos. Daí deriva a avaliação de riscos e benefícios;
    3. **justiça**: distribuir de forma equitativa os ônus e os benefícios da pesquisa. Daí deriva a seleção justa dos participantes, que não deve recair sobre grupos vulneráveis apenas por conveniência.

10.1.2 O sistema brasileiro

No Brasil, a ética em pesquisa com seres humanos se organizou a partir da Resolução nº 196/1996 do Conselho Nacional de Saúde (CNS), que criou o sistema formado pelos **Comitês de Ética em Pesquisa** (CEPs) e pela **Comissão Nacional de Ética em Pesquisa** (Conep), conhecido como sistema CEP/Conep. A Resolução nº 196/1996 foi substituída pela **Resolução CNS nº 466/2012**, que estabelece as diretrizes gerais, e complementada pela **Resolução CNS nº 510/2016**, específica para pesquisas em ciências humanas e sociais, cujos métodos (entrevistas, observação participante, grupos focais) exigem adaptações das regras pensadas para a pesquisa biomédica. Os projetos são submetidos eletronicamente pela **Plataforma Brasil**.

Em 2024, a **Lei nº 14.874**, de 28 de maio de 2024, deu à matéria, pela primeira vez, o estatuto de lei federal. Ela estabelece princípios e regras para a pesquisa

com seres humanos e institui o **Sistema Nacional de Ética em Pesquisa com Seres Humanos**, composto por uma **instância nacional de ética em pesquisa**, no âmbito do Ministério da Saúde, e pela **instância de análise ética**, exercida pelos CEPs. Entre outros pontos, a lei:

- classifica as pesquisas por nível de risco e define que as de risco baixo ou moderado podem ser analisadas por CEPs **credenciados**, enquanto as de risco elevado exigem CEPs **acreditados**;
- fixa prazos para a análise dos projetos pelos CEPs;
- regula o uso de placebo, que só é admitido isoladamente quando não houver métodos comprovados de prevenção, diagnóstico ou tratamento para a condição estudada;
- regula o **acesso pós-estudo**, isto é, o fornecimento gratuito do medicamento experimental aos participantes de ensaios clínicos após o término do estudo, nas condições que especifica;
- regula a guarda e o uso de material biológico em **biobancos** e **biorrepositórios**.

A lei foi regulamentada pelo **Decreto nº 12.651/2025**, que prevê que as normas do Conselho Nacional de Saúde continuem em vigor, naquilo que não contrariarem a lei e o decreto, até que a instância nacional edite as suas, e que a Conep continue a atuar como instância recursal até a posse dos membros da instância nacional. Durante esse período de transição, o pesquisador deve acompanhar as orientações do CEP ao qual submete seus projetos.

Para ensaios clínicos com medicamentos que visem ao registro sanitário, aplicam-se também as normas da **Agência Nacional de Vigilância Sanitária** (Anvisa), atualizadas pela RDC nº 945/2024, e as diretrizes internacionais de **Boas Práticas Clínicas** do ICH (*International Council for Harmonisation*), cuja versão E6(R3) foi finalizada em janeiro de 2025.

10.1.3 O que precisa passar pelo comitê de ética

Toda pesquisa que envolva seres humanos, direta ou indiretamente, incluindo o uso de seus dados ou de seu material biológico, deve ser aprovada por um CEP **antes** de seu início. Isso inclui estudos que parecem inofensivos, como questionários anônimos, entrevistas e análises de prontuários. A avaliação ética não pode ser obtida retroativamente: dados coletados sem aprovação prévia não podem, em geral, ser publicados. As resoluções preveem situações específicas que dispensam a avaliação, como pesquisas com dados de acesso público irrestrito e sem identificação dos indivíduos (por exemplo, dados agregados publicados pelo DATASUS ou pelo IBGE); em caso de dúvida, a consulta ao CEP é o caminho seguro.

O CEP avalia, entre outros aspectos: a relevância e a validade científica do projeto (um estudo mal desenhado expõe os participantes a riscos sem a perspectiva

de produzir conhecimento útil, e é, por isso, antiético); a relação entre riscos e benefícios; a seleção dos participantes; o processo de consentimento; a proteção da privacidade e da confidencialidade; e a qualificação da equipe.

10.1.4 O consentimento livre e esclarecido

O **consentimento livre e esclarecido** é a manifestação da vontade do participante de tomar parte na pesquisa, depois de ter recebido e compreendido as informações necessárias. É um **processo**, e não apenas um documento: começa no convite, envolve a explicação, o tempo para reflexão e para perguntas, e continua durante todo o estudo, com o direito de retirar o consentimento a qualquer momento, sem prejuízo.

O **Termo de Consentimento Livre e Esclarecido** (TCLE) registra esse processo. Deve ser escrito em linguagem acessível ao participante (e não em jargão técnico ou jurídico) e conter, entre outros elementos:

- a justificativa, os objetivos e os procedimentos do estudo, inclusive sua duração;
- os riscos e desconfortos possíveis e as medidas para minimizá-los;
- os benefícios esperados, sem exagerá-los;
- as alternativas de tratamento disponíveis, quando for o caso;
- a garantia de liberdade de recusar ou de retirar o consentimento sem penalidade;
- a garantia de sigilo e privacidade;
- as formas de ressarcimento de despesas e de indenização por eventuais danos;
- os contatos do pesquisador e do CEP.

O TCLE não pode conter cláusulas que sugiram renúncia a direitos ou isenção de responsabilidade do pesquisador.

Pessoas com autonomia reduzida. Crianças, adolescentes e adultos com capacidade de decisão comprometida participam de pesquisas mediante consentimento de seus representantes legais e, sempre que possível, com seu próprio **assentimento**, obtido em linguagem adequada à sua compreensão. Outras situações de **vulnerabilidade** (pessoas privadas de liberdade, em relação de subordinação com o pesquisador, como alunos e funcionários, ou em situação de pobreza extrema) exigem cuidados adicionais para que a participação seja verdadeiramente livre.

Dispensa do TCLE. Em estudos retrospectivos com dados de prontuários ou de bases administrativas, obter o consentimento de cada participante pode ser impossível (pacientes que morreram ou que não podem ser localizados) ou introduzir viés de seleção grave. Nessas situações, o CEP pode autorizar a dispensa do TCLE, mediante justificativa, desde que sejam garantidas a confidencialidade e a proteção dos dados.

10.1.5 Proteção de dados pessoais

A **Lei Geral de Proteção de Dados Pessoais** (LGPD, Lei nº 13.709/2018) se aplica também à pesquisa. Dados de saúde, genéticos e biométricos são classificados como **dados pessoais sensíveis**. A lei permite o tratamento desses dados para a realização de estudos por órgão de pesquisa, garantida, sempre que possível, a **anonimização**. Na prática, isso significa:

- coletar apenas os dados necessários aos objetivos do estudo (princípio da minimização);
- separar os dados identificadores (nome, CPF, endereço) dos dados de pesquisa, ligando-os por um código cuja chave fica guardada em local seguro, com acesso restrito;
- armazenar os dados em ambientes protegidos, e não em computadores pessoais sem criptografia ou em serviços de armazenamento sem garantias;
- antes de compartilhar dados, avaliar o risco de **reidentificação**: a combinação de variáveis aparentemente inofensivas (data de nascimento, sexo, bairro, data de internação) pode identificar uma pessoa, sobretudo em populações pequenas ou com condições raras.

10.1.6 Pesquisa com animais

A pesquisa com animais no Brasil é regulada pela **Lei nº 11.794/2008**, conhecida como Lei Arouca, que criou o **Conselho Nacional de Controle de Experimentação Animal** (Concea) e determinou que toda instituição que realize pesquisa ou ensino com animais tenha uma **Comissão de Ética no Uso de Animais** (Ceua). Nenhum projeto com animais pode começar sem aprovação da Ceua.

O princípio orientador é o dos **3Rs**, proposto por Russell e Burch (1959):

- **substituição** (*replacement*): usar métodos alternativos que dispensem animais, sempre que possível (cultivos celulares, organoides, modelos computacionais);
- **redução** (*reduction*): usar o menor número de animais compatível com uma resposta confiável, o que exige cálculo de tamanho amostral e bom desenho experimental. Note que reduzir o número de animais a ponto de o experimento não ter poder para responder à pergunta não é ético: os animais terão sido usados em vão;
- **refinamento** (*refinement*): minimizar a dor, o sofrimento e o estresse, com analgesia, anestesia, manejo adequado, enriquecimento ambiental e critérios de desfecho humanitário.

Os princípios de desenho experimental do capítulo *Desenhos de pesquisa* (unidade experimental, randomização, cegamento, controles adequados) são

também exigências éticas: um experimento mal desenhado desperdiça vidas animais.

10.2 Plágio e integridade acadêmica

10.2.1 Má conduta científica

A definição mais aceita de **má conduta científica** abrange três práticas, resumidas pela sigla FFP:

- **fabricação**: inventar dados ou resultados e registrá-los ou relatá-los;
- **falsificação**: manipular materiais, equipamentos, processos, dados ou resultados, ou omitir dados, de modo que a pesquisa não seja representada com exatidão. Inclui a manipulação inadequada de imagens (por exemplo, duplicar ou recortar bandas de *western blot* de forma a alterar o resultado);
- **plágio**: apropriar-se de ideias, processos, resultados ou textos de outra pessoa sem o devido crédito.

Em uma metanálise de inquéritos com pesquisadores, cerca de 2% admitiram ter fabricado ou falsificado dados ao menos uma vez, e a proporção que relatou ter conhecimento dessas práticas por parte de colegas foi bem maior (Fanelli 2009). A manipulação inadequada de imagens foi identificada em cerca de 4% de mais de 20 mil artigos biomédicos examinados em um estudo sistemático (Bik et al. 2016). Mais recentemente, as **fábricas de artigos** (*paper mills*), empresas que vendem manuscritos fraudulentos e autorias, tornaram-se um problema importante para os periódicos.

10.2.2 Plágio e suas formas

O plágio não se limita à cópia literal de um texto. Inclui:

- copiar trechos sem aspas e sem citação, mesmo que a fonte seja mencionada em outro lugar;
- parafrasear de perto um texto, trocando palavras mas mantendo a estrutura, sem citação;
- apresentar como próprias ideias, hipóteses ou dados de outros, inclusive de pareceres confidenciais ou de conversas;
- traduzir um texto de outra língua sem citação.

A **publicação duplicada** (publicar os mesmos resultados em mais de um artigo sem informar os editores e leitores) e o **fatiamento** (*salami slicing*: dividir os resultados de um mesmo estudo em vários artigos para aumentar o número de

publicações) distorcem a literatura: em uma metanálise, o mesmo grupo de pacientes pode ser contado duas vezes. O **reaproveitamento de texto** dos próprios trabalhos anteriores (às vezes chamado de autoplágio) é aceitável em alguns contextos, como a descrição de métodos padronizados, desde que a fonte seja citada; não é aceitável na apresentação de resultados ou na discussão.

Para evitar o plágio: cite a fonte de toda ideia, dado ou texto que não seja seu; use aspas para citações literais; ao fazer anotações de leitura, registre sempre a referência e distinga o que é citação literal do que é sua síntese; e escreva a partir da compreensão do conteúdo, e não a partir do texto original aberto ao lado.

10.2.3 Práticas questionáveis de pesquisa

Entre a conduta íntegra e a má conduta explícita, há um conjunto de **práticas questionáveis de pesquisa**, muito mais frequentes que a fraude e, em conjunto, provavelmente mais danosas à confiabilidade da literatura (John et al. 2012):

- relatar seletivamente os desfechos, as análises ou os estudos que deram resultados "positivos";
- coletar mais dados depois de ver que o resultado não foi estatisticamente significativo, e parar quando ele se torna significativo;
- testar várias especificações de modelo, transformações, critérios de exclusão de observações ou de *outliers* e relatar apenas a que produz o resultado desejado (*p-hacking*);
- apresentar hipóteses formuladas depois de conhecer os resultados como se fossem prévias (HARKing, capítulo *Formulação de problemas e hipóteses*);
- arredondar valores p para baixo (relatar $p = 0{,}054$ como "$p < 0{,}05$");
- omitir limitações relevantes ou descrever os métodos de forma incompleta.

O que torna essas práticas danosas é que cada uma, isoladamente, pode parecer uma decisão analítica razoável. Seu efeito cumulativo, porém, é inflar a taxa de falsos positivos muito além do nível nominal de 5%. As defesas são as discutidas ao longo do livro: plano de análise definido antes do acesso aos dados, registro prévio, relato completo de todos os desfechos e análises realizadas, compartilhamento de dados e código, e distinção explícita entre análises confirmatórias e exploratórias.

10.2.4 Autoria, conflitos de interesse e uso de ferramentas

Os critérios de autoria foram apresentados no capítulo *Comunicação científica*. **Conflitos de interesse** existem quando interesses secundários (financeiros, profissionais, pessoais, institucionais) podem influenciar, ou parecer influenciar,

o julgamento sobre o interesse primário, que é a validade da pesquisa. Ter conflitos de interesse não é, em si, má conduta; omiti-los é. Devem ser declarados aos comitês de ética, aos periódicos e aos leitores.

O uso de ferramentas de **inteligência artificial generativa** na pesquisa e na redação levanta questões novas. As orientações de editores e de organizações como o ICMJE e o COPE convergem em alguns pontos: essas ferramentas não podem ser autoras, porque não podem assumir responsabilidade pelo trabalho; seu uso deve ser declarado; e os autores são integralmente responsáveis pela exatidão do conteúdo, inclusive por referências inexistentes ou afirmações incorretas que a ferramenta possa ter produzido. Revisores não devem carregar manuscritos confidenciais em serviços externos.

10.2.5 Correção da literatura

Quando um erro grave ou uma má conduta é identificado em um artigo publicado, a literatura deve ser corrigida. Erros honestos que não invalidam as conclusões levam a uma **errata**; erros que as invalidam, ou má conduta, levam à **retratação**. Um artigo retratado continua acessível, marcado como tal, para que se saiba o que aconteceu. Corrigir os próprios erros é uma demonstração de integridade, e não um motivo de vergonha. O **COPE** (*Committee on Publication Ethics*) publica orientações seguidas pela maioria dos editores para lidar com suspeitas de má conduta.

No Brasil, as principais agências de fomento publicaram diretrizes de integridade, como as do CNPq e o Código de Boas Práticas Científicas da FAPESP, e muitas universidades têm comissões de integridade em pesquisa que recebem e apuram denúncias.

10.3 Regulamentações e normas em pesquisa

Além das normas de ética com seres humanos e animais, outras regulamentações podem se aplicar, conforme o tipo de pesquisa.

- **Ensaios clínicos.** Além da aprovação ética, ensaios clínicos com medicamentos e produtos para a saúde que visem ao registro sanitário estão sujeitos à anuência da Anvisa e devem ser **registrados** em uma plataforma pública antes do início do recrutamento, como o **ReBEC** (Registro Brasileiro de Ensaios Clínicos) ou outro registro primário reconhecido pela Organização Mundial da Saúde. A Lei nº 14.874/2024 também exige o registro de ensaios clínicos em bases públicas.
- **Patrimônio genético e conhecimento tradicional associado.** Pesquisas que acessem o patrimônio genético brasileiro (por exemplo, sequenciar o genoma de uma planta ou de um microrganismo nativo, ou

estudar compostos extraídos deles) ou o conhecimento tradicional associado de povos indígenas e comunidades tradicionais estão sujeitas à **Lei nº 13.123/2015** e devem ser cadastradas no **SisGen** antes da publicação dos resultados ou do envio de amostras ao exterior. A exigência alcança muitos projetos de ecologia, microbiologia e farmacologia de produtos naturais.

- **Biossegurança.** Pesquisas com organismos geneticamente modificados estão sujeitas à **Lei nº 11.105/2005** e às normas da **Comissão Técnica Nacional de Biossegurança** (CTNBio), e a instituição deve ter uma **Comissão Interna de Biossegurança**. Laboratórios que manipulam agentes biológicos devem seguir as normas de níveis de biossegurança.
- **Coleta de material biológico da biodiversidade.** Coletas de material zoológico e botânico para fins científicos, especialmente em unidades de conservação, exigem autorização, obtida pelo sistema **SISBIO**.
- **Dados pessoais.** A LGPD, discutida acima, aplica-se a qualquer pesquisa que trate dados pessoais.

Essas exigências não são burocracia sem sentido: protegem participantes, comunidades, a biodiversidade e a própria credibilidade da pesquisa. Devem ser consideradas desde o planejamento, porque podem levar meses para ser cumpridas.

10.4 Responsabilidade social do cientista

10.4.1 Os valores da ciência

O sociólogo Robert Merton (1973) descreveu um conjunto de normas que caracterizariam o *ethos* da ciência, conhecidas pela sigla CUDOS:

- **comunalismo**: o conhecimento científico é um bem comum, e os resultados devem ser compartilhados;
- **universalismo**: as afirmações são avaliadas por critérios impessoais, independentemente de quem as faz (nacionalidade, gênero, posição);
- **desinteresse**: a pesquisa deve servir ao avanço do conhecimento, e não a interesses pessoais do pesquisador;
- **ceticismo organizado**: toda afirmação deve ser submetida ao escrutínio crítico da comunidade antes de ser aceita.

Essas normas descrevem um ideal, e não a prática real, que é afetada por competição, incentivos de carreira e interesses comerciais. Mas oferecem um ponto de referência útil para avaliar a própria conduta e as instituições científicas.

10.4.2 Ciência aberta

A **ciência aberta** é um conjunto de práticas que busca tornar a pesquisa mais transparente, acessível e reprodutível: acesso aberto às publicações, compartilhamento de dados e código, protocolos e registros prévios públicos, revisão por pares aberta e participação da sociedade na pesquisa. A Recomendação da UNESCO sobre Ciência Aberta, de 2021, adotada pelos Estados-membros, incluindo o Brasil, propõe um marco comum para essas práticas. Para dados, os princípios **FAIR** orientam que eles sejam **localizáveis** (*findable*), **acessíveis**, **interoperáveis** e **reutilizáveis**. Compartilhar dados de saúde exige conciliar a abertura com a proteção da privacidade dos participantes, por exemplo por meio da anonimização ou do acesso controlado.

10.4.3 Comunicação com a sociedade

A pesquisa em saúde é financiada, em grande parte, com recursos públicos, e seus resultados afetam decisões de pacientes, profissionais e gestores. Comunicar a ciência ao público, e não apenas aos pares, faz parte da responsabilidade do pesquisador. Isso inclui comunicar a **incerteza** de forma honesta (um único estudo raramente resolve uma questão), evitar o exagero nos comunicados à imprensa, que frequentemente transformam associações em causalidade e resultados em animais em promessas para humanos, e participar do combate à desinformação.

10.4.4 Pesquisa, equidade e uso do conhecimento

A responsabilidade social também se manifesta nas escolhas sobre **o que** pesquisar e **com quem**. As doenças que afetam principalmente populações pobres recebem, proporcionalmente, pouco investimento em pesquisa. Grupos historicamente sub-representados em estudos clínicos (mulheres, idosos, populações não brancas, pessoas com múltiplas doenças) ficam sem evidência sobre a eficácia e a segurança dos tratamentos que recebem. Pesquisas em comunidades indígenas, quilombolas ou de baixa renda devem envolver essas comunidades no planejamento e garantir que elas se beneficiem dos resultados, e não apenas sirvam como fonte de dados.

Por fim, o conhecimento produzido pode ser usado para fins diferentes dos pretendidos. Pesquisas de **uso dual**, que podem ser empregadas tanto para benefício quanto para dano (por exemplo, estudos que aumentam a transmissibilidade de patógenos), exigem avaliação cuidadosa de riscos e, às vezes, restrições à divulgação de detalhes técnicos. O cientista não controla todos os usos de seu trabalho, mas não está isento de refletir sobre eles.

10.5 Resumo do capítulo

- As normas de ética em pesquisa nasceram de abusos (Nuremberg, Tuskegee) e se apoiam em três princípios: respeito às pessoas, beneficência e justiça.
- No Brasil, a pesquisa com seres humanos é regida pela Lei nº 14.874/2024, regulamentada pelo Decreto nº 12.651/2025, e pelas resoluções do CNS (em especial a 466/2012 e a 510/2016) enquanto vigorarem. Toda pesquisa envolvendo seres humanos, seus dados ou seu material biológico deve ser aprovada por um CEP antes de começar.
- O consentimento é um processo contínuo; o TCLE deve ser compreensível e não pode sugerir renúncia a direitos. Pessoas com autonomia reduzida exigem proteção adicional e, quando possível, assentimento.
- A LGPD classifica dados de saúde como sensíveis; minimize, separe identificadores, proteja e avalie o risco de reidentificação.
- A pesquisa com animais exige aprovação da Ceua e segue os 3Rs; um experimento mal desenhado é também antiético.
- Má conduta inclui fabricação, falsificação e plágio. Práticas questionáveis (relato seletivo, *p-hacking*, HARKing) são mais frequentes e também comprometem a literatura.
- Outras normas podem se aplicar: registro de ensaios clínicos, Lei da Biodiversidade (SisGen), biossegurança, autorizações de coleta.
- A responsabilidade social do cientista inclui práticas de ciência aberta, comunicação honesta da incerteza, atenção à equidade e reflexão sobre os usos do conhecimento.

10.6 Exercícios

1. Um pesquisador quer analisar dados de prontuários de 2.000 pacientes atendidos nos últimos dez anos em seu hospital. Precisa de aprovação do CEP? Precisa obter o TCLE de cada paciente? Justifique.

2. Identifique os problemas éticos no seguinte cenário: um professor convida seus alunos de graduação a participar de uma pesquisa sobre hábitos de sono, durante a aula, e informa que a participação valerá um ponto extra na prova.

3. Um grupo planeja um experimento com 4 camundongos por grupo, argumentando que assim reduz o número de animais, em respeito aos 3Rs. O cálculo de tamanho amostral indicou que seriam necessários 12 por grupo para detectar o efeito de interesse. Discuta.

4. Um pesquisador analisou seus dados com e sem a exclusão de três pacientes com valores extremos. Sem a exclusão, $p = 0{,}09$; com a exclusão, $p =$

0,03. Ele relatou apenas a segunda análise, sem mencionar a primeira. Classifique a conduta e indique como ele deveria ter procedido.

5. Um estudo de etnobotânica pretende identificar plantas usadas por uma comunidade tradicional para tratar feridas e testar a atividade antimicrobiana de seus extratos. Que normas, além da aprovação ética, se aplicam?

10.7 Respostas dos exercícios

1. Sim, precisa de aprovação do CEP antes de iniciar: o uso de dados de pacientes é pesquisa envolvendo seres humanos, ainda que indiretamente. A obtenção do TCLE de cada paciente pode ser inviável (pacientes falecidos, sem contato atualizado) e introduzir viés de seleção; o pesquisador pode solicitar ao CEP a dispensa do TCLE, justificando a inviabilidade e descrevendo as medidas de proteção da confidencialidade (por exemplo, extração dos dados com codificação, sem nomes, com acesso restrito à chave de identificação). A decisão sobre a dispensa é do CEP.

2. Há relação de subordinação entre professor e alunos, o que compromete a liberdade da decisão: os alunos podem se sentir pressionados a participar. O convite em sala, na presença do professor, agrava a pressão. O ponto extra é um incentivo indevido, que também prejudica os alunos que optarem por não participar. Uma alternativa seria o convite feito por outro pesquisador, sem o professor presente, com participação anônima e sem qualquer vínculo com a avaliação da disciplina.

3. A redução prevista nos 3Rs não significa usar o menor número absoluto de animais, mas o menor número **suficiente para uma resposta confiável**. Com 4 animais por grupo, o experimento terá poder muito baixo; provavelmente não detectará o efeito, se existir, e, se detectar, tenderá a superestimá-lo. Os animais terão sido usados sem produzir conhecimento confiável, o que é eticamente pior do que usar 12 por grupo. Alternativas legítimas para reduzir o número são melhorar o desenho (blocos, medidas repetidas, desfechos mais precisos).

4. É uma prática questionável de pesquisa (relato seletivo de análises, uma forma de *p-hacking*), que pode chegar à falsificação se a omissão for deliberada para alterar a conclusão. O critério de exclusão de valores extremos deveria ter sido definido antes da análise, no plano de análise; se não foi, as duas análises deveriam ser relatadas, com a justificativa para a exclusão, e a análise com todos os dados deveria ser apresentada como principal ou, no mínimo, como análise de sensibilidade.

5. Aprovação do CEP, por envolver seres humanos (entrevistas com membros da comunidade), considerando a vulnerabilidade e a necessidade de consentimento adequado ao contexto cultural, inclusive coletivo; cadastro no SisGen, pela Lei nº 13.123/2015, por envolver acesso ao patrimônio genético

e ao conhecimento tradicional associado, com consentimento prévio informado da comunidade e regras de repartição de benefícios; e, se a coleta ocorrer em unidade de conservação, autorização pelo SISBIO.

Capítulo 11

Aplicações práticas e estudos de caso

Hércules Rezende Freitas, Ph.D.[1]

[1]Universidade do Estado do Rio de Janeiro (UERJ), Faculdade de Ciências Médicas, Departamento de Ciências Médicas Integradas, Laboratório de Informática em Saúde (LabInfoS), Cabo Frio/RJ, Brasil.

Este capítulo aplica os métodos dos capítulos anteriores a problemas típicos de quatro áreas: epidemiologia e saúde pública, genética e biologia molecular, ecologia e conservação, e farmacologia e ensaios clínicos. Cada seção apresenta os métodos mais característicos da área, com exemplos resolvidos e código em R, e destaca os erros mais frequentes. Os dados são fictícios ou simulados, construídos para ilustrar os cálculos.

11.1 Epidemiologia e saúde pública

11.1.1 Intervalos de confiança para medidas de associação

O capítulo *Desenhos de pesquisa* apresentou o risco relativo (RR), a razão de chances (OR), a diferença de riscos (DR) e o número necessário para tratar ou para causar dano (NNT/NNH). Como qualquer estimativa, essas medidas precisam de intervalos de confiança. Retomamos o exemplo da coorte daquele capítulo: 80 casos entre 2.000 fumantes e 30 casos entre 3.000 não fumantes, em cinco anos. Na notação da tabela 2×2, $a = 80$, $b = 1.920$, $c = 30$ e $d = 2.970$.

Risco relativo. A distribuição amostral do RR é assimétrica (ele não pode ser negativo e pode crescer sem limite), mas a do seu **logaritmo** é aproximadamente normal. Por isso, o intervalo é calculado na escala logarítmica e depois transformado de volta (Katz et al. 1978):

$$\mathrm{EP}[\ln(\mathrm{RR})] = \sqrt{\frac{1}{a} - \frac{1}{a+b} + \frac{1}{c} - \frac{1}{c+d}},$$
$$\mathrm{IC}_{95\%} = \exp\left[\ln(\mathrm{RR}) \pm 1{,}96 \times \mathrm{EP}\right].$$

No exemplo, $\ln(4) = 1{,}386$ e $\mathrm{EP} = \sqrt{1/80 - 1/2.000 + 1/30 - 1/3.000} \approx 0{,}212$. O intervalo é $\exp(1{,}386 \pm 0{,}416)$, de 2,64 a 6,06. Note que o intervalo não é simétrico em torno de 4: a assimetria na escala original é consequência da simetria na escala logarítmica.

Razão de chances. O método de Woolf (Woolf 1955) segue a mesma lógica:

$$\mathrm{EP}[\ln(\mathrm{OR})] = \sqrt{\frac{1}{a} + \frac{1}{b} + \frac{1}{c} + \frac{1}{d}}.$$

No exemplo, $\mathrm{OR} = 4{,}125$, $\mathrm{EP} \approx 0{,}216$ e o IC de 95% vai de 2,70 a 6,30.

Diferença de riscos. O intervalo mais simples (de Wald) é $\mathrm{DR} \pm 1{,}96\sqrt{p_1(1-p_1)/n_1 + p_0(1-p_0)/n_0}$, mas, assim como o intervalo de Wald para uma proporção (capítulo *Bioestatística inferencial*), tem cobertura ruim quando os riscos são pequenos ou as amostras são pequenas. O método de Newcombe (Newcombe 1998) combina os intervalos de Wilson de cada proporção e tem desempenho muito melhor. Sendo (l_1, u_1) e (l_0, u_0) os intervalos de Wilson de p_1 e p_0:

$$\text{limite inferior} = \mathrm{DR} - \sqrt{(p_1 - l_1)^2 + (u_0 - p_0)^2},$$
$$\text{limite superior} = \mathrm{DR} + \sqrt{(u_1 - p_1)^2 + (p_0 - l_0)^2}.$$

NNT e NNH. O intervalo de confiança do NNT (ou NNH) é obtido invertendo os limites do intervalo da diferença de riscos (Altman 1998). Quando o intervalo da DR inclui zero, o intervalo do NNT passa pelo infinito e deve ser apresentado com cuidado (por exemplo, "NNT para benefício de 10 a ∞ e NNT para dano de 50 a ∞").

O código a seguir implementa os quatro cálculos:

```
medidas_2x2 <- function(a, b, c, d, nivel = 0.95) {
  z <- qnorm(1 - (1 - nivel) / 2)
  n1 <- a + b; n0 <- c + d; p1 <- a / n1; p0 <- c / n0
  rr <- p1 / p0; ep_rr <- sqrt(1/a - 1/n1 + 1/c - 1/n0)
  or <- (a * d) / (b * c); ep_or <- sqrt(1/a + 1/b + 1/c + 1/d)
  rd <- p1 - p0
  w1 <- prop.test(a, n1, correct = FALSE, conf.level = nivel)$conf.int
  w0 <- prop.test(c, n0, correct = FALSE, conf.level = nivel)$conf.int
  rd_ic <- c(rd - sqrt((p1 - w1[1])^2 + (w0[2] - p0)^2),
             rd + sqrt((w1[2] - p1)^2 + (p0 - w0[1])^2))
```

Tabela 11.1: Óbitos, população e taxas de mortalidade por 1.000 habitantes em dois municípios fictícios, por faixa etária.

Faixa	Óbitos A	População A	Taxa A (‰)	Óbitos B	População B	Taxa B (‰)	População padrão
0 a 39 anos	8	8000	1,0	3	3000	1,0	5000
40 a 64 anos	9	1500	6,0	15	3000	5,0	3000
65 anos ou mais	25	500	50,0	160	4000	40,0	2000
Total	42	10000	4,2	178	10000	17,8	10000

```
  data.frame(
    medida = c("Risco relativo", "Razão de chances", "Diferença de
     ↪  riscos", "NNT/NNH"),
    estimativa = c(rr, or, rd, 1 / rd),
    inferior = c(exp(log(rr) - z * ep_rr), exp(log(or) - z * ep_or),
     ↪  rd_ic[1], 1 / rd_ic[2]),
    superior = c(exp(log(rr) + z * ep_rr), exp(log(or) + z * ep_or),
     ↪  rd_ic[2], 1 / rd_ic[1])
  )
}
res_coorte <- medidas_2x2(a = 80, b = 1920, c = 30, d = 2970)
res_coorte$estimativa <- round(res_coorte$estimativa, 4)
res_coorte$inferior <- round(res_coorte$inferior, 4)
res_coorte$superior <- round(res_coorte$superior, 4)
res_coorte
```

```
##                medida estimativa inferior superior
## 1      Risco relativo     4.0000   2.6393   6.0622
## 2    Razão de chances     4.1250   2.7008   6.3002
## 3 Diferença de riscos     0.0300   0.0212   0.0400
## 4             NNT/NNH    33.3333  25.0219  47.2320
```

O resultado pode ser relatado assim: "o risco de doença em cinco anos foi de 4,0% nos fumantes e de 1,0% nos não fumantes (RR = 4,0; IC 95%: 2,6 a 6,1; diferença de riscos de 3,0 pontos percentuais; IC 95%: 2,1 a 4,0; NNH = 33; IC 95%: 25 a 47)". Pacotes como `epitools` e `epiR` oferecem essas e outras medidas, mas convém saber exatamente o que calculam.

11.1.2 Padronização de taxas

Comparar taxas brutas de mortalidade entre populações com estruturas etárias diferentes pode ser enganoso, porque a mortalidade depende fortemente da idade. A Tabela 11.1 mostra dois municípios fictícios.

A taxa bruta de B (17,8 por 1.000) é mais de quatro vezes a de A (4,2 por 1.000). Mas, em cada faixa etária, a mortalidade de A é igual ou maior que a de

B. A diferença bruta se deve inteiramente à estrutura etária: 40% da população de B tem 65 anos ou mais, contra 5% em A. A idade é um fator de confusão na comparação, exatamente como no exemplo do café e do tabagismo do capítulo *Desenhos de pesquisa*.

A **padronização direta** responde à pergunta: qual seria a taxa de cada município se ambos tivessem a mesma estrutura etária? Aplicam-se as taxas específicas de cada município a uma **população padrão** comum e calcula-se a taxa resultante:

$$\text{taxa padronizada} = \frac{\sum_k t_k P_k}{\sum_k P_k},$$

em que t_k é a taxa na faixa k e P_k é a população padrão nessa faixa.

```
taxa_padronizada <- function(obitos, pop, pop_padrao) {
  sum((obitos / pop) * pop_padrao) / sum(pop_padrao) * 1000
}
c(A = taxa_padronizada(obA, popA, padrao), B = taxa_padronizada(obB,
 ↪  popB, padrao))
```

```
##    A    B
## 12.3 10.0
```

Com a mesma estrutura etária, a taxa de A (12,3 por 1.000) é maior que a de B (10,0 por 1.000): a conclusão se inverte. Os valores absolutos das taxas padronizadas dependem da população padrão escolhida (frequentemente a população brasileira de um censo, ou a população padrão mundial da Organização Mundial da Saúde) e só servem para comparação; não devem ser interpretados como a mortalidade "real" de cada município. Quando as taxas específicas por idade de uma população são instáveis (populações pequenas), usa-se a **padronização indireta**, que aplica taxas de referência à estrutura etária da população estudada e produz a **razão de mortalidade padronizada** (óbitos observados / óbitos esperados).

11.1.3 Acurácia de testes diagnósticos

No capítulo *Bioestatística inferencial*, vimos como sensibilidade, especificidade e prevalência determinam os valores preditivos. Em um estudo de acurácia, um teste é aplicado a 1.000 pessoas que também passam pelo padrão de referência: 100 têm a doença, das quais 90 testam positivo; 900 não a têm, das quais 855 testam negativo.

```
vp <- 90; fn <- 10; fp <- 45; vn <- 855
sens <- vp / (vp + fn); espec <- vn / (vn + fp)
c(sensibilidade = sens, especificidade = espec,
  RV_positiva = sens / (1 - espec), RV_negativa = (1 - sens) / espec)
```

```
##  sensibilidade especificidade    RV_positiva    RV_negativa
##      0.9000000      0.9500000     18.0000000      0.1052632
```

```
prop.test(vp, vp + fn, correct = FALSE)$conf.int    # IC de Wilson para a
 ↪  sensibilidade
```

```
## [1] 0.8256343 0.9447709
## attr(,"conf.level")
## [1] 0.95
```

```
prop.test(vn, vn + fp, correct = FALSE)$conf.int    # IC de Wilson para a
 ↪  especificidade
```

```
## [1] 0.9337508 0.9624241
## attr(,"conf.level")
## [1] 0.95
```

A sensibilidade é de 90% (IC 95%: 82,6% a 94,5%) e a especificidade, de 95% (93,4% a 96,2%). Note que a sensibilidade, estimada com apenas 100 doentes, é muito menos precisa que a especificidade, estimada com 900. Estudos de acurácia precisam planejar o tamanho amostral considerando o número de doentes e o de não doentes, e não apenas o total.

As **razões de verossimilhança** (RV) combinam sensibilidade e especificidade em uma medida que não depende da prevalência. A RV positiva ($\text{sens}/(1-\text{espec}) = 18$) indica quantas vezes um resultado positivo é mais provável em um doente do que em um não doente. Na forma de chances do teorema de Bayes, a chance de doença após o teste é a chance antes do teste multiplicada pela RV: um teste positivo multiplica por 18 a chance de doença. RVs positivas acima de 10 e negativas abaixo de 0,1 costumam indicar testes que alteram substancialmente a probabilidade de doença. A diretriz STARD orienta o relato desses estudos.

11.1.4 Dados secundários em saúde pública

Grande parte da pesquisa em saúde pública no Brasil usa dados secundários dos sistemas de informação do SUS: o Sistema de Informações sobre Mortalidade (SIM), o de Nascidos Vivos (SINASC), o de Internações Hospitalares (SIH), o Ambulatorial (SIA) e o de Agravos de Notificação (SINAN), disponibilizados

pelo DATASUS. No R, o pacote `microdatasus` (Saldanha et al. 2019) automatiza o download e o pré-processamento desses microdados.

Esses dados oferecem cobertura nacional e amostras enormes, mas foram produzidos para fins administrativos e de faturamento, e não para pesquisa. Antes de analisá-los, é preciso considerar: a completude e a qualidade de cada variável (que variam entre regiões e ao longo do tempo); a ausência de identificadores que permitam seguir o mesmo indivíduo entre registros (uma internação não é um paciente); mudanças de códigos, tabelas e regras de preenchimento; e o fato de os sistemas registrarem apenas quem teve acesso ao serviço. Uma amostra muito grande reduz o erro aleatório, mas não reduz nenhum desses vieses (veja a discussão sobre *big data* no capítulo *Tópicos avançados em bioestatística*).

11.2 Genética e biologia molecular

11.2.1 Equilíbrio de Hardy–Weinberg

Em uma população grande, com acasalamento aleatório e sem seleção, mutação ou migração, as frequências genotípicas de um locus com dois alelos (A, com frequência p, e a, com frequência $q = 1 - p$) permanecem estáveis em p^2 (AA), $2pq$ (Aa) e q^2 (aa). Esse é o **equilíbrio de Hardy–Weinberg** (Hardy 1908). Em estudos genéticos de associação, desvios do equilíbrio entre os controles frequentemente indicam erros de genotipagem, e são usados como controle de qualidade.

Exemplo. Em 1.000 indivíduos, observaram-se 380 AA, 440 Aa e 180 aa. A frequência do alelo A é $p = (2 \times 380 + 440)/2.000 = 0{,}60$. As frequências esperadas sob o equilíbrio são $1.000 \times 0{,}36 = 360$, $1.000 \times 0{,}48 = 480$ e $1.000 \times 0{,}16 = 160$. O teste qui-quadrado compara observados e esperados:

$$X^2 = \frac{(380-360)^2}{360} + \frac{(440-480)^2}{480} + \frac{(180-160)^2}{160} = 1{,}11 + 3{,}33 + 2{,}50 = 6{,}94.$$

Os graus de liberdade são $3 - 1 - 1 = 1$: três classes, menos um pela restrição de que o total é fixo, menos um pelo parâmetro p estimado a partir dos próprios dados. O valor p é de cerca de 0,008, e há deficiência de heterozigotos em relação ao esperado.

```
obs <- c(AA = 380, Aa = 440, aa = 180)
p_A <- (2 * obs["AA"] + obs["Aa"]) / (2 * sum(obs))
esp <- sum(obs) * c(p_A^2, 2 * p_A * (1 - p_A), (1 - p_A)^2)
x2 <- sum((obs - esp)^2 / esp)
c(qui_quadrado = x2, p = pchisq(x2, df = 1, lower.tail = FALSE))
```

```
## qui_quadrado            p
##  6.944444444  0.008407995
```

Note que a função `chisq.test()` não deve ser usada diretamente aqui, porque ela não desconta o grau de liberdade do parâmetro estimado. Para alelos raros, em que algumas frequências esperadas são pequenas, recomenda-se um teste exato (Wigginton et al. 2005).

11.2.2 Comparações múltiplas em estudos genômicos

Estudos de expressão gênica, de associação genômica ampla ou de proteômica testam milhares de hipóteses ao mesmo tempo. Com 20.000 genes e $\alpha = 0{,}05$, cerca de 1.000 genes seriam "significativos" por acaso, mesmo que nenhum estivesse associado ao desfecho. Há duas estratégias principais de correção.

- **Controle da taxa de erro por família** (FWER): limita a probabilidade de **ao menos um** falso positivo. O método de Bonferroni compara cada valor p com α/m, sendo m o número de testes. É muito conservador quando m é grande. Nos estudos de associação genômica ampla, o limiar convencional de 5×10^{-8} corresponde a uma correção de Bonferroni para cerca de um milhão de testes independentes.
- **Controle da taxa de falsas descobertas** (FDR): limita a **proporção esperada** de falsos positivos entre os resultados declarados significativos. O procedimento de Benjamini e Hochberg (Benjamini and Hochberg 1995) ordena os m valores p do menor para o maior, $p_{(1)} \leq \cdots \leq p_{(m)}$, encontra o maior k tal que $p_{(k)} \leq \frac{k}{m} q$, em que q é a FDR desejada, e declara significativos os k menores valores p. Em estudos exploratórios de grande escala, em que se aceita que uma fração pequena das descobertas seja falsa em troca de mais poder, a FDR é o critério usual.

```r
p_valores <- c(0.0002, 0.0009, 0.004, 0.008, 0.012, 0.019, 0.031, 0.044,
 ↪  0.27, 0.62)
data.frame(p = p_valores,
           p_bonferroni = p.adjust(p_valores, method = "bonferroni"),
           p_BH = round(p.adjust(p_valores, method = "BH"), 4))
```

```
##         p p_bonferroni   p_BH
## 1  0.0002        0.002 0.0020
## 2  0.0009        0.009 0.0045
## 3  0.0040        0.040 0.0133
## 4  0.0080        0.080 0.0200
## 5  0.0120        0.120 0.0240
## 6  0.0190        0.190 0.0317
## 7  0.0310        0.310 0.0443
## 8  0.0440        0.440 0.0550
```

```
## 9  0.2700        1.000 0.3000
## 10 0.6200        1.000 0.6200
```

Dos dez testes, oito têm $p < 0{,}05$ sem correção; com Bonferroni, apenas três permanecem abaixo de 0,05; com Benjamini–Hochberg a uma FDR de 5%, sete. Os valores ajustados pelo método BH (às vezes chamados de valores q) podem ser comparados diretamente com a FDR desejada.

11.2.3 Quantificação relativa por PCR em tempo real

Na PCR quantitativa em tempo real (qPCR), o **ciclo de quantificação** (Ct ou Cq) é o ciclo em que a fluorescência ultrapassa um limiar; quanto maior a quantidade inicial do alvo, menor o Ct. Se a eficiência da amplificação for próxima de 100%, a quantidade de produto dobra a cada ciclo, e uma diferença de um ciclo corresponde a uma diferença de duas vezes na quantidade inicial. O **método** $2^{-\Delta\Delta C_t}$ (Livak and Schmittgen 2001) calcula a expressão relativa de um gene-alvo, normalizada por um gene de referência, entre uma condição tratada e uma controle:

1. $\Delta C_t = C_t^{\text{alvo}} - C_t^{\text{referência}}$, para cada amostra;
2. $\Delta\Delta C_t = \overline{\Delta C_t}_{\text{tratado}} - \overline{\Delta C_t}_{\text{controle}}$;
3. expressão relativa (*fold change*) $= 2^{-\Delta\Delta C_t}$.

```
ct_alvo_c <- c(24.1, 24.5, 23.9); ct_ref_c <- c(18.0, 18.3, 17.9)   #
 ↪  controles
ct_alvo_t <- c(22.6, 22.9, 22.2); ct_ref_t <- c(18.1, 18.2, 17.8)   #
 ↪  tratados
dct_c <- ct_alvo_c - ct_ref_c
dct_t <- ct_alvo_t - ct_ref_t
ddct <- mean(dct_t) - mean(dct_c)
teste_qpcr <- t.test(dct_t, dct_c)
c(ddCt = ddct, fold_change = 2^-ddct)
```

```
##        ddCt fold_change
##   -1.566667    2.962195
```

```
2^-rev(teste_qpcr$conf.int)   # IC 95% da expressão relativa
```

```
## [1] 2.385974 3.677576
```

```
teste_qpcr$p.value
```

```
## [1] 0.0003004469
```

O gene-alvo está cerca de 3,0 vezes mais expresso nas amostras tratadas (IC 95%: 2,4 a 3,7). A análise exige três cuidados:

1. **A análise estatística deve ser feita na escala dos ΔC_t**, que é logarítmica e aproximadamente normal, e não na escala do *fold change*. Os valores de expressão relativa são assimétricos (um aumento de duas vezes corresponde a 2, mas uma redução de duas vezes, a 0,5), e médias e testes nessa escala são enganosos. O intervalo é calculado nos ΔC_t e transformado depois, como no código.
2. **A unidade experimental** (capítulo *Desenhos de pesquisa*) é a amostra biológica independente (o animal, o paciente, a cultura independente), e não a réplica técnica (o mesmo cDNA pipetado em três poços). As réplicas técnicas devem ser promediadas antes da análise. Com apenas três réplicas biológicas por grupo, como no exemplo, as estimativas são imprecisas e o poder é baixo.
3. O método supõe eficiências de amplificação próximas de 100% e semelhantes para o alvo e a referência, o que deve ser verificado com curvas de diluição, e que o gene de referência não seja afetado pelo tratamento. As diretrizes MIQE detalham os itens que devem ser relatados.

11.3 Ecologia e conservação

11.3.1 Índices de diversidade

A diversidade de uma comunidade depende de dois componentes: a **riqueza** (o número de espécies) e a **equabilidade** (quão uniformemente os indivíduos se distribuem entre as espécies). Duas comunidades com a mesma riqueza podem ter diversidades muito diferentes. Sendo p_i a proporção de indivíduos da espécie i em uma comunidade com S espécies:

- **índice de Shannon** (Shannon 1948): $H' = -\sum_{i=1}^{S} p_i \ln p_i$. Vale zero quando há uma única espécie e atinge o máximo, $\ln S$, quando todas as espécies têm a mesma abundância;
- **índice de Gini–Simpson** (Simpson 1949): $1 - D = 1 - \sum_{i=1}^{S} p_i^2$, a probabilidade de dois indivíduos sorteados (com reposição) pertencerem a espécies diferentes.

Considere duas comunidades com quatro espécies e 100 indivíduos cada: na comunidade A, as abundâncias são 40, 30, 20 e 10; na B, 85, 5, 5 e 5.

```
shannon <- function(x) { p <- x / sum(x); -sum(p * log(p)) }
gini_simpson <- function(x) { p <- x / sum(x); 1 - sum(p^2) }
```

```r
comunidades <- list(A = c(40, 30, 20, 10), B = c(85, 5, 5, 5))
t(sapply(comunidades, function(x)
  c(riqueza = length(x), shannon = shannon(x), gini_simpson =
   ↪  gini_simpson(x),
    especies_efetivas = exp(shannon(x)))))
```

```
##   riqueza   shannon gini_simpson especies_efetivas
## A       4 1.2798542         0.70          3.596115
## B       4 0.5875009         0.27          1.799486
```

As duas comunidades têm a mesma riqueza, mas A é muito mais diversa ($H' = 1{,}28$ contra 0,59). Os valores dos índices não têm uma escala intuitiva. Uma forma de interpretá-los é convertê-los em **números efetivos de espécies** (os chamados números de Hill): $\exp(H')$ é o número de espécies igualmente abundantes que produziria o mesmo valor do índice. A comunidade A equivale a 3,6 espécies igualmente abundantes; a B, a apenas 1,8.

A riqueza observada, porém, depende do **esforço amostral**, porque quanto mais indivíduos se amostram, mais espécies raras aparecem. Comparar a riqueza de áreas amostradas com esforços diferentes é inválido. Usam-se curvas de acumulação de espécies, rarefação (comparar as áreas com o mesmo número de indivíduos) ou estimadores de riqueza total, disponíveis em pacotes como `vegan` e `iNEXT`.

11.3.2 Estimativa do tamanho populacional por captura e recaptura

Para estimar o tamanho N de uma população animal que não pode ser contada diretamente, captura-se e marca-se uma amostra de M indivíduos, que são soltos. Depois de um tempo suficiente para que se misturem à população, captura-se uma segunda amostra de C indivíduos, dos quais R estão marcados. Se a proporção de marcados na segunda amostra reflete a proporção na população, $R/C \approx M/N$, o que leva ao **estimador de Lincoln–Petersen**: $\hat{N} = MC/R$.

Esse estimador é enviesado para cima em amostras pequenas. A versão corrigida de Chapman é

$$\hat{N}_C = \frac{(M+1)(C+1)}{R+1} - 1, \qquad \widehat{\mathrm{Var}}(\hat{N}_C) = \frac{(M+1)(C+1)(M-R)(C-R)}{(R+1)^2(R+2)}.$$

Exemplo. Foram marcados 50 anfíbios; na segunda captura, 12 dos 60 indivíduos estavam marcados.

```
M <- 50; C_cap <- 60; R <- 12
N_lp <- M * C_cap / R
N_ch <- (M + 1) * (C_cap + 1) / (R + 1) - 1
var_ch <- (M + 1) * (C_cap + 1) * (M - R) * (C_cap - R) / ((R + 1)^2 * (R
 ↪  + 2))
c(Lincoln_Petersen = N_lp, Chapman = N_ch, EP = sqrt(var_ch),
  IC_inf = N_ch - 1.96 * sqrt(var_ch), IC_sup = N_ch + 1.96 *
   ↪  sqrt(var_ch))
```

```
## Lincoln_Petersen          Chapman               EP           IC_inf
##        250.00000        238.30769         48.97281        142.32098
##           IC_sup
##        334.29441
```

A estimativa de Chapman é de cerca de 238 indivíduos, com IC aproximado de 142 a 334. A amplitude do intervalo mostra que, com 12 recapturas, a estimativa é imprecisa. As suposições do método merecem tanta atenção quanto o cálculo: a população deve ser **fechada** entre as capturas (sem nascimentos, mortes ou migração), a marcação não pode afetar a sobrevivência nem a probabilidade de recaptura, as marcas não podem ser perdidas e todos os indivíduos devem ter a mesma probabilidade de captura. Animais que aprendem a evitar armadilhas, por exemplo, levam a superestimar N. Para populações abertas e estudos com várias ocasiões de captura, existem modelos mais gerais (Jolly–Seber, modelos de ocupação).

11.3.3 Contagens e superdispersão

Dados de ecologia são frequentemente **contagens**: número de indivíduos por parcela, de ninhos por transecto, de espécies por fragmento. Contagens são inteiras, não negativas e, em geral, assimétricas, e a distribuição de referência para elas é a de **Poisson**, em que a variância é igual à média. Na prática, contagens ecológicas costumam ter variância muito maior que a média (**superdispersão**), porque os organismos se agregam. Um índice simples é a razão variância/média: valores próximos de 1 são compatíveis com distribuição aleatória; valores muito maiores que 1 indicam agregação.

```
set.seed(21)
parcelas <- rnbinom(40, mu = 4, size = 1.2)   # contagens agregadas
 ↪  (binomial negativa)
c(media = mean(parcelas), variancia = var(parcelas), razao =
 ↪  var(parcelas) / mean(parcelas))
```

```
##     media variancia     razao
##  5.125000 19.086538  3.724203
```

Analisar contagens superdispersas como se fossem de Poisson subestima os erros padrão e produz valores p pequenos demais. Os modelos adequados (regressão de Poisson com correção, binomial negativa) são apresentados no capítulo *Tópicos avançados em bioestatística*. A pseudorreplicação (capítulo *Desenhos de pesquisa*) também é frequente em ecologia: várias parcelas dentro de um único fragmento de floresta não são réplicas independentes do efeito da fragmentação.

11.4 Farmacologia e ensaios clínicos

11.4.1 Curvas dose-resposta

A relação entre a concentração de um fármaco e sua resposta costuma ter forma sigmoide quando a concentração é representada em escala logarítmica. O modelo logístico de quatro parâmetros (relacionado à equação de Hill) descreve essa relação:

$$y = \text{mín} + \frac{\text{máx} - \text{mín}}{1 + 10^{(\log_{10} \text{EC}_{50} - \log_{10} x)\, h}},$$

em que mín e máx são as respostas nas concentrações muito baixas e muito altas, EC_{50} é a concentração que produz metade do efeito máximo (uma medida de **potência**) e h é o coeficiente de inclinação. Como o modelo não é linear nos parâmetros, ele é ajustado por **mínimos quadrados não lineares**, com a função `nls()`. Estimar o $\log_{10} \text{EC}_{50}$, e não a EC_{50} diretamente, melhora o comportamento numérico e torna o intervalo de confiança mais apropriado.

```
set.seed(42)
dose <- rep(10^seq(-2, 2, by = 0.5), each = 3)
resposta <- 100 / (1 + (2 / dose)^1.2) + rnorm(length(dose), 0, 5)
ajuste_dr <- nls(resposta ~ minimo + (maximo - minimo) / (1 +
 ↪  10^((logEC50 - log10(dose)) * h)),
                 start = list(minimo = 0, maximo = 100, logEC50 = 0, h =
                  ↪  1))
round(summary(ajuste_dr)$coefficients, 3)
```

```
##         Estimate Std. Error t value Pr(>|t|)
## minimo     3.044      2.342   1.300    0.206
## maximo   102.822      3.667  28.037    0.000
## logEC50    0.403      0.059   6.811    0.000
## h          1.059      0.141   7.489    0.000
```

```
ic_log <- confint.default(ajuste_dr)["logEC50", ]
ec50 <- 10^c(estimativa = unname(coef(ajuste_dr)["logEC50"]), ic_log)
ec50
```

```
## estimativa      2.5 %     97.5 %
##   2.529236   1.936553   3.303309
```

```
plot(dose, resposta, log = "x", pch = 19, col = "grey35",
     xlab = "Concentração (µM, escala logarítmica)", ylab = "Resposta (%
      ↪  do máximo)")
grade <- 10^seq(-2, 2, length.out = 200)
lines(grade, predict(ajuste_dr, newdata = data.frame(dose = grade)), lwd
 ↪  = 2)
abline(v = ec50[1], lty = 2)
```

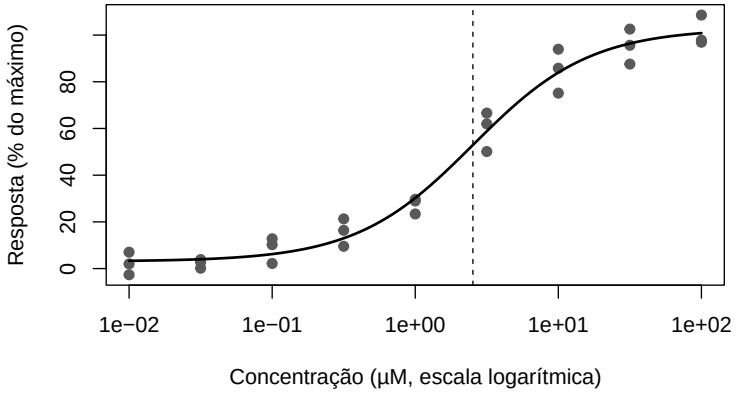


Figura 11.1: Curva dose-resposta ajustada pelo modelo logístico de quatro parâmetros (dados simulados, três réplicas por concentração). A linha vertical tracejada indica a EC50 estimada.

A EC_{50} estimada é de 2,53 µM (IC 95%: 1,94 a 3,30); os dados foram simulados com $EC_{50} = 2$ µM. O intervalo foi calculado na escala logarítmica e transformado, e por isso é assimétrico. As réplicas devem ser experimentos independentes (por exemplo, culturas preparadas em dias diferentes), e não poços da mesma placa, para que o intervalo reflita a variabilidade relevante.

11.4.2 Parâmetros farmacocinéticos

Após a administração oral de uma dose única, as concentrações plasmáticas de um fármaco foram medidas em sete tempos (Tabela 11.2).

A **concentração máxima** ($C_{\text{máx}}$) é de 80 ng/mL, atingida em $t_{\text{máx}} = 2$ h. A **área sob a curva** (ASC, ou AUC), que mede a exposição total ao fármaco, é

Tabela 11.2: Concentrações plasmáticas após dose oral única (dados fictícios).

Tempo (h)	Concentração (ng/mL)
0,5	42
1,0	68
2,0	80
4,0	61
6,0	44
8,0	31
12,0	16

calculada pela **regra dos trapézios**: entre dois tempos consecutivos, a área é aproximada por um trapézio,

$$\mathrm{ASC}_{t_i \to t_{i+1}} = \frac{(C_i + C_{i+1})}{2}\,(t_{i+1} - t_i).$$

Somando todos os trapézios (e o triângulo inicial, supondo concentração zero no tempo zero), obtém-se a ASC_{0-12}. Na fase de eliminação, se a cinética for de primeira ordem, o logaritmo da concentração cai linearmente com o tempo, com inclinação $-k_e$ (a constante de eliminação). Daí se obtêm a **meia-vida**, $t_{1/2} = \ln 2 / k_e$, e a área extrapolada até o infinito, $\mathrm{ASC}_{0-\infty} = \mathrm{ASC}_{0-t} + C_{\text{última}}/k_e$.

```
asc_trap <- sum(diff(c(0, tempo_pk)) * (head(c(0, conc_pk), -1) +
 ↪  tail(c(0, conc_pk), -1)) / 2)
fase_elim <- tempo_pk >= 4
ke <- -coef(lm(log(conc_pk[fase_elim]) ~ tempo_pk[fase_elim]))[2]
c(ASC_0_12 = asc_trap, ke = unname(ke), meia_vida = unname(log(2) / ke),
  ASC_0_inf = unname(asc_trap + conc_pk[length(conc_pk)] / ke))
```

```
##    ASC_0_12          ke   meia_vida   ASC_0_inf
## 527.0000000   0.1677343   4.1324119 622.3889635
```

A ASC_{0-12} é de 527 ng · h/mL, a meia-vida de eliminação é de cerca de 4,1 h e a $\mathrm{ASC}_{0-\infty}$, de cerca de 622 ng · h/mL. A escolha dos pontos da fase terminal (aqui, de 4 a 12 h) influencia a estimativa e deve seguir um critério definido previamente. Note que a área extrapolada (cerca de 15% do total) é considerável; diretrizes regulatórias recomendam que a coleta se estenda até que a extrapolação seja pequena.

11.4.3 Bioequivalência

Dois medicamentos com o mesmo princípio ativo são considerados **bioequivalentes** quando produzem exposições sistêmicas semelhantes. Em um estudo

típico, voluntários recebem o medicamento teste e o de referência em ordem aleatória (desenho cruzado, capítulo *Desenhos de pesquisa*), e comparam-se a ASC e a $C_{\text{máx}}$. O critério usual é que o intervalo de confiança de 90% da **razão das médias geométricas** (teste/referência) esteja inteiramente contido entre 80% e 125%.

Três aspectos desse critério merecem explicação:

1. **A análise é feita na escala logarítmica**, porque parâmetros farmacocinéticos são assimétricos e porque diferenças de logaritmos correspondem a razões na escala original. Os limites são simétricos na escala log: $\ln(0{,}80) = -0{,}223$ e $\ln(1{,}25) = +0{,}223$.
2. **O intervalo é de 90%, e não de 95%**, porque o procedimento equivale a dois testes unilaterais com $\alpha = 5\%$ cada (o procedimento TOST (Schuirmann 1987)): rejeita-se que a razão seja menor que 80% e também que seja maior que 125%.
3. **A hipótese nula é a de não equivalência.** Ao contrário dos testes de superioridade, aqui a ausência de diferença estatisticamente significativa não demonstra equivalência; é preciso mostrar que o intervalo inteiro está dentro dos limites. Um estudo pequeno e impreciso não demonstra bioequivalência, mesmo que a razão estimada seja próxima de 100%.

```
set.seed(7)
n_vol <- 12
asc_ref <- rlnorm(n_vol, log(600), 0.3)
asc_teste <- asc_ref * exp(rnorm(n_vol, log(0.95), 0.10))
dif_log <- log(asc_teste) - log(asc_ref)
ic90 <- t.test(dif_log, conf.level = 0.90)$conf.int
c(razao_geometrica = exp(mean(dif_log)), IC90_inf = exp(ic90[1]),
  IC90_sup = exp(ic90[2]))
```

```
## razao_geometrica         IC90_inf         IC90_sup
##        1.0004943        0.9464727        1.0575992
```

A razão das médias geométricas foi de 100,0%, com IC de 90% de 94,6% a 105,8%, inteiramente contido no intervalo de 80% a 125%: os produtos seriam considerados bioequivalentes para a ASC. Em um estudo real, a análise usaria um modelo que inclui os efeitos de sequência, período e formulação.

11.4.4 Tamanho amostral em ensaios clínicos

O cálculo do tamanho amostral deve ser feito antes do início do ensaio e baseado no desfecho principal. Ele depende de quatro elementos: o nível de significância (α), o poder desejado ($1 - \beta$), o **tamanho de efeito** que se quer detectar e

a **variabilidade** do desfecho (o desvio padrão, para desfechos contínuos, ou a proporção no grupo controle, para desfechos binários).

Para um ensaio em que a proporção de eventos no grupo controle é de 30% e se deseja detectar uma redução para 20%, com $\alpha = 0{,}05$ e poder de 80%:

```
power.prop.test(p1 = 0.30, p2 = 0.20, sig.level = 0.05, power = 0.80)
```

```
##
##      Two-sample comparison of proportions power calculation
##
##               n = 293.1513
##              p1 = 0.3
##              p2 = 0.2
##       sig.level = 0.05
##           power = 0.8
##     alternative = two.sided
##
## NOTE: n is number in *each* group
```

São necessários cerca de 294 participantes por grupo, antes de considerar as perdas de seguimento (se forem esperados 10% de perdas, recrutam-se cerca de $294/0{,}9 \approx 327$ por grupo). O ponto mais difícil do cálculo é a escolha do tamanho de efeito. Ele deve corresponder à **menor diferença clinicamente relevante**, e não ao efeito que se espera ou que se deseja encontrar: escolher um efeito irrealisticamente grande produz um tamanho amostral pequeno e um estudo sem poder para detectar efeitos plausíveis. Estimativas de estudos-piloto pequenos são muito imprecisas e tendem a superestimar os efeitos.

11.5 Resumo do capítulo

- Intervalos de confiança para RR e OR são calculados na escala logarítmica e transformados; para a diferença de riscos, o método de Newcombe é preferível ao de Wald; o intervalo do NNT inverte os limites da diferença de riscos.
- Taxas brutas podem ser confundidas pela estrutura etária; a padronização direta compara populações com uma estrutura comum.
- Em estudos de acurácia, a precisão da sensibilidade depende do número de doentes e a da especificidade, do número de não doentes. As razões de verossimilhança não dependem da prevalência.
- Dados secundários do SUS oferecem grande cobertura, mas trazem vieses que o tamanho da amostra não corrige.
- O teste de Hardy–Weinberg tem um grau de liberdade a menos pelo parâmetro estimado. Em estudos genômicos, controle a FDR (Benjamini–Hochberg) ou a FWER (Bonferroni), conforme o objetivo.

- Na qPCR, analise os ΔC_t, e não o *fold change*, e use réplicas biológicas como unidade experimental.
- Índices de diversidade combinam riqueza e equabilidade; a riqueza depende do esforço amostral. Captura e recaptura dependem de suposições fortes sobre a população e as marcas.
- Contagens superdispersas não devem ser analisadas como Poisson simples.
- Curvas dose-resposta são ajustadas por mínimos quadrados não lineares; estime o $\log \mathrm{EC}_{50}$.
- A ASC é calculada pela regra dos trapézios; a meia-vida, pela inclinação da fase terminal na escala logarítmica.
- A bioequivalência exige que o IC de 90% da razão geométrica esteja entre 80% e 125%; ausência de diferença não é equivalência.
- O tamanho amostral deve se basear na menor diferença clinicamente relevante e prever perdas.

11.6 Exercícios

1. Em um ensaio, 30 de 200 pacientes do grupo controle e 18 de 200 do grupo tratado tiveram o evento. Calcule o RR, a diferença de riscos e o NNT, com intervalos de confiança de 95%, usando a função `medidas_2x2()` (note que, para um tratamento benéfico, o "grupo exposto" na função pode ser o tratado). Interprete o intervalo do NNT.

2. Por que a taxa de mortalidade bruta de um município com muitos idosos pode ser maior do que a de outro com população jovem, mesmo que a mortalidade em cada faixa etária seja menor? Como a padronização resolve esse problema?

3. Em 500 controles de um estudo genético, observaram-se 300 GG, 150 GA e 50 AA. Teste o equilíbrio de Hardy–Weinberg.

4. Um experimento de qPCR comparou três camundongos tratados e três controles, com três réplicas técnicas de cada amostra. O pesquisador analisou os 9 valores de cada grupo com um teste t sobre os valores de *fold change*. Aponte os dois erros.

5. Calcule o índice de Shannon e o número efetivo de espécies de uma comunidade com cinco espécies de abundâncias iguais. Compare com o valor máximo $\ln S$.

6. Um estudo de bioequivalência com 8 voluntários obteve razão de médias geométricas de 100% e IC de 90% de 78% a 128%. Os produtos são bioequivalentes? Os produtos são diferentes? O que você recomendaria?

11.7 Respostas dos exercícios

1. Com o grupo tratado como "exposto" ($a = 18$, $b = 182$, $c = 30$, $d = 170$): risco de 9% nos tratados e 15% nos controles; RR = 0,60 (IC 95%: aproximadamente 0,35 a 1,04); diferença de riscos de -6 pontos percentuais (IC 95% de Newcombe: aproximadamente $-12{,}5$ a 0,4 pontos percentuais). O NNT estimado é cerca de 17 (a função devolve $-16{,}7$: o sinal negativo indica que o "exposto", aqui o tratamento, reduz o risco, ou seja, trata-se de um NNT para benefício; valores positivos indicam NNH). Como o intervalo da diferença de riscos inclui zero, o intervalo do NNT passa pelo infinito: os dados são compatíveis desde um NNT para benefício de cerca de 8 até nenhum efeito, e até um pequeno dano (NNH muito grande, acima de 200). O estudo é inconclusivo.

```
medidas_2x2(a = 18, b = 182, c = 30, d = 170)
```

```
##                 medida  estimativa    inferior     superior
## 1      Risco relativo   0.6000000   0.3459974  1.040470185
## 2    Razão de chances   0.5604396   0.3012991  1.042460888
## 3 Diferença de riscos  -0.0600000  -0.1247020  0.004178594
## 4             NNT/NNH -16.6666667 239.3149571 -8.019115555
```

2. A mortalidade aumenta muito com a idade; um município com muitos idosos terá mais óbitos totais por habitante mesmo que, em cada faixa etária, as pessoas morram menos que no outro município. A idade confunde a comparação. A padronização direta aplica as taxas específicas de cada município a uma mesma população padrão, removendo o efeito da diferença de estrutura etária.

3. $p(G) = (2 \times 300 + 150)/1.000 = 0{,}75$. Esperados: $500 \times 0{,}5625 = 281{,}25$ (GG), $500 \times 0{,}375 = 187{,}5$ (GA), $500 \times 0{,}0625 = 31{,}25$ (AA). $X^2 = (18{,}75^2/281{,}25) + (37{,}5^2/187{,}5) + (18{,}75^2/31{,}25) = 1{,}25 + 7{,}5 + 11{,}25 = 20{,}0$, com 1 grau de liberdade, $p < 0{,}001$. Há forte desvio do equilíbrio (deficiência de heterozigotos), o que, em controles, sugere investigar erros de genotipagem ou estrutura populacional.

4. (a) Pseudorreplicação: as réplicas técnicas foram tratadas como observações independentes; o n correto é 3 por grupo (a média das réplicas técnicas de cada animal). (b) O teste foi feito na escala do *fold change*, que é assimétrica; a análise deveria ser feita nos ΔC_t (escala logarítmica), com transformação posterior para apresentar a expressão relativa.

5. Com $p_i = 0{,}2$ para todas: $H' = -5 \times 0{,}2 \times \ln 0{,}2 = \ln 5 \approx 1{,}609$, que é o máximo $\ln S$. O número efetivo de espécies é $\exp(1{,}609) = 5$: quando todas as espécies têm a mesma abundância, o número efetivo é igual à riqueza.

6. Não é possível concluir bioequivalência, porque o IC de 90% ultrapassa os limites de 80% e 125%. Também não é possível concluir que sejam diferentes: a estimativa pontual é de 100%, e o intervalo largo reflete apenas a imprecisão de um estudo com 8 voluntários. O estudo é inconclusivo por falta de poder; a recomendação é realizar um estudo com tamanho amostral calculado a partir da variabilidade intraindividual observada.

Capítulo 12

Tópicos avançados em bioestatística

Hércules Rezende Freitas, Ph.D.[1]

[1]Universidade do Estado do Rio de Janeiro (UERJ), Faculdade de Ciências Médicas, Departamento de Ciências Médicas Integradas, Laboratório de Informática em Saúde (LabInfoS), Cabo Frio/RJ, Brasil.

Os capítulos anteriores apresentaram os métodos que respondem à maior parte das perguntas de pesquisa com desfechos contínuos e observações independentes. Muitos problemas reais escapam a esse quadro: o desfecho é binário (óbito, complicação) ou uma contagem (número de quedas); as observações são agrupadas ou repetidas no mesmo indivíduo; o interesse está no tempo até um evento, que nem todos os participantes chegam a apresentar; há milhares de variáveis para poucas observações; ou é preciso combinar os resultados de vários estudos. Este capítulo introduz os métodos para essas situações e uma abordagem alternativa à inferência, a bayesiana. Cada seção é uma introdução: o objetivo é que o leitor entenda a lógica, saiba quando o método é necessário, interprete corretamente os resultados e reconheça os erros mais comuns. Os pacotes usados (`MASS`, `nlme`, `survival`) acompanham a instalação padrão do R.

12.1 Modelos lineares generalizados

12.1.1 Por que generalizar o modelo linear

A regressão linear do capítulo *Análise de dados* supõe que o desfecho tenha distribuição normal com variância constante, e que sua média seja uma função linear das variáveis explicativas. Para um desfecho binário, essas suposições falham: a média é uma probabilidade, limitada entre 0 e 1, e uma reta pode prever valores fora desse intervalo; a variância depende da média ($\pi(1-\pi)$). Para contagens, a média deve ser positiva e a variância tende a crescer com a média.

Os **modelos lineares generalizados** (MLG, ou GLM) (Nelder and Wedderburn 1972) resolvem esses problemas com três componentes:

1. um **componente aleatório**: a distribuição do desfecho, escolhida entre a família exponencial (normal, binomial, Poisson, gama, entre outras);
2. um **preditor linear**: $\eta = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p$, como na regressão linear;
3. uma **função de ligação** g, que conecta a média do desfecho ao preditor linear: $g(\mu) = \eta$.

A regressão linear é o caso particular com distribuição normal e ligação identidade ($g(\mu) = \mu$). Os parâmetros são estimados por **máxima verossimilhança**, e não por mínimos quadrados, e os testes e intervalos se baseiam em aproximações para amostras grandes.

12.1.2 Regressão logística

Para desfechos binários, usa-se a distribuição binomial com a ligação **logit**, o logaritmo da chance:

$$\ln\left(\frac{\pi}{1-\pi}\right) = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p.$$

A consequência mais importante para a interpretação é que e^{β_j} é a **razão de chances** (OR) associada a um aumento de uma unidade em X_j, mantidas constantes as demais variáveis.

Simulamos 600 pacientes cirúrgicos em que a probabilidade de complicação pós-operatória depende da idade, do tabagismo e do diabetes:

```
set.seed(2027)
n_cir <- 600
cirurgia <- data.frame(idade = round(runif(n_cir, 30, 85)),
                       fumante = rbinom(n_cir, 1, 0.25),
                       diabetes = rbinom(n_cir, 1, 0.20))
lp <- -6 + 0.06 * cirurgia$idade + 0.8 * cirurgia$fumante + 0.6 *
 ↪  cirurgia$diabetes
cirurgia$complicacao <- rbinom(n_cir, 1, plogis(lp))
table(cirurgia$complicacao)
```

```
##
##   0   1
## 524  76
```

```
modelo_log <- glm(complicacao ~ idade + fumante + diabetes, family =
 ↪  binomial, data = cirurgia)
round(exp(cbind(OR = coef(modelo_log), confint.default(modelo_log))), 3)
```

```
##                OR 2.5 % 97.5 %
## (Intercept) 0.004 0.001  0.013
## idade       1.054 1.035  1.074
## fumante     2.510 1.492  4.225
## diabetes    1.918 1.076  3.422
```

Interpretação: ajustando para idade e diabetes, a chance de complicação dos fumantes é 2,51 vezes a dos não fumantes (IC 95%: 1,49 a 4,23). Para a idade, a OR de 1,054 refere-se a um ano a mais; para uma diferença de dez anos, a OR é $e^{10\beta} = 1{,}69$. A primeira linha da tabela (o intercepto) não tem interpretação útil como OR.

A razão de chances é difícil de comunicar e, quando o desfecho é frequente, afasta-se do risco relativo (capítulo *Desenhos de pesquisa*). Uma forma complementar de apresentar os resultados é por meio de **probabilidades previstas**: pelo modelo, um fumante sem diabetes tem probabilidade de complicação de 11,0% aos 50 anos e de 26,1% aos 70.

Tamanho amostral. Em regressão logística, a informação disponível depende do número de eventos, e não do número de participantes: 1.000 pacientes com 20 complicações fornecem pouca informação. A regra prática clássica de pelo menos 10 eventos por variável incluída no modelo (Peduzzi et al. 1996) é uma aproximação; para modelos de predição, recomendam-se cálculos formais de tamanho amostral (Riley et al. 2020). Com poucos eventos, as estimativas ficam enviesadas, e os intervalos, imprecisos.

12.1.3 Regressão de Poisson e binomial negativa

Para **contagens** (número de quedas, de crises, de internações), usa-se a distribuição de Poisson com ligação logarítmica: $\ln(\mu) = \beta_0 + \beta_1 X_1 + \cdots$. Então e^{β_j} é a **razão de taxas**. Quando os participantes são acompanhados por tempos diferentes, o modelo inclui o logaritmo do tempo de acompanhamento como **termo de compensação** (*offset*), com coeficiente fixo em 1, de modo que o modelo descreve a taxa (eventos por unidade de tempo), e não a contagem bruta.

Simulamos um estudo com 200 idosos acompanhados por 6 a 12 meses, metade dos quais recebeu um programa de prevenção de quedas:

```
set.seed(5)
n_q <- 200
```

```
quedas <- data.frame(grupo = rep(c("controle", "intervencao"), each = n_q
 ↪  / 2),
                     meses = round(runif(n_q, 6, 12)))
taxa <- ifelse(quedas$grupo == "intervencao", 0.07, 0.10)
quedas$n_quedas <- rnbinom(n_q, mu = taxa * quedas$meses, size = 1.5)

modelo_pois <- glm(n_quedas ~ grupo + offset(log(meses)), family =
 ↪  poisson, data = quedas)
dispersao <- sum(residuals(modelo_pois, type = "pearson")^2) /
 ↪  df.residual(modelo_pois)
dispersao
```

```
## [1] 1.668488
```

```
modelo_nb <- glm.nb(n_quedas ~ grupo + offset(log(meses)), data = quedas)
rbind(Poisson = exp(c(coef(modelo_pois)[2],
 ↪  confint.default(modelo_pois)[2, ])),
      Binomial_negativa = exp(c(coef(modelo_nb)[2],
       ↪  confint.default(modelo_nb)[2, ])))
```

```
##                    grupointervencao     2.5 %    97.5 %
## Poisson                   0.7084208 0.5118637 0.9804565
## Binomial_negativa         0.7332746 0.4811530 1.1175064
```

A distribuição de Poisson supõe que a variância seja igual à média. A razão entre a soma dos quadrados dos resíduos de Pearson e os graus de liberdade estima esse parâmetro de dispersão; aqui, ela vale 1,67, indicando **superdispersão** (capítulo *Aplicações práticas e estudos de caso*). Com superdispersão, o modelo de Poisson subestima os erros padrão: o valor p para o efeito da intervenção é 0,038 no modelo de Poisson e 0,149 no modelo **binomial negativo**, que inclui um parâmetro adicional para a variância extra. A estimativa pontual da razão de taxas é semelhante nos dois modelos; o que muda é a precisão. Alternativas são o modelo quase-Poisson e os erros padrão robustos. Quando há excesso de zeros (muitos participantes sem nenhum evento, por razões estruturais), existem modelos específicos de inflação de zeros.

12.2 Modelos mistos

12.2.1 Observações agrupadas e medidas repetidas

Todos os métodos vistos até aqui supõem observações independentes. Essa suposição é violada sempre que os dados têm uma estrutura hierárquica: medidas repetidas no mesmo paciente ao longo do tempo, pacientes agrupados em hospitais, alunos em escolas, neurônios em animais (a pseudorreplicação do capítulo

Desenhos de pesquisa). Observações de uma mesma unidade tendem a ser mais parecidas entre si do que observações de unidades diferentes. Ignorar essa correlação produz erros padrão incorretos: em geral, subestimados para efeitos que variam entre os grupos e superestimados para efeitos que variam dentro dos indivíduos.

Os **modelos mistos** (ou modelos de efeitos aleatórios, ou modelos multinível) (Pinheiro and Bates 2000) incluem, além dos **efeitos fixos** de interesse (tratamento, tempo), **efeitos aleatórios** que representam a variação entre as unidades. O modelo mais simples tem um **intercepto aleatório**: cada indivíduo i tem seu próprio nível basal, que se desvia da média por uma quantidade b_i, suposta normal com média zero e variância τ^2:

$$Y_{ij} = \beta_0 + b_i + \beta_1 \,\text{tempo}_{ij} + \cdots + \varepsilon_{ij}, \qquad b_i \sim N(0, \tau^2), \quad \varepsilon_{ij} \sim N(0, \sigma^2).$$

A proporção da variância total que se deve às diferenças entre indivíduos é o **coeficiente de correlação intraclasse**, $\text{CCI} = \tau^2/(\tau^2 + \sigma^2)$, que é também a correlação entre duas medidas do mesmo indivíduo.

12.2.2 Exemplo

Trinta pacientes hipertensos (15 controles e 15 tratados) tiveram a pressão sistólica medida em quatro visitas. Comparamos uma regressão linear comum, que ignora que as medidas são do mesmo paciente, com um modelo misto com intercepto aleatório por paciente:

```
set.seed(8)
n_pac <- 30
longit <- expand.grid(visita = 0:3, id = 1:n_pac)
longit$grupo <- ifelse(longit$id <= 15, "controle", "tratado")
b_i <- rnorm(n_pac, 0, 8)
longit$pas <- 140 + b_i[longit$id] - 1 * longit$visita -
  3 * longit$visita * (longit$grupo == "tratado") + rnorm(nrow(longit),
  ↪  0, 4)

modelo_ingenuo <- lm(pas ~ visita * grupo, data = longit)
modelo_misto <- lme(pas ~ visita * grupo, random = ~ 1 | id, data =
 ↪  longit)
round(summary(modelo_ingenuo)$coefficients, 3)
```

```
##                    Estimate Std. Error t value Pr(>|t|)
## (Intercept)         138.082      2.133  64.733    0.000
## visita               -2.061      1.140  -1.808    0.073
## grupotratado          3.197      3.017   1.060    0.291
## visita:grupotratado  -2.047      1.612  -1.269    0.207
```

```
round(summary(modelo_misto)$tTable, 3)
```

```
##                       Value Std.Error DF t-value p-value
## (Intercept)         138.082     2.505 88  55.125   0.000
## visita               -2.061     0.522 88  -3.947   0.000
## grupotratado          3.197     3.542 28   0.902   0.375
## visita:grupotratado  -2.047     0.739 88  -2.771   0.007
```

As estimativas dos efeitos fixos são idênticas nos dois modelos, mas os erros padrão não. O termo de interação `visita:grupotratado`, que mede quanto a pressão cai a mais por visita no grupo tratado, tem erro padrão de 1,61 no modelo ingênuo e de 0,74 no modelo misto, com valores p de 0,207 e 0,007, respectivamente. O modelo misto separa a grande variação entre pacientes (que não afeta a comparação das inclinações, porque cada paciente serve como seu próprio controle ao longo do tempo) da variação dentro de cada paciente. O CCI estimado é de 0,80: 80% da variância total se deve a diferenças estáveis entre pacientes.

Extensões incluem **inclinações aleatórias** (cada paciente com sua própria taxa de variação), estruturas de correlação para medidas próximas no tempo, vários níveis de agrupamento (medidas em pacientes em hospitais) e modelos mistos generalizados para desfechos binários e contagens. Para ensaios por conglomerados e estudos multicêntricos, o modelo misto é a análise padrão. Os pacotes `nlme` e `lme4` são os mais usados no R.

12.3 Análise de sobrevivência

12.3.1 Tempo até o evento e censura

Em muitos estudos, o desfecho é o **tempo até um evento**: óbito, recidiva, alta, falha de um implante. A dificuldade característica é a **censura**: para alguns participantes, o evento não é observado até o fim do acompanhamento, porque o estudo terminou, porque o participante foi perdido ou porque saiu do estudo por outro motivo. Sabe-se apenas que o tempo até o evento é maior que o tempo observado.

Excluir os participantes censurados ou tratá-los como se tivessem tido o evento no último contato enviesa os resultados. Analisar apenas a proporção de eventos ignora o tempo e trata da mesma forma um óbito no primeiro mês e no quinto ano. Os métodos de análise de sobrevivência usam a informação dos censurados enquanto estiveram em observação. Eles supõem **censura não informativa**: a razão da censura não está relacionada ao prognóstico. Se os pacientes que pioram tendem a abandonar o acompanhamento, essa suposição é violada.

Tabela 12.1: Cálculo do estimador de Kaplan–Meier para oito pacientes.

Tempo t_j	Em risco n_j	Eventos d_j	$1 - d_j/n_j$	$\hat{S}(t_j)$
3	8	1	$7/8 = 0{,}875$	0,875
6	6	1	$5/6 = 0{,}833$	$0{,}875 \times 0{,}833 = 0{,}729$
8	5	2	$3/5 = 0{,}600$	$0{,}729 \times 0{,}600 = 0{,}438$
12	2	1	$1/2 = 0{,}500$	$0{,}438 \times 0{,}500 = 0{,}219$

12.3.2 O estimador de Kaplan–Meier

A **função de sobrevivência** $S(t)$ é a probabilidade de o evento ainda não ter ocorrido até o tempo t. O estimador de **Kaplan–Meier** (Kaplan and Meier 1958) a calcula como um produto de probabilidades condicionais: em cada tempo t_j em que ocorre ao menos um evento, a probabilidade de "sobreviver" a esse tempo, para quem chegou até ele, é $1 - d_j/n_j$, em que d_j é o número de eventos e n_j o número de participantes **em risco** (ainda em observação e sem o evento) imediatamente antes de t_j. Então

$$\hat{S}(t) = \prod_{t_j \le t} \left(1 - \frac{d_j}{n_j}\right).$$

Exemplo resolvido. Oito pacientes foram acompanhados após uma cirurgia; os tempos até a recidiva, em meses, foram 3, 5+, 6, 8, 8, 10+, 12 e 15+, em que o sinal "+" indica censura. A Tabela 12.1 mostra o cálculo.

Note como a censura atua: o paciente censurado aos 5 meses contribui para o conjunto em risco aos 3 meses, mas não aos 6; por isso, aos 6 meses há 6, e não 7, pacientes em risco. A estimativa é de que 43,8% dos pacientes estejam livres de recidiva aos 8 meses.

```
tempo_km <- c(3, 5, 6, 8, 8, 10, 12, 15)
evento_km <- c(1, 0, 1, 1, 1, 0, 1, 0)
summary(survfit(Surv(tempo_km, evento_km) ~ 1))
```

```
## Call: survfit(formula = Surv(tempo_km, evento_km) ~ 1)
##
##  time n.risk n.event survival std.err lower 95% CI upper 95% CI
##     3      8       1    0.875   0.117       0.6734            1
##     6      6       1    0.729   0.165       0.4680            1
##     8      5       2    0.438   0.188       0.1885            1
##    12      2       1    0.219   0.181       0.0432            1
```

12.3.3 Comparação de grupos: log-rank e modelo de Cox

Para comparar curvas de sobrevivência entre grupos, o **teste log-rank** compara, em cada tempo de evento, o número observado de eventos em cada grupo com o número esperado se as curvas fossem iguais, e acumula essas diferenças ao longo do tempo.

O **modelo de riscos proporcionais de Cox** (Cox 1972) permite incluir várias variáveis explicativas. Ele modela a **função de risco** (*hazard*), a taxa instantânea de ocorrência do evento entre os que ainda não o apresentaram:

$$h(t \mid X) = h_0(t)\exp(\beta_1 X_1 + \cdots + \beta_p X_p),$$

em que $h_0(t)$ é um risco basal que não precisa ser especificado. A quantidade e^{β_j} é a **razão de riscos** (*hazard ratio*, HR). O modelo supõe que as razões de riscos sejam **constantes ao longo do tempo** (riscos proporcionais), suposição que deve ser verificada, por exemplo com os resíduos de Schoenfeld (`cox.zph()`).

```
set.seed(3)
n_s <- 120
grupo_s <- rep(c("A", "B"), each = n_s / 2)
t_evento <- rexp(n_s, rate = ifelse(grupo_s == "B", 0.05, 0.08))
t_censura <- runif(n_s, 0, 30)
sobrev <- data.frame(grupo = grupo_s, tempo = pmin(t_evento, t_censura),
                     evento = as.integer(t_evento <= t_censura))
survdiff(Surv(tempo, evento) ~ grupo, data = sobrev)
```

```
## Call:
## survdiff(formula = Surv(tempo, evento) ~ grupo, data = sobrev)
##
##          N Observed Expected (O-E)^2/E (O-E)^2/V
## grupo=A 60       36     27.2      2.84      5.11
## grupo=B 60       26     34.8      2.22      5.11
##
##  Chisq= 5.1  on 1 degrees of freedom, p= 0.02
```

```
modelo_cox <- coxph(Surv(tempo, evento) ~ grupo, data = sobrev)
summary(modelo_cox)$conf.int
```

```
##        exp(coef) exp(-coef) lower .95 upper .95
## grupoB 0.5616237   1.780552 0.3382368 0.9325456
```

```
cox.zph(modelo_cox)
```

```
##        chisq df    p
## grupo  0.735  1 0.39
## GLOBAL 0.735  1 0.39
```

```
plot(survfit(Surv(tempo, evento) ~ grupo, data = sobrev), lty = c(1, 2),
 ↪  lwd = 2, mark.time = TRUE,
     xlab = "Tempo (meses)", ylab = "Probabilidade de sobrevivência livre
      ↪  de evento")
legend("topright", legend = c("Grupo A", "Grupo B"), lty = c(1, 2), lwd =
 ↪  2, bty = "n")
```

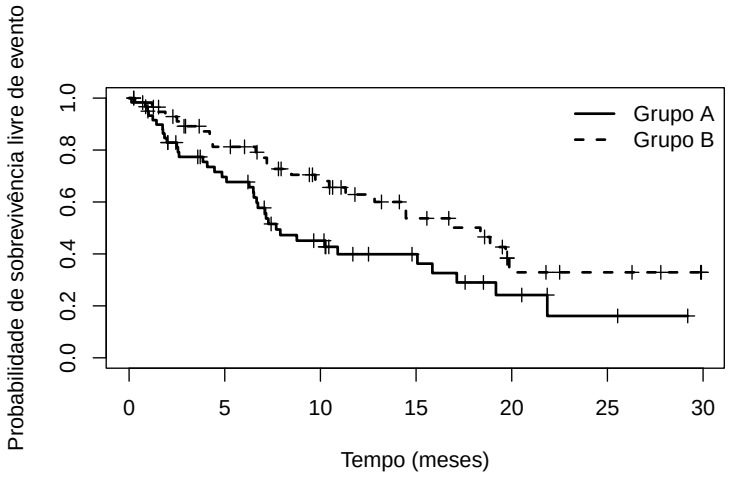


Figura 12.1: Curvas de Kaplan–Meier para dois grupos (dados simulados). As marcas verticais indicam censuras.

O grupo B tem uma razão de riscos de 0,56 (IC 95%: 0,34 a 0,93) em relação ao grupo A: em qualquer momento, o risco instantâneo do evento é cerca de 44% menor no grupo B. A verificação dos riscos proporcionais não indica violação. Uma razão de riscos não é um risco relativo cumulativo, e é útil complementá-la com medidas absolutas, como a sobrevivência estimada em um tempo de interesse ou a **sobrevivência mediana** (o tempo em que $\hat{S}(t) = 0{,}5$).

Dois erros frequentes merecem atenção. O primeiro é o **viés do tempo imortal** (capítulo *Desenhos de pesquisa*), que surge quando se classificam os pacientes por um evento que ocorre durante o acompanhamento. O segundo é ignorar **riscos competitivos**: quando um evento (por exemplo, óbito por outra causa) impede a ocorrência do evento de interesse, o complemento do Kaplan–Meier superestima a incidência cumulativa, e métodos específicos são necessários.

12.4 Inferência bayesiana

12.4.1 A lógica bayesiana

Os métodos dos capítulos anteriores pertencem à abordagem **frequentista**, em que os parâmetros são constantes desconhecidas e as probabilidades se referem a resultados de amostras hipotéticas repetidas. Na abordagem **bayesiana**, a incerteza sobre os próprios parâmetros é descrita por distribuições de probabilidade (Gelman et al. 2013). O teorema de Bayes (capítulo *Bioestatística inferencial*), aplicado a um parâmetro θ e aos dados y, fica

$$\underbrace{p(\theta \mid y)}_{\text{posteriori}} \propto \underbrace{p(y \mid \theta)}_{\text{verossimilhança}} \times \underbrace{p(\theta)}_{\text{priori}} .$$

- A **distribuição a priori** descreve o conhecimento sobre θ antes dos dados (por exemplo, a partir de estudos anteriores), ou uma posição deliberadamente pouco informativa.
- A **verossimilhança** descreve quão compatíveis os dados são com cada valor de θ; é a mesma quantidade usada nos métodos de máxima verossimilhança.
- A **distribuição a posteriori** combina as duas e descreve o conhecimento atualizado. Dela se extraem estimativas (média ou mediana a posteriori) e **intervalos de credibilidade**.

12.4.2 Um exemplo com proporção

Em um estudo-piloto, 12 de 40 pacientes apresentaram um efeito adverso. Queremos estimar a proporção θ de pacientes com o efeito. Se a priori for uma distribuição **beta**, Beta(α, β), e os dados forem x eventos em n pacientes, a posteriori também será beta: Beta$(\alpha + x, \beta + n - x)$. Essa conveniência matemática (a priori e a posteriori na mesma família) é chamada de **conjugação**.

- Com uma priori **uniforme**, Beta$(1, 1)$, que atribui a mesma densidade a todos os valores entre 0 e 1, a posteriori é Beta$(13, 29)$.
- Com uma priori **informativa** baseada em estudos anteriores, que sugeriam uma proporção em torno de 20%, por exemplo Beta$(4, 16)$ (média de 0,20, equivalente à informação de cerca de 20 pacientes), a posteriori é Beta$(16, 44)$.

```
posteriores <- list(uniforme = c(13, 29), informativa = c(16, 44))
t(sapply(posteriores, function(p) c(
  media = p[1] / sum(p),
  IC_cred_inf = qbeta(0.025, p[1], p[2]),
```

```
  IC_cred_sup = qbeta(0.975, p[1], p[2]),
  P_maior_25 = 1 - pbeta(0.25, p[1], p[2]))))
```

```
##                media IC_cred_inf IC_cred_sup P_maior_25
## uniforme    0.3095238   0.1808494   0.4553740  0.7944354
## informativa 0.2666667   0.1636327   0.3844241  0.5983543
```

```
curve(dbeta(x, 13, 29), 0, 0.7, lwd = 2, ylim = c(0, 10.5), ylab =
 ↪  "Densidade", xlab = "Proporção de efeitos adversos")
curve(dbeta(x, 16, 44), add = TRUE, lwd = 2, col = "grey50")
curve(dbeta(x, 1, 1), add = TRUE, lty = 2)
curve(dbeta(x, 4, 16), add = TRUE, lty = 2, col = "grey50")
abline(v = 12 / 40, lty = 3)
legend("topright", bty = "n", lwd = 2, lty = c(1, 1, 2, 2), col =
 ↪  c("black", "grey50", "black", "grey50"),
       legend = c("Posteriori (priori uniforme)", "Posteriori (priori
        ↪  informativa)",
                  "Priori uniforme", "Priori informativa"), cex = 0.8)
```

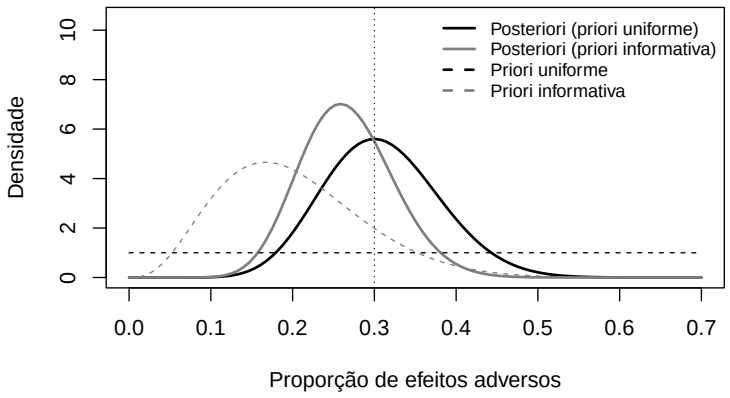


Figura 12.2: Distribuições a priori (tracejadas) e a posteriori (contínuas) para a proporção de efeitos adversos, com priori uniforme (preto) e informativa (cinza). A linha vertical indica a proporção observada (12/40).

Com a priori uniforme, a média a posteriori é de 0,31, com intervalo de credibilidade de 95% de 0,18 a 0,46, valores próximos do intervalo de Wilson frequentista (0,18 a 0,45). Com a priori informativa, a estimativa é puxada em direção a 0,20 (média de 0,27) e o intervalo fica mais estreito, porque a priori acrescenta informação. A interpretação do intervalo de credibilidade é a que muitos atribuem,

erroneamente, ao intervalo de confiança: dada a priori e os dados, há 95% de probabilidade de θ estar entre os limites. Também é possível calcular diretamente probabilidades de interesse, como a probabilidade de a proporção ser maior que 25% (0,79 com a priori uniforme), algo que um valor p não fornece.

12.4.3 Vantagens e cuidados

A abordagem bayesiana permite incorporar formalmente o conhecimento prévio, responde diretamente a perguntas como "qual a probabilidade de o tratamento ser benéfico?", lida naturalmente com modelos complexos e com a atualização sequencial dos dados, e não depende de regras de parada fixas. Seus cuidados são: a priori deve ser justificada e especificada antes de ver os dados, e os resultados devem ser acompanhados de **análises de sensibilidade** com prioris diferentes, sobretudo quando os dados são escassos e a priori tem grande influência. Para modelos sem solução conjugada, as posterioris são obtidas por métodos de simulação (cadeias de Markov Monte Carlo), implementados em programas como Stan, acessível pelo R por pacotes como `brms` e `rstanarm`.

12.5 Bioinformática e *big data*

12.5.1 Dados de alta dimensão

As tecnologias "ômicas" (genômica, transcriptômica, proteômica, metabolômica) e os registros eletrônicos de saúde produzem conjuntos de dados com características que desafiam os métodos clássicos. O caso típico de alta dimensão tem muito mais variáveis do que observações ($p \gg n$): por exemplo, a expressão de 20.000 genes em 100 amostras. Nessa situação, um modelo de regressão com todas as variáveis não pode sequer ser ajustado, e a seleção de variáveis se torna uma fonte importante de erro.

12.5.2 Sobreajuste e o viés de seleção

A simulação a seguir mostra o problema central. Geramos 100 observações de um desfecho e 1.000 variáveis preditoras, todas independentes do desfecho (puro ruído). Usando as primeiras 50 observações, selecionamos as 10 variáveis mais correlacionadas com o desfecho e ajustamos uma regressão:

```
set.seed(99)
n_obs <- 100; n_var <- 1000
X <- matrix(rnorm(n_obs * n_var), n_obs)
y <- rnorm(n_obs)
treino <- 1:50; teste <- 51:100
```

```
correlacoes <- abs(cor(X[treino, ], y[treino]))
selecionadas <- order(correlacoes, decreasing = TRUE)[1:10]
ajuste <- lm(y[treino] ~ X[treino, selecionadas])
r2_treino <- summary(ajuste)$r.squared
previsto <- cbind(1, X[teste, selecionadas]) %*% coef(ajuste)
r2_teste <- cor(previsto, y[teste])^2
c(R2_treino = r2_treino, R2_teste = r2_teste)
```

```
## R2_treino  R2_teste
## 0.6520786 0.0129579
```

Nos dados usados para selecionar as variáveis e ajustar o modelo, o R^2 é de 0,65: o modelo parece explicar 65% da variação do desfecho. Em dados novos, o R^2 cai para 0,01, porque não há relação alguma a ser encontrada. O modelo se ajustou ao ruído da amostra (**sobreajuste**), e a seleção das variáveis com os mesmos dados usados para avaliar o modelo produziu um otimismo enorme. Esse **viés de seleção** foi documentado em estudos de assinaturas gênicas que relatavam taxas de erro de classificação próximas de zero, impossíveis de reproduzir (Ambroise and McLachlan 2002).

As defesas são:

- **validação** em dados que não foram usados em nenhuma etapa da construção do modelo, inclusive a seleção de variáveis. A **validação cruzada** divide os dados em k partes, constrói o modelo em $k-1$ partes e o avalia na parte restante, repetindo o procedimento para cada parte; todas as etapas (seleção, ajuste, escolha de parâmetros) devem ser repetidas dentro de cada divisão;
- **regularização**: métodos como o LASSO (Tibshirani 1996) e a regressão *ridge* penalizam a magnitude dos coeficientes, encolhendo-os em direção a zero e, no caso do LASSO, selecionando variáveis de forma mais estável. O pacote `glmnet` os implementa;
- **validação externa** em uma população independente, idealmente de outro centro ou período, antes de qualquer uso clínico de um modelo preditivo.

12.5.3 Efeitos de lote e outros problemas

Em experimentos de alta dimensão, as amostras são frequentemente processadas em **lotes** (dias, placas, corridas de sequenciamento). Diferenças técnicas entre lotes podem produzir variações maiores que os efeitos biológicos e, se os lotes coincidirem com os grupos de comparação (todos os casos em um lote, todos os controles em outro), o efeito do lote fica completamente confundido com o efeito biológico, sem possibilidade de correção (Leek et al. 2010). A solução é de desenho, e não de análise: distribuir os grupos de forma balanceada e aleatória entre os lotes (capítulo *Desenhos de pesquisa*).

12.5.4 Grandes bases de dados

Em grandes bases administrativas e registros eletrônicos, o problema é o oposto: há milhões de observações, e o erro aleatório se torna desprezível. Isso pode criar uma falsa sensação de certeza. Intervalos de confiança estreitíssimos em torno de uma estimativa enviesada não a tornam correta. Meng (2018) mostrou que, quando a probabilidade de um indivíduo estar na base depende, ainda que fracamente, da variável estudada, uma amostra enorme e não aleatória pode conter menos informação útil que uma pequena amostra aleatória. Em bases de saúde, a seleção (quem procura o serviço, quem é registrado), a qualidade dos registros e a confusão são as principais ameaças, e nenhuma diminui com o tamanho da base. Os princípios de desenho do capítulo *Desenhos de pesquisa*, como a emulação de um ensaio-alvo, são tão importantes nesses estudos quanto em estudos pequenos.

12.6 Metanálise

12.6.1 Combinando estudos

A **metanálise** é a combinação estatística dos resultados de vários estudos que respondem à mesma pergunta. É, em geral, a etapa final de uma revisão sistemática (capítulo *Formulação de problemas e hipóteses*), e só faz sentido quando os estudos são suficientemente semelhantes em população, intervenção, comparador e desfecho. Uma metanálise de estudos enviesados produz uma estimativa enviesada e precisa.

Cada estudo i fornece uma estimativa do efeito, y_i (por exemplo, o logaritmo de uma razão de chances, ou uma diferença de médias), e seu erro padrão, EP_i. A estimativa combinada é uma **média ponderada pelo inverso da variância**: estudos mais precisos recebem mais peso.

12.6.2 Efeito fixo e efeitos aleatórios

No **modelo de efeito fixo** (ou comum), supõe-se que todos os estudos estimam o mesmo efeito verdadeiro θ, e que as diferenças entre eles se devem apenas ao erro amostral:

$$w_i = \frac{1}{\text{EP}_i^2}, \qquad \hat{\theta}_F = \frac{\sum w_i y_i}{\sum w_i}, \qquad \text{EP}(\hat{\theta}_F) = \frac{1}{\sqrt{\sum w_i}}.$$

No **modelo de efeitos aleatórios**, supõe-se que os efeitos verdadeiros variam entre os estudos (por diferenças de população, dose, desenho), em torno de uma média μ, com variância entre estudos τ^2. Os pesos passam a ser $w_i^* =$

Tabela 12.2: Estudos incluídos na metanálise (dados fictícios).

Estudo	OR	ln(OR)	EP	Peso (efeito fixo)	Peso (%)
1	0,62	-0,478	0,20	25,0	12,7
2	0,80	-0,223	0,15	44,4	22,6
3	0,45	-0,799	0,30	11,1	5,6
4	0,95	-0,051	0,12	69,4	35,3
5	0,70	-0,357	0,25	16,0	8,1
6	0,58	-0,545	0,18	30,9	15,7

$1/(\mathrm{EP}_i^2 + \tau^2)$. O estimador de τ^2 mais conhecido é o de DerSimonian e Laird (DerSimonian and Laird 1986):

$$\hat{\tau}^2 = \max\left(0,\ \frac{Q - (k-1)}{\sum w_i - \sum w_i^2 / \sum w_i}\right),$$

em que k é o número de estudos e $Q = \sum w_i (y_i - \hat{\theta}_F)^2$ é a estatística de heterogeneidade de Cochran, que segue aproximadamente uma qui-quadrado com $k-1$ graus de liberdade se não houver heterogeneidade.

A **heterogeneidade** é quantificada pelo $I^2 = \max\left(0, \frac{Q-(k-1)}{Q}\right)$, a proporção da variabilidade observada entre as estimativas que se deve a diferenças reais, e não ao acaso (Higgins and Thompson 2002). O teste Q tem pouco poder com poucos estudos, e o I^2 é impreciso; ambos devem ser interpretados com cautela.

12.6.3 Exemplo

Seis estudos avaliaram o efeito de uma intervenção sobre a ocorrência de um desfecho, com as razões de chances e os erros padrão do log OR da Tabela 12.2.

```
metanalise <- function(yi, ep) {
  w <- 1 / ep^2; k <- length(yi)
  fixo <- sum(w * yi) / sum(w); ep_fixo <- sqrt(1 / sum(w))
  Q <- sum(w * (yi - fixo)^2)
  tau2 <- max(0, (Q - (k - 1)) / (sum(w) - sum(w^2) / sum(w)))
  I2 <- max(0, (Q - (k - 1)) / Q)
  w_ale <- 1 / (ep^2 + tau2)
  aleat <- sum(w_ale * yi) / sum(w_ale); ep_aleat <- sqrt(1 / sum(w_ale))
  list(OR_fixo = exp(fixo + c(est = 0, inf = -1.96, sup = 1.96) *
   ↪  ep_fixo),
       OR_aleatorio = exp(aleat + c(est = 0, inf = -1.96, sup = 1.96) *
        ↪  ep_aleat),
       Q = Q, p_Q = pchisq(Q, k - 1, lower.tail = FALSE), I2 = I2, tau2
        ↪  = tau2)
```

```
}
res_meta <- metanalise(yi, ep_i)
res_meta
```

```
## $OR_fixo
##       est       inf       sup
## 0.7492849 0.6515974 0.8616177
##
## $OR_aleatorio
##       est       inf       sup
## 0.7059909 0.5722516 0.8709862
##
## $Q
## [1] 9.986127
##
## $p_Q
## [1] 0.07562929
##
## $I2
## [1] 0.4993054
##
## $tau2
## [1] 0.03271899
```

```
k <- length(yi)
w_ale <- 1 / (ep_i^2 + res_meta$tau2)
op <- par(mar = c(4, 6, 1, 1))
plot(NA, xlim = log(c(0.2, 2)), ylim = c(0.5, k + 1.5), yaxt = "n", xaxt
 ↪  = "n",
     xlab = "Razão de chances (escala logarítmica)", ylab = "")
eixo <- c(0.25, 0.5, 1, 2)
axis(1, at = log(eixo), labels = num(eixo, 2))
axis(2, at = c(k:1 + 1, 0.9), labels = c(paste("Estudo", 1:k),
 ↪  "Combinado"), las = 1, tick = FALSE)
abline(v = 0, lty = 2)
segments(yi - 1.96 * ep_i, k:1 + 1, yi + 1.96 * ep_i, k:1 + 1)
symbols(yi, k:1 + 1, squares = sqrt(w_ale / max(w_ale)) * 0.12, inches =
 ↪  FALSE, add = TRUE, bg = "black")
ic_c <- log(res_meta$OR_aleatorio)
polygon(c(ic_c[2], ic_c[1], ic_c[3], ic_c[1]), c(0.9, 1.15, 0.9, 0.65),
 ↪  col = "grey50", border = "black")
```

```
par(op)
```

A estimativa combinada pelo modelo de efeitos aleatórios é uma OR de 0,71 (IC 95%: 0,57 a 0,87); pelo modelo de efeito fixo, 0,75 (0,65 a 0,86). A heterogeneidade é moderada ($Q = 9{,}99$, com 5 graus de liberdade, $p = 0{,}076$; $I^2 =$

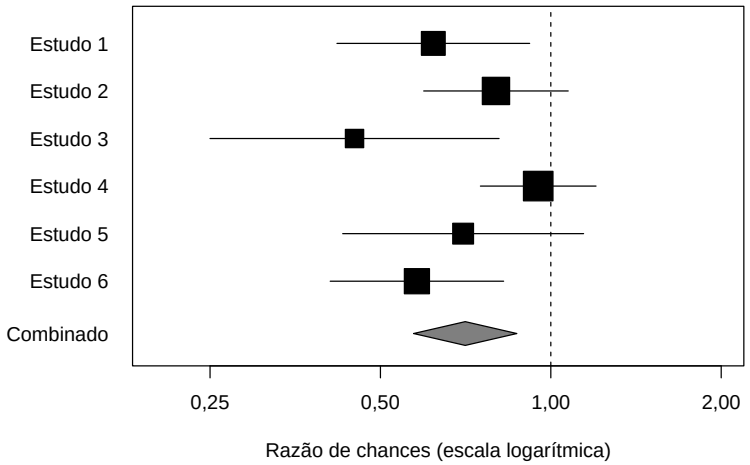


Figura 12.3: Gráfico de floresta (forest plot) da metanálise. Os quadrados representam as estimativas de cada estudo, com área proporcional ao peso no modelo de efeitos aleatórios, e as linhas, seus intervalos de confiança de 95%. O losango representa a estimativa combinada. O eixo horizontal está em escala logarítmica.

50%). No modelo de efeitos aleatórios, os pesos ficam mais equilibrados entre os estudos e o intervalo se alarga, refletindo a incerteza adicional da variação entre estudos.

Algumas observações práticas:

- a escolha entre efeito fixo e efeitos aleatórios deve ser feita antes da análise, com base no que se supõe sobre os estudos, e não pelo resultado do teste de heterogeneidade. Em ciências da saúde, em que os estudos raramente são idênticos, o modelo de efeitos aleatórios é o mais usado;
- com poucos estudos, o método de DerSimonian–Laird subestima a incerteza; o ajuste de Hartung–Knapp–Sidik–Jonkman produz intervalos com cobertura mais adequada (IntHout et al. 2014);
- a heterogeneidade deve ser explorada, quando possível, por análises de subgrupo e metarregressão definidas previamente, e não apenas relatada;
- o **viés de publicação** (estudos com resultados nulos têm menor chance de serem publicados) pode distorcer a estimativa combinada. O **gráfico de funil** (estimativa versus precisão) e testes de assimetria, como o de Egger (Egger et al. 1997), ajudam a detectá-lo, mas têm baixo poder com poucos estudos, e assimetria pode ter outras causas;
- os pacotes `meta` e `metafor` implementam todos esses métodos e produzem gráficos de floresta e de funil para publicação.

12.7 Resumo do capítulo

- Modelos lineares generalizados combinam uma distribuição, um preditor linear e uma função de ligação. Na regressão logística, e^{β} é uma razão de chances; na de Poisson, uma razão de taxas. Inclua o tempo de acompanhamento como *offset* e verifique a superdispersão.
- Em regressão logística, a informação depende do número de eventos.
- Observações agrupadas ou repetidas não são independentes; modelos mistos separam a variação entre e dentro das unidades. O CCI quantifica a correlação intraunidade.
- Na análise de sobrevivência, a censura é tratada pelo estimador de Kaplan–Meier, pelo teste log-rank e pelo modelo de Cox. Verifique a proporcionalidade dos riscos e cuide do tempo imortal e dos riscos competitivos.
- A inferência bayesiana combina priori e verossimilhança em uma posteriori; intervalos de credibilidade têm interpretação probabilística direta. Justifique a priori e faça análises de sensibilidade.
- Com muitas variáveis e poucas observações, a seleção e a avaliação de um modelo com os mesmos dados produzem otimismo enorme. Use validação cruzada (incluindo a seleção dentro dela), regularização e validação externa.
- Efeitos de lote confundidos com grupos não podem ser corrigidos na análise. Grandes bases reduzem o erro aleatório, mas não os vieses.
- A metanálise combina estudos por ponderação pelo inverso da variância. Prefira, em geral, o modelo de efeitos aleatórios; avalie a heterogeneidade (Q, I^2, τ^2) e o viés de publicação com cautela.

12.8 Exercícios

1. Em uma regressão logística para óbito hospitalar, o coeficiente da idade (em anos) foi 0,045. Calcule e interprete a OR para 1 ano e para 10 anos.

2. Um estudo comparou o número de crises epilépticas em pacientes tratados com dois medicamentos, acompanhados por tempos diferentes. Que modelo você usaria? Como lidaria com o tempo de acompanhamento? Como verificaria se o modelo é adequado?

3. Em um estudo, 20 pacientes tiveram a glicemia medida em 6 visitas. Os autores analisaram as 120 medidas com uma regressão linear comum. Qual o problema? Que método seria adequado?

4. Calcule o estimador de Kaplan–Meier para os tempos 2, 4+, 4, 7, 9+, 11, em meses ("+" indica censura).

5. Em um estudo, 3 de 10 pacientes responderam a um tratamento. Calcule a média e o intervalo de credibilidade de 95% a posteriori com priori

Beta$(1, 1)$. Use `qbeta()`.

6. Um pesquisador mediu a expressão de 15.000 genes em 40 tumores, selecionou os 20 genes mais associados à resposta ao tratamento e construiu um classificador, que acertou 100% dos casos nos mesmos 40 tumores. O que você conclui?

7. Em uma metanálise de 8 estudos, $Q = 7{,}2$. Calcule o I^2. A ausência de heterogeneidade estatística significa que os estudos são homogêneos?

12.9 Respostas dos exercícios

1. $\text{OR}_{1 \text{ ano}} = e^{0{,}045} \approx 1{,}046$: cada ano a mais está associado a uma chance de óbito 4,6% maior, ajustando para as demais variáveis. $\text{OR}_{10 \text{ anos}} = e^{0{,}45} \approx 1{,}57$: uma diferença de dez anos está associada a uma chance 57% maior. Note que não se multiplica a OR de um ano por 10; eleva-se à décima potência (ou multiplica-se o coeficiente por 10 antes de exponenciar).

2. Regressão de Poisson com o logaritmo do tempo de acompanhamento como *offset*, para modelar a taxa de crises; e^{β} do medicamento é a razão de taxas. Verificaria a superdispersão (razão entre a soma dos quadrados dos resíduos de Pearson e os graus de liberdade); contagens de crises costumam ser muito superdispersas, caso em que usaria a binomial negativa. Também verificaria excesso de zeros.

3. As 6 medidas de um mesmo paciente não são independentes; tratá-las como 120 observações independentes produz erros padrão incorretos. Um modelo misto, com efeito aleatório para o paciente (e, possivelmente, inclinação aleatória no tempo), é adequado.

4. Tempos ordenados: 2, 4, 4+, 7, 9+, 11. Por convenção, quando um evento e uma censura ocorrem no mesmo tempo, considera-se que a censura ocorre logo depois. Aos 2 meses: 6 em risco, 1 evento, $\widehat{S} = 5/6 = 0{,}833$. Aos 4: 5 em risco, 1 evento, $\widehat{S} = 0{,}833 \times 4/5 = 0{,}667$. Aos 7: 3 em risco (saíram o evento e a censura aos 4), 1 evento, $\widehat{S} = 0{,}667 \times 2/3 = 0{,}444$. Aos 11: 1 em risco (o censurado aos 9 saiu), 1 evento, $\widehat{S} = 0$.

5. Posteriori Beta$(1 + 3, 1 + 7)$ = Beta$(4, 8)$; média $4/12 = 0{,}33$; intervalo de credibilidade de 95%: `qbeta(c(0.025, 0.975), 4, 8)`, aproximadamente 0,11 a 0,61. O intervalo largo reflete a pequena quantidade de dados.

6. O desempenho de 100% é quase certamente fruto de sobreajuste e de viés de seleção: com 15.000 genes e 40 tumores, sempre é possível encontrar genes que separam perfeitamente os grupos por acaso. A seleção dos genes e a avaliação foram feitas com os mesmos dados. O classificador precisa ser

avaliado por validação cruzada que inclua a etapa de seleção, e validado em um conjunto independente de tumores.

7. $I^2 = \max(0, (7{,}2 - 7)/7{,}2) \approx 0{,}03$, ou 3%. Não necessariamente: com 8 estudos, o teste Q tem pouco poder, e o I^2 é muito impreciso. A ausência de heterogeneidade estatística não demonstra que os estudos sejam clinicamente homogêneos; isso deve ser avaliado pelas características dos estudos (populações, intervenções, desfechos).

Capítulo 13

Recursos adicionais

Este capítulo reúne materiais de consulta: uma bibliografia comentada para aprofundar os temas do livro, um glossário dos principais termos, tabelas das distribuições estatísticas usadas nos capítulos de inferência e análise, e uma lista de ferramentas e recursos *online*.

13.1 Bibliografia recomendada

A lista a seguir não é exaustiva. Foram escolhidas obras de referência reconhecidas, que complementam este livro em profundidade ou em abordagem. Edições mais recentes devem ser preferidas quando existirem.

13.1.1 Metodologia e epidemiologia

- **Hulley SB, Cummings SR, Browner WS, Grady DG, Newman TB. *Designing Clinical Research*. 4. ed. Lippincott Williams & Wilkins, 2013.** Guia prático para planejar estudos clínicos, da pergunta ao tamanho amostral. Há tradução para o português (*Delineando a pesquisa clínica*).
- **Lash TL, VanderWeele TJ, Haneuse S, Rothman KJ. *Modern Epidemiology*. 4. ed. Wolters Kluwer, 2021.** A referência mais completa em métodos epidemiológicos, para leitores avançados.
- **Fletcher GS. *Clinical Epidemiology: The Essentials*. 6. ed. Wolters Kluwer, 2020.** Introdução à epidemiologia clínica orientada para a prática médica, com tradução para o português (*Epidemiologia clínica: elementos essenciais*).
- **Hernán MA, Robins JM. *Causal Inference: What If*. Chapman & Hall/CRC, 2020.** Inferência causal com dados observacionais, incluindo a emulação de ensaios-alvo. Disponível gratuitamente no site dos autores.

13.1.2 Bioestatística

- **Altman DG. *Practical Statistics for Medical Research*. Chapman & Hall, 1991.** Clássico, claro e orientado para a pesquisa médica.
- **Kirkwood BR, Sterne JAC. *Essential Medical Statistics*. 2. ed. Blackwell, 2003.** Cobre de forma acessível desde os fundamentos até regressão logística, de Poisson e sobrevivência.
- **Harrell FE. *Regression Modeling Strategies*. 2. ed. Springer, 2015.** Referência sobre construção, validação e interpretação de modelos de regressão, com ênfase em evitar o sobreajuste.
- **Gelman A, Hill J, Vehtari A. *Regression and Other Stories*. Cambridge University Press, 2020.** Regressão aplicada com ênfase em simulação, interpretação e abordagem bayesiana. Disponível gratuitamente em formato eletrônico.
- **Gelman A, Carlin JB, Stern HS, Dunson DB, Vehtari A, Rubin DB. *Bayesian Data Analysis*. 3. ed. Chapman & Hall/CRC, 2013.** Referência em estatística bayesiana, para leitores avançados.

13.1.3 Programação e análise reprodutível

- **Wickham H, Çetinkaya-Rundel M, Grolemund G. *R for Data Science*. 2. ed. O'Reilly, 2023.** Introdução à análise de dados com R e o *tidyverse*. Disponível gratuitamente *online*.
- **Xie Y. *bookdown: Authoring Books and Technical Documents with R Markdown*. Chapman & Hall/CRC, 2016.** Documentação do pacote usado para produzir este livro, também disponível *online*.
- **Wilke CO. *Fundamentals of Data Visualization*. O'Reilly, 2019.** Princípios de construção de gráficos científicos, independentes do *software*. Disponível gratuitamente *online*.

13.1.4 Comunicação e integridade

- **Recomendações do ICMJE** (*Recommendations for the Conduct, Reporting, Editing, and Publication of Scholarly Work in Medical Journals*), atualizadas periodicamente no site do comitê.
- **Diretrizes de relato da rede EQUATOR**, reunidas no site da rede, com versões traduzidas para o português de várias delas.

13.2 Glossário de termos

Amostra. Subconjunto da população efetivamente observado em um estudo.

Amplitude interquartil (AIQ). Diferença entre o terceiro e o primeiro quartis; cobre os 50% centrais dos dados.

Análise por intenção de tratar. Análise de um ensaio randomizado em que os participantes são comparados segundo o grupo para o qual foram alocados, independentemente do tratamento efetivamente recebido.

Cegamento. Ocultação, para participantes, profissionais, avaliadores ou analistas, do tratamento recebido por cada participante.

Censura. Em análise de sobrevivência, situação em que o evento não foi observado durante o acompanhamento; sabe-se apenas que o tempo até o evento é maior que o tempo observado.

Coeficiente de correlação de Pearson (r). Medida, entre -1 e 1, da intensidade da associação linear entre duas variáveis quantitativas.

Coeficiente de correlação de Spearman (r_s). Correlação de Pearson calculada sobre os postos; mede associação monotônica.

Coeficiente de determinação (R^2). Proporção da variabilidade da variável resposta explicada pelo modelo de regressão.

Coeficiente de variação. Desvio padrão dividido pela média, em geral expresso em porcentagem.

Colisor. Variável que é efeito comum de duas outras; ajustar para ela pode criar uma associação espúria entre essas duas.

Confusão. Distorção da associação entre exposição e desfecho causada por um terceiro fator associado a ambos e que não está no caminho causal.

Desvio padrão. Raiz quadrada da variância; medida de dispersão na mesma unidade dos dados.

Diferença de riscos. Diferença entre os riscos de dois grupos; medida absoluta de associação.

Distribuição amostral. Distribuição de uma estatística ao longo de todas as amostras possíveis de mesmo tamanho.

Efeito aleatório. Em modelos mistos, componente que representa a variação entre unidades (pacientes, hospitais) em torno de uma média.

Erro padrão. Desvio padrão da distribuição amostral de uma estatística; mede a precisão de uma estimativa.

Erro tipo I. Rejeitar a hipótese nula quando ela é verdadeira (falso positivo).

Erro tipo II. Não rejeitar a hipótese nula quando ela é falsa (falso negativo).

Especificidade. Proporção de não doentes com resultado negativo em um teste diagnóstico.

Estimador. Regra para calcular, a partir de uma amostra, uma aproximação de um parâmetro.

Falseabilidade. Propriedade de uma teoria que proíbe certos resultados, de modo que observações possam refutá-la.

Grau de liberdade. Número de valores que podem variar livremente no cálculo de uma estatística, dadas as restrições impostas.

HARKing. Apresentação de hipóteses formuladas depois de conhecer os resultados como se fossem prévias.

Heterogeneidade. Em metanálise, variação nos efeitos verdadeiros entre os estudos.

Hipótese nula. Hipótese estatística, em geral de ausência de efeito, que é avaliada por um teste de hipóteses.

Incidência. Ocorrência de casos novos de uma condição em uma população inicialmente livre dela, em um período (risco) ou por pessoa-tempo (taxa).

Interação. Situação em que o efeito de uma variável sobre o desfecho depende do valor de outra.

Intervalo de confiança. Intervalo calculado por um procedimento que, em amostras repetidas, contém o parâmetro em uma proporção especificada das vezes (por exemplo, 95%).

Intervalo de credibilidade. Na abordagem bayesiana, intervalo que contém o parâmetro com uma probabilidade especificada, dada a priori e os dados.

Mediador. Variável no caminho causal entre a exposição e o desfecho.

Mediana. Valor que divide a amostra ordenada em duas metades.

Metanálise. Combinação estatística dos resultados de vários estudos.

Moda. Valor ou categoria mais frequente.

Número necessário para tratar (NNT). Inverso da diferença de riscos; número de pacientes que precisam ser tratados para que um deles se beneficie.

Ocultação da alocação. Proteção da sequência de randomização para que a próxima alocação não possa ser conhecida antes da inclusão do participante.

Parâmetro. Característica numérica da população, em geral desconhecida.

Poder estatístico. Probabilidade de um teste rejeitar a hipótese nula quando existe um efeito de determinado tamanho.

Prevalência. Proporção de pessoas que têm uma condição em um momento.

Pseudorreplicação. Tratamento de medidas não independentes (por exemplo, várias células de um mesmo animal) como se fossem unidades experimentais independentes.

Quantil. Valor abaixo do qual está uma proporção especificada dos dados.

Randomização. Alocação dos participantes aos grupos por sorteio.

Razão de chances (OR). Razão entre as chances de um evento em dois grupos.

Razão de riscos (*hazard ratio*). Razão entre as funções de risco instantâneo de dois grupos, em análise de sobrevivência.

Regressão à média. Tendência de valores extremos em uma medida serem seguidos por valores mais próximos da média em uma segunda medida.

Risco relativo (RR). Razão entre os riscos de um evento em dois grupos.

Sensibilidade. Proporção de doentes com resultado positivo em um teste diagnóstico.

Sobreajuste. Ajuste de um modelo ao ruído de uma amostra específica, que resulta em desempenho ruim em dados novos.

Taxa de falsas descobertas (FDR). Proporção esperada de falsos positivos entre os resultados declarados significativos.

Teorema central do limite. Resultado segundo o qual a distribuição da média amostral se aproxima da normal à medida que o tamanho da amostra cresce.

Unidade experimental. Menor unidade que pode receber, de forma independente, uma condição experimental; define o tamanho amostral.

Valor *p*. Probabilidade de obter uma estatística de teste tão extrema quanto, ou mais extrema que, a observada, supondo verdadeiras a hipótese nula e as demais suposições do modelo.

Variância. Média dos quadrados dos desvios em relação à média (com divisor $n-1$ na variância amostral).

Viés. Erro sistemático que desloca a estimativa em uma direção; não diminui com o aumento da amostra.

13.3 Tabelas estatísticas

As tabelas a seguir foram geradas com as funções de distribuição do R (`pnorm()`, `qt()`, `qchisq()` e `qf()`), e podem ser reproduzidas ou ampliadas pelo leitor. Na prática, os programas estatísticos calculam valores p e quantis exatos, e as tabelas servem principalmente para consulta rápida e para o estudo dos exemplos resolvidos.

13.3.1 Distribuição normal padrão

A Tabela 13.1 fornece $\Phi(z) = P(Z \leq z)$ para z de 0,00 a 3,49. A linha indica o valor de z até a primeira casa decimal, e a coluna, a segunda casa. Para valores negativos, use a simetria: $\Phi(-z) = 1 - \Phi(z)$.

13.3.2 Distribuição *t* de Student

A Tabela 13.2 fornece os quantis $t_{\text{gl};\,q}$, isto é, os valores tais que $P(T \leq t) = q$. Para um intervalo de confiança bilateral de 95%, use a coluna 0,975; para um teste bilateral com $\alpha = 0{,}05$, o valor crítico é o mesmo.

13.3.3 Distribuição qui-quadrado

A Tabela 13.3 fornece os quantis $\chi^2_{\text{gl};\,q}$. Para testes qui-quadrado (que são unilaterais à direita) com $\alpha = 0{,}05$, use a coluna 0,95.

13.3.4 Distribuição *F*

A Tabela 13.4 fornece os valores críticos $F_{0{,}95}$ (nível de significância de 5%), com os graus de liberdade do numerador nas colunas e os do denominador nas linhas. Para outros níveis, use `qf(1 - alfa, gl1, gl2)`.

13.4 Links e ferramentas *online*

Os endereços abaixo eram válidos no momento da redação. Como sítios mudam, recomenda-se localizar os recursos pelo nome em um buscador caso algum endereço deixe de funcionar.

13.4.1 Programas estatísticos

- **R e CRAN**: https://cran.r-project.org (linguagem R e repositório de pacotes).
- **RStudio** (Posit): https://posit.co/download/rstudio-desktop/ (ambiente de desenvolvimento para R).
- **Quarto**: https://quarto.org (documentos reprodutíveis com R, Python e outras linguagens).
- **Python**: https://www.python.org; **Jupyter**: https://jupyter.org.
- **JASP**: https://jasp-stats.org e **jamovi**: https://www.jamovi.org (programas gratuitos com interface gráfica, baseados em R).

Tabela 13.1: Função de distribuição acumulada da normal padrão, $\Phi(z)$.

z	0,00	0,01	0,02	0,03	0,04	0,05	0,06	0,07	0,08	0,09
0,0	0,5000	0,5040	0,5080	0,5120	0,5160	0,5199	0,5239	0,5279	0,5319	0,5359
0,1	0,5398	0,5438	0,5478	0,5517	0,5557	0,5596	0,5636	0,5675	0,5714	0,5753
0,2	0,5793	0,5832	0,5871	0,5910	0,5948	0,5987	0,6026	0,6064	0,6103	0,6141
0,3	0,6179	0,6217	0,6255	0,6293	0,6331	0,6368	0,6406	0,6443	0,6480	0,6517
0,4	0,6554	0,6591	0,6628	0,6664	0,6700	0,6736	0,6772	0,6808	0,6844	0,6879
0,5	0,6915	0,6950	0,6985	0,7019	0,7054	0,7088	0,7123	0,7157	0,7190	0,7224
0,6	0,7257	0,7291	0,7324	0,7357	0,7389	0,7422	0,7454	0,7486	0,7517	0,7549
0,7	0,7580	0,7611	0,7642	0,7673	0,7704	0,7734	0,7764	0,7794	0,7823	0,7852
0,8	0,7881	0,7910	0,7939	0,7967	0,7995	0,8023	0,8051	0,8078	0,8106	0,8133
0,9	0,8159	0,8186	0,8212	0,8238	0,8264	0,8289	0,8315	0,8340	0,8365	0,8389
1,0	0,8413	0,8438	0,8461	0,8485	0,8508	0,8531	0,8554	0,8577	0,8599	0,8621
1,1	0,8643	0,8665	0,8686	0,8708	0,8729	0,8749	0,8770	0,8790	0,8810	0,8830
1,2	0,8849	0,8869	0,8888	0,8907	0,8925	0,8944	0,8962	0,8980	0,8997	0,9015
1,3	0,9032	0,9049	0,9066	0,9082	0,9099	0,9115	0,9131	0,9147	0,9162	0,9177
1,4	0,9192	0,9207	0,9222	0,9236	0,9251	0,9265	0,9279	0,9292	0,9306	0,9319
1,5	0,9332	0,9345	0,9357	0,9370	0,9382	0,9394	0,9406	0,9418	0,9429	0,9441
1,6	0,9452	0,9463	0,9474	0,9484	0,9495	0,9505	0,9515	0,9525	0,9535	0,9545
1,7	0,9554	0,9564	0,9573	0,9582	0,9591	0,9599	0,9608	0,9616	0,9625	0,9633
1,8	0,9641	0,9649	0,9656	0,9664	0,9671	0,9678	0,9686	0,9693	0,9699	0,9706
1,9	0,9713	0,9719	0,9726	0,9732	0,9738	0,9744	0,9750	0,9756	0,9761	0,9767
2,0	0,9772	0,9778	0,9783	0,9788	0,9793	0,9798	0,9803	0,9808	0,9812	0,9817
2,1	0,9821	0,9826	0,9830	0,9834	0,9838	0,9842	0,9846	0,9850	0,9854	0,9857
2,2	0,9861	0,9864	0,9868	0,9871	0,9875	0,9878	0,9881	0,9884	0,9887	0,9890
2,3	0,9893	0,9896	0,9898	0,9901	0,9904	0,9906	0,9909	0,9911	0,9913	0,9916
2,4	0,9918	0,9920	0,9922	0,9925	0,9927	0,9929	0,9931	0,9932	0,9934	0,9936
2,5	0,9938	0,9940	0,9941	0,9943	0,9945	0,9946	0,9948	0,9949	0,9951	0,9952
2,6	0,9953	0,9955	0,9956	0,9957	0,9959	0,9960	0,9961	0,9962	0,9963	0,9964
2,7	0,9965	0,9966	0,9967	0,9968	0,9969	0,9970	0,9971	0,9972	0,9973	0,9974
2,8	0,9974	0,9975	0,9976	0,9977	0,9977	0,9978	0,9979	0,9979	0,9980	0,9981
2,9	0,9981	0,9982	0,9982	0,9983	0,9984	0,9984	0,9985	0,9985	0,9986	0,9986
3,0	0,9987	0,9987	0,9987	0,9988	0,9988	0,9989	0,9989	0,9989	0,9990	0,9990
3,1	0,9990	0,9991	0,9991	0,9991	0,9992	0,9992	0,9992	0,9992	0,9993	0,9993
3,2	0,9993	0,9993	0,9994	0,9994	0,9994	0,9994	0,9994	0,9995	0,9995	0,9995
3,3	0,9995	0,9995	0,9995	0,9996	0,9996	0,9996	0,9996	0,9996	0,9996	0,9997
3,4	0,9997	0,9997	0,9997	0,9997	0,9997	0,9997	0,9997	0,9997	0,9997	0,9998

Tabela 13.2: Quantis da distribuição t de Student. A linha ∞ corresponde à normal padrão.

gl	0,9000	0,9500	0,9750	0,9900	0,9950	0,9995
1	3,078	6,314	12,706	31,821	63,657	636,619
2	1,886	2,920	4,303	6,965	9,925	31,599
3	1,638	2,353	3,182	4,541	5,841	12,924
4	1,533	2,132	2,776	3,747	4,604	8,610
5	1,476	2,015	2,571	3,365	4,032	6,869
6	1,440	1,943	2,447	3,143	3,707	5,959
7	1,415	1,895	2,365	2,998	3,499	5,408
8	1,397	1,860	2,306	2,896	3,355	5,041
9	1,383	1,833	2,262	2,821	3,250	4,781
10	1,372	1,812	2,228	2,764	3,169	4,587
11	1,363	1,796	2,201	2,718	3,106	4,437
12	1,356	1,782	2,179	2,681	3,055	4,318
13	1,350	1,771	2,160	2,650	3,012	4,221
14	1,345	1,761	2,145	2,624	2,977	4,140
15	1,341	1,753	2,131	2,602	2,947	4,073
16	1,337	1,746	2,120	2,583	2,921	4,015
17	1,333	1,740	2,110	2,567	2,898	3,965
18	1,330	1,734	2,101	2,552	2,878	3,922
19	1,328	1,729	2,093	2,539	2,861	3,883
20	1,325	1,725	2,086	2,528	2,845	3,850
21	1,323	1,721	2,080	2,518	2,831	3,819
22	1,321	1,717	2,074	2,508	2,819	3,792
23	1,319	1,714	2,069	2,500	2,807	3,768
24	1,318	1,711	2,064	2,492	2,797	3,745
25	1,316	1,708	2,060	2,485	2,787	3,725
26	1,315	1,706	2,056	2,479	2,779	3,707
27	1,314	1,703	2,052	2,473	2,771	3,690
28	1,313	1,701	2,048	2,467	2,763	3,674
29	1,311	1,699	2,045	2,462	2,756	3,659
30	1,310	1,697	2,042	2,457	2,750	3,646
40	1,303	1,684	2,021	2,423	2,704	3,551
50	1,299	1,676	2,009	2,403	2,678	3,496
60	1,296	1,671	2,000	2,390	2,660	3,460
80	1,292	1,664	1,990	2,374	2,639	3,416
100	1,290	1,660	1,984	2,364	2,626	3,390
120	1,289	1,658	1,980	2,358	2,617	3,373
∞	1,282	1,645	1,960	2,326	2,576	3,291

Tabela 13.3: Quantis da distribuição qui-quadrado.

gl	0,005	0,025	0,050	0,900	0,950	0,975	0,990	0,995
1	0,000	0,001	0,004	2,706	3,841	5,024	6,635	7,879
2	0,010	0,051	0,103	4,605	5,991	7,378	9,210	10,597
3	0,072	0,216	0,352	6,251	7,815	9,348	11,345	12,838
4	0,207	0,484	0,711	7,779	9,488	11,143	13,277	14,860
5	0,412	0,831	1,145	9,236	11,070	12,833	15,086	16,750
6	0,676	1,237	1,635	10,645	12,592	14,449	16,812	18,548
7	0,989	1,690	2,167	12,017	14,067	16,013	18,475	20,278
8	1,344	2,180	2,733	13,362	15,507	17,535	20,090	21,955
9	1,735	2,700	3,325	14,684	16,919	19,023	21,666	23,589
10	2,156	3,247	3,940	15,987	18,307	20,483	23,209	25,188
11	2,603	3,816	4,575	17,275	19,675	21,920	24,725	26,757
12	3,074	4,404	5,226	18,549	21,026	23,337	26,217	28,300
13	3,565	5,009	5,892	19,812	22,362	24,736	27,688	29,819
14	4,075	5,629	6,571	21,064	23,685	26,119	29,141	31,319
15	4,601	6,262	7,261	22,307	24,996	27,488	30,578	32,801
16	5,142	6,908	7,962	23,542	26,296	28,845	32,000	34,267
17	5,697	7,564	8,672	24,769	27,587	30,191	33,409	35,718
18	6,265	8,231	9,390	25,989	28,869	31,526	34,805	37,156
19	6,844	8,907	10,117	27,204	30,144	32,852	36,191	38,582
20	7,434	9,591	10,851	28,412	31,410	34,170	37,566	39,997
21	8,034	10,283	11,591	29,615	32,671	35,479	38,932	41,401
22	8,643	10,982	12,338	30,813	33,924	36,781	40,289	42,796
23	9,260	11,689	13,091	32,007	35,172	38,076	41,638	44,181
24	9,886	12,401	13,848	33,196	36,415	39,364	42,980	45,559
25	10,520	13,120	14,611	34,382	37,652	40,646	44,314	46,928
26	11,160	13,844	15,379	35,563	38,885	41,923	45,642	48,290
27	11,808	14,573	16,151	36,741	40,113	43,195	46,963	49,645
28	12,461	15,308	16,928	37,916	41,337	44,461	48,278	50,993
29	13,121	16,047	17,708	39,087	42,557	45,722	49,588	52,336
30	13,787	16,791	18,493	40,256	43,773	46,979	50,892	53,672
40	20,707	24,433	26,509	51,805	55,758	59,342	63,691	66,766
50	27,991	32,357	34,764	63,167	67,505	71,420	76,154	79,490
60	35,534	40,482	43,188	74,397	79,082	83,298	88,379	91,952
80	51,172	57,153	60,391	96,578	101,879	106,629	112,329	116,321
100	67,328	74,222	77,929	118,498	124,342	129,561	135,807	140,169

Tabela 13.4: Valores críticos da distribuição F para $\alpha = 0{,}05$.

gl2 \ gl1	1	2	3	4	5	6	7
1	161,45	199,50	215,71	224,58	230,16	233,99	236,77
2	18,51	19,00	19,16	19,25	19,30	19,33	19,35
3	10,13	9,55	9,28	9,12	9,01	8,94	8,89
4	7,71	6,94	6,59	6,39	6,26	6,16	6,09
5	6,61	5,79	5,41	5,19	5,05	4,95	4,88
6	5,99	5,14	4,76	4,53	4,39	4,28	4,21
7	5,59	4,74	4,35	4,12	3,97	3,87	3,79
8	5,32	4,46	4,07	3,84	3,69	3,58	3,50
9	5,12	4,26	3,86	3,63	3,48	3,37	3,29
10	4,96	4,10	3,71	3,48	3,33	3,22	3,14
11	4,84	3,98	3,59	3,36	3,20	3,09	3,01
12	4,75	3,89	3,49	3,26	3,11	3,00	2,91
13	4,67	3,81	3,41	3,18	3,03	2,92	2,83
14	4,60	3,74	3,34	3,11	2,96	2,85	2,76
15	4,54	3,68	3,29	3,06	2,90	2,79	2,71
16	4,49	3,63	3,24	3,01	2,85	2,74	2,66
17	4,45	3,59	3,20	2,96	2,81	2,70	2,61
18	4,41	3,55	3,16	2,93	2,77	2,66	2,58
19	4,38	3,52	3,13	2,90	2,74	2,63	2,54
20	4,35	3,49	3,10	2,87	2,71	2,60	2,51
21	4,32	3,47	3,07	2,84	2,68	2,57	2,49
22	4,30	3,44	3,05	2,82	2,66	2,55	2,46
23	4,28	3,42	3,03	2,80	2,64	2,53	2,44
24	4,26	3,40	3,01	2,78	2,62	2,51	2,42
25	4,24	3,39	2,99	2,76	2,60	2,49	2,40
26	4,23	3,37	2,98	2,74	2,59	2,47	2,39
27	4,21	3,35	2,96	2,73	2,57	2,46	2,37
28	4,20	3,34	2,95	2,71	2,56	2,45	2,36
29	4,18	3,33	2,93	2,70	2,55	2,43	2,35
30	4,17	3,32	2,92	2,69	2,53	2,42	2,33
40	4,08	3,23	2,84	2,61	2,45	2,34	2,25
60	4,00	3,15	2,76	2,53	2,37	2,25	2,17
120	3,92	3,07	2,68	2,45	2,29	2,18	2,09

Tabela 13.4: Valores críticos da distribuição F para $\alpha = 0{,}05$ (continuação).

gl2 \ gl1	8	9	10	12	15	20
1	238,88	240,54	241,88	243,91	245,95	248,01
2	19,37	19,38	19,40	19,41	19,43	19,45
3	8,85	8,81	8,79	8,74	8,70	8,66
4	6,04	6,00	5,96	5,91	5,86	5,80
5	4,82	4,77	4,74	4,68	4,62	4,56
6	4,15	4,10	4,06	4,00	3,94	3,87
7	3,73	3,68	3,64	3,57	3,51	3,44
8	3,44	3,39	3,35	3,28	3,22	3,15
9	3,23	3,18	3,14	3,07	3,01	2,94
10	3,07	3,02	2,98	2,91	2,85	2,77
11	2,95	2,90	2,85	2,79	2,72	2,65
12	2,85	2,80	2,75	2,69	2,62	2,54
13	2,77	2,71	2,67	2,60	2,53	2,46
14	2,70	2,65	2,60	2,53	2,46	2,39
15	2,64	2,59	2,54	2,48	2,40	2,33
16	2,59	2,54	2,49	2,42	2,35	2,28
17	2,55	2,49	2,45	2,38	2,31	2,23
18	2,51	2,46	2,41	2,34	2,27	2,19
19	2,48	2,42	2,38	2,31	2,23	2,16
20	2,45	2,39	2,35	2,28	2,20	2,12
21	2,42	2,37	2,32	2,25	2,18	2,10
22	2,40	2,34	2,30	2,23	2,15	2,07
23	2,37	2,32	2,27	2,20	2,13	2,05
24	2,36	2,30	2,25	2,18	2,11	2,03
25	2,34	2,28	2,24	2,16	2,09	2,01
26	2,32	2,27	2,22	2,15	2,07	1,99
27	2,31	2,25	2,20	2,13	2,06	1,97
28	2,29	2,24	2,19	2,12	2,04	1,96
29	2,28	2,22	2,18	2,10	2,03	1,94
30	2,27	2,21	2,16	2,09	2,01	1,93
40	2,18	2,12	2,08	2,00	1,92	1,84
60	2,10	2,04	1,99	1,92	1,84	1,75
120	2,02	1,96	1,91	1,83	1,75	1,66

- **G*Power**: programa gratuito para cálculo de poder e tamanho amostral.
- **OpenEpi**: https://www.openepi.com (calculadoras epidemiológicas *online*).

13.4.2 Bases bibliográficas e de evidências

- **PubMed**: https://pubmed.ncbi.nlm.nih.gov.
- **Biblioteca Virtual em Saúde** (LILACS e outras bases): https://bvsalud.org.
- **DeCS/MeSH**: https://decs.bvsalud.org.
- **SciELO**: https://www.scielo.org.
- **Portal de Periódicos da CAPES**: https://www.periodicos.capes.gov.br.
- **Cochrane Library**: https://www.cochranelibrary.com.
- **DOAJ** (periódicos de acesso aberto): https://doaj.org.

13.4.3 Diretrizes, registros e integridade

- **Rede EQUATOR** (diretrizes de relato): https://www.equator-network.org.
- **ICMJE**: https://www.icmje.org.
- **COPE**: https://publicationethics.org.
- **ReBEC** (Registro Brasileiro de Ensaios Clínicos): https://ensaiosclinicos.gov.br.
- **ClinicalTrials.gov**: https://clinicaltrials.gov.
- **PROSPERO** (registro de revisões sistemáticas): https://www.crd.york.ac.uk/prospero/.
- **OSF** (*Open Science Framework*, registro prévio e compartilhamento de dados): https://osf.io.
- **Zenodo** (repositório de dados e código): https://zenodo.org.
- **Plataforma Brasil** (submissão de projetos aos CEPs): https://plataformabrasil.saude.gov.br.
- **Retraction Watch**: https://retractionwatch.com.

13.4.4 Dados de saúde

- **DATASUS** (informações de saúde e TabNet): https://datasus.saude.gov.br.
- **IBGE** (dados demográficos e sistema SIDRA): https://www.ibge.gov.br.
- **Global Health Observatory** (OMS): https://www.who.int/data/gho.

Agresti, Alan, and Brent A. Coull. 1998. "Approximate Is Better Than 'Exact' for Interval Estimation of Binomial Proportions." *The American Statistician* 52 (2): 119–26. https://doi.org/10.1080/00031305.1998.10480550.

Altman, Douglas G. 1998. "Confidence Intervals for the Number Needed to Treat." *BMJ* 317 (7168): 1309–12. https://doi.org/10.1136/bmj.317.7168.1309.

Altman, Douglas G., and J. Martin Bland. 1996. "Detecting Skewness from Summary Information." *BMJ* 313 (7066): 1200. https://doi.org/10.1136/bmj.313.7066.1200.

Altman, Douglas G., and J. Martin Bland. 2005. "Standard Deviations and Standard Errors." *BMJ* 331 (7521): 903. https://doi.org/10.1136/bmj.331.7521.903.

Ambroise, Christophe, and Geoffrey J. McLachlan. 2002. "Selection Bias in Gene Extraction on the Basis of Microarray Gene-Expression Data." *Proceedings of the National Academy of Sciences* 99 (10): 6562–66. https://doi.org/10.1073/pnas.102102699.

Anscombe, F. J. 1973. "Graphs in Statistical Analysis." *The American Statistician* 27 (1): 17–21. https://doi.org/10.1080/00031305.1973.10478966.

Austin, Peter C., and Ewout W. Steyerberg. 2015. "The Number of Subjects Per Variable Required in Linear Regression Analyses." *Journal of Clinical Epidemiology* 68 (6): 627–36. https://doi.org/10.1016/j.jclinepi.2014.12.014.

Baumer, Benjamin, and Dana Udwin. 2015. "R Markdown." *WIREs Computational Statistics* 7 (3): 167–77. https://doi.org/10.1002/wics.1348.

Beecher, Henry K. 1966. "Ethics and Clinical Research." *New England Journal of Medicine* 274 (24): 1354–60. https://doi.org/10.1056/NEJM196606162742405.

Benjamini, Yoav, and Yosef Hochberg. 1995. "Controlling the False Discovery Rate: A Practical and Powerful Approach to Multiple Testing." *Journal of the Royal Statistical Society: Series B (Methodological)* 57 (1): 289–300. https://doi.org/10.1111/j.2517-6161.1995.tb02031.x.

Bik, Elisabeth M., Arturo Casadevall, and Ferric C. Fang. 2016. "The Prevalence of Inappropriate Image Duplication in Biomedical Research Publications." *mBio* 7 (3): e00809–16. https://doi.org/10.1128/mBio.00809-16.

Bland, J. Martin, and Douglas G. Altman. 1986. "Statistical Methods for Assessing Agreement Between Two Methods of Clinical Measurement." *The*

Lancet 327 (8476): 307–10. https://doi.org/10.1016/S0140-6736(86)90837-8.

Boutron, Isabelle, Susan Dutton, Philippe Ravaud, and Douglas G. Altman. 2010. "Reporting and Interpretation of Randomized Controlled Trials with Statistically Nonsignificant Results for Primary Outcomes." *JAMA* 303 (20): 2058–64. https://doi.org/10.1001/jama.2010.651.

Brand, Amy, Liz Allen, Micah Altman, Marjorie Hlava, and Jo Scott. 2015. "Beyond Authorship: Attribution, Contribution, Collaboration, and Credit." *Learned Publishing* 28 (2): 151–55. https://doi.org/10.1087/20150211.

Broman, Karl W., and Kara H. Woo. 2018. "Data Organization in Spreadsheets." *The American Statistician* 72 (1): 2–10. https://doi.org/10.1080/00031305.2017.1375989.

Brown, Lawrence D., T. Tony Cai, and Anirban DasGupta. 2001. "Interval Estimation for a Binomial Proportion." *Statistical Science* 16 (2): 101–33. https://doi.org/10.1214/ss/1009213286.

Bryan, Jennifer. 2023. *Gapminder: Data from Gapminder*. https://cran.r-project.org/web/packages/gapminder/index.html.

Chambers, John M. 1980. "Statistical Computing: History and Trends." *The American Statistician* 34 (4): 238–43. https://doi.org/10.1080/00031305.1980.10483038.

Chang, Winston, Joe Cheng, J. J. Allaire, et al. 2024. *Shiny: Web Application Framework for R*. https://cran.r-project.org/web/packages/shiny/index.html.

Cleveland, William S., and Robert McGill. 1984. "Graphical Perception: Theory, Experimentation, and Application to the Development of Graphical Methods." *Journal of the American Statistical Association* 79 (387): 531–54. https://doi.org/10.1080/01621459.1984.10478080.

Cochran, William G. 1954. "Some Methods for Strengthening the Common χ^2 Tests." *Biometrics* 10 (4): 417–51. https://doi.org/10.2307/3001616.

Cox, D. R. 1972. "Regression Models and Life-Tables." *Journal of the Royal Statistical Society: Series B (Methodological)* 34 (2): 187–220. https://doi.org/10.1111/j.2517-6161.1972.tb00899.x.

Delacre, Marie, Daniël Lakens, and Christophe Leys. 2017. "Why Psychologists Should by Default Use Welch's t-Test Instead of Student's t-Test." *International Review of Social Psychology* 30 (1): 92–101. https://doi.org/10.5334/

irsp.82.

DerSimonian, Rebecca, and Nan Laird. 1986. "Meta-Analysis in Clinical Trials." *Controlled Clinical Trials* 7 (3): 177–88. https://doi.org/10.1016/0197-2456(86)90046-2.

Devereaux, P. J., Braden J. Manns, William A. Ghali, et al. 2001. "Physician Interpretations and Textbook Definitions of Blinding Terminology in Randomized Controlled Trials." *JAMA* 285 (15): 2000–2003. https://doi.org/10.1001/jama.285.15.2000.

Divine, George W., H. James Norton, Anna E. Barón, and Elizabeth Juarez-Colunga. 2018. "The Wilcoxon–Mann–Whitney Procedure Fails as a Test of Medians." *The American Statistician* 72 (3): 278–86. https://doi.org/10.1080/00031305.2017.1305291.

Doll, Richard, and A. Bradford Hill. 1950. "Smoking and Carcinoma of the Lung." *British Medical Journal* 2 (4682): 739–48. https://doi.org/10.1136/bmj.2.4682.739.

Egger, Matthias, George Davey Smith, Martin Schneider, and Christoph Minder. 1997. "Bias in Meta-Analysis Detected by a Simple, Graphical Test." *BMJ* 315 (7109): 629–34. https://doi.org/10.1136/bmj.315.7109.629.

Evidence-Based Medicine Working Group. 1992. "Evidence-Based Medicine: A New Approach to Teaching the Practice of Medicine." *JAMA* 268 (17): 2420–25. https://doi.org/10.1001/jama.1992.03490170092032.

Fanelli, Daniele. 2009. "How Many Scientists Fabricate and Falsify Research? A Systematic Review and Meta-Analysis of Survey Data." *PLoS ONE* 4 (5): e5738. https://doi.org/10.1371/journal.pone.0005738.

Freedman, David, and Persi Diaconis. 1981. "On the Histogram as a Density Estimator: L2 Theory." *Zeitschrift für Wahrscheinlichkeitstheorie Und Verwandte Gebiete* 57 (4): 453–76. https://doi.org/10.1007/BF01025868.

Galton, Francis. 1886. "Regression Towards Mediocrity in Hereditary Stature." *The Journal of the Anthropological Institute of Great Britain and Ireland* 15: 246–63. https://doi.org/10.2307/2841583.

Gamble, Carrol, Ashma Krishan, Deborah Stocken, et al. 2017. "Guidelines for the Content of Statistical Analysis Plans in Clinical Trials." *JAMA* 318 (23): 2337–43. https://doi.org/10.1001/jama.2017.18556.

Gelman, Andrew, John B. Carlin, Hal S. Stern, David B. Dunson, Aki Vehtari, and Donald B. Rubin. 2013. *Bayesian Data Analysis*. 3rd ed. Chapman;

Hall/CRC.

Greenland, Sander, Judea Pearl, and James M. Robins. 1999. "Causal Diagrams for Epidemiologic Research." *Epidemiology* 10 (1): 37–48. https://doi.org/10.1097/00001648-199901000-00008.

Greenland, Sander, Stephen J. Senn, Kenneth J. Rothman, et al. 2016. "Statistical Tests, p Values, Confidence Intervals, and Power: A Guide to Misinterpretations." *European Journal of Epidemiology* 31 (4): 337–50. https://doi.org/10.1007/s10654-016-0149-3.

Grudniewicz, Agnes, David Moher, Kelly D. Cobey, et al. 2019. "Predatory Journals: No Definition, No Defence." *Nature* 576 (7786): 210–12. https://doi.org/10.1038/d41586-019-03759-y.

Hardy, G. H. 1908. "Mendelian Proportions in a Mixed Population." *Science* 28 (706): 49–50. https://doi.org/10.1126/science.28.706.49.

Harrell, Frank E., Jr. 2015. *Regression Modeling Strategies: With Applications to Linear Models, Logistic and Ordinal Regression, and Survival Analysis*. 2nd ed. Springer Series in Statistics. Springer. https://doi.org/10.1007/978-3-319-19425-7.

Harris, Charles R., K. Jarrod Millman, Stéfan J. van der Walt, et al. 2020. "Array Programming with NumPy." *Nature* 585: 357–62. https://doi.org/10.1038/s41586-020-2649-2.

Hempel, Carl G. 1966. *Philosophy of Natural Science*. Prentice-Hall.

Hernán, Miguel A., and James M. Robins. 2016. "Using Big Data to Emulate a Target Trial When a Randomized Trial Is Not Available." *American Journal of Epidemiology* 183 (8): 758–64. https://doi.org/10.1093/aje/kwv254.

Herndon, Thomas, Michael Ash, and Robert Pollin. 2014. "Does High Public Debt Consistently Stifle Economic Growth? A Critique of Reinhart and Rogoff." *Cambridge Journal of Economics* 38 (2): 257–79. https://doi.org/10.1093/cje/bet075.

Higgins, Julian P. T., and Simon G. Thompson. 2002. "Quantifying Heterogeneity in a Meta-Analysis." *Statistics in Medicine* 21 (11): 1539–58. https://doi.org/10.1002/sim.1186.

Hill, Austin Bradford. 1965. "The Environment and Disease: Association or Causation?" *Proceedings of the Royal Society of Medicine* 58 (5): 295–300. https://doi.org/10.1177/003591576505800503.

Hopewell, Sally, An-Wen Chan, Gary S. Collins, et al. 2025. "CONSORT 2025 Statement: Updated Guideline for Reporting Randomised Trials." *BMJ* 389: e081123. https://doi.org/10.1136/bmj-2024-081123.

Hornik, Kurt. 2012. "The Comprehensive r Archive Network." *WIREs Computational Statistics* 4 (4): 394–98. https://doi.org/10.1002/wics.1212.

Hulley, Stephen B., Steven R. Cummings, Warren S. Browner, Deborah G. Grady, and Thomas B. Newman. 2013. *Designing Clinical Research*. 4th ed. Lippincott Williams & Wilkins.

Hunter, John D. 2007. "Matplotlib: A 2D Graphics Environment." *Computing in Science & Engineering* 9 (3): 90–95. https://doi.org/10.1109/MCSE.2007.55.

Hyndman, Rob J., and Yanan Fan. 1996. "Sample Quantiles in Statistical Packages." *The American Statistician* 50 (4): 361–65. https://doi.org/10.1080/00031305.1996.10473566.

Ihaka, Ross, and Robert Gentleman. 1996. "R: A Language for Data Analysis and Graphics." *Journal of Computational and Graphical Statistics* 5 (3): 299–314. https://doi.org/10.1080/10618600.1996.10474713.

IntHout, Joanna, John P. A. Ioannidis, and George F. Borm. 2014. "The Hartung-Knapp-Sidik-Jonkman Method for Random Effects Meta-Analysis Is Straightforward and Considerably Outperforms the Standard DerSimonian-Laird Method." *BMC Medical Research Methodology* 14: 25. https://doi.org/10.1186/1471-2288-14-25.

Ioannidis, John P. A. 2005. "Why Most Published Research Findings Are False." *PLoS Medicine* 2 (8): e124. https://doi.org/10.1371/journal.pmed.0020124.

John, Leslie K., George Loewenstein, and Drazen Prelec. 2012. "Measuring the Prevalence of Questionable Research Practices with Incentives for Truth Telling." *Psychological Science* 23 (5): 524–32. https://doi.org/10.1177/0956797611430953.

Jolliffe, Ian T., and Jorge Cadima. 2016. "Principal Component Analysis: A Review and Recent Developments." *Philosophical Transactions of the Royal Society A* 374 (2065): 20150202. https://doi.org/10.1098/rsta.2015.0202.

Kaplan, E. L., and Paul Meier. 1958. "Nonparametric Estimation from Incomplete Observations." *Journal of the American Statistical Association* 53 (282): 457–81. https://doi.org/10.1080/01621459.1958.10501452.

Katz, D., J. Baptista, S. P. Azen, and M. C. Pike. 1978. "Obtaining Confidence

Intervals for the Risk Ratio in Cohort Studies." *Biometrics* 34 (3): 469–74. https://doi.org/10.2307/2530610.

Kerr, Norbert L. 1998. "HARKing: Hypothesizing After the Results Are Known." *Personality and Social Psychology Review* 2 (3): 196–217. https://doi.org/10.1207/s15327957pspr0203_4.

Kuhn, Thomas S. 1962. *The Structure of Scientific Revolutions*. University of Chicago Press.

Lang, Thomas A., and Douglas G. Altman. 2015. "Basic Statistical Reporting for Articles Published in Biomedical Journals: The "Statistical Analyses and Methods in the Published Literature" or the SAMPL Guidelines." *International Journal of Nursing Studies* 52 (1): 5–9. https://doi.org/10.1016/j.ijnurstu.2014.09.006.

Lazic, Stanley E. 2010. "The Problem of Pseudoreplication in Neuroscientific Studies: Is It Affecting Your Analysis?" *BMC Neuroscience* 11: 5. https://doi.org/10.1186/1471-2202-11-5.

Leek, Jeffrey T., Robert B. Scharpf, Héctor Corrada Bravo, et al. 2010. "Tackling the Widespread and Critical Impact of Batch Effects in High-Throughput Data." *Nature Reviews Genetics* 11 (10): 733–39. https://doi.org/10.1038/nrg2825.

Livak, Kenneth J., and Thomas D. Schmittgen. 2001. "Analysis of Relative Gene Expression Data Using Real-Time Quantitative PCR and the $2^{-\Delta\Delta C_T}$ Method." *Methods* 25 (4): 402–8. https://doi.org/10.1006/meth.2001.1262.

Mann, H. B., and D. R. Whitney. 1947. "On a Test of Whether One of Two Random Variables Is Stochastically Larger Than the Other." *The Annals of Mathematical Statistics* 18 (1): 50–60. https://doi.org/10.1214/aoms/1177730491.

Marshall, Barry J., and J. Robin Warren. 1984. "Unidentified Curved Bacilli in the Stomach of Patients with Gastritis and Peptic Ulceration." *The Lancet* 323 (8390): 1311–15. https://doi.org/10.1016/S0140-6736(84)91816-6.

McGill, Robert, John W. Tukey, and Wayne A. Larsen. 1978. "Variations of Box Plots." *The American Statistician* 32 (1): 12–16. https://doi.org/10.1080/00031305.1978.10479236.

McKinney, Wes. 2010. "Data Structures for Statistical Computing in Python." *Proceedings of the 9th Python in Science Conference*, 56–61. https://doi.org/10.25080/Majora-92bf1922-00a.

Meng, Xiao-Li. 2018. "Statistical Paradises and Paradoxes in Big Data (I): Law of Large Populations, Big Data Paradox, and the 2016 US Presidential Election." *The Annals of Applied Statistics* 12 (2): 685–726. https://doi.org/10.1214/18-AOAS1161SF.

Merton, Robert K. 1973. *The Sociology of Science: Theoretical and Empirical Investigations*. University of Chicago Press.

Nelder, J. A., and R. W. M. Wedderburn. 1972. "Generalized Linear Models." *Journal of the Royal Statistical Society: Series A (General)* 135 (3): 370–84. https://doi.org/10.2307/2344614.

Newcombe, Robert G. 1998. "Interval Estimation for the Difference Between Independent Proportions: Comparison of Eleven Methods." *Statistics in Medicine* 17 (8): 873–90. https://doi.org/10.1002/(SICI)1097-0258(19980430)17:8%3C873::AID-SIM779%3E3.0.CO;2-I.

Nosek, Brian A., Charles R. Ebersole, Alexander C. DeHaven, and David T. Mellor. 2018. "The Preregistration Revolution." *Proceedings of the National Academy of Sciences* 115 (11): 2600–2606. https://doi.org/10.1073/pnas.1708274114.

Open Science Collaboration. 2015. "Estimating the Reproducibility of Psychological Science." *Science* 349 (6251): aac4716. https://doi.org/10.1126/science.aac4716.

Page, Matthew J., Joanne E. McKenzie, Patrick M. Bossuyt, et al. 2021. "The PRISMA 2020 Statement: An Updated Guideline for Reporting Systematic Reviews." *BMJ* 372: n71. https://doi.org/10.1136/bmj.n71.

Pebesma, Edzer, Roger Bivand, Etienne Racine, et al. 2024. *Sf: Simple Features for R*. https://cran.r-project.org/web/packages/sf/index.html.

Pedersen, Thomas Lin, and David Robinson. 2024. *Gganimate: A Grammar of Animated Graphics*. https://cran.r-project.org/web/packages/gganimate/index.html.

Peduzzi, Peter, John Concato, Elizabeth Kemper, Theodore R. Holford, and Alvan R. Feinstein. 1996. "A Simulation Study of the Number of Events Per Variable in Logistic Regression Analysis." *Journal of Clinical Epidemiology* 49 (12): 1373–79. https://doi.org/10.1016/S0895-4356(96)00236-3.

Percie du Sert, Nathalie, Viki Hurst, Amrita Ahluwalia, et al. 2020. "The ARRIVE Guidelines 2.0: Updated Guidelines for Reporting Animal Research." *PLoS Biology* 18 (7): e3000410. https://doi.org/10.1371/journal.pbio.3000410.

Pinheiro, José C., and Douglas M. Bates. 2000. *Mixed-Effects Models in S and S-PLUS*. Springer. https://doi.org/10.1007/b98882.

Popper, Karl R. 1959. *The Logic of Scientific Discovery*. Hutchinson.

Riley, Richard D., Joie Ensor, Kym I. E. Snell, et al. 2020. "Calculating the Sample Size Required for Developing a Clinical Prediction Model." *BMJ* 368: m441. https://doi.org/10.1136/bmj.m441.

Rochon, Justine, Matthias Gondan, and Meinhard Kieser. 2012. "To Test or Not to Test: Preliminary Assessment of Normality When Comparing Two Independent Samples." *BMC Medical Research Methodology* 12: 81. https://doi.org/10.1186/1471-2288-12-81.

Rougier, Nicolas P., Michael Droettboom, and Philip E. Bourne. 2014. "Ten Simple Rules for Better Figures." *PLoS Computational Biology* 10 (9): e1003833. https://doi.org/10.1371/journal.pcbi.1003833.

Rousseeuw, Peter J. 1987. "Silhouettes: A Graphical Aid to the Interpretation and Validation of Cluster Analysis." *Journal of Computational and Applied Mathematics* 20: 53–65. https://doi.org/10.1016/0377-0427(87)90125-7.

Russell, W. M. S., and R. L. Burch. 1959. *The Principles of Humane Experimental Technique*. Methuen.

Sackett, David L. 1979. "Bias in Analytic Research." *Journal of Chronic Diseases* 32 (1-2): 51–63. https://doi.org/10.1016/0021-9681(79)90012-2.

Sackett, David L., William M. C. Rosenberg, J. A. Muir Gray, R. Brian Haynes, and W. Scott Richardson. 1996. "Evidence Based Medicine: What It Is and What It Isn't." *BMJ* 312 (7023): 71–72. https://doi.org/10.1136/bmj.312.7023.71.

Saldanha, Raphael de Freitas, Ronaldo Rocha Bastos, and Christovam Barcellos. 2019. "Microdatasus: Pacote Para Download e Pré-Processamento de Microdados Do Departamento de Informática Do SUS (DATASUS)." *Cadernos de Saúde Pública* 35 (9): e00032419. https://doi.org/10.1590/0102-311X00032419.

Schuirmann, Donald J. 1987. "A Comparison of the Two One-Sided Tests Procedure and the Power Approach for Assessing the Equivalence of Average Bioavailability." *Journal of Pharmacokinetics and Biopharmaceutics* 15 (6): 657–80. https://doi.org/10.1007/BF01068419.

Schulz, Kenneth F., Iain Chalmers, Richard J. Hayes, and Douglas G. Altman. 1995. "Empirical Evidence of Bias: Dimensions of Methodological Quality

Associated with Estimates of Treatment Effects in Controlled Trials." *JAMA* 273 (5): 408–12. https://doi.org/10.1001/jama.1995.03520290060030.

Seabold, Skipper, and Josef Perktold. 2010. "Statsmodels: Econometric and Statistical Modeling with Python." *Proceedings of the 9th Python in Science Conference*, 92–96. https://doi.org/10.25080/Majora-92bf1922-011.

Shannon, C. E. 1948. "A Mathematical Theory of Communication." *Bell System Technical Journal* 27 (3): 379–423. https://doi.org/10.1002/j.1538-7305.1948.tb01338.x.

Siegel, Sidney, and N. John Castellan Jr. 1988. *Nonparametric Statistics for the Behavioral Sciences*. 2nd ed. McGraw-Hill.

Simpson, E. H. 1949. "Measurement of Diversity." *Nature* 163 (4148): 688. https://doi.org/10.1038/163688a0.

Sollaci, Luciana B., and Mauricio G. Pereira. 2004. "The Introduction, Methods, Results, and Discussion (IMRAD) Structure: A Fifty-Year Survey." *Journal of the Medical Library Association* 92 (3): 364–67.

Spearman, C. 1904. "The Proof and Measurement of Association Between Two Things." *The American Journal of Psychology* 15 (1): 72–101. https://doi.org/10.2307/1412159.

Stevens, S. S. 1946. "On the Theory of Scales of Measurement." *Science* 103 (2684): 677–80. https://doi.org/10.1126/science.103.2684.677.

Student. 1908. "The Probable Error of a Mean." *Biometrika* 6 (1): 1–25. https://doi.org/10.1093/biomet/6.1.1.

Sturges, Herbert A. 1926. "The Choice of a Class Interval." *Journal of the American Statistical Association* 21 (153): 65–66. https://doi.org/10.1080/01621459.1926.10502161.

Tibshirani, Robert. 1996. "Regression Shrinkage and Selection via the Lasso." *Journal of the Royal Statistical Society: Series B (Methodological)* 58 (1): 267–88. https://doi.org/10.1111/j.2517-6161.1996.tb02080.x.

Tukey, John W. 1949. "Comparing Individual Means in the Analysis of Variance." *Biometrics* 5 (2): 99–114. https://doi.org/10.2307/3001913.

Tukey, John W. 1977. *Exploratory Data Analysis*. Addison-Wesley.

Virtanen, Pauli, Ralf Gommers, Travis E. Oliphant, et al. 2020. "SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python." *Nature Meth-*

ods 17: 261–72. https://doi.org/10.1038/s41592-019-0686-2.

von Elm, Erik, Douglas G. Altman, Matthias Egger, Stuart J. Pocock, Peter C. Gøtzsche, and Jan P. Vandenbroucke. 2007. "The Strengthening the Reporting of Observational Studies in Epidemiology (STROBE) Statement: Guidelines for Reporting Observational Studies." *The Lancet* 370 (9596): 1453–57. https://doi.org/10.1016/S0140-6736(07)61602-X.

von Hippel, Paul T. 2005. "Mean, Median, and Skew: Correcting a Textbook Rule." *Journal of Statistics Education* 13 (2). https://doi.org/10.1080/10691898.2005.11910556.

Wasserstein, Ronald L., and Nicole A. Lazar. 2016. "The ASA Statement on p-Values: Context, Process, and Purpose." *The American Statistician* 70 (2): 129–33. https://doi.org/10.1080/00031305.2016.1154108.

Weissgerber, Tracey L., Natasa M. Milic, Stacey J. Winham, and Vesna D. Garovic. 2015. "Beyond Bar and Line Graphs: Time for a New Data Presentation Paradigm." *PLoS Biology* 13 (4): e1002128. https://doi.org/10.1371/journal.pbio.1002128.

Welch, B. L. 1947. "The Generalization of 'Student's' Problem When Several Different Population Variances Are Involved." *Biometrika* 34 (1-2): 28–35. https://doi.org/10.1093/biomet/34.1-2.28.

Wickham, Hadley. 2011. "Ggplot2." *WIREs Computational Statistics* 3 (2): 180–85. https://doi.org/10.1002/wics.147.

Wickham, Hadley, Peter Danenberg, Gábor Csárdi, and Manuel Eugster. 2024. *Roxygen2: In-Line Documentation for R.* https://cran.r-project.org/web/packages/roxygen2/index.html.

Wigginton, Janis E., David J. Cutler, and Gonçalo R. Abecasis. 2005. "A Note on Exact Tests of Hardy-Weinberg Equilibrium." *American Journal of Human Genetics* 76 (5): 887–93. https://doi.org/10.1086/429864.

Wilcoxon, Frank. 1945. "Individual Comparisons by Ranking Methods." *Biometrics Bulletin* 1 (6): 80–83. https://doi.org/10.2307/3001968.

Wilke, Claus O. 2019. *Fundamentals of Data Visualization.* O'Reilly Media.

Wilson, Edwin B. 1927. "Probable Inference, the Law of Succession, and Statistical Inference." *Journal of the American Statistical Association* 22 (158): 209–12. https://doi.org/10.1080/01621459.1927.10502953.

Woolf, Barnet. 1955. "On Estimating the Relation Between Blood Group and

Disease." *Annals of Human Genetics* 19 (4): 251–53. https://doi.org/10.1111/j.1469-1809.1955.tb01348.x.

World Medical Association. 2025. "World Medical Association Declaration of Helsinki: Ethical Principles for Medical Research Involving Human Participants." *JAMA* 333 (1): 71–74. https://doi.org/10.1001/jama.2024.21972.

Xie, Yihui. 2024. *Knitr: A General-Purpose Package for Dynamic Report Generation in R*. https://cran.r-project.org/web/packages/knitr/index.html.

Ziemann, Mark, Yotam Eren, and Assam El-Osta. 2016. "Gene Name Errors Are Widespread in the Scientific Literature." *Genome Biology* 17: 177. https://doi.org/10.1186/s13059-016-1044-7.